

# Sesión 1 · Pruebas de Hipótesis

## Nivelación Econometría — Doctorado en Políticas Públicas

Amaru Agüero Jiménez (a.agueroj@udd.cl)


marzo de 2026

# Panorama de la sesión

| Bloque                  | Concepto clave                             | Herramienta en R                                     |
|-------------------------|--------------------------------------------|------------------------------------------------------|
| Lógica de la inferencia | $H_0$ , $H_1$ , distribución nula          | <code>pt()</code> , <code>qt()</code>                |
| Valor-p y decisión      | $\alpha$ , regiones de rechazo, ASA        | <code>t.test()</code>                                |
| Errores y potencia      | Tipo I/II, $1 - \beta$ , tamaño de muestra | <code>power.t.test()</code>                          |
| Pruebas t               | una muestra, dos (Welch), pareada          | <code>t.test()</code>                                |
| Variables categóricas   | independencia, proporciones                | <code>chisq.test()</code> , <code>prop.test()</code> |
| Buenas prácticas        | relevancia, d de Cohen, p-hacking          | corrección de Bonferroni                             |

**i Datos de trabajo:** `gapminder` (142 países, 2007) y microdatos simulados de un programa de empleo juvenil. En evaluación de políticas, cada rechazo de  $H_0$  es una decisión sobre recursos públicos: conviene entender exactamente qué afirma (y qué no) una prueba de hipótesis.

# La prueba de hipótesis en el flujo econométrico



*Flujo iterativo: los diagnosticos pueden llevar a re-especificar*

- La econometría traduce preguntas de política a **parámetros**:  $\mu$ ,  $p$ ,  $\beta$ .
- Estimar no basta: hay que separar **señal de ruido muestral**.
- Toda evaluación de impacto termina en un contraste: ¿el efecto es distinguible de cero?
- Esta sesión construye la caja de herramientas del contraste; las próximas la aplican a coeficientes de regresión.

# La lógica frecuentista en seis pasos

| Paso               | Qué se hace                            | Ejemplo: transferencia monetaria |
|--------------------|----------------------------------------|----------------------------------|
| 1. Formular        | $H_0$ : sin efecto; $H_1$ : hay efecto | $H_0$ : el consumo no cambia     |
| 2. Elegir $\alpha$ | riesgo tolerado de falso positivo      | $\alpha = 0.05$                  |
| 3. Estadístico     | según tipo de variable y diseño        | t de dos muestras                |
| 4. Calcular        | con los datos muestrales               | $t = 2.41$                       |
| 5. Valor-p         | prob. de algo tan extremo bajo $H_0$   | $p = 0.017$                      |
| 6. Decidir         | $p < \alpha$ implica rechazar $H_0$    | se rechaza: hay efecto           |

Razonamiento por contradicción: **asumimos que el programa no funciona** ( $H_0$ ) y preguntamos qué tan improbables serían nuestros datos en ese mundo. Los pasos 1 y 2 se fijan **antes** de mirar los datos.

# Hipótesis nula y alternativa: quién carga la prueba

## Hipótesis nula ( $H_0$ )

- Afirma “no efecto” o “no diferencia”: el statu quo
- Se asume verdadera hasta que la evidencia la contradiga
- Nunca se “acepta”: solo se **no rechaza**
- Ej:  $\mu = 100$ ,  $\mu_1 = \mu_2$ ,  $p = 0.5$

## Hipótesis alternativa ( $H_1$ )

- Lo que el investigador quiere demostrar
- Sobre ella recae la **carga de la prueba**
- Puede ser bilateral o unilateral
- Ej:  $\mu \neq 100$ ,  $\mu_1 \neq \mu_2$ ,  $p > 0.5$

**i Ejemplo — subsidio al empleo juvenil.**  $H_0$ : la tasa de ocupación de beneficiarios es igual a la de no beneficiarios.  $H_1$ : las tasas difieren. Si no logramos rechazar  $H_0$ , no probamos que el programa “no sirve”: solo que la evidencia es insuficiente.

## ¿Bilateral o unilateral? La dirección se decide antes


| Tipo                 | $H_1$            | Cuándo usarla                | Ejemplo de política                               |
|----------------------|------------------|------------------------------|---------------------------------------------------|
| Bilateral            | $\mu \neq \mu_0$ | interesa cualquier dirección | ¿La reforma cambió el gasto de bolsillo en salud? |
| Unilateral derecha   | $\mu > \mu_0$    | solo interesa un aumento     | ¿El subsidio aumentó el empleo formal?            |
| Unilateral izquierda | $\mu < \mu_0$    | solo interesa una caída      | ¿La beca redujo la deserción escolar?             |

 La cola se elige **antes de ver los datos**, por teoría o diseño. Elegirla después de mirar el signo del efecto duplica de facto el error Tipo I: es una forma de p-hacking. Ante la duda, use la bilateral (más conservadora).

# El estadístico de prueba y su distribución nula


$$t = \frac{\text{estimación} - \text{valor bajo } H_0}{\text{error estándar}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

- Resume los datos en **un número**: a cuántos errores estándar está la estimación del valor nulo.
- La **distribución nula** describe cómo se comportaría ese número si  $H_0$  fuera cierta (aquí,  $t$  de Student con  $n - 1$  gl).
- Un  $|t|$  grande significa datos improbables bajo  $H_0$ .



Con 25 gl y  $\alpha = 0.05$  bilateral, la regla es rechazar si  $|t| > 2.06$ .

# Valor-p: la definición precisa




**Valor-p:** probabilidad de obtener un estadístico **tan extremo o más** que el observado, *suponiendo que  $H_0$  es cierta*. Es  $P(\text{datos extremos} \mid H_0)$  — no la probabilidad de que  $H_0$  sea verdadera.



# El valor-p en la práctica: dos escenarios

## Distribucion bajo $H_0$ : Interpretacion del p-valor



Mismo umbral  $\alpha = 0.05$ : a la izquierda,  $t = 1.2$  deja mucha área en las colas ( $p = 0.23$ ) y no se rechaza; a la derecha,  $t = 2.8$  deja un área mínima ( $p = 0.005$ ) y se rechaza  $H_0$ .

# Lo que el valor-p NO significa

| Malinterpretación frecuente                    | Realidad                                                                                            |
|------------------------------------------------|-----------------------------------------------------------------------------------------------------|
| “p es la probabilidad de que $H_0$ sea cierta” | p se calcula <i>asumiendo</i> $H_0$ : es $P(\text{datos} \mid H_0)$ , no $P(H_0 \mid \text{datos})$ |
| “p = 0.20 demuestra que no hay efecto”         | ausencia de evidencia no es evidencia de ausencia (puede faltar potencia)                           |
| “p < 0.05 implica un efecto importante”        | con n grande, efectos triviales producen p minúsculos                                               |
| “1 - p es la probabilidad de replicar”         | p no informa sobre replicabilidad del hallazgo                                                      |
| “p = 0.049 y p = 0.051 son mundos distintos”   | 0.05 es una convención, no un umbral físico                                                         |

**!** **Declaración ASA (Wasserstein & Lazar, 2016):** el valor-p no mide la probabilidad de la hipótesis ni el tamaño del efecto, y ninguna decisión científica o de política debería basarse solo en si p cruza un umbral. Reporte p exacto, IC y tamaño de efecto.

# Nivel de significancia y valores críticos

| $\alpha$ | Crítico bilateral (z) | Crítico unilateral (z) | Uso típico               |
|----------|-----------------------|------------------------|--------------------------|
| 0.10     | 1.645                 | 1.282                  | análisis exploratorio    |
| 0.05     | 1.960                 | 1.645                  | convención dominante     |
| 0.01     | 2.576                 | 2.326                  | decisiones de alto costo |

- $\alpha$  es la probabilidad de **error Tipo I** que el investigador acepta a priori: define la región de rechazo en las colas de la distribución nula.
- Bajar  $\alpha$  hace la prueba más exigente: menos falsos positivos, pero más falsos negativos ( $\beta$  sube).
- En muestras pequeñas los críticos de la t son mayores que los de z (colas más pesadas): con 24 gl, el crítico bilateral al 5 % es 2.06, no 1.96.


# Matriz de decisión: los cuatro escenarios

| Decisión          | $H_0$ verdadera                        | $H_0$ falsa                            |
|-------------------|----------------------------------------|----------------------------------------|
| Rechazar $H_0$    | <b>Error Tipo I</b> (prob = $\alpha$ ) | Correcto: potencia ( $1 - \beta$ )     |
| No rechazar $H_0$ | Correcto (prob = $1 - \alpha$ )        | <b>Error Tipo II</b> (prob = $\beta$ ) |

- **Error Tipo I (falso positivo):** declarar efectivo un programa que no lo es — se financia una política inútil.
- **Error Tipo II (falso negativo):** no detectar un programa que sí funciona — se cancela una política valiosa.
- Reducir  $\alpha$  aumenta  $\beta$  y viceversa; la única forma de reducir ambos es **aumentar n**.


💡 **Analogía judicial:** Tipo I = condenar a un inocente; Tipo II = absolver a un culpable. El sistema fija  $\alpha$  bajo porque considera peor el falso positivo — igual que la estadística.

# Errores Tipo I y II en las distribuciones



- Área **naranja**:  $\alpha$ , cola de la distribución bajo  $H_0$  más allá del valor crítico.
- Área **morada**:  $\beta$ , parte de la distribución bajo  $H_1$  que cae en zona de no rechazo.
- Mover el crítico a la derecha (bajar  $\alpha$ ) agranda el área morada: el trade-off es geométrico.
- Si las campanas se separan (efecto mayor) o se angostan (más  $n$ , menos  $\sigma$ ), ambos errores caen a la vez.

# Potencia: la zona que el diseño debe maximizar




**Potencia** = probabilidad de rechazar  $H_0$  cuando es falsa (área verde). El estándar de diseño en evaluación de impacto es potencia  $\geq 0.80$ : un estudio con potencia 0.30 casi garantiza no detectar el efecto aunque exista.

# Cuatro palancas determinan la potencia

- **Tamaño de efecto:** efectos más grandes se detectan más fácil; es la palanca que *no* controla el evaluador.
- **Tamaño de muestra ( $n$ ):** más  $n$  reduce el error estándar; la palanca principal de diseño.
- **Nivel  $\alpha$ :** un  $\alpha$  mayor da más potencia, al precio de más falsos positivos.
- **Varianza ( $\sigma^2$ ):** menos ruido (mejor medición, estratificación) aumenta la potencia.

Con dos grupos, detectar un efecto pequeño ( $d = 0.2$ ) con 80 % de potencia exige **cerca de 400 casos por grupo** (unos 200 en total si el contraste es de una sola muestra, como ilustra la figura).




# power.t.test: diseñar el tamaño de muestra

```
# ¿Que n necesito? (d = 0.5)
p1 <- power.t.test(delta = 0.5,
                   sd = 1,
                   sig.level = 0.05,
                   power = 0.80)
ceiling(p1$n)    # n por grupo
```

```
[1] 64
```

```
# ¿Que potencia logro con n = 30?
p2 <- power.t.test(n = 30,
                   delta = 0.5,
                   sd = 1,
                   sig.level = 0.05)
round(p2$power, 2)
```

```
[1] 0.48
```





# Prueba t de una muestra en R

**Pregunta:** ¿la esperanza de vida promedio mundial en 2007 difiere de 70 años?  $H_0 : \mu = 70$  vs  $H_1 : \mu \neq 70$ , con  $\alpha = 0.05$ .

```
t1 <- t.test(datos$lifeExp, mu = 70)
tidy(t1) %>%
  select(estimate, statistic, p.value, conf.low, conf.high) %>%
  mutate(across(everything(), ~ round(.x, 3)))
```

# A tibble: 1 x 5

|   | estimate | statistic | p.value | conf.low | conf.high |
|---|----------|-----------|---------|----------|-----------|
|   | <dbl>    | <dbl>     | <dbl>   | <dbl>    | <dbl>     |
| 1 | 67.0     | -2.95     | 0.004   | 65.0     | 69.0      |

- La media muestral (67.0 años) está a casi 3 errores estándar de 70: se **rechaza**  $H_0$  al 5 %.
- Lectura equivalente: el IC 95 % [65.0, 69.0] **no contiene** 70.
- Supuestos: muestra aleatoria, observaciones independientes, normalidad aproximada (o n grande, por TCL).

## Dos muestras: ¿Welch o pooled?

| Aspecto                   | Pooled (clásica)                  | Welch (defecto en R)                     |
|---------------------------|-----------------------------------|------------------------------------------|
| Supuesto sobre varianzas  | iguales ( $\sigma_1 = \sigma_2$ ) | pueden diferir                           |
| Grados de libertad        | $n_1 + n_2 - 2$                   | aproximación de Satterthwaite            |
| Si las varianzas difieren | error Tipo I distorsionado        | robusta                                  |
| En <code>t.test()</code>  | <code>var.equal = TRUE</code>     | <code>var.equal = FALSE</code> (defecto) |



En evaluación de programas los grupos tratado y control rara vez comparten varianza: el tratamiento suele *aumentar* la dispersión de resultados (impactos heterogéneos). Use **Welch** salvo que tenga una razón fuerte para lo contrario.

# Prueba t de dos muestras: programa de empleo

Simulamos un programa de empleo juvenil: salarios mensuales (miles de pesos) de 120 controles (media 521, DE 80) y 110 tratados (media 552, DE 129).

```
welch <- t.test(salario ~ grupo, data = empleo)
pooled <- t.test(salario ~ grupo, data = empleo, var.equal = TRUE)
tibble(version = c("Welch", "Pooled"),
        t = c(welch$statistic, pooled$statistic),
        gl = c(welch$parameter, pooled$parameter),
        p = c(welch$p.value, pooled$p.value)) %>%
  mutate(across(-version, ~ round(.x, 3)))
```

# A tibble: 2 x 4

|   | version | t     | gl    | p     |
|---|---------|-------|-------|-------|
|   | <chr>   | <dbl> | <dbl> | <dbl> |
| 1 | Welch   | -2.15 | 180.  | 0.033 |
| 2 | Pooled  | -2.19 | 228   | 0.03  |

Ambas versiones rechazan  $H_0 : \mu_T = \mu_C$  al 5 %, pero no siempre coinciden: con varianzas y tamaños desiguales, la pooled puede sobre o subestimar la evidencia. Los gl de Welch (no enteros) reflejan la corrección.

# Prueba t pareada: antes y después de capacitar

Ingresos de 80 trabajadores antes y después de una capacitación. Parear **elimina la heterogeneidad individual**: la prueba se hace sobre las diferencias  $d_i$ , con  $n - 1$  gl.

```
res <- t.test(despues, antes,  
              paired = TRUE)  
# diferencia media  
round(as.numeric(res$estimate), 1)
```


```
[1] 23.3
```

```
# IC 95% de la diferencia  
round(as.numeric(res$conf.int), 1)
```

```
[1] 14.8 31.7
```

```
# valor-p  
signif(res$p.value, 2)
```


```
[1] 4.9e-07
```



# Chi-cuadrado de independencia: concepto

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \quad E_{ij} = \frac{\text{fila}_i \times \text{col}_j}{n}$$

- $H_0$ : las dos variables categóricas son **independientes**;  $H_1$ : están asociadas.
- Grados de libertad:  $(r - 1)(c - 1)$ .
- Requisito:  $E_{ij} \geq 5$  en al menos 80 % de las celdas.
- Detecta asociación, **no dirección ni causalidad**.



La distribución  $\chi^2$  se desplaza a la derecha al crecer los gl; siempre se rechaza en la **cola superior**.

# Chi-cuadrado en R: educación y voto

¿Se asocia el nivel educativo con votar? Encuesta a 600 personas ( $\alpha = 0.05$ ):

|            | Voto | No voto | Total |
|------------|------|---------|-------|
| Superior   | 180  | 20      | 200   |
| Secundaria | 150  | 50      | 200   |
| Primaria   | 90   | 110     | 200   |
| Total      | 420  | 180     | 600   |

```
chisq.test(tabla)
```

Pearson's Chi-squared test


```
data:  tabla
```

```
X-squared = 100, df = 2, p-value < 2.2e-16
```

Con  $\chi^2 = 100$  y 2 gl,  $p < 0.001$ : se rechaza la independencia — la participación electoral está fuertemente asociada al nivel educativo.

# Chi-cuadrado: observado vs esperado

## Frecuencias observadas vs esperadas bajo independencia



El estadístico acumula las brechas entre barras: educación primaria vota **mucho menos** de lo que la independencia predice (90 vs 140) y concentra la mayor parte del  $\chi^2$ .

# Pruebas de proporciones con prop.test

## Una proporción

$$z = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}$$

```
# 132 de 200 comunas elegibles
# implementaron el programa
una <- prop.test(x = 132, n = 200,
                 p = 0.5)
round(as.numeric(una$estimate), 3)
```

```
[1] 0.66
```

```
signif(una$p.value, 3)
```

```
[1] 8.4e-06
```

Requisito de la aproximación normal:  $np_0 \geq 5$  y  $n(1 - p_0) \geq 5$ . `prop.test()` aplica por defecto la corrección de continuidad de Yates; ambos contrastes rechazan  $H_0$  al 5%.

## Dos proporciones

$$z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p})(\frac{1}{n_1} + \frac{1}{n_2})}}$$

```
# empleo a 12 meses:
# 96/160 tratados, 62/158 control
dos <- prop.test(x = c(96, 62),
                 n = c(160, 158))
round(as.numeric(dos$estimate), 3)
```

```
[1] 0.600 0.392
```

```
signif(dos$p.value, 3)
```

```
[1] 0.000331
```



# Significancia estadística no es relevancia práctica

## Mismo programa, dos estudios



Con  $n$  enorme, un efecto de 0.4 pp es “significativo” pero **irrelevante** para la política; el piloto sugiere un efecto grande pero impreciso. La pregunta de política es *cuánto* (IC y magnitud), no solo si  $p < 0.05$ .

# Tamaño de efecto: d de Cohen

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_p}, \quad s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

Expresa la diferencia en **desviaciones estándar**: comparable entre estudios y variables. Referencias de Cohen (1988): 0.2 pequeño · 0.5 mediano · 0.8 grande (orientadoras, no dogma).

```
sal_c <- empleo$salario[empleo$grupo == "Control"]
sal_t <- empleo$salario[empleo$grupo == "Tratamiento"]
sp <- sqrt(((length(sal_c) - 1) * var(sal_c) +
            (length(sal_t) - 1) * var(sal_t)) / (nrow(empleo) - 2))
round((mean(sal_t) - mean(sal_c)) / sp, 2)
```

```
[1] 0.29
```


El programa de empleo mueve salarios en ~0.3 DE: efecto pequeño-mediano. Reportar d junto al valor-p permite comparar el programa con otras intervenciones y alimentar análisis costo-efectividad.

# Comparaciones múltiples: el error se acumula

| Pruebas ( $m$ ) | $P(\text{al menos 1 falso positivo})$ | $\alpha$ de Bonferroni ( $0.05/m$ ) |
|-----------------|---------------------------------------|-------------------------------------|
| 1               | 5.0 %                                 | 0.05                                |
| 5               | 22.6 %                                | 0.01                                |
| 10              | 40.1 %                                | 0.005                               |
| 20              | 64.2 %                                | 0.0025                              |
| 100             | 99.4 %                                | 0.0005                              |

- Con  $H_0$  cierta en todas,  $P(\geq 1 \text{ falso positivo}) = 1 - (1 - \alpha)^m$ : probar 20 subgrupos casi garantiza un “hallazgo”.
- **p-hacking**: probar especificaciones, outcomes o subgrupos hasta que algo dé  $p < 0.05$  y reportar solo eso.
- **Bonferroni** ( $\alpha/m$ ) controla el error familiar; es conservadora — Holm o FDR son alternativas menos costosas. La mejor defensa: preregistrar hipótesis y reportar **todas** las pruebas.

# p-hacking: simulación de la trampa



Todo se simula **bajo  $H_0$  cierta** (efecto nulo). Con una prueba por estudio, los valores-p son uniformes y el 4.8 % cae bajo 0.05; si se prueban 5 outcomes y se reporta el mínimo, la tasa de falsos positivos se multiplica por cuatro (21.4 %).

# Síntesis: protocolo de un contraste bien hecho

## Checklist antes de reportar

- 1  $H_0$ ,  $H_1$  y dirección definidas *a priori*
- 2  $\alpha$  y potencia fijados en la etapa de diseño (power.t.test)
- 3 Prueba elegida según tipo de variable y estructura (pareo, varianzas)
- 4 Reportar p exacto + IC + tamaño de efecto (d)
- 5 Declarar cuántas pruebas se hicieron; corregir si son varias
- 6 Distinguir significancia de relevancia práctica

**Funciones de la sesión:** `t.test()` `prop.test()`  
`chisq.test()` `power.t.test()` `qt()` `pt()`

## Matriz de Decision en Pruebas de Hipotesis

|                | H0 es Verdadera                                             | H0 es Falsa                                             |
|----------------|-------------------------------------------------------------|---------------------------------------------------------|
| Rechazar H0    | <b>ERROR TIPO I</b><br>(Falso Positivo)<br>Prob = alpha     | <b>CORRECTO</b><br>(Potencia)<br>Prob = 1 - beta        |
| No rechazar H0 | <b>CORRECTO</b><br>(Verdadero Negativo)<br>Prob = 1 - alpha | <b>ERROR TIPO II</b><br>(Falso Negativo)<br>Prob = beta |

alpha = nivel de significancia (típicamente 0.05) | beta = probabilidad de Error Tipo II

**Próxima sesión:** regresión lineal simple y MCO — los mismos contrastes, aplicados a  $\beta$ .

# Ejercicio para practicar (30 min)

Con `gapminder` filtrado al año **1977**:

- 1 Pruebe si la esperanza de vida promedio mundial difiere de 60 años (formule  $H_0/H_1$ , elija cola y justifique).
- 2 Compare la esperanza de vida entre África y las Américas con Welch y con pooled. ¿Cambia la conclusión? ¿Cuál reportaría?
- 3 Calcule la  $d$  de Cohen de esa comparación e interprétela.
- 4 Cree la variable `alta_vida` (esperanza sobre la mediana global) y pruebe con `chisq.test()` si se asocia al continente. Grafique observado vs esperado.
- 5 Con `prop.test()`, contraste si la proporción de países con `alta_vida` en Asia difiere de 0.5.
- 6 ¿Qué  $n$  por grupo exigiría detectar  $d = 0.3$  con potencia 0.80 y  $\alpha = 0.05$ ? Use `power.t.test()`.

**i Referencias:** Wooldridge, *Introductory Econometrics* (apéndice C) · Stock & Watson, *Introduction to Econometrics* (cap. 3) · Wasserstein & Lazar (2016), "The ASA Statement on p-Values", *The American Statistician* · Cohen (1988), *Statistical Power Analysis*.