

Sesión 1 · Pruebas de Hipótesis

Nivelación Econometría — Doctorados en Políticas Públicas y en Ciencias de la Complejidad Social ·
Universidad del Desarrollo

Amaru Agüero Jiménez (a.agueroj@udd.cl)


marzo de 2026

Panorama de la sesión

Bloque	Concepto clave	Herramienta en R
Lógica de la inferencia	H_0 , H_1 , distribución nula	<code>pt()</code> , <code>qt()</code>
Valor-p y decisión	α , regiones de rechazo, ASA	<code>t.test()</code>
Errores y potencia	Tipo I/II, $1 - \beta$, tamaño de muestra	<code>power.t.test()</code>
Pruebas t	una muestra, dos (Welch), pareada	<code>t.test()</code>
Variables categóricas	independencia, proporciones	<code>chisq.test()</code> , <code>prop.test()</code>
Buenas prácticas	relevancia, d de Cohen, p-hacking	corrección de Bonferroni

i Datos de trabajo: `gapminder` (142 países, 2007) y microdatos simulados de un programa de empleo juvenil. En evaluación de políticas, cada rechazo de H_0 es una decisión sobre recursos públicos: conviene entender exactamente qué afirma (y qué no) una prueba de hipótesis.

La prueba de hipótesis en el flujo econométrico



Flujo iterativo: los diagnosticos pueden llevar a re-especificar

- La econometría traduce preguntas de política a **parámetros**: μ , p , β .
- Estimar no basta: hay que separar **señal de ruido muestral**.
- Toda evaluación de impacto termina en un contraste: ¿el efecto es distinguible de cero?
- Esta sesión construye la caja de herramientas del contraste; las próximas la aplican a coeficientes de regresión.

La lógica frecuentista en seis pasos

Paso	Qué se hace	Ejemplo: transferencia monetaria
1. Formular	H_0 : sin efecto; H_1 : hay efecto	H_0 : el consumo no cambia
2. Elegir α	riesgo tolerado de falso positivo	$\alpha = 0.05$
3. Estadístico	según tipo de variable y diseño	t de dos muestras
4. Calcular	con los datos muestrales	$t = 2.41$
5. Valor-p	prob. de algo tan extremo bajo H_0	$p = 0.017$
6. Decidir	$p < \alpha$ implica rechazar H_0	se rechaza: hay efecto

Razonamiento por contradicción: **asumimos que el programa no funciona** (H_0) y preguntamos qué tan improbables serían nuestros datos en ese mundo. Los pasos 1 y 2 se fijan **antes** de mirar los datos.

Hipótesis nula y alternativa: quién carga la prueba

Hipótesis nula (H_0)

- Afirma “no efecto” o “no diferencia”: el statu quo
- Se asume verdadera hasta que la evidencia la contradiga
- Nunca se “acepta”: solo se **no rechaza**
- Ej: $\mu = 100$, $\mu_1 = \mu_2$, $p = 0.5$

Hipótesis alternativa (H_1)

- Lo que el investigador quiere demostrar
- Sobre ella recae la **carga de la prueba**
- Puede ser bilateral o unilateral
- Ej: $\mu \neq 100$, $\mu_1 \neq \mu_2$, $p > 0.5$

i Ejemplo — subsidio al empleo juvenil. H_0 : la tasa de ocupación de beneficiarios es igual a la de no beneficiarios. H_1 : las tasas difieren. Si no logramos rechazar H_0 , no probamos que el programa “no sirve”: solo que la evidencia es insuficiente.

¿Bilateral o unilateral? La dirección se decide antes


Tipo	H_1	Cuándo usarla	Ejemplo de política
Bilateral	$\mu \neq \mu_0$	interesa cualquier dirección	¿La reforma cambió el gasto de bolsillo en salud?
Unilateral derecha	$\mu > \mu_0$	solo interesa un aumento	¿El subsidio aumentó el empleo formal?
Unilateral izquierda	$\mu < \mu_0$	solo interesa una caída	¿La beca redujo la deserción escolar?

 La cola se elige **antes de ver los datos**, por teoría o diseño. Elegirla después de mirar el signo del efecto duplica de facto el error Tipo I: es una forma de p-hacking. Ante la duda, use la bilateral (más conservadora).

El estadístico de prueba y su distribución nula


$$t = \frac{\text{estimación} - \text{valor bajo } H_0}{\text{error estándar}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

- Resume los datos en **un número**: a cuántos errores estándar está la estimación del valor nulo.
- La **distribución nula** describe cómo se comportaría ese número si H_0 fuera cierta (aquí, t de Student con $n - 1$ gl).
- Un $|t|$ grande significa datos improbables bajo H_0 .



Con 25 gl y $\alpha = 0.05$ bilateral, la regla es rechazar si $|t| > 2.06$.



Valor-p: la definición precisa



Valor-p: probabilidad de obtener un estadístico **tan extremo o más** que el observado, *suponiendo que H_0 es cierta*. Es $P(\text{datos extremos} \mid H_0)$ — no la probabilidad de que H_0 sea verdadera.

El valor-p en la práctica: dos escenarios

Distribucion bajo H_0 : Interpretacion del p-valor



Mismo umbral $\alpha = 0.05$: a la izquierda, $t = 1.2$ deja mucha área en las colas ($p = 0.23$) y no se rechaza; a la derecha, $t = 2.8$ deja un área mínima ($p = 0.005$) y se rechaza H_0 .

Lo que el valor-p NO significa

Malinterpretación frecuente	Realidad
“p es la probabilidad de que H_0 sea cierta”	p se calcula <i>asumiendo</i> H_0 : es $P(\text{datos} \mid H_0)$, no $P(H_0 \mid \text{datos})$
“p = 0.20 demuestra que no hay efecto”	ausencia de evidencia no es evidencia de ausencia (puede faltar potencia)
“p < 0.05 implica un efecto importante”	con n grande, efectos triviales producen p minúsculos
“1 - p es la probabilidad de replicar”	p no informa sobre replicabilidad del hallazgo
“p = 0.049 y p = 0.051 son mundos distintos”	0.05 es una convención, no un umbral físico

! **Declaración ASA (Wasserstein & Lazar, 2016):** el valor-p no mide la probabilidad de la hipótesis ni el tamaño del efecto, y ninguna decisión científica o de política debería basarse solo en si p cruza un umbral. Reporte p exacto, IC y tamaño de efecto.

Nivel de significancia y valores críticos

α	Crítico bilateral (z)	Crítico unilateral (z)	Uso típico
0.10	1.645	1.282	análisis exploratorio
0.05	1.960	1.645	convención dominante
0.01	2.576	2.326	decisiones de alto costo

- α es la probabilidad de **error Tipo I** que el investigador acepta a priori: define la región de rechazo en las colas de la distribución nula.
- Bajar α hace la prueba más exigente: menos falsos positivos, pero más falsos negativos (β sube).
- En muestras pequeñas los críticos de la t son mayores que los de z (colas más pesadas): con 24 gl, el crítico bilateral al 5 % es 2.06, no 1.96.


Matriz de decisión: los cuatro escenarios

Decisión	H_0 verdadera	H_0 falsa
Rechazar H_0	Error Tipo I (prob = α)	Correcto: potencia ($1 - \beta$)
No rechazar H_0	Correcto (prob = $1 - \alpha$)	Error Tipo II (prob = β)

- **Error Tipo I (falso positivo):** declarar efectivo un programa que no lo es — se financia una política inútil.
- **Error Tipo II (falso negativo):** no detectar un programa que sí funciona — se cancela una política valiosa.
- Reducir α aumenta β y viceversa; la única forma de reducir ambos es **aumentar n**.


💡 **Analogía judicial:** Tipo I = condenar a un inocente; Tipo II = absolver a un culpable. El sistema fija α bajo porque considera peor el falso positivo — igual que la estadística.

Errores Tipo I y II en las distribuciones



- Área **naranja**: α , cola de la distribución bajo H_0 más allá del valor crítico.
- Área **morada**: β , parte de la distribución bajo H_1 que cae en zona de no rechazo.
- Mover el crítico a la derecha (bajar α) agranda el área morada: el trade-off es geométrico.
- Si las campanas se separan (efecto mayor) o se angostan (más n , menos σ), ambos errores caen a la vez.

Potencia: la zona que el diseño debe maximizar




Potencia = probabilidad de rechazar H_0 cuando es falsa (área verde). El estándar de diseño en evaluación de impacto es potencia ≥ 0.80 : un estudio con potencia 0.30 casi garantiza no detectar el efecto aunque exista.

Cuatro palancas determinan la potencia

- **Tamaño de efecto:** efectos más grandes se detectan más fácil; es la palanca que *no* controla el evaluador.
- **Tamaño de muestra (n):** más n reduce el error estándar; la palanca principal de diseño.
- **Nivel α :** un α mayor da más potencia, al precio de más falsos positivos.
- **Varianza (σ^2):** menos ruido (mejor medición, estratificación) aumenta la potencia.

Con dos grupos, detectar un efecto pequeño ($d = 0.2$) con 80 % de potencia exige **cerca de 400 casos por grupo** (unos 200 en total si el contraste es de una sola muestra, como ilustra la figura).




power.t.test: diseñar el tamaño de muestra

```
# ¿Que n necesito? (d = 0.5)
p1 <- power.t.test(delta = 0.5,
                   sd = 1,
                   sig.level = 0.05,
                   power = 0.80)
ceiling(p1$n)    # n por grupo
```

```
[1] 64
```

```
# ¿Que potencia logro con n = 30?
p2 <- power.t.test(n = 30,
                   delta = 0.5,
                   sd = 1,
                   sig.level = 0.05)
round(p2$power, 2)
```

```
[1] 0.48
```



Prueba t de una muestra en R

Pregunta: ¿la esperanza de vida promedio mundial en 2007 difiere de 70 años? $H_0 : \mu = 70$ vs $H_1 : \mu \neq 70$, con $\alpha = 0.05$.

```
t1 <- t.test(datos$lifeExp, mu = 70)
tidy(t1) %>%
  select(estimate, statistic, p.value, conf.low, conf.high) %>%
  mutate(across(everything(), ~ round(.x, 3)))
```

A tibble: 1 x 5

	estimate	statistic	p.value	conf.low	conf.high
	<dbl>	<dbl>	<dbl>	<dbl>	<dbl>
1	67.0	-2.95	0.004	65.0	69.0

- La media muestral (67.0 años) está a casi 3 errores estándar de 70: se **rechaza** H_0 al 5 %.
- Lectura equivalente: el IC 95 % [65.0, 69.0] **no contiene** 70.
- Supuestos: muestra aleatoria, observaciones independientes, normalidad aproximada (o n grande, por TCL).

Dos muestras: ¿Welch o pooled?

Aspecto	Pooled (clásica)	Welch (defecto en R)
Supuesto sobre varianzas	iguales ($\sigma_1 = \sigma_2$)	pueden diferir
Grados de libertad	$n_1 + n_2 - 2$	aproximación de Satterthwaite
Si las varianzas difieren	error Tipo I distorsionado	robusta
En <code>t.test()</code>	<code>var.equal = TRUE</code>	<code>var.equal = FALSE</code> (defecto)



En evaluación de programas los grupos tratado y control rara vez comparten varianza: el tratamiento suele *aumentar* la dispersión de resultados (impactos heterogéneos). Use **Welch** salvo que tenga una razón fuerte para lo contrario.

Prueba t de dos muestras: programa de empleo

Simulamos un programa de empleo juvenil: salarios mensuales (miles de pesos) de 120 controles (media 521, DE 80) y 110 tratados (media 552, DE 129).

```
welch <- t.test(salario ~ grupo, data = empleo)
pooled <- t.test(salario ~ grupo, data = empleo, var.equal = TRUE)
tibble(version = c("Welch", "Pooled"),
        t = c(welch$statistic, pooled$statistic),
        gl = c(welch$parameter, pooled$parameter),
        p = c(welch$p.value, pooled$p.value)) %>%
  mutate(across(-version, ~ round(.x, 3)))
```

A tibble: 2 x 4

	version	t	gl	p
	<chr>	<dbl>	<dbl>	<dbl>
1	Welch	-2.15	180.	0.033
2	Pooled	-2.19	228	0.03

Ambas versiones rechazan $H_0 : \mu_T = \mu_C$ al 5 %, pero no siempre coinciden: con varianzas y tamaños desiguales, la pooled puede sobre o subestimar la evidencia. Los gl de Welch (no enteros) reflejan la corrección.

Prueba t pareada: antes y después de capacitar

Ingresos de 80 trabajadores antes y después de una capacitación. Parear **elimina la heterogeneidad individual**: la prueba se hace sobre las diferencias d_i , con $n - 1$ gl.

```
res <- t.test(despues, antes,  
              paired = TRUE)  
# diferencia media  
round(as.numeric(res$estimate), 1)
```


```
[1] 23.3
```

```
# IC 95% de la diferencia  
round(as.numeric(res$conf.int), 1)
```

```
[1] 14.8 31.7
```

```
# valor-p  
signif(res$p.value, 2)
```


```
[1] 4.9e-07
```



Chi-cuadrado de independencia: concepto

$$\chi^2 = \sum_{i,j} \frac{(O_{ij} - E_{ij})^2}{E_{ij}}, \quad E_{ij} = \frac{\text{fila}_i \times \text{col}_j}{n}$$

- H_0 : las dos variables categóricas son **independientes**; H_1 : están asociadas.
- Grados de libertad: $(r - 1)(c - 1)$.
- Requisito: $E_{ij} \geq 5$ en al menos 80 % de las celdas.
- Detecta asociación, **no dirección ni causalidad**.



La distribución χ^2 se desplaza a la derecha al crecer los gl; siempre se rechaza en la **cola superior**.

Chi-cuadrado en R: educación y voto

¿Se asocia el nivel educativo con votar? Encuesta a 600 personas ($\alpha = 0.05$):

	Voto	No voto	Total
Superior	180	20	200
Secundaria	150	50	200
Primaria	90	110	200
Total	420	180	600

```
chisq.test(tabla)
```

Pearson's Chi-squared test


```
data:  tabla
```

```
X-squared = 100, df = 2, p-value < 2.2e-16
```

Con $\chi^2 = 100$ y 2 gl, $p < 0.001$: se rechaza la independencia — la participación electoral está fuertemente asociada al nivel educativo.

Chi-cuadrado: observado vs esperado

Frecuencias observadas vs esperadas bajo independencia



El estadístico acumula las brechas entre barras: educación primaria vota **mucho menos** de lo que la independencia predice (90 vs 140) y concentra la mayor parte del χ^2 .

Pruebas de proporciones con prop.test

Una proporción

$$z = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}$$

```
# 132 de 200 comunas elegibles
# implementaron el programa
una <- prop.test(x = 132, n = 200,
                 p = 0.5)
round(as.numeric(una$estimate), 3)
```

```
[1] 0.66
```

```
signif(una$p.value, 3)
```

```
[1] 8.4e-06
```

Requisito de la aproximación normal: $np_0 \geq 5$ y $n(1 - p_0) \geq 5$. `prop.test()` aplica por defecto la corrección de continuidad de Yates; ambos contrastes rechazan H_0 al 5%.

Dos proporciones

$$z = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}(1 - \hat{p})(\frac{1}{n_1} + \frac{1}{n_2})}}$$

```
# empleo a 12 meses:
# 96/160 tratados, 62/158 control
dos <- prop.test(x = c(96, 62),
                 n = c(160, 158))
round(as.numeric(dos$estimate), 3)
```

```
[1] 0.600 0.392
```

```
signif(dos$p.value, 3)
```

```
[1] 0.000331
```


Significancia estadística no es relevancia práctica

Mismo programa, dos estudios



Con n enorme, un efecto de 0.4 pp es “significativo” pero **irrelevante** para la política; el piloto sugiere un efecto grande pero impreciso. La pregunta de política es *cuánto* (IC y magnitud), no solo si $p < 0.05$.

Tamaño de efecto: d de Cohen

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_p}, \quad s_p = \sqrt{\frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}}$$

Expresa la diferencia en **desviaciones estándar**: comparable entre estudios y variables. Referencias de Cohen (1988): 0.2 pequeño · 0.5 mediano · 0.8 grande (orientadoras, no dogma).

```
sal_c <- empleo$salario[empleo$grupo == "Control"]
sal_t <- empleo$salario[empleo$grupo == "Tratamiento"]
sp <- sqrt(((length(sal_c) - 1) * var(sal_c) +
            (length(sal_t) - 1) * var(sal_t)) / (nrow(empleo) - 2))
round((mean(sal_t) - mean(sal_c)) / sp, 2)
```

```
[1] 0.29
```


El programa de empleo mueve salarios en ~0.3 DE: efecto pequeño-mediano. Reportar d junto al valor-p permite comparar el programa con otras intervenciones y alimentar análisis costo-efectividad.

Comparaciones múltiples: el error se acumula

Pruebas (m)	$P(\text{al menos 1 falso positivo})$	α de Bonferroni ($0.05/m$)
1	5.0 %	0.05
5	22.6 %	0.01
10	40.1 %	0.005
20	64.2 %	0.0025
100	99.4 %	0.0005

- Con H_0 cierta en todas, $P(\geq 1 \text{ falso positivo}) = 1 - (1 - \alpha)^m$: probar 20 subgrupos casi garantiza un “hallazgo”.
- **p-hacking**: probar especificaciones, outcomes o subgrupos hasta que algo dé $p < 0.05$ y reportar solo eso.
- **Bonferroni** (α/m) controla el error familiar; es conservadora — Holm o FDR son alternativas menos costosas. La mejor defensa: preregistrar hipótesis y reportar **todas** las pruebas.

p-hacking: simulación de la trampa



Todo se simula **bajo H_0 cierta** (efecto nulo). Con una prueba por estudio, los valores-p son uniformes y el 4.8 % cae bajo 0.05; si se prueban 5 outcomes y se reporta el mínimo, la tasa de falsos positivos se multiplica por cuatro (21.4 %).

Síntesis: protocolo de un contraste bien hecho

Checklist antes de reportar

- 1 H_0 , H_1 y dirección definidas *a priori*
- 2 α y potencia fijados en la etapa de diseño (power.t.test)
- 3 Prueba elegida según tipo de variable y estructura (pareo, varianzas)
- 4 Reportar p exacto + IC + tamaño de efecto (d)
- 5 Declarar cuántas pruebas se hicieron; corregir si son varias
- 6 Distinguir significancia de relevancia práctica

Funciones de la sesión: `t.test()` `prop.test()`
`chisq.test()` `power.t.test()` `qt()` `pt()`

Matriz de Decision en Pruebas de Hipotesis

	H0 es Verdadera	H0 es Falsa
Rechazar H0	ERROR TIPO I (Falso Positivo) Prob = alpha	CORRECTO (Potencia) Prob = 1 - beta
No rechazar H0	CORRECTO (Verdadero Negativo) Prob = 1 - alpha	ERROR TIPO II (Falso Negativo) Prob = beta

alpha = nivel de significancia (típicamente 0.05) | beta = probabilidad de Error Tipo II

Próxima sesión: regresión lineal simple y MCO — los mismos contrastes, aplicados a β .

Ejercicio para practicar (30 min)

Con `gapminder` filtrado al año **1977**:

- 1 Pruebe si la esperanza de vida promedio mundial difiere de 60 años (formule H_0/H_1 , elija cola y justifique).
- 2 Compare la esperanza de vida entre África y las Américas con Welch y con pooled. ¿Cambia la conclusión? ¿Cuál reportaría?
- 3 Calcule la d de Cohen de esa comparación e interprétela.
- 4 Cree la variable `alta_vida` (esperanza sobre la mediana global) y pruebe con `chisq.test()` si se asocia al continente. Grafique observado vs esperado.
- 5 Con `prop.test()`, contraste si la proporción de países con `alta_vida` en Asia difiere de 0.5.
- 6 ¿Qué n por grupo exigiría detectar $d = 0.3$ con potencia 0.80 y $\alpha = 0.05$? Use `power.t.test()`.

i Referencias: Wooldridge, *Introductory Econometrics* (apéndice C) · Stock & Watson, *Introduction to Econometrics* (cap. 3) · Wasserstein & Lazar (2016), "The ASA Statement on p-Values", *The American Statistician* · Cohen (1988), *Statistical Power Analysis*.