Regresión Lineal Simple

Sesión 2: Modelos Econométricos Fundamentales

Amaru Agüero

Doctorado en Ciencias de la Complejidad Social — CICS, UDD

24 de marzo de 2026

Universidad del Desarrollo
Facultad de Gobierno

Agenda

- Correlación vs. causalidad: conceptos fundamentales
- Modelo de regresión lineal simple: formulación
- Estimación por Mínimos Cuadrados Ordinarios (MCO/OLS)
- Interpretación de coeficientes
- Bondad de ajuste: R^2 y R^2 ajustado
- Errores estándar e inferencia estadística
- Supuestos del modelo clásico (Gauss-Markov)
- Implementación práctica en R
- Ejercicio práctico y conclusiones

Correlación vs. Causalidad

¿Qué es la correlación?

- **Correlación**: mide la asociación lineal entre dos variables
- Rango: $-1 \leq \rho \leq 1$
- **Coeficiente de Pearson**:

$$\rho = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

- Información: fuerza y dirección de la relación
- **Límite**: no implica relación causa-efecto

Punto Clave

Correlación alta no implica causalidad: confounding, reverse causality, relaciones espurias

Correlación vs. Causalidad

De la correlación a la causalidad

- **Regresión**: permite modelar la relación *condicional*
- Bajo ciertos **supuestos**, podemos interpretar coeficientes causalmente
- Supuesto crítico: **exogeneidad** de los regresores
- Si $E[\varepsilon|X] = 0$, entonces β_1 mide el efecto causal de X en Y

Ejemplo

¿Correlación entre educación y salario implica causalidad?

- Correlación: positiva y fuerte
- Causalidad: bajo supuestos (p.ej., habilidad no omitida)
- Regresión: estima el efecto ceteris paribus

Modelo poblacional

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Notación y componentes:

- Y: variable dependiente (endógena)
- X: variable independiente (exógena)
- β_0: intercepto (parámetro poblacional)
- β_1: pendiente (parámetro de interés)
- ε: término de error (inobservable)

Interpretación ceteris paribus:

$$\beta_1 = \frac{\partial E[Y|X]}{\partial X}$$

Modelo de Regresión Lineal Simple

Visualización

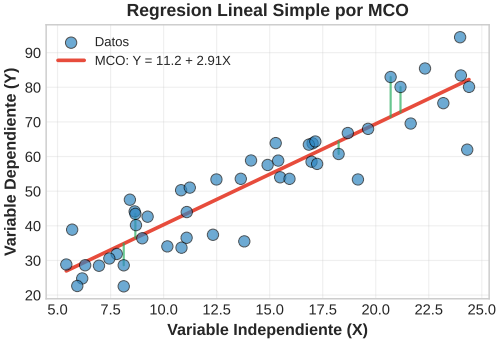

Línea roja: $\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X$ (recta estimada)
Puntos: pares observados (X_i, Y_i) con su error $\hat{\varepsilon}_i = Y_i - \hat{Y}_i$

Estimación por Mínimos Cuadrados Ordinarios

Principio y derivación intuitiva

Objetivo: minimizar la suma de errores al cuadrado (SSE)

$$SSE = \sum_{i=1}^{n} \varepsilon_i^2 = \sum_{i=1}^{n} (Y_i - \beta_0 - \beta_1 X_i)^2$$

Condiciones de primer orden (igualando derivadas a cero):

$$\frac{\partial SSE}{\partial \beta_0} = -2 \sum_i (Y_i - \beta_0 - \beta_1 X_i) = 0$$

$$\frac{\partial SSE}{\partial \beta_1} = -2 \sum_i X_i (Y_i - \beta_0 - \beta_1 X_i) = 0$$

Resultado: sistema de ecuaciones normales que se resuelve para $\hat{\beta}_0$ y $\hat{\beta}_1$.

Estimación por Mínimos Cuadrados Ordinarios

Fórmulas de los estimadores

Estimadores MCO

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^{n}(X_i - \bar{X})^2} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$$

Propiedades (bajo supuestos):

- Insesgados: $E[\hat{\beta}_j] = \beta_j$
- Consistentes: $\hat{\beta}_j \xrightarrow{p} \beta_j$
- Eficientes: varianza mínima entre estimadores lineales insesgados (BLUE)

Interpretación de Coeficientes

Significado económico

Pendiente $\hat{\beta}_1$:

- Cambio en Y cuando X aumenta en una unidad
- Efecto marginal ceteris paribus
- Unidades: mismo ratio que $\frac{[Y]}{[X]}$

Ejemplo: Si Y = salario (USD/año) y X = educación (años)

- $\hat{\beta}_1 = 2000$ significa: 1 año adicional de educación $\Rightarrow$ +USD 2000 de salario

Intercepto $\hat{\beta}_0$:

- Valor predicho de Y cuando $X = 0$
- Interpretación económica no siempre directa
- Referencia para la recta de regresión

Interpretación de Coeficientes

Transformaciones logarítmicas

Modelo	**Forma**	**Interpretación de $\hat{\beta}_1$**
Lineal	$Y = \beta_0 + \beta_1 X + \varepsilon$	Cambio absoluto en Y
Log-Log	$\ln Y = \beta_0 + \beta_1 \ln X + \varepsilon$	Elasticidad (% cambio)
Log-Lin	$\ln Y = \beta_0 + \beta_1 X + \varepsilon$	Cambio % en Y
Lin-Log	$Y = \beta_0 + \beta_1 \ln X + \varepsilon$	Cambio en Y por % cambio en X

Ejemplo Log-Log: Si $\hat{\beta}_1 = 0.5$, entonces un aumento de 1% en X implica un aumento de 0.5% en Y (elasticidad de demanda, etc.).

Bondad de Ajuste: R^2 y R^2 Ajustado

Medidas de explicación de variabilidad

Descomposición de variabilidad:

- $SST = SSE + SSR$ (suma total = suma explicada + suma residual)
- $\sum(Y_i - \bar{Y})^2 = \sum(Y_i - \hat{Y}_i)^2 + \sum(\hat{Y}_i - \bar{Y})^2$

Coeficiente de determinación

$$R^2 = 1 - \frac{SSE}{SST} = \frac{SSR}{SST}$$

Proporción de varianza en Y explicada por X (rango: $[0, 1]$)

R^2 **ajustado:** penaliza por número de regresores

$$\bar{R}^2 = 1 - \frac{SSE/(n-k)}{SST/(n-1)}$$

donde k = número de parámetros, n = número de observaciones.

Bondad de Ajuste: Visualización

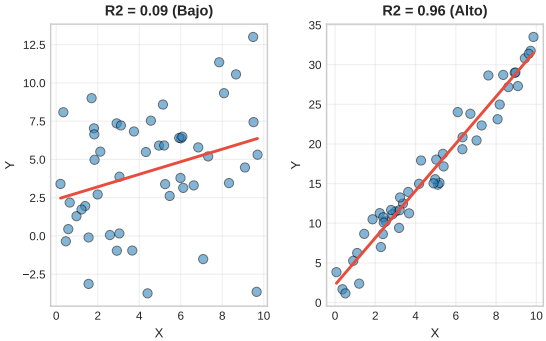

Izquierda: bajo R^2 (residuos grandes) | Derecha: alto R^2 (residuos pequeños)

Errores Estándar e Inferencia Estadística

Varianza de los estimadores

Varianza residual: $\hat{\sigma}^2 = \frac{SSE}{n-2}$, $\quad SE(\hat{\beta}_1) = \frac{\hat{\sigma}}{\sqrt{\sum_i (X_i - \bar{X})^2}}$

Prueba t de significancia

$t = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)} \sim t_{n-2} \quad | \quad H_0 : \beta_1 = 0 \text{ vs } H_1 : \beta_1 \neq 0$

IC 95%: $\hat{\beta}_1 \pm t_{0.025, n-2} \cdot SE(\hat{\beta}_1)$

Salida típica de software (ej. R):

	Coef.	SE	t-stat	p-valor
(Intercept)	$\hat{\beta}_0$	$SE(\hat{\beta}_0)$	t_0	p_0
X	$\hat{\beta}_1$	$SE(\hat{\beta}_1)$	t_1	p_1

Regla de decisión:

- Si p-valor $< 0.05 \Rightarrow$ rechazamos H_0 (coeficiente significativo)
- Si p-valor $\geq 0.05 \Rightarrow$ no rechazamos H_0

Nota: Significancia estadística $\neq$ significancia económica/práctica

Supuestos del Modelo Clásico

Condiciones para la validez de MCO

1. **Linealidad**: relación lineal en parámetros: $Y = \beta_0 + \beta_1 X + \varepsilon$
2. **Exogeneidad**: $E[\varepsilon|X] = 0$ (errores no correlacionados con X)
3. **Sin multicolinealidad exacta**: varianza de X es positiva y finita
4. **Homocedasticidad**: $\text{Var}(\varepsilon|X) = \sigma^2$ (varianza constante)
5. **Sin autocorrelación**: $\text{Cov}(\varepsilon_i, \varepsilon_j|X) = 0$ para $i \neq j$
6. **Normalidad** (para inferencia): $\varepsilon \sim N(0, \sigma^2)$

Teorema Gauss-Markov: Bajo supuestos 1–5, MCO es el estimador BLUE (mejor linealmente insesgado).

Diagnóstico de Supuestos

Gráficos de residuos

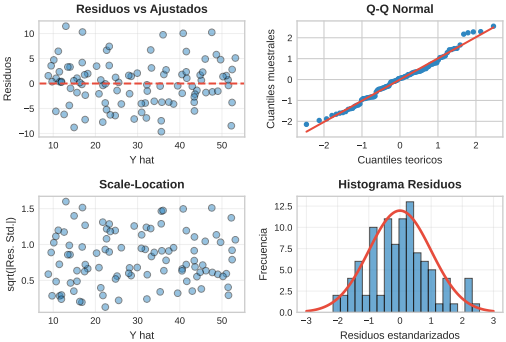

Paneles: Residuos vs. Ajustados | Q-Q plot | Scale-Location | Residuos vs. Palanca

Implementación Práctica en R

Estimación del modelo

```r
# Cargar datos
data(mtcars)

# Linear regression: mpg ~ wt
modelo <- lm(mpg ~ wt, data = mtcars)

# Resumen detallado
summary(modelo)
```

Salida: coeficientes, errores estándar, t-estadísticos, p-valores, R^2, prueba F global.

Implementación Práctica en R

Gráficos de diagnóstico

```r
# Diagnostic plots (4 panels)
plot(modelo)

# Predictions
predichos <- predict(modelo)

# Residuos
residuos <- residuals(modelo)

# Acceso a componentes
coef(modelo)         # Coeficientes
confint(modelo)      # Intervalos de confianza
```

El comando `plot()` automáticamente genera los 4 gráficos estándar de diagnóstico.

Ejercicio Práctico

Datos: Dataset `mtcars` (Motor Trend Car Road Tests)

Pregunta: ¿Cómo el peso del automóvil afecta el consumo de combustible?

Tareas:

1. Estimar el modelo: $\text{mpg} = \beta_0 + \beta_1 \text{wt} + \varepsilon$
2. Interpretar $\hat{\beta}_1$ (¿unidades? ¿signo? ¿magnitud?)
3. ¿Es $\hat{\beta}_1$ estadísticamente significativo al 5%?
4. Calcular R^2 e interpretar (¿qué % de variación explica?)
5. Realizar diagnóstico gráfico de supuestos (`plot(modelo)`)
6. ¿Se cumplen los supuestos? Comentar sobre heterocedasticidad y normalidad

Resumen y Próximas Sesiones

Conceptos clave de hoy:

- Regresión vs. correlación: causalidad requiere supuestos
- MCO minimiza suma de cuadrados de residuos
- Coeficientes se interpretan como efectos marginales ceteris paribus
- R^2 mide la proporción de varianza explicada
- Supuestos Gauss-Markov garantizan optimalidad de MCO
- Diagnóstico de supuestos es fundamental

Próximas sesiones:

- Sesión 3: Regresión múltiple (múltiples regresores)
- Sesión 4: Violación de supuestos y métodos robustos
- Sesión 5: Variables categóricas y especificación