

Sesión 2 · Regresión Lineal Simple

Nivelación Econometría — Doctorados en Políticas Públicas y en Ciencias de la Complejidad Social ·
Universidad del Desarrollo

Amaru Agüero Jiménez (a.agueroj@udd.cl)


marzo de 2026

Panorama de la sesión

Bloque	Concepto clave	Herramienta en R
El modelo	$y = \beta_0 + \beta_1 x + u$; causal vs predictivo	—
Estimación MCO	Minimizar la suma de cuadrados	<code>lm()</code> , <code>broom::tidy()</code>
Interpretación	Unidades, formas funcionales, logs	<code>log()</code>
Bondad de ajuste	R^2 : qué es y qué no es	<code>broom::glance()</code>
Inferencia	$SE(\hat{\beta}_1)$, prueba t, IC	<code>confint()</code> , <code>sandwich</code>
Supuestos	Gauss-Markov, heterocedasticidad	<code>plot(modelo)</code>
Predicción	Bandas media vs individuo; extrapolación	<code>predict()</code>

i Datos de trabajo: wage1 (Wooldridge): 526 trabajadores (EE.UU., 1976) con salario por hora y educación. ¿Cuánto rinde un año más de escolaridad? gapminder 2007 reaparece para formas funcionales.

La regresión en el flujo econométrico




Flujo iterativo: los diagnósticos pueden llevar a re-especificar

- **Pregunta de política:** ¿cuánto aumenta el salario un año adicional de educación?
- **Modelo:** $y = \beta_0 + \beta_1 x + u$ traduce la pregunta a un parámetro: β_1 .
- **Estimación:** MCO entrega $\hat{\beta}_1$ a partir de los datos.
- **Inferencia:** ¿es $\hat{\beta}_1$ distinguible del ruido muestral? (sesión 1).
- **Hoy:** el eslabón modelo $\rightarrow$ estimación $\rightarrow$ interpretación $\rightarrow$ diagnóstico.

El modelo poblacional: $y = \beta_0 + \beta_1 x + u$

$$y = \beta_0 + \beta_1 x + u$$

- y : variable dependiente (el resultado de interés)
- x : variable explicativa (la palanca de política)
- β_0, β_1 : **parámetros poblacionales** desconocidos
- u : término de error — *todo lo demás* que afecta a y
- Si $E[u | x] = 0$, entonces $E[y | x] = \beta_0 + \beta_1 x$: la recta es la **media condicional**



Dos lecturas del mismo modelo: predictiva y causal

Lectura	Pregunta que responde	Requisito clave	Uso en política pública
Predictiva	¿Cuál es el salario <i>esperado</i> de alguien con 12 años de educación?	Buen ajuste dentro del rango de los datos	Focalización, proyecciones, alertas tempranas
Causal	¿Cuánto <i>subiría</i> el salario si la política agrega un año de educación?	Exogeneidad: $E[u \mid x] = 0$	Evaluación de reformas, análisis costo-beneficio

! La misma recta estimada admite ambas lecturas. Lo que decide cuál es válida no es el software sino los **supuestos**: si la habilidad (omitida en u) se correlaciona con la educación, $\hat{\beta}_1$ predice bien pero **no** mide el efecto causal.

Los datos: wage1 de Wooldridge

```
data("wage1", package = "wooldridge")
wage1 %>% select(wage, educ, exper) %>% glimpse()
```

Rows: 526

Columns: 3


```
$ wage  <dbl> 3.10, 3.24, 3.00, 6.00, 5.30, 8.75, 11.25, 5.00, 3.60, 18.18, 6.~
$ educ  <int> 11, 12, 11, 8, 12, 16, 18, 12, 12, 17, 16, 13, 12, 12, 16, 1~
$ exper <int> 2, 22, 2, 44, 7, 9, 15, 5, 26, 22, 8, 3, 15, 18, 31, 14, 10, 16,~
```

- wage: salario promedio por hora (USD de 1976) — nuestra y
- educ: años de educación formal (rango 0–18) — nuestra x
- $\text{lwage} = \log(\text{wage})$: la usaremos para semi-elasticidades
- Corte transversal de la CPS: cada fila es un trabajador distinto

Primer vistazo: siempre graficar antes de estimar

```
ggplot(wage1,  
  aes(x = educ, y = wage)) +  
  geom_jitter(width = .2,  
    alpha = .35,  
    color = celeste) +  
  geom_smooth(method = "lm",  
    se = FALSE,  
    color = rojo) +  
  labs(x = "Educación (años)",  
    y = "Salario (USD/hora)")
```

- Nube con pendiente positiva y mucha dispersión
- educ es discreta: el *jitter* evita el sobretrazado
- La recta resume $E[y \mid x]$; los puntos recuerdan que u existe



MCO: minimizar la suma de cuadrados de los residuos

Cada recta candidata (β_0, β_1) deja residuos $\hat{u}_i = y_i - \beta_0 - \beta_1 x_i$. MCO elige la recta que minimiza:

$$\min_{\beta_0, \beta_1} SCR = \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Condiciones de primer orden (derivar e igualar a cero):

$$\sum_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \quad \sum_i x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$

- **¿Por qué cuadrados?** Penaliza más los errores grandes, es diferenciable y tiene solución única (si $\text{Var}(x) > 0$).
- Las condiciones implican: los residuos **suman cero** y **no se correlacionan** con x .

Los estimadores MCO: fórmula y verificación en R

$$\hat{\beta}_1 = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sum_i (x_i - \bar{x})^2} = \frac{\widehat{\text{Cov}}(x, y)}{\widehat{\text{Var}}(x)} \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

```
b1 <- cov(wage1$educ, wage1$wage) / var(wage1$educ)
b0 <- mean(wage1$wage) - b1 * mean(wage1$educ)
round(c(b0_manual = b0, b1_manual = b1), 4)
```

```
b0_manual b1_manual
-0.9049    0.5414
```


```
round(coef(lm(wage ~ educ, data = wage1)), 4)
```

```
(Intercept)      educ
-0.9049        0.5414
```

La pendiente es la covarianza reescalada por la varianza de x ; la recta MCO siempre pasa por el punto de medias $(\bar{x}, \bar{y})$.

Anatomía del gráfico de regresión

Submuestra de 70 trabajadores: observado, ajustado y residuo



Cada observación se descompone en $y_i = \hat{y}_i + \hat{u}_i$: valor **ajustado** (sobre la recta) más **residuo** (distancia vertical). MCO hace que los cuadrados de esos segmentos sumen lo mínimo posible.

lm() con broom: salida ordenada

```
tidy(modelo) %>% kable(digits = 3)
```

term	estimate	std.error	statistic	p.value
(Intercept)	-0.905	0.685	-1.321	0.187
educ	0.541	0.053	10.167	0.000

```
glance(modelo) %>%  
  select(r.squared, sigma, statistic, p.value, nobs) %>%  
  kable(digits = 3)
```

r.squared	sigma	statistic	p.value	nobs
0.165	3.378	103.363	0	526

`tidy()` devuelve la tabla de coeficientes como *data frame*; `glance()` resume el ajuste global. Ambos son preferibles a leer `summary()` a ojo: alimentan tablas y gráficos reproducibles.

Interpretación: los coeficientes tienen unidades

$$\widehat{wage} = -0.90 + 0.54 \cdot educ$$

- **Unidades de $\hat{\beta}_1$:** unidades de y por unidad de $x \rightarrow$ aquí, **USD/hora por año de educación**.
- Cada año adicional de educación se asocia con **+0.54 USD/hora**, un 9 % del salario medio (5.90 USD/hora).
- Cuatro años de universidad: $4 \times 0.54 = 2.17$ USD/hora, un 37 % del salario medio — **significancia económica**, no solo estadística.
- **Intercepto:** $\hat{\beta}_0 = -0.90$ sería el salario con $educ = 0$. Un salario negativo es absurdo: el intercepto ancla la recta, pero no siempre tiene lectura propia fuera del soporte de los datos.

! Para leer 0.54 como **efecto causal** de una reforma educativa se requiere $E[u \mid educ] = 0$: que la habilidad, el entorno familiar y la calidad escolar (todos en u) no se muevan con la educación. La sesión 3 ataca este problema con controles.

Formas funcionales: la misma herramienta, otra pregunta

Modelo	Especificación	Interpretación de β_1	Ejemplo típico
Nivel-nivel	$y = \beta_0 + \beta_1 x + u$	+1 unidad de x : y cambia β_1 unidades	Salario vs educación
Log-nivel	$\ln y = \beta_0 + \beta_1 x + u$	+1 unidad de x : y cambia $100\beta_1$ %	Retorno a la educación
Nivel-log	$y = \beta_0 + \beta_1 \ln x + u$	+1 % en x : y cambia $\beta_1/100$ unidades	Esperanza de vida vs PIB
Log-log	$\ln y = \beta_0 + \beta_1 \ln x + u$	+1 % en x : y cambia β_1 % (elasticidad)	Demanda vs precio




Los logs convierten efectos absolutos en relativos, comprimen colas derechas y estabilizan la varianza; solo aplican a variables estrictamente positivas. La forma se elige por **teoría y datos**, no por comodidad.


Log-nivel en acción: el retorno a la educación

```
modelo_log <- lm(lwage ~ educ,  
                 data = wage1)  
round(coef(modelo_log), 3)  
  
ggplot(wage1,  
       aes(x = educ, y = lwage)) +  
  geom_jitter(width = .2,  
             alpha = .35) +  
  geom_smooth(method = "lm")
```

- $\hat{\beta}_1 = 0.083$: cada año de educación se asocia con un salario **~8.3 % mayor**
- Es el “retorno a la educación”, pieza central del debate sobre gratuidad y becas
- En logs la dispersión es más pareja: adelanto de homocedasticidad



Elegir forma funcional con los datos: gapminder



En niveles la recta falla en ambos extremos (no linealidad evidente); con $\ln(x)$ la relación se endereza y el R^2 sube de 0.46 a 0.65. Lectura nivel-log: duplicar el PIB per cápita (+100 %) se asocia con ~5 años más de vida.



R^2 : descomposición de la varianza

$$SST = SSE + SSR$$

- $SST = \sum (y_i - \bar{y})^2$: variación **total**
- $SSE = \sum (\hat{y}_i - \bar{y})^2$: **explicada** por el modelo
- $SSR = \sum (y_i - \hat{y}_i)^2$: **residual**


$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST} \in [0, 1]$$

En regresión simple, $R^2 = r_{xy}^2$: el cuadrado de la correlación.



i Cuidado con la notación: aquí seguimos a Wooldridge (SSE = explicada, SSR = residual); otros textos invierten las siglas. Verifique siempre la definición antes de comparar fórmulas.

Anatomía de la descomposición: total, explicada, residual



La desviación total de cada punto respecto de $\bar{y}$ (línea punteada) se parte en el tramo que la recta **explica** y el residuo que queda. R^2 es la fracción de los cuadrados verdes sobre los morados.

R^2 : qué responde y qué no

Pregunta	¿La responde el R^2 ?
¿Qué fracción de la varianza de y explica x ?	Sí : exactamente eso
¿Es grande o importante el efecto $\hat{\beta}_1$?	No: magnitud y ajuste son cosas distintas
¿La relación es causal?	No: eso depende de $E[u \mid x] = 0$, no del ajuste
¿Qué tan precisa es una predicción individual?	Solo en parte: mirar $\hat{\sigma}$ y las bandas de predicción
¿Un R^2 bajo invalida el hallazgo?	No : $\hat{\beta}_1$ puede ser preciso y relevante igual

! En $\text{wage} \sim \text{educ}$, $R^2 = 0.165$: la educación “solo” explica el 16.5 % de la varianza salarial y, aun así, el retorno estimado es fuerte, preciso y central para la política educativa. En microdatos, los R^2 bajos son la norma, no una falla.

Error estándar de $\hat{\beta}_1$: la precisión del estimador


$$SE(\hat{\beta}_1) = \frac{\hat{\sigma}}{\sqrt{\sum_i (x_i - \bar{x})^2}}$$

$$\hat{\sigma}^2 = \frac{SSR}{n - 2}$$

La precisión **mejora** con:

- Menos ruido en y ($\hat{\sigma}$ pequeño)
- Más observaciones (n grande)
- Más varianza en x : sin variación en la palanca de política, no hay información sobre su efecto

40 rectas MCO, una por muestra



Prueba t del coeficiente e intervalo de confianza

$$H_0 : \beta_1 = 0 \quad \text{vs} \quad H_1 : \beta_1 \neq 0 \quad t = \frac{\hat{\beta}_1}{SE(\hat{\beta}_1)} \sim t_{n-2}$$

```
tidy(modelo, conf.int = TRUE) %>%  
  select(term, estimate, std.error, statistic, conf.low, conf.high) %>%  
  kable(digits = 3)
```

term	estimate	std.error	statistic	conf.low	conf.high
(Intercept)	-0.905	0.685	-1.321	-2.250	0.441
educ	0.541	0.053	10.167	0.437	0.646


- $t = 0.541/0.053 = 10.2 \gg 1.96$: rechazamos H_0 ($p < 0.001$) — el retorno no es ruido muestral.
- **IC 95 %:** [0.44, 0.65] USD/hora por año. Para costo-beneficio importa el rango completo, no solo el punto: con 0.44 la reforma puede dejar de ser rentable.
- El intercepto no es significativo ($t = -1.32$): no hay evidencia de salario base distinto de cero, coherente con su falta de sentido económico aquí.

Supuestos de Gauss-Markov (RLS1–RLS5)

#	Supuesto	Significado	¿Qué pasa si falla?
RLS1	Lineal en parámetros	$y = \beta_0 + \beta_1 x + u$	Cambiar forma funcional (logs)
RLS2	Muestreo aleatorio	Muestra i.i.d. de la población	Sesgo de selección
RLS3	Variación en x	$\text{Var}(x) > 0$	$\hat{\beta}_1$ no existe
RLS4	Media condicional cero	$E[u \mid x] = 0$	Sesgo: sin lectura causal
RLS5	Homocedasticidad	$\text{Var}(u \mid x) = \sigma^2$	SE clásicos inválidos $\rightarrow$ robustos

- **Teorema de Gauss-Markov:** bajo RLS1–RLS5, MCO es **BLUE** (mejor estimador lineal insesgado).
- RLS1–RLS4 bastan para el insesgamiento; la normalidad de u solo se usa para la t exacta con n pequeño.

Homocedasticidad vs heterocedasticidad



Ambos paneles comparten la misma recta poblacional: con heterocedasticidad el “abanico” no sesga $\hat{\beta}_1$, pero invalida los errores estándar clásicos. Es el caso típico de los ingresos: a mayor educación, salarios más dispersos.





La solución estándar: errores robustos (HC1)

```
modelsummary(list("SE clásicos" = modelo, "SE robustos (HC1)" = modelo),  
  vcov = c("classical", "HC1"), fmt = 3,  
  output = "markdown", gof_map = c("nobs", "r.squared"))
```

	SE clásicos	SE robustos (HC1)
(Intercept)	-0.905 (0.685)	-0.905 (0.725)
educ	0.541 (0.053)	0.541 (0.061)
Num.Obs.	526	526
R2	0.165	0.165

Los coeficientes no cambian — solo su precisión estimada: el SE de educ sube de 0.053 a 0.061 (+15 %). Aquí la conclusión se mantiene; en casos límite puede voltear la significancia. En la práctica profesional, reportar SE robustos es el estándar por defecto.


Diagnóstico gráfico: los cuatro paneles de `plot(modelo)`



- **Residuos vs ajustados:** debe verse ruido sin patrón; una U delata no linealidad (RLS1), un abanico delata heterocedasticidad (RLS5).
- **Q-Q plot:** puntos sobre la diagonal $\rightarrow$ residuos aproximadamente normales.
- **Scale-Location:** línea plana $\rightarrow$ varianza estable.
- **Residuos vs palanca:** detecta observaciones influyentes que “tiran” de la recta.


El cuarteto de Anscombe: por qué graficar siempre

Cuatro conjuntos, una misma recta MCO: $y = 3 + 0.5x$



Medias, varianzas, correlación, recta y R^2 : **idénticos**. Pero solo el Conjunto 1 justifica una regresión lineal; el 2 es curvo, y el 3 y el 4 dependen de un único punto. La tabla de coeficientes jamás sustituye al gráfico.

Bandas de confianza vs bandas de predicción



La banda de **confianza** cubre la media condicional $E[y | x]$; la de **predicción** agrega la varianza individual $\hat{\sigma}^2$ y es mucho más ancha. Ambas se ensanchan lejos de $\bar{x}$, donde hay menos información.


Predicción con intervalos en predict()

```
nuevos <- tibble(educ = c(8, 12, 16))
bind_cols(
  nuevos,
  as_tibble(predict(modelo, nuevos, interval = "confidence")) %>%
    rename(ajuste = fit, conf_inf = lwr, conf_sup = upr),
  as_tibble(predict(modelo, nuevos, interval = "prediction")) %>%
    select(lwr, upr) %>% rename(pred_inf = lwr, pred_sup = upr)
) %>% kable(digits = 2)
```

educ	ajuste	conf_inf	conf_sup	pred_inf	pred_sup
8	3.43	2.87	3.98	-3.23	10.09
12	5.59	5.30	5.89	-1.05	12.23
16	7.76	7.30	8.22	1.10	14.41

- La media salarial con 12 años se estima con precisión ([5.30, 5.89]); el salario de **un** trabajador con 12 años, no ([-1.05, 12.23]).
- El límite inferior negativo delata al modelo en niveles: motivo adicional para trabajar con lwage.

Extrapolación: el modelo solo sabe lo que vio



Dentro del rango observado la recta aproxima bien; fuera, promete impactos crecientes donde la relación real ya se agotó (rendimientos decrecientes). Escalar un programa piloto es, casi siempre, una extrapolación.

Correlación, regresión y causalidad: tres niveles

Herramienta	Qué entrega	Qué exige	Qué NO garantiza
Correlación r	Fuerza y signo de la asociación lineal; simétrica y sin unidades	Dos variables cuantitativas	Dirección del efecto ni causalidad
Regresión MCO	Recta con unidades: predicción y efecto marginal condicional	Elegir y y x , forma funcional, supuestos RLS1–RLS5	Causalidad sin exogeneidad ($E[u x] = 0$)
Inferencia causal	Efecto de intervenir sobre x	Diseño: experimentos, IV, diferencias en diferencias, RD	—

⚠ En regresión simple, $R^2 = r^2$ ($0.406^2 = 0.165$ en $\text{wage} \sim \text{educ}$): la regresión no agrega “causalidad” a la correlación — agrega unidades, predicción y un marco de supuestos que hay que defender. Subir de nivel requiere **diseño**, no más decimales.

Síntesis: qué debe salir en su análisis

Checklist de la regresión simple

- 1 Graficar antes de estimar (Anscombe)
- 2 Estimar con `lm()` y leer $\hat{\beta}_1$ **en sus unidades**
- 3 Elegir forma funcional según la pregunta (% vs unidades)
- 4 Reportar R^2 sin sobreinterpretarlo: ajuste causalidad relevancia
- 5 Inferencia con SE robustos; IC junto al punto estimado
- 6 Diagnóstico de residuos: linealidad y varianza
- 7 Predicción con bandas y dentro del rango observado
- 8 Lectura causal solo si $E[u \mid x] = 0$ es defendible

Funciones R de esta sesión

`lm()` `coef()` `fitted()` `residuals()`
`confint()` `predict()` `broom::tidy()`
`broom::glance()` `modelsummary()`
`coeftest()` `vcovHC()` `geom_smooth(method = "lm")`

Próxima sesión: regresión múltiple — controlar por confusores y el sesgo de variable omitida, la puerta de entrada a la lectura causal.

Ejercicio para practicar (30 min)

Con wage1 de wooldridge:

- 1 Estime `wage ~ exper` e interprete $\hat{\beta}_1$ con sus unidades. ¿Es plausible como efecto causal de la experiencia?
- 2 Estime `lwage ~ exper`. ¿En qué porcentaje se asocia cada año de experiencia con el salario?
- 3 Compare los R^2 de ambos modelos con `glance()`. ¿Invalida un R^2 bajo la relación? Justifique.
- 4 Construya el IC 95 % de $\hat{\beta}_1$ con `confint()` y con SE robustos (`coeftest(m, vcov = vcovHC(m, "HC1"))`). ¿Cambia alguna conclusión?
- 5 Grafique la relación con `geom_smooth(method = "lm")` y examine los residuos: ¿hay señales de no linealidad? Pruebe agregar $I(exper^2)$ como adelanto de la sesión 3.

i Referencias: Wooldridge, *Introductory Econometrics* (caps. 2 y 8) · Stock & Watson, *Introduction to Econometrics* (caps. 4–5) · Angrist & Pischke, *Mostly Harmless Econometrics* (cap. 3).