

Sesión 3 · Regresión Lineal Múltiple

Nivelación Econometría — Doctorado en Políticas Públicas

Amaru Agüero Jiménez (a.agueroj@udd.cl)

marzo de 2026

Panorama de la sesión

Bloque	Concepto clave	Herramienta en R
Del simple al múltiple	efecto parcial, <i>ceteris paribus</i>	<code>lm(y ~ x1 + x2)</code>
Sesgo de variable omitida	fórmula y dirección del sesgo	simulación, modelos anidados
Estructuras causales	confusora, collider, mediadora	DAGs
Dummies e interacciones	categoría de referencia, efecto heterogéneo	<code>factor()</code> , <code>x1 * x2</code>
Inferencia conjunta	R^2 ajustado, prueba F	<code>anova()</code> , <code>glance()</code>
Diagnósticos	VIF, residuos, heterocedasticidad	<code>vif()</code> , <code>bptest()</code> , <code>vcovHC()</code>

i Datos de trabajo: microdatos simulados de mercado laboral ($n = 200$): educación, experiencia, género e ingreso. Como el modelo generador es conocido, podremos comparar cada especificación contra el **efecto verdadero** — el lujo que nunca tenemos con datos reales.

Del modelo simple al múltiple

Regresión simple: todo lo que no es X queda escondido en el error

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

Regresión múltiple: los controles salen del error y entran al modelo

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon, \quad \hat{\beta} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}$$

- β_j es el **efecto parcial** de X_j sobre Y , manteniendo constantes los demás regresores (*ceteris paribus*): comparar **comparables**.
- Requisitos: $(\mathbf{X}^\top \mathbf{X})$ invertible (sin colinealidad perfecta) y **exogeneidad**, $E[\varepsilon \mid \mathbf{X}] = 0$.
- En evaluación de políticas, la pregunta nunca es “¿qué variables suben el R^2 ?” sino “¿qué controles necesito para aislar el efecto causal?”.

Datos de trabajo: un mercado laboral simulado


Modelo generador (la “verdad” que intentaremos recuperar):

$$\log(\text{Ingreso}) = 9 + 0.15 \text{ Educ} + 0.08 \text{ Exper} + 0.25 \text{ Mujer} - 0.04 (\text{Educ} \times \text{Mujer}) + \varepsilon$$

educacion	experiencia	genero	log_ingreso	ingreso
17.1	0.0	Mujer	11.4	93075
11.3	18.3	Mujer	12.2	205891
14.1	26.7	Hombre	13.2	567917
14.9	35.6	Mujer	13.8	962490

- Retorno verdadero a la educación: **15 % por año** para hombres y **11 %** para mujeres (hay interacción).
- La experiencia suma un 8 % por año; el error tiene DE 0.3 (heterogeneidad no observada).

Sesgo de variable omitida: la anatomía del problema



Modelo verdadero: $Y = \beta_0 + \beta_1 X + \beta_2 Z + \varepsilon$

Modelo corto (omite Z): $Y = \beta_0 + \beta_1 X + u$

Hay sesgo **solo si se cumplen ambas:**

- 1 Z afecta a Y : $\beta_2 \neq 0$
- 2 Z se correlaciona con X : $\text{Cov}(X, Z) \neq 0$

$$\text{Sesgo}(\hat{\beta}_1) = \beta_2 \cdot \frac{\text{Cov}(X, Z)}{\text{Var}(X)}$$

El estimador queda **sesgado e inconsistente**: más datos no arreglan el problema.

¿Hacia dónde apunta el sesgo?

La fórmula del sesgo permite **firmar** el error antes de tener los datos:

Efecto de Z sobre Y	$\text{Cov}(X, Z) > 0$	$\text{Cov}(X, Z) < 0$
$\beta_2 > 0$	Sesgo positivo : sobreestima	Sesgo negativo : subestima
$\beta_2 < 0$	Sesgo negativo : subestima	Sesgo positivo : sobreestima

! **Ejemplo clásico:** retorno a la educación omitiendo *habilidad*. La habilidad aumenta el salario ($\beta_2 > 0$) y se correlaciona positivamente con los años de estudio ($\text{Cov} > 0$) $\Rightarrow$ el modelo corto **exagera** el retorno a la educación. Antes de estimar, ya sabemos en qué dirección desconfiar.

Simulación: el modelo corto exagera el retorno


```
set.seed(123); n_s <- 300
sim <- tibble(
  habilidad = rnorm(n_s),
  educ = 12 + 1.5 * habilidad + rnorm(n_s, 0, 1.5),
  log_sal = 8 + 0.08 * educ + 0.35 * habilidad + rnorm(n_s, 0, 0.25))
corto <- lm(log_sal ~ educ, data = sim)
largo <- lm(log_sal ~ educ + habilidad, data = sim)
```

Modelo	Coef. educación
Verdadero (DGP)	0.080
Corto: omite habilidad	0.183
Largo: controla habilidad	0.073

El sesgo observado ($0.183 - 0.073 = 0.110$) coincide con la fórmula:
 $0.35 \times \text{Cov}(\text{educ}, \text{hab}) / \text{Var}(\text{educ}) \approx 0.111$.


La confusora a la vista: dos rectas, dos historias

```
b <- coef(largo)
ggplot(sim,
  aes(educ, log_sal)) +
  geom_point(aes(color = habilidad),
    alpha = .8) +
  geom_smooth(method = "lm",
    se = FALSE,
    color = rojo) +
  geom_abline(intercept = b[1],
    slope = b[2],
    color = verde,
    linewidth = 1.1) +
  scale_color_gradient(
    low = "#F9E79F", high = azul)
```



Recta **roja**: modelo corto (pendiente 0.18).
Recta **verde**: modelo largo, a habilidad media
(pendiente 0.07). La educación “hereda” el
efecto de la habilidad omitida.

Tres estructuras causales: el DAG decide



La misma variable Z exige acciones **opuestas** según su rol causal: el diagrama, no la correlación, dicta la especificación.

Confusora: controlar, siempre

Estructura: $X \leftarrow Z \rightarrow Y$

Cómo reconocerla:

- Z está asociada con X (la exposición)
- Z afecta a Y por un canal propio
- Z **no** es consecuencia de X (ocurre “antes”)

Acción: incluir Z en el modelo. Controlar **cierra** el camino espurio $X \leftarrow Z \rightarrow Y$.



Política pública: ¿la educación (X) aumenta el ingreso (Y)? El nivel socioeconómico familiar (Z) financia más años de estudio **y** abre redes laborales. Sin controlar por Z , atribuimos a la escuela lo que hace la cuna.



Lo mismo con un **programa de empleo**: si los municipios más pobres reciben más cobertura, la pobreza comunal confunde el efecto del programa sobre la empleabilidad.


Collider: controlar introduce sesgo

Estructura: $X \rightarrow Z \leftarrow Y$

- Z es **consecuencia común** de X y de Y
- Sin controlar: no hay sesgo
- Condicionar en Z **abre** un camino espurio (paradoja de Berkson)

Ejemplo: una beca se asigna por mérito académico o por vulnerabilidad. Entre los becados, mérito y vulnerabilidad se correlacionan **negativamente** aunque en la población sean independientes.

Analizar solo becados inventa una correlación



Mediadora: depende de la pregunta

Estructura: $X \rightarrow Z \rightarrow Y$ — la variable Z es parte del **mecanismo** por el que X actúa.

- **Efecto total** de X (lo que suele importar para decidir la política): **no** controlar por Z .
- **Efecto directo** (¿queda efecto fuera del mecanismo?): controlar por Z , sabiendo que se descuenta el canal mediado.

⚠ **Política pública:** capacitación laboral (X) $\rightarrow$ empleo formal (Z) $\rightarrow$ ingreso (Y). Si evaluamos la capacitación “controlando por empleo”, borramos justamente el canal por el que el programa funciona y concluimos, erróneamente, que “no tiene efecto”.

La **modificadora de efecto** es distinta: no está en el camino causal, pero cambia la magnitud del efecto de X — se modela con una **interacción** (lo veremos en unas slides).

¿Controlar o no controlar? Hoja de ruta

Rol de Z	Estructura	¿Controlar?	Costo de equivocarse
Confusora	$X \leftarrow Z \rightarrow Y$	Sí, siempre	Omitirla $\Rightarrow$ OVB
Collider	$X \rightarrow Z \leftarrow Y$	No, nunca	Controlar abre camino espurio
Mediadora	$X \rightarrow Z \rightarrow Y$	Total: no · Directo: sí	Controlar absorbe el efecto
Modificadora	Z altera el efecto $X \rightarrow Y$	Interacción $X \times Z$	Sin ella, solo efecto promedio


! Criterio práctico: **dibujar el DAG antes de escribir `lm()`**. No todo lo que correlaciona con X e Y es un control válido — la lista de covariables es una decisión causal, no estadística.

Variables dummy: categorías en la regresión

$$\text{Mujer}_i = \begin{cases} 1 & \text{si mujer} \\ 0 & \text{si hombre} \end{cases}$$

$$Y = \beta_0 + \beta_1 \text{Educ} + \beta_2 \text{Mujer} + \varepsilon$$

- β_0 : intercepto de la **categoría de referencia** (hombres)
- β_2 : brecha promedio mujer–hombre, a igual educación
- Con C categorías se crean $C - 1$ dummies; la omitida es la base (`relevel()` la cambia)



Dummy en R: brecha de género condicional

```
m3 <- lm(log_ingreso ~ educacion + experiencia + mujer, data = datos)
tidy(m3) %>% kable(digits = 3)
```

term	estimate	std.error	statistic	p.value
(Intercept)	9.167	0.120	76.506	0
educacion	0.134	0.008	16.562	0
experiencia	0.081	0.002	33.104	0
mujer	-0.256	0.045	-5.700	0

- La dummy desplaza el **intercepto**: dos rectas paralelas, separadas por $\hat{\beta}_{\text{mujer}} = -0.256$.
- En un modelo log-lineal: las mujeres ganan $e^{-0.256} - 1 \approx -23\%$ **a igual educación y experiencia**.
- Ojo: es la brecha **promedio**; el DGP tiene interacción, así que la brecha real varía con la educación.


Interacciones: el efecto marginal deja de ser constante

$$Y = \beta_0 + \beta_1 \text{Educ} + \beta_2 \text{Mujer} + \beta_3 (\text{Educ} \times \text{Mujer}) + \varepsilon$$

El efecto de la educación ahora **depende** del género:

$$\frac{\partial Y}{\partial \text{Educ}} = \beta_1 + \beta_3 \cdot \text{Mujer}$$

- β_1 : retorno para **hombres** (base)
- $\beta_1 + \beta_3$: retorno para **mujeres**
- β_2 : brecha de intercepto cuando $\text{Educ} = 0$
(extrapolación: interpretar con cautela)



Interacción en R: retornos distintos por género


```
m4 <- lm(log_ingreso ~ educacion * mujer + experiencia, data = datos)
tidy(m4) %>% kable(digits = 3)
```

term	estimate	std.error	statistic	p.value
(Intercept)	8.846	0.151	58.549	0.000
educacion	0.159	0.011	14.729	0.000
mujer	0.429	0.210	2.047	0.042
experiencia	0.081	0.002	33.903	0.000
educacion:mujer	-0.053	0.016	-3.344	0.001

- Retorno hombres: **15.9 %** por año; retorno mujeres: $0.159 - 0.053 = \mathbf{10.6 \%}$ (DGP: 15 % y 11 %).
- $\hat{\beta}_3 = -0.053$ con $p = 0.001$: el género es una **modificadora de efecto** del retorno educativo.
- Implicancia de política: un subsidio educativo uniforme genera ganancias **heterogéneas** por grupo.

Rectas paralelas (dummy) vs pendientes distintas (interacción)

```
grid <- expand_grid(
  educacion = seq(8, 20, .5),
  mujer = c(0, 1),
  experiencia = 15)
pred <- bind_rows(
  mutate(grid,
    m = "Solo dummy",
    y = predict(m3, grid)),
  mutate(grid,
    m = "Con interacción",
    y = predict(m4, grid)))
ggplot(pred,
  aes(educacion, y,
    color = factor(mujer))) +
  geom_line(linewidth = 1.1) +
  facet_wrap(~ m)
```



R^2 ajustado: pagar por cada parámetro

$$R^2_{aj} = 1 - (1 - R^2) \frac{n - 1}{n - k - 1}$$

```
m1 <- lm(log_ingreso ~ educacion, data = datos)
m2 <- lm(log_ingreso ~ educacion + experiencia, data = datos)
list(M1 = m1, M2 = m2, M3 = m3, M4 = m4) %>%
  map_dfr(glance, .id = "Modelo") %>%
  select(Modelo, r.squared, adj.r.squared, AIC) %>% kable(digits = 3)
```

Modelo	r.squared	adj.r.squared	AIC
M1	0.138	0.134	494.225
M2	0.854	0.853	141.100
M3	0.875	0.873	112.423
M4	0.882	0.879	103.271

- El R^2 **nunca baja** al agregar regresores: no sirve para elegir entre especificaciones.
- El ajustado (y AIC/BIC) penaliza parámetros: premia el ajuste **parsimonioso**.
- Un R^2 alto no valida el modelo causal: un collider también “sube el R^2 ”.

Prueba F: significancia conjunta

$$H_0 : \beta_{q_1} = \dots = \beta_{q_m} = 0 \quad F = \frac{(R_{nr}^2 - R_r^2)/q}{(1 - R_{nr}^2)/(n - k - 1)} \sim F_{q, n-k-1}$$

```
anova(m3, m4) %>% tidy() %>%  
  mutate(Modelo = c("M3 (restringido)", "M4 (+ interacción)")) %>%  
  select(Modelo, df.residual, rss, statistic, p.value) %>% kable(digits = 3)
```

Modelo	df.residual	rss	statistic	p.value
M3 (restringido)	196	19.542		
M4 (+ interacción)	195	18.482	11.182	0.001

- `anova(m3, m4)` contrasta modelos **anidados**: ¿aportan las variables extra en conjunto?
- Aquí $F = 11.2$, $p = 0.001$: la interacción educación $\times$ género mejora el modelo.
- Uso típico: bloques de dummies (regiones, cohortes) donde ningún coeficiente individual “brilla” pero el bloque sí importa.

Modelos anidados: la tabla que delata el OVB

Modelos Anidados: Detectando Sesgo por Variable Omitida

	Modelo 1 (Simple)	Modelo 2 (+ Control)	Modelo 3 (+ Dummy)	Modelo 4 (Completo)
Educacion	5.200***	3.800***	3.650***	4.100***
Experiencia	---	0.950***	0.920***	0.890***
Mujer	---	---	-2.100**	-4.500*
Educ x Mujer	---	---	---	0.350*
R2	0.32	0.48	0.51	0.53
R2 ajust.	0.31	0.47	0.50	0.52
N	500	500	500	500

Educacion cambia de 5.2 a 3.8 al agregar Experiencia = evidencia de OVB

*** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$

Señal de OVB: el coeficiente de interés **cambia sustancialmente** (regla práctica: más de 20 %) al sumar un control con sentido teórico. Estabilidad del coeficiente = especificación robusta.

Estabilidad del coeficiente de educación

```
coefs <- list(M1 = m1, M2 = m2,
             M3 = m3, M4 = m4) %>%
  map_dfr(
    ~ tidy(.x, conf.int = TRUE),
    .id = "modelo") %>%
  filter(term == "educacion")
ggplot(coefs,
       aes(modelo, estimate)) +
  geom_pointrange(
    aes(ymin = conf.low,
        ymax = conf.high),
    color = azul) +
  geom_hline(yintercept = 0.15,
             linetype = "dashed",
             color = rojo)
```

La línea roja es el retorno verdadero del grupo base (0.15). En M4 el coeficiente es el retorno de **hombres**; en M1–M3, un promedio.




Tabla profesional de modelos con modelsummary

	M1	M3	M4
Educación	0.119*** (0.021)	0.134*** (0.008)	0.159*** (0.011)
Experiencia		0.081*** (0.002)	0.081*** (0.002)
Mujer		-0.256*** (0.045)	0.429* (0.210)
Educación × Mujer			-0.053*** (0.016)
Num.Obs.	200	200	200
R2	0.138	0.875	0.882
R2 Adj.	0.134	0.873	0.879
● $p < 0.1$, * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$			

Código: `modelsummary(list(m1, m3, m4), stars = TRUE)`.

Multicolinealidad: síntoma y medición (VIF)

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{(1 - R_j^2) \sum_i (X_{ij} - \bar{X}_j)^2} \quad \text{VIF}_j = \frac{1}{1 - R_j^2}$$

```
vif(m3)
```

educacion	experiencia	mujer
1.008789	1.007769	1.006812


```
set.seed(99)
datos2 <- datos %>% mutate(edad = 6 + educacion + experiencia + rnorm(n, 0, 2))
vif(lm(log_ingreso ~ educacion + experiencia + edad + mujer, data = datos2))
```

educacion	experiencia	edad	mujer
3.011473	22.230616	23.359288	1.007582

Agregar edad (que es casi 6 + educ + exper) dispara el VIF de experiencia y edad por sobre 20: la misma información entra dos veces y los EE explotan.

VIF: qué hacer y qué no hacer

Diagnostico de Multicolinealidad




Qué hacer ($VIF > 10$ en un control):

- Eliminar redundancias **por teoría** (edad vs experiencia miden lo mismo)
- Combinar variables en índices
- Aceptarla si solo afecta controles, no la variable de interés

Qué NO hacer:


- Botar la **variable de interés** o una confusora clave por su VIF
- Tratarla como sesgo: la multicolinealidad **no sesga**, solo reduce precisión
- “Resolverla” con selección automática por p-valores

Diagnóstico de residuos: los tres gráficos de rigor



1: media cero y sin patrón $\Rightarrow$ forma funcional correcta. **2:** puntos sobre la diagonal $\Rightarrow$ normalidad. **3:** banda horizontal $\Rightarrow$ varianza constante. En R base: `plot(m3)`.

Heterocedasticidad: el abanico en los residuos



Con $\text{Var}(\varepsilon_i)$ creciente, MCO sigue siendo **insesgado**, pero los EE clásicos son inválidos: los t y los IC mienten. Típico en ingresos, gasto municipal, matrícula.

Breusch-Pagan y errores estándar robustos

```
m_niv <- lm(ingreso_miles ~ educacion + experiencia + mujer, data = datos)
bptest(m_niv)
```

studentized Breusch-Pagan test

data: m_niv

BP = 30.235, df = 3, p-value = 1.232e-06

Término	Estimación	EE clásico	EE robusto (HC1)
educacion	42.8	4.8	6.3
experiencia	24.9	1.5	2.5
mujer	-88.9	26.8	23.5

- BP rechaza H_0 ($p < 0.001$): inferir con `coeftest(m_niv, vcov = vcovHC(m_niv, "HC1"))` — cambia el EE, no $\hat{\beta}$.
- Alternativa aquí: modelar $\log(\text{ingreso})$ — el BP sobre m3 ya no rechaza ($p = 0.81$).

Qué NO hacer en regresión múltiple

Práctica	Por qué falla	Alternativa
Controlar por colliders o mediadores	Introduce sesgo / borra el efecto	DAG antes de $\text{lm}()$
<i>Kitchen sink</i> : meter todo lo disponible	Colliders, VIF alto, sobreajuste	Controles justificados causalmente
Elegir variables por las estrellitas	p-hacking; invalida la inferencia	Especificación por teoría + robustez
Perseguir el R^2 máximo	R^2 no mide causalidad	Pregunta causal y diseño
Ignorar la heterocedasticidad	EE y p-valores inválidos	EE robustos, logs



Una regresión con 30 controles no es “más rigurosa”: cada control es una **afirmación causal** que hay que poder defender.

Síntesis: checklist del análisis de regresión múltiple

Antes y después de `lm()`

- 1 Dibujar el DAG: confusoras sí, colliders no, mediadoras según la pregunta
- 2 Firmar el sesgo esperado con la fórmula del OVB
- 3 Reportar modelos anidados y la estabilidad del coeficiente de interés
- 4 Dummies con categoría de referencia explícita; interacciones para heterogeneidad
- 5 F para bloques; R^2 ajustado / AIC para parsimonia
- 6 VIF, residuos y Breusch-Pagan; EE robustos si corresponde

Funciones R de esta sesión

`lm()` `tidy()` `glance()` `predict()` `anova()`
`relevel()` `car::vif()` `lmtest::bptest()`
`lmtest::coeftest()` `sandwich::vcovHC()`
`modelsummary()`

Próxima sesión: práctica integradora en R con datos reales.

Ejercicio para practicar (30 min)

Con `data("wage1", package = "wooldridge")` (526 trabajadores, EE.UU.):

- 1 Estime los modelos anidados: `M1 lwage ~ educ`; `M2 + exper + tenure`; `M3 + female`; `M4 lwage ~ educ * female + exper + tenure`.
- 2 ¿Cambia el retorno a la educación más de 20 % entre M1 y M2? ¿Qué confusora explica el cambio y cuál es la dirección del sesgo según la fórmula?
- 3 Contraste M3 vs M4 con `anova()`. Si la interacción es significativa, ¿qué rol causal juega `female`?
- 4 Calcule `vif()` en M3 y aplique `bptest()`. Si hay heterocedasticidad, reestime los EE con `vcovHC()` y compare la inferencia.
- 5 Presente M1–M4 con `modelsummary()`: ¿cuál especificación defendería ante un comité de política pública y por qué?

i Referencias: Wooldridge, *Introductory Econometrics* (caps. 3–8) · Angrist & Pischke, *Mostly Harmless Econometrics* (cap. 3) · Cunningham, *Causal Inference: The Mixtape* (DAGs) · Huntington-Klein, *The Effect*.