# Regresión Lineal Múltiple

## Sesión 3 — Econometría

Amaru Agüero

Doctorado en Ciencias de la Complejidad Social — CICS, UDD

25 de marzo de 2026

Universidad del Desarrollo
Facultad de Gobierno

# Agenda

1. De regresión simple a múltiple
2. Sesgo de variable omitida (OVB)
3. **Estructuras causales: confusora, collider, modificadora**
4. **Modelos anidados e identificación de sesgos**
5. Variables de control: cuándo y cuáles
6. Variables categóricas (dummy variables)
7. Términos de interacción
8. Pruebas de significancia (individual y conjunta)
9. Multicolinealidad
10. Implementación en R

# De la Regresión Simple a la Múltiple

**Regresión Simple:**

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

**Regresión Múltiple:**

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + \varepsilon$$

- **Interpretación:** $\beta_j$ es el efecto parcial de $X_j$ en $Y$, manteniendo otros regresores constantes (*ceteris paribus*)
- **Ventaja:** Controlar por variables confundidoras
- **Supuesto clave:** Exogeneidad — los regresores son independientes del error

# Estimación por Mínimos Cuadrados Ordinarios

Minimizamos la suma de residuos al cuadrado:

$$\min_{\boldsymbol{\beta}} \sum_{i=1}^{n} (Y_i - \beta_0 - \beta_1 X_{i1} - \cdots - \beta_k X_{ik})^2$$

**Solución matricial:**

$$\hat{\boldsymbol{\beta}} = (\mathrm{X}^T \mathrm{X})^{-1} \mathrm{X}^T \mathrm{Y}$$

- X es la matriz de regresores $(n \times (k+1))$
- Y es el vector de observaciones dependientes
- Supuesto: $(\mathrm{X}^T \mathrm{X})$ debe ser invertible (no multicolinealidad perfecta)

# Sesgo de Variable Omitida (OVB)

**Problema:** ¿Qué pasa si omitimos una variable relevante?

**Modelo verdadero:** $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$
**Modelo estimado (omitiendo $X_2$):** $Y = \beta_0 + \beta_1 X_1 + u$

**Sesgo de variable omitida ocurre si:**

1. La variable omitida $X_2$ afecta a $Y$ ($\beta_2 \neq 0$), **Y**
2. La variable omitida $X_2$ está correlacionada con $X_1$ ($\text{Cov}(X_1, X_2) \neq 0$)

**Magnitud del sesgo:**

$$\text{Sesgo}(\hat{\beta}_1) = \beta_2 \cdot \frac{\text{Cov}(X_1, X_2)}{\text{Var}(X_1)}$$

**Resultado**: $\hat{\beta}_1$ es sesgado e inconsistente.

# Sesgo de Variable Omitida — Ejemplo Visual

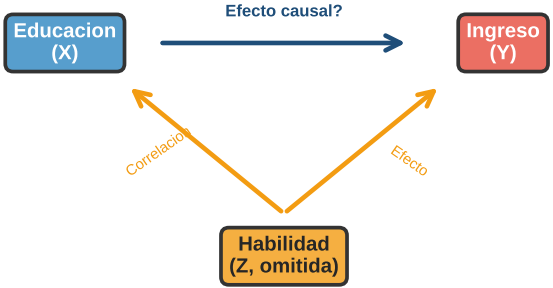


*Omitir Z sesga la estimacion de X -> Y*

# Estructuras Causales: Tres Tipos de Variables

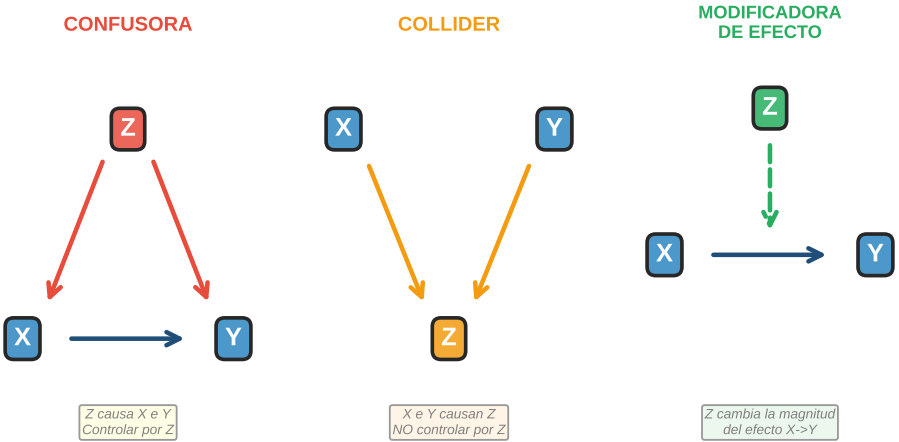


Cada estructura requiere una estrategia diferente de control.

# Variable Confusora (Confounder)

## Definición

Variable $Z$ que **causa tanto** a $X$ como a $Y$, generando asociación espuria.

**Estructura causal:** $X \leftarrow Z \rightarrow Y$

**Cómo identificarla:**

- $Z$ está asociada con $X$ (exposición)
- $Z$ afecta a $Y$ (resultado), independientemente de $X$
- $Z$ **no es** consecuencia de $X$ (no está en el camino causal)

**Acción:** **Controlar por** $Z$ (incluirla en el modelo)

## Ejemplo

Efecto de educación ($X$) en ingreso ($Y$), con nivel socioeconómico familiar ($Z$) como confusora: familias ricas dan más educación y más oportunidades laborales.

# Variable Collider (Colisionador)

## Definición

Variable $Z$ **causada por** $X$ *y* por $Y$. Controlar por ella **introduce sesgo**.

**Estructura causal:** $X \rightarrow Z \leftarrow Y$

**Cómo identificarla:**

- $Z$ es **consecuencia** de $X$ y de $Y$ (o de sus causas)
- $X$ e $Y$ no están conectados excepto a través de $Z$
- Condicionar en $Z$ *abre* un camino espurio entre $X$ e $Y$

**Acción:** **NO controlar por $Z$**

## Ejemplo

Talento ($X$) y belleza ($Y$) son independientes, pero ambos causan fama ($Z$). Si analizamos *solo famosos*, aparece correlación negativa espuria ("paradoja de Berkson").

# Modificadora de Efecto (Effect Modifier)

## Definición

Variable $Z$ que **cambia la magnitud o dirección** del efecto de $X$ sobre $Y$.

**Estructura:** $Z$ modifica la relación $X \to Y$ (no confunde)

**Cómo identificarla:**

- El efecto de $X$ en $Y$ cambia según el valor de $Z$
- Se detecta con un **término de interacción** ($X \times Z$) significativo
- Estratificar por $Z$ muestra pendientes diferentes

**Acción:** **Incluir interacción** $X \times Z$ en el modelo

## Ejemplo

El retorno a la educación ($X$) en salario ($Y$) difiere por género ($Z$): incluir Educ $\times$ Mujer para capturar esta heterogeneidad.

# Resumen: ¿Controlar o No Controlar?

| | **Confusora** | **Collider** | **Modificadora** |
|---|---|---|---|
| **DAG** | $X \leftarrow Z \rightarrow Y$ | $X \rightarrow Z \leftarrow Y$ | $Z$ modifica $X \rightarrow Y$ |
| **Si NO controlas** | Sesgo | Sin sesgo | Efecto promedio |
| **Si controlas** | Sin sesgo | Introduce sesgo | Efectos por grupo |
| **Acción correcta** | Controlar | No controlar | Interacción |

**Criterio práctico para decidir:**

1. Dibujar el DAG (diagrama causal) del problema
2. Identificar si $Z$ es causa común, consecuencia común, o modificador
3. Aplicar la regla correspondiente

*"No todo lo que correlaciona con $X$ e $Y$ debe ser un control."*

# Modelos Anidados: Detectando OVB

## Modelos Anidados: Detectando Sesgo por Variable Omitida

| | Modelo 1 (Simple) | Modelo 2 (+ Control) | Modelo 3 (+ Dummy) | Modelo 4 (Completo) |
|---|---|---|---|---|
| **Educacion** | 5.200*** | 3.800*** | 3.650*** | 4.100*** |
| **Experiencia** | --- | 0.950*** | 0.920*** | 0.890*** |
| **Mujer** | --- | --- | -2.100** | -4.500* |
| **Educ x Mujer** | --- | --- | --- | 0.350* |
| **R2** | 0.32 | 0.48 | 0.51 | 0.53 |
| **R2 ajust.** | 0.31 | 0.47 | 0.50 | 0.52 |
| **N** | 500 | 500 | 500 | 500 |

*Educacion cambia de 5.2 a 3.8 al agregar Experiencia = evidencia de OVB*
**** p<0.001, ** p<0.01, * p<0.05*

# Identificación de Sesgos con Modelos Anidados

## Método

Estimar modelos progresivamente más completos y observar cómo cambian los coeficientes de interés.

**Señales de OVB:**

- El coeficiente de interés **cambia sustancialmente** (>20%) al agregar controles
- El $R^2$ aumenta considerablemente con la nueva variable
- La nueva variable es significativa y tiene sentido teórico

**Señales de que NO hay OVB:**

- El coeficiente se mantiene estable al agregar controles
- Los controles son significativos pero no alteran el efecto principal

**Herramienta formal: Test de Hausman**

$$H = (\hat{\beta}_{\text{restringido}} - \hat{\beta}_{\text{completo}})^T [\text{Var}(\hat{\beta}_r) - \text{Var}(\hat{\beta}_c)]^{-1} (\hat{\beta}_r - \hat{\beta}_c) \sim \chi^2_q$$

# Modelos Anidados en R

```r
# Modelo 1: Solo variable de interes
m1 <- lm(ingreso ~ educacion, data = datos)

# Modelo 2: Agregar control (experiencia)
m2 <- lm(ingreso ~ educacion + experiencia, data = datos)

# Modelo 3: Agregar dummy (genero)
m3 <- lm(ingreso ~ educacion + experiencia + mujer, data = datos)

# Modelo 4: Agregar interaccion
m4 <- lm(ingreso ~ educacion * mujer + experiencia, data = datos)

# Comparar coeficientes lado a lado
library(stargazer)
stargazer(m1, m2, m3, m4, type = "text",
          column.labels = c("Simple","+ Control","+ Dummy","Completo"))

# Test F para comparar modelos anidados
anova(m1, m2)  # Test: es experiencia significativa?
anova(m3, m4)  # Test: es la interaccion significativa?
```

# Variables de Control: Cuándo y Cuáles Incluir

**¿Cuándo incluir una variable como control?**

- Es una **confusora**: afecta a $Y$ y está correlacionada con $X$
- NO es un **collider**: no es consecuencia de $X$ e $Y$
- NO es un **mediador**: no está en el camino causal $X \to Z \to Y$

**¿Cuáles NO incluir?**

- Colliders: introducen sesgo (Berkson)
- Mediadores: absorben parte del efecto causal
- Variables post-tratamiento (consecuencias de $X$)

**Criterio práctico:**

- Dibujar el DAG antes de estimar
- Incluir variables demográficas clásicas (edad, género, educación)
- Reportar resultados con y sin controles (modelos anidados)

# Variables Categóricas: Dummy Variables

**Problema:** Cómo incluir variables cualitativas (género, región, estado)

**Solución:** Convertir en variables binarias (0/1)

**Ejemplo:** Género

$$\text{Mujer} = \begin{cases} 1 & \text{si es mujer} \\ 0 & \text{si es hombre (categoría de referencia)} \end{cases}$$

**Modelo:**

$$\text{Salario} = \beta_0 + \beta_1 \text{Mujer} + \beta_2 \text{Educación} + \varepsilon$$

**Interpretación:**

- $\beta_0$: salario promedio para hombres (categoría de referencia)
- $\beta_1$: diferencia promedio de salario entre mujeres y hombres
- **Regla:** Para $C$ categorías, crear $C - 1$ variables dummy

# Variables Dummy: Ejemplo Visual

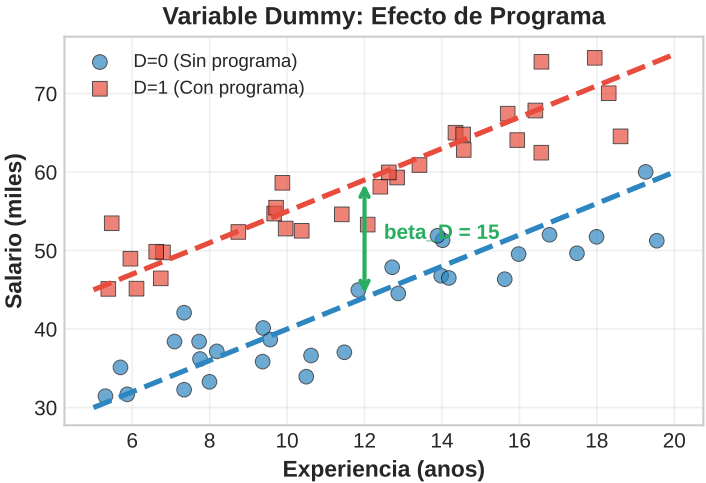

# Términos de Interacción

**Motivación:** Efecto heterogéneo — El retorno a la educación ¿difiere por género?

**Modelo:**

$$\text{Salario} = \beta_0 + \beta_1 \text{Educ} + \beta_2 \text{Mujer} + \beta_3 (\text{Educ} \times \text{Mujer}) + \varepsilon$$

**Interpretación:**

- $\beta_1$: retorno a educación para hombres (grupo base)
- $\beta_2$: diferencia de intercepto (mujeres vs hombres, cuando Educ=0)
- $\beta_3$: **diferencia en retorno** de educación (mujeres vs hombres)
- Retorno para mujeres: $\beta_1 + \beta_3$

## Conexión con modificadora de efecto

Si $\beta_3$ es significativo, el género es una **modificadora de efecto** del retorno a la educación.

# Interacción: Ejemplo Visual

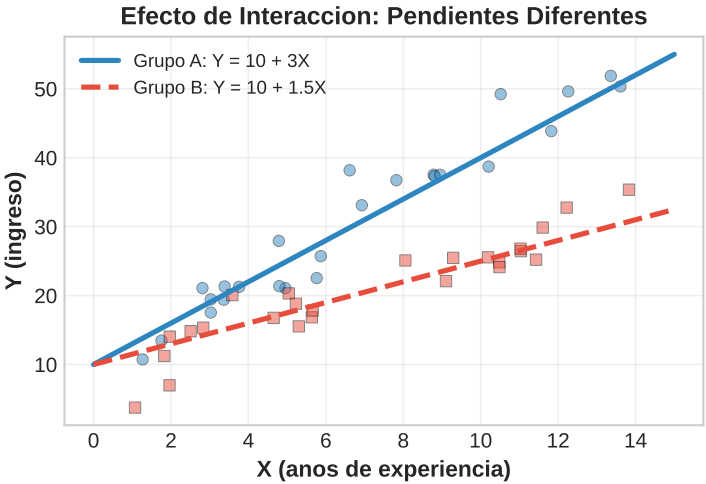

# Pruebas de Significancia Individual (t-test)

**Pregunta:** ¿Es el coeficiente $\hat{\beta}_j$ estadísticamente diferente de cero?

**Hipótesis nula:** $H_0 : \beta_j = 0$ (la variable no afecta a $Y$)
**Estadístico de prueba:**

$$t = \frac{\hat{\beta}_j}{\text{EE}(\hat{\beta}_j)} \sim t_{n-k-1}$$

**Decisión (al nivel $\alpha = 0.05$):**

- Si $|t| > 1.96$ (aprox): rechazamos $H_0$ — variable significativa
- Notación en tablas: *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$

**Intervalo de confianza al 95%:**

$$\hat{\beta}_j \pm t_{\alpha/2} \cdot \text{EE}(\hat{\beta}_j)$$

# Pruebas de Significancia Conjunta (F-test)

**Pregunta:** ¿Son **conjuntamente** significativas un grupo de coeficientes?

**Hipótesis nula:** $H_0 : \beta_1 = \beta_2 = \cdots = \beta_q = 0$

**Estadístico F:**

$$F = \frac{(R_u^2 - R_r^2)/q}{(1 - R_u^2)/(n - k - 1)} \sim F_{q,n-k-1}$$

- $R_u^2$: modelo no restringido (completo)
- $R_r^2$: modelo restringido (sin las variables testeadas)
- $q$: número de restricciones

**Aplicación clave:** Comparar modelos anidados con `anova(m1, m2)` en R.

# Multicolinealidad

**Definición:** Correlación alta entre regresores

**¿Por qué es un problema?**

- Aumenta varianza de estimadores: $\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{(1-R_j^2)\sum(X_j-\bar{X}_j)^2}$
- Intervalos de confianza más amplios
- Dificultad para separar efectos individuales

**Detección: Factor de Inflación de Varianza (VIF)**

$$\text{VIF}_j = \frac{1}{1-R_j^2}$$

- $\text{VIF} = 1$: sin colinealidad
- $\text{VIF} < 5$: aceptable
- $\text{VIF} > 10$: problemático

**Nota**: Multicolinealidad NO causa sesgo, solo reduce precisión.

# Diagnóstico de Multicolinealidad: VIF

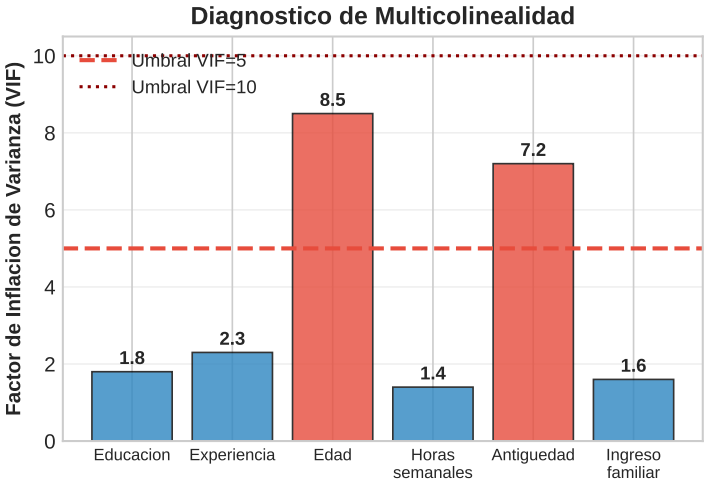

# Implementación en R: Estimación y Diagnósticos

```r
# Estimar modelos
datos <- read.csv("datos.csv")
m1 <- lm(Y ~ X1, data = datos)
m2 <- lm(Y ~ X1 + X2 + X3, data = datos)
m3 <- lm(Y ~ X1 * factor(genero) + X2, data = datos)

# Resumen
summary(m2)

# VIF
library(car)
vif(m2)

# Comparar modelos anidados
anova(m1, m2)

# Tabla profesional
library(stargazer)
stargazer(m1, m2, m3, type = "text")
```

# Ejercicio Práctico

**Dataset** `mtcars`: Modelar consumo de combustible (`mpg`)

**Tareas:**

1. Estimar modelos anidados:
   - M1: `mpg ~ wt`
   - M2: `mpg ~ wt + hp`
   - M3: `mpg ~ wt + hp + factor(cyl)`
   - M4: `mpg ~ wt * am + hp + factor(cyl)`
2. Comparar coeficientes: ¿hay evidencia de OVB en M1?
3. Calcular VIF en M3
4. Si la interacción en M4 es significativa, ¿qué tipo de variable es `am`?

# Resumen

- **OVB:** Omitir confusoras sesga coeficientes; usar modelos anidados para detectar
- **Tres estructuras causales:**
  - Confusora ($X \leftarrow Z \rightarrow Y$): controlar
  - Collider ($X \rightarrow Z \leftarrow Y$): **no** controlar
  - Modificadora: incluir interacción
- **Modelos anidados:** Si $\hat{\beta}$ cambia >20% al agregar control $\rightarrow$ evidencia de OVB
- **Variables dummy** para categóricas ($C - 1$ dummies); **interacciones** para efectos heterogéneos
- **Pruebas t** (individual) y **F** (conjunta/anidados); **VIF** para multicolinealidad

**Próxima sesión:** Práctica integradora en R

## ¿Preguntas?