Práctica Integradora en R (Parte 1)
Pruebas de Hipótesis y Regresión Simple

Amaru Agüero

Doctorado en Ciencias de la Complejidad Social — CICS, UDD

26 de marzo de 2026

Universidad del Desarrollo
Facultad de Gobierno

Agenda de Hoy

- Carga y exploración de datos sociales en R
- Estadística descriptiva: `summary()`, `head()`, `str()`
- Pruebas de hipótesis: *t*-test, prueba de proporciones
- Prueba chi-cuadrado para independencia
- Regresión simple: `lm()` y diagnósticos
- Visualización de resultados con `ggplot2`
- Ejercicio integrador

Paquetes a instalar:

```
install.packages("lmtest")        # Regression tests
install.packages("sandwich")      # Robust errors
install.packages("car")           # Diagnostic tests
install.packages("stargazer")     # Regression tables
install.packages("ggplot2")       # Graphics
```

Carga de Datos Sociales en R

Formatos comunes:

```r
# CSV
datos <- read.csv("datos_sociales.csv", encoding = "UTF-8")

# Excel
library(readxl)
datos <- read_excel("datos.xlsx", sheet = "Sheet1")

# Stata
library(haven)
datos <- read_dta("datos.dta")

# Desde URL
url <- "https://ejemplo.com/datos.csv"
datos <- read.csv(url)
```

Nota: Verificar siempre codificación UTF-8 para caracteres españoles.

Exploración de Datos: Primeros Pasos

```r
# Ver dimensiones
dim(datos)                # filas x columnas

# First and last rows
head(datos, n=10)
tail(datos, n=5)

# Estructura del dataset
str(datos)

# Nombres de columnas
names(datos)
colnames(datos)

# Clases de variables
class(datos$variable)
sapply(datos, class)
```

Estas funciones básicas nos permiten entender la estructura y calidad de nuestros datos.

Estadística Descriptiva (I): summary()

```
# Resumen general del dataset
summary(datos)

# Summary of a specific variable
summary(datos$salario)

# Typical output:
#    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
#   500.0  1500.0  2000.0  2050.3  2500.0  5000.0
```

Proporciona: mínimo, Q1, mediana, media, Q3, máximo.

Útil para: Detectar valores faltantes, outliers, distribución asimétrica.

Estadística Descriptiva (II): Medidas Específicas

```r
# Media y mediana
mean(datos$salario)
median(datos$salario)

# Standard deviation, variance
sd(datos$salario)
var(datos$salario)

# Cuantiles personalizados
quantile(datos$salario, c(0.25, 0.50, 0.75, 0.95))

# Analysis by group
aggregate(datos$salario ~ datos$region, FUN=mean)

library(dplyr)
datos %>%
  group_by(region) %>%
  summarise(media_salario = mean(salario),
            sd_salario = sd(salario))
```

Prueba t: Comparación de Medias

Hipótesis: $H_0 : \mu_1 = \mu_2$ vs. $H_a : \mu_1 \neq \mu_2$

```
# t-test de dos muestras independientes
t.test(salario ~ genero, data=datos)

# Salida:
# t = 2.45, df = 98, p-value = 0.0156
# 95 percent confidence interval: [50.2, 450.8]
# mean in group F: 2000
# mean in group M: 1775

# t-test de muestras pareadas
t.test(datos$salario_2023, datos$salario_2024,
       paired=TRUE)
```

Interpretación: Si p-value < 0.05, rechazamos H_0.

Prueba t: Opciones Avanzadas

```r
# Especificar nivel de significancia
t.test(salario ~ genero, data=datos,
       alternative="greater", conf.level=0.95)

# Sin asumir varianzas iguales (Welch)
t.test(salario ~ genero, data=datos, var.equal=FALSE)

# Con varianzas iguales (Student)
t.test(salario ~ genero, data=datos, var.equal=TRUE)

# Prueba de igualdad de varianzas (Levene)
library(car)
leveneTest(salario ~ genero, data=datos)
```

Nota: Siempre verificar normalidad y homocedasticidad antes de aplicar t-test.

Prueba de Proporciones

Pregunta: ¿Es la proporción de mujeres en la muestra diferente de 0.5?

```
# Tabla de frecuencias
table(datos$genero)
# Female   Male
#    45     55

# Prueba de proporciones
prop.test(45, 100, p=0.5)

# Salida:
# X-squared = 1, df = 1, p-value = 0.3173
# null hypothesis: true p is equal to 0.5
# 95% confidence interval: [0.35, 0.55]
# sample estimate: p = 0.45
```

$H_0 : p = 0.5$ vs. $H_a : p \neq 0.5$. No rechazamos H_0.

Prueba Chi-Cuadrado: Independencia

Pregunta: ¿Son el género y la región independientes?

```
# Tabla de contingencia
tabla <- table(datos$genero, datos$region)
tabla
#         Norte  Centro  Sur
# Female     20      15   10
# Male       25      20   10

# Prueba chi-cuadrado
chisq.test(tabla)

# Salida:
# X-squared = 0.65, df = 2, p-value = 0.7232
# No evidence of association
```

Chi-Cuadrado: Análisis Detallado

```r
# Guardar resultados
chi_result <- chisq.test(tabla)

# Frecuencias observadas vs. esperadas
chi_result$observed
chi_result$expected

# Residuos estandarizados
chi_result$residuals

# Contribution to chi-square
(chi_result$observed - chi_result$expected)^2 /
  chi_result$expected
```

Los residuos permiten identificar celdas que más contribuyen a rechazar H_0.

Regresión Simple: Especificación y Estimación

Modelo: $Y = \beta_0 + \beta_1 X + u$

```r
# Estimar modelo lineal
modelo_simple <- lm(salario ~ educacion, data=datos)

# Ver resultados
summary(modelo_simple)

# Acceder a coeficientes
coef(modelo_simple)
model$coefficients
modelo_simple$coefficients[1]  # intercepto
modelo_simple$coefficients[2]  # pendiente
```

Interpretación: Un año adicional de educación se asocia con cambio en salario.

Interpretación: Output de summary()

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   500.20     150.30   3.326  0.00122 **
educacion     320.45      45.80   6.996  1.2e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 450.2 on 98 degrees of freedom
Multiple R-squared: 0.333, Adjusted R-squared: 0.326
F-statistic: 48.95 on 1 and 98 DF, p-value: 1.2e-10
```

- **Estimate**: coeficiente estimado
- **Std. Error**: error estándar
- **t value**: estadístico t
- **Pr(>|t|)**: p-value bilateral
- **R-squared**: bondad de ajuste (R^2)

Diagnósticos: Validación del Modelo

```r
# Diagnostic plots
plot(modelo_simple)

# Residuos del modelo
residuos <- residuals(modelo_simple)

# Valores ajustados
ajustados <- fitted(modelo_simple)

# Pruebas de normalidad
shapiro.test(residuos)

# Homocedasticidad
library(lmtest)
bptest(modelo_simple)  # Breusch-Pagan
```

Supuestos MCO: Linealidad, normalidad de residuos, homocedasticidad, no autocorrelación.

Visualización: Gráfico de Regresión

```
library(ggplot2)

ggplot(datos, aes(x=educacion, y=salario)) +
  geom_point(color="uddblue", alpha=0.6, size=3) +
  geom_smooth(method="lm", se=TRUE,
              color="uddlight", fill="uddlight") +
  labs(title="Relaci n: Educaci n vs. Salario",
       x="A os de Educaci n",
       y="Salario Mensual (USD)") +
  theme_minimal() +
  theme(plot.title = element_text(hjust=0.5, size=14))
```

`geom_smooth(method="lm")` ajusta la línea de regresión automáticamente.

Gráficos Múltiples: Diagnósticos

```
# Crear gr fico de 2x2
par(mfrow=c(2,2))
plot(modelo_simple)

# O con ggplot2
library(ggfortify)
autoplot(modelo_simple, label.size=2)

# Gr fico de residuos vs. ajustados
ggplot(data.frame(ajustados, residuos),
       aes(x=ajustados, y=residuos)) +
  geom_point() +
  geom_hline(yintercept=0, linetype="dashed") +
  theme_minimal()
```

Buscar: patrón aleatorio en residuos, normalidad, sin outliers influyentes.

Ejercicio Integrador (Parte 1)

Dataset: Encuesta de 150 hogares con variables:

- `ingresos`: ingreso mensual (USD)
- `educacion`: años de educación
- `genero`: F/M
- `region`: Norte/Centro/Sur
- `empleo`: Empleado/Desempleado

Tareas: (1) Load and explore data; (2) Income by gender (t-test); (3) Region–employment chi-square; (4) Estimate income model; (5) Interpret β, R^2; (6) Validate assumptions; (7) Visualize with ggplot2.

*Próxima: **regresión múltiple, dummy variables, errores robustos**.*

Resumen Sesión 4

Conceptos clave: Data import/exploration, descriptive stats, hypothesis tests, simple regression, OLS validation, ggplot2

Próxima (27 de marzo): Multiple regression, dummy variables, interactions, robust errors, econometric workflow