

Sesión 4 · Práctica Integradora en R (Parte 1)

Nivelación Econometría — Doctorado en Políticas Públicas

Amaru Agüero Jiménez (a.agueroj@udd.cl)


marzo de 2026

Panorama de la sesión

Paso del análisis	Qué se hace	Herramienta en R
Pregunta y datos	pregunta, carga, diccionario	<code>read_csv()</code> , <code>glimpse()</code>
Inspección y limpieza	NA, valores imposibles	<code>filter()</code> , <code>drop_na()</code>
Descriptivos y gráficos	tabla por grupo, gráficos	<code>summarise()</code> , <code>ggplot2</code>
Contrastes previos	t, proporciones, chi-cuadrado	<code>t.test()</code> , <code>prop.test()</code>
Regresión simple	estimación, logs, IC, predicción	<code>lm()</code> , <code>broom</code> , <code>predict()</code>
Diagnóstico	residuos, Breusch-Pagan, Shapiro	<code>bptest()</code> , <code>shapiro.test()</code>
Informe	tabla final, lectura crítica	<code>modelsummary()</code>

i Datos de trabajo: encuesta simulada de 150 hogares. Ventaja de simular: conocemos el proceso generador y al final compararemos lo **estimado** con lo **verdadero**.

El mapa: hoy recorreremos el flujo completo



Flujo iterativo: los diagnosticos pueden llevar a re-especificar

- Las sesiones 1 y 2 dieron la teoría: **contrastes de hipótesis y MCO**.
- Hoy las integramos en **un solo caso**, de la pregunta de política al informe.
- Cada slide es un paso preciso: su código, su salida y una línea de interpretación.
- La regla de la práctica: **ningún número se reporta sin haber pasado por este flujo**.

Paso 1 · Pregunta de política y estrategia empírica

Elemento	En nuestro caso
Pregunta de política	¿Cuánto mayor es el ingreso asociado a un año más de educación?
Variable dependiente (Y)	ingreso mensual del hogar (USD)
Variable explicativa (X)	años de educación del jefe de hogar
Parámetro objetivo	β_1 en $Y = \beta_0 + \beta_1 X + u$
Contrastes previos	brechas por género y situación laboral (sesión 1)
Producto final	tabla de regresión + lectura crítica

⚠ β_1 medirá **asociación**. Si además es causal (o no) se discute en el Paso 13 — y la respuesta honesta será “todavía no lo sabemos”.

Paso 2 · Cargar datos reales: los formatos usuales

```
# CSV (readr, parte del tidyverse)
encuesta <- read_csv("encuesta_hogares.csv")

# Excel
library(readxl)
encuesta <- read_excel("encuesta.xlsx", sheet = "datos")

# Stata / SPSS (archivos de encuestas oficiales)
library(haven)
encuesta <- read_dta("casen.dta")

# Directamente desde una URL
encuesta <- read_csv("https://ejemplo.org/datos.csv")
```

- Verificar siempre la **codificación** (UTF-8) y los **códigos de valores perdidos** (-99, 999, "NS/NR") que cada encuesta define en su manual.
- Hoy, en lugar de cargar, **simulamos** la encuesta: así controlamos la verdad.

Paso 2 · La encuesta: 150 hogares simulados

```
set.seed(2026)
n <- 150
encuesta <- tibble(
  educacion = round(pmin(pmax(rnorm(n, 13, 3), 4), 21)),
  genero    = sample(c("Hombre", "Mujer"), n, replace = TRUE, prob = c(0.52, 0.48)),
  region    = sample(c("Norte", "Centro", "Sur"), n, replace = TRUE,
    prob = c(0.30, 0.45, 0.25)),
  empleo    = sample(c("Empleado", "Desempleado"), n, replace = TRUE,
    prob = c(0.85, 0.15)),
  ingresos  = round(exp(6.2 + 0.09 * educacion + 0.15 * (genero == "Hombre") -
    0.35 * (empleo == "Desempleado") + rnorm(n, 0, 0.30)))
)
encuesta$ingresos[c(17, 84)] <- NA # dos hogares no reportan ingreso
encuesta$educacion[131] <- 99    # un error de digitacion
```

El proceso generador es **log-lineal**: el retorno verdadero de la educación es **9% por año**. Como en la vida real, la base llega con problemas sembrados: dos NA y un valor imposible.

Diccionario de variables

Variable	Tipo	Valores	Rol en el análisis
ingresos	continua de razón	USD mensuales	dependiente (Y)
educacion	discreta	4–21 años	explicativa (X)
genero	nominal	Hombre / Mujer	contraste de brechas
region	nominal	Norte / Centro / Sur	contraste chi-cuadrado
empleo	nominal	Empleado / Desempleado	proporciones y brechas



El diccionario se escribe **antes** de tocar los datos: define unidades, rangos válidos y el rol de cada variable. Sin él, no hay forma de detectar el 99 de educación como error.

Paso 3 · Inspección: ¿qué llegó en la base?

```
glimpse(encuesta)
```

```
Rows: 150
```

```
Columns: 5
```

```
$ educacion <dbl> 15, 10, 13, 13, 11, 5, 11, 10, 13, 12, 12, 11, 12, 12, 5, 17~  
$ genero    <chr> "Hombre", "Hombre", "Mujer", "Hombre", "Mujer", "Hombre", "M~  
$ region    <chr> "Sur", "Norte", "Centro", "Norte", "Centro", "Norte", "Norte~  
$ empleo    <chr> "Empleado", "Empleado", "Empleado", "Empleado", "Empleado", ~  
$ ingresos  <dbl> 2089, 1632, 1055, 1653, 1664, 938, 1435, 952, 1840, 877, 882~
```

- educacion e ingresos son numéricas; las otras tres, texto (categóricas).
- glimpse() muestra tipo y primeros valores de cada columna en una pantalla.
- Todavía **no** calculamos nada: primero hay que validar rangos y valores perdidos.

Paso 3 · Limpieza: NA y valores imposibles

```
colSums(is.na(encuesta))      # ¿cuantos NA por variable?
```

```
educacion    genero    region    empleo    ingresos
           0         0         0         0         2
```

```
range(encuesta$educacion)     # el maximo 99 es imposible
```

```
[1]  5 99
```

```
encuesta <- encuesta %>%
  filter(educacion <= 22) %>% # elimina el error de digitacion
  drop_na()                  # elimina los ingresos no reportados
nrow(encuesta)
```

```
[1] 147
```

- Quedan **147 de 150** hogares: cada exclusión se **documenta** (cuántos, por qué).
- Regla de oro: nunca eliminar observaciones “en silencio” — el informe final debe poder reproducirse desde la base cruda.

Paso 4 · Descriptivos: la tabla por grupo

```
encuesta %>% group_by(genero) %>%  
  summarise(n = n(), media = mean(ingresos), mediana = median(ingresos),  
            de = sd(ingresos), educ_media = mean(educacion)) %>%  
  mutate(across(where(is.numeric), ~ round(.x, 1))) %>%  
  kable()
```

genero	n	media	mediana	de	educ_media
Hombre	81	1845.4	1715.0	853.1	12.8
Mujer	66	1740.0	1442.5	827.5	13.1


- La brecha de medias es de **105 USD** a favor de los hombres: ¿señal o ruido muestral? El Paso 6 lo contrasta formalmente.
- En ambos grupos la mediana está bajo la media: distribuciones con **cola derecha**.

Paso 5 · La distribución del ingreso

```
media_i <- mean(encuesta$ingresos)
mediana_i <- median(encuesta$ingresos)

ggplot(encuesta, aes(x = ingresos)) +
  geom_histogram(bins = 22,
                 fill = celeste,
                 color = "white") +
  geom_vline(xintercept = media_i,
             color = rojo) +
  geom_vline(xintercept = mediana_i,
             color = verde) +
  labs(x = "Ingreso mensual (USD)",
       y = "N° de hogares")
```


Media (rojo) a la derecha de la mediana (verde):
sesgo positivo, típico de ingresos. Anticipa la forma log del Paso 8.



Paso 5 · Educación e ingresos: el scatter clave

```
ggplot(encuesta,  
  aes(x = educacion,  
      y = ingresos)) +  
  geom_jitter(width = 0.2,  
             alpha = 0.5,  
             color = azul) +  
  geom_smooth(method = "lm",  
             color = rojo) +  
  labs(x = "Años de educación",  
       y = "Ingreso mensual (USD)")
```

La recta MCO resume la asociación: pendiente positiva y nítida ($r = 0.61$). `geom_jitter()` separa los puntos apilados en cada año de educación.



Paso 6 · ¿Brecha por género? Prueba t de Welch

$H_0 : \mu_H = \mu_M$ vs $H_1 : \mu_H \neq \mu_M$, con $\alpha = 0.05$ (sesión 1).

```
t_gen <- t.test(ingresos ~ genero, data = encuesta)
tidy(t_gen) %>%
  select(estimate1, estimate2, statistic, p.value, conf.low, conf.high) %>%
  kable(digits = 3, col.names = c("media H", "media M", "t", "valor-p",
                                "IC inf", "IC sup"))
```


media H	media M	t	valor-p	IC inf	IC sup
1845.432	1739.955	0.758	0.45	-169.602	380.557

- Con $p = 0.45$ **no se rechaza** H_0 : la brecha de 105 USD es indistinguible del ruido.
- El IC 95 % $[-170, 381]$ es ancho: con $n \approx 74$ por grupo la **potencia** es baja. Ausencia de evidencia no es evidencia de ausencia (el generador sí premia 15 % a los hombres).

Paso 6 · La brecha vista en el gráfico

```
ggplot(encuesta,
       aes(x = genero, y = ingresos,
           fill = genero)) +
  geom_boxplot(alpha = .6,
               outlier.color = rojo) +
  geom_jitter(width = .15,
              alpha = .3) +
  labs(x = NULL,
       y = "Ingreso mensual (USD)") +
  theme(legend.position = "none")
```

Las cajas se **superponen** casi por completo: la imagen es coherente con el $p = 0.45$ de la prueba t. Gráfico y contraste deben contarse la misma historia.



Paso 6 · Desempleo: prueba de proporciones

¿La tasa de desempleo de la muestra difiere de la referencia nacional del 10%? $H_0 : p = 0.10$.

```
tab_empleo <- table(encuesta$empleo)
tab_empleo
```

Desempleado	Empleado
26	121

```
prop.test(tab_empleo["Desempleado"], sum(tab_empleo), p = 0.10) %>%
  tidy() %>%
  select(estimate, statistic, p.value, conf.low, conf.high) %>%
  kable(digits = 3)
```

estimate	statistic	p.value	conf.low	conf.high
0.177	8.816	0.003	0.121	0.25

Con $\hat{p} = 0.177$ y $p = 0.003$ **se rechaza** H_0 : la zona encuestada tiene un desempleo significativamente mayor que la referencia — dato relevante para focalizar el programa.

Paso 6 · ¿Empleo y región asociados? Chi-cuadrado

```
tab_er <- table(encuesta$empleo, encuesta$region)
kable(tab_er)
```

	Centro	Norte	Sur
Desempleado	10	6	10
Empleado	54	42	25

```
chisq.test(tab_er) %>% tidy() %>% kable(digits = 3)
```

statistic	p.value	parameter	method
3.922	0.141	2	Pearson's Chi-squared test

Con $p = 0.141$ **no se rechaza** la independencia: el desempleo no se concentra en una región. Requisito verificado: todas las frecuencias esperadas superan 5.

Paso 7 · Primera regresión: `lm()`

$$\text{ingresos}_i = \beta_0 + \beta_1 \text{educacion}_i + u_i$$

```
m1 <- lm(ingresos ~ educacion, data = encuesta)
tidy(m1) %>%
  mutate(across(c(estimate, std.error, statistic), ~ round(.x, 1)),
         p.value = format.pval(p.value, digits = 2, eps = 0.001)) %>%
  kable()
```

term	estimate	std.error	statistic	p.value
(Intercept)	-349.8	239.5	-1.5	0.15
educacion	166.0	18.0	9.2	<0.001

- Nunca reportar el `summary()` completo: `broom::tidy()` entrega los coeficientes como tabla ordenada, lista para el informe.
- La ecuación estimada: $\widehat{\text{ingresos}} = -350 + 166.1 \cdot \text{educacion}$.

Paso 7 · Interpretación de los coeficientes

$$\widehat{\text{ingresos}} = -350 + 166.1 \cdot \text{educacion}$$

- **Pendiente** ($\hat{\beta}_1 = 166$): cada año adicional de educación se **asocia** con 166 USD más de ingreso mensual promedio. Es la cifra que responde la pregunta de política — en niveles.
- **Intercepto** ($\hat{\beta}_0 = -350$): el “ingreso con 0 años de educación” es una **extrapolación sin soporte** — la educación mínima observada es 4 años. No se interpreta (y su $p = 0.15$ lo confirma irrelevante).
- Las unidades importan: $\hat{\beta}_1$ está en **USD por año de educación**; si Y estuviera en miles, el coeficiente sería 0.166.

! Decir “se asocia” no es modestia retórica: es la diferencia entre describir la encuesta y afirmar que **más aulas producen** 166 USD. Lo segundo requiere el Paso 13.

Paso 8 · Forma funcional: el modelo en logs

```
m2 <- lm(log(ingresos) ~ educacion, data = encuesta)
tidy(m2) %>%
  mutate(across(c(estimate, std.error, statistic), ~ round(.x, 3)),
         p.value = format.pval(p.value, digits = 2, eps = 0.001)) %>%
  kable()
```

term	estimate	std.error	statistic	p.value
(Intercept)	6.303	0.126	49.924	<0.001
educacion	0.085	0.009	8.908	<0.001

- Modelo **log-nivel**: $100 \cdot \hat{\beta}_1 \approx 8.5\%$ más de ingreso por año adicional de educación (una *semi-elasticidad*, el clásico retorno de Mincer).
- El generador usaba **9 %**: la regresión lo recupera dentro del error muestral.
- El log respeta la naturaleza multiplicativa del ingreso y domará los residuos (Paso 12).

Paso 9 · Bondad de ajuste: R^2

```
glance(m1) %>%  
  select(r.squared, adj.r.squared, sigma, statistic, nobs) %>%  
  kable(digits = 3, col.names = c("R2", "R2 ajustado", "sigma", "F", "n"))
```

R2	R2 ajustado	sigma	F	n
0.369	0.365	669.747	84.927	147

- La educación explica el **36.9 %** de la varianza del ingreso; el resto es heterogeneidad no modelada (experiencia, sector, suerte).
- $\hat{\sigma} = 670$ USD: el error típico de predicción del modelo en niveles.
- Un R^2 “bajo” **no invalida** el modelo para estimar β_1 ; y no comparar R^2 entre m1 y m2: sus variables dependientes son distintas (niveles vs log).

Paso 10 · Inferencia sobre 1: t e intervalo

$H_0 : \beta_1 = 0$ (la educación no se asocia al ingreso) vs $H_1 : \beta_1 \neq 0$.

```
tidy(m1, conf.int = TRUE) %>%  
  filter(term == "educacion") %>%  
  select(term, estimate, std.error, statistic, conf.low, conf.high) %>%  
  kable(digits = 1)
```

term	estimate	std.error	statistic	conf.low	conf.high
educacion	166	18	9.2	130.4	201.6

- El estadístico es el de la sesión 1: $t = \hat{\beta}_1 / ee(\hat{\beta}_1) = 166.1/18 = 9.2$, con $p < 0.001$: **se rechaza H_0** con holgura.
- Lectura equivalente: el IC 95 % [130, 202] **no contiene el cero**.
- La inferencia asume los supuestos MCO — que aún no verificamos (Paso 12): la tabla se firma solo después del diagnóstico.

Paso 11 · Predicción: puntual y por intervalo

¿Qué ingreso predice el modelo para un hogar con 16 años de educación?

```
nuevo <- tibble(educacion = 16)
predict(m1, nuevo, interval = "confidence")
```

	fit	lwr	upr
1	2306.241	2151.975	2460.507

```
predict(m1, nuevo, interval = "prediction")
```


	fit	lwr	upr
1	2306.241	973.5543	3638.927

- Puntual: **2.306 USD**. IC de **confianza** [2.152, 2.461]: dónde está el ingreso *promedio* de los hogares con 16 años.
- IC de **predicción** [974, 3.639]: dónde caerá un *hogar individual* — mucho más ancho porque suma la varianza de u .
- Error frecuente en informes: usar el IC de confianza para prometer resultados a nivel individual.

Paso 12 · Diagnóstico visual: residuos

```
diag1 <- tibble(  
  ajustado = fitted(m1),  
  residuo  = resid(m1))  
  
ggplot(diag1,  
  aes(ajustado, residuo)) +  
  geom_point(alpha = .5,  
    color = azul) +  
  geom_hline(yintercept = 0,  
    linetype = "dashed") +  
  geom_smooth(se = FALSE,  
    color = naranja) +  
  labs(x = "Valores ajustados",  
    y = "Residuos")
```

El **abanico** que se abre hacia la derecha es heterocedasticidad: la varianza del ingreso crece con su nivel.



Paso 12 · Pruebas formales de los supuestos

```
list("Shapiro (niveles)" = shapiro.test(resid(m1)),  
     "Shapiro (log)"     = shapiro.test(resid(m2)),  
     "Breusch-Pagan (niveles)" = bptest(m1),  
     "Breusch-Pagan (log)"     = bptest(m2)) %>%  
map_df(tidy, .id = "prueba") %>%  
select(prueba, statistic, p.value) %>%  
mutate(statistic = round(statistic, 2), p.value = signif(p.value, 2)) %>%  
kable()
```

prueba	statistic	p.value
Shapiro (niveles)	0.97	7.5e-03
Shapiro (log)	0.98	1.6e-02
Breusch-Pagan (niveles)	18.05	2.2e-05
Breusch-Pagan (log)	0.29	5.9e-01

- En **niveles** se rechazan normalidad y homocedasticidad: la inferencia clásica de `m1` queda en duda.
- El **log** corrige la heterocedasticidad (BP: $p = 0.59$); la normalidad queda justa, pero con $n = 147$ el TCL protege los IC. Decisión: **reportar el modelo log** (próxima sesión: errores robustos con `sandwich`).


Bonus · ggplotly(): interactividad en una línea

```
library(plotly)

p <- ggplot(encuesta,
  aes(educacion, ingresos,
      color = empleo)) +
  geom_jitter(width = .2,
              alpha = .6) +
  labs(x = "Años de educación",
       y = "Ingreso (USD)")

ggplotly(p) # eso es todo
```

ggplotly() convierte cualquier ggplot en un gráfico interactivo (tooltip, zoom, filtro por leyenda). Todas las figuras de esta sesión usan ese truco en la versión HTML; en el PDF quedan estáticas.



Paso 13 · ¿Es causal el 8.5 %? Lectura crítica

Amenaza	Mecanismo en este caso	Efecto sobre $\hat{\beta}_1$
Variable omitida	la habilidad eleva educación e ingresos a la vez	sesgo al alza
Causalidad inversa	familias con más ingreso compran más educación	sesgo al alza
Selección muestral	los NA de ingreso rara vez son aleatorios	dirección incierta
Error de medición en X	años de educación auto-reportados	atenuación (hacia 0)

! Aquí conocemos el generador y el 8.5 % **sí** es (casi) el efecto verdadero — lujo que los datos reales no dan. Con encuestas reales, pasar de asociación a causa exige **diseño**: experimentos, variables instrumentales, discontinuidades (sesiones siguientes del doctorado).

Paso 14 · Mini-informe: la tabla final

```
modelsummary(list("Ingresos (USD)" = m1, "log(Ingresos)" = m2),  
  output = "markdown", fmt = 2,  
  stars = c("*" = .05, "***" = .01, "****" = .001),  
  gof_map = c("nobs", "r.squared"))
```

	Ingresos (USD)	log(Ingresos)
(Intercept)	-349.77 (239.52)	6.30*** (0.13)
educacion	166.00*** (18.01)	0.08*** (0.01)
Num.Obs.	147	147
R2	0.369	0.354

• $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$

Cómo se redacta: “Cada año adicional de educación se asocia con ingresos 8.5 % mayores (IC 95 %: 6.6–10.3 %; $p < 0.001$; $n = 147$). La estimación es asociativa, no causal.”

Síntesis: checklist del análisis integrador

Antes de entregar un informe

- 1 Pregunta y parámetro objetivo definidos a priori
- 2 Diccionario de variables y exclusiones documentadas
- 3 Tabla descriptiva por grupo (siempre con n)
- 4 Gráfico exploratorio antes de cualquier modelo
- 5 Contrastes previos con hipótesis explícitas
- 6 Coeficientes interpretados en sus unidades
- 7 Diagnóstico de residuos antes de firmar la inferencia
- 8 Asociación y causalidad claramente separadas

Funciones de la sesión

`glimpse()` `drop_na()` `t.test()`
`prop.test()` `chisq.test()` `lm()` `tidy()`
`glance()` `confint()` `predict()` `bptest()`
`shapiro.test()` `ggplotly()`
`modelsummary()`

Próxima sesión: Práctica Parte 2 — regresión múltiple, variables dummy, interacciones y errores robustos.

Ejercicio para practicar (30 min)

Replique el flujo completo con datos **reales**: `data("wage1", package = "wooldridge")` (526 trabajadores, EE.UU. 1976; salario por hora `wage`, educación `educ`, mujer `female`).

- 1 Escriba el diccionario de `wage`, `educ`, `female` y revise NA y rangos.
- 2 Construya la tabla descriptiva de `wage` por género (`n`, media, mediana, DE).
- 3 Contraste la brecha salarial por género con la prueba t de Welch e interprete el IC.
- 4 Estime `wage ~ educ` y `log(wage) ~ educ`; interprete $\hat{\beta}_1$ en cada métrica y compare el retorno con el 8.5 % de la encuesta simulada.
- 5 Grafique residuos vs ajustados y aplique `bptest()` y `shapiro.test()` a ambos modelos. ¿Cuál reportaría?
- 6 Prediga el salario con 16 años de educación con IC de confianza y de predicción, y explique la diferencia entre ambos a un tomador de decisiones.

i Referencias: Wooldridge, *Introductory Econometrics* (caps. 2, 4 y apéndice C) · Stock & Watson, *Introduction to Econometrics* (caps. 4–5) · Wickham & Grolemund, *R for Data Science* (importación y EDA).