

Sesión 5 · Práctica Integradora en R (Parte 2)

Nivelación Econometría — Doctorados en Políticas Públicas y en Ciencias de la Complejidad Social ·
Universidad del Desarrollo

Amaru Agüero Jiménez (a.agueroj@udd.cl)

marzo de 2026

Panorama de la sesión

Bloque	Concepto clave	Herramienta en R
Del simple al múltiple	sesgo de variable omitida	<code>lm()</code> , <code>broom::tidy()</code>
Categorías e interacciones	categoría base, efectos marginales	<code>factor()</code> , <code>educacion * genero</code>
Contraste de modelos	prueba F de modelos anidados	<code>anova()</code>
Diagnósticos	VIF, residuos, Breusch-Pagan	<code>car::vif()</code> , <code>lmtest::bptest()</code>
Robustez	errores estándar HC	<code>sandwich::vcovHC()</code> , <code>coeftest()</code>
Reporte	tabla de modelos, escenarios	<code>modelsummary()</code> , <code>predict()</code>

i Continuación de la Parte 1: allí exploramos datos, hicimos pruebas de hipótesis y regresión simple. Hoy completamos el flujo econométrico con **regresión múltiple**: especificar, diagnosticar, corregir y reportar — todo sobre un mismo caso.

El caso: retornos a la educación y brechas salariales

Pregunta de política: ¿cuánto aumenta el salario un año adicional de educación, y difiere ese retorno entre hombres y mujeres?

Variable	Tipo	Papel en el análisis
salario (miles de pesos)	continua	dependiente (Y)
educacion (años)	continua	regresor de interés
experiencia, edad (años)	continuas	controles
genero (Mujer/Hombre)	binaria	dummy + interacción
region (Sur/Centro/Norte)	categorica	dummies de control
sector (3 categorías)	categorica	reservada para el ejercicio


Trabajamos con una encuesta laboral **simulada** ($n = 250$): conocer el modelo verdadero nos permite verificar si cada técnica recupera lo que debería.

Simulación: el modelo verdadero es conocido

```
set.seed(42)
n <- 250
datos <- tibble(
  genero = sample(c("Mujer", "Hombre"), n, replace = TRUE,
    prob = c(.45, .55)),
  region = sample(c("Sur", "Centro", "Norte"), n, replace = TRUE,
    prob = c(.35, .35, .30)),
  sector = sample(c("Servicios", "Industria", "Tecnología"), n,
    replace = TRUE, prob = c(.40, .35, .25)),
  edad = round(rnorm(n, mean = 40, sd = 10)),
  educacion = round(rnorm(n, mean = 13, sd = 3), 1),
  experiencia = round(pmax(edad - educacion - 6 + rnorm(n, 0, 4), 0), 1),
  salario = round(pmax(800,
    2200 + 320 * educacion + 125 * experiencia +
    200 * (genero == "Hombre") +
    150 * (region == "Centro") + 280 * (region == "Norte") +
    950 * (genero == "Hombre") * (educacion - 13) / 3 +
    rnorm(n, mean = 0, sd = 450)))
)
```

- Retorno “verdadero” de la educación: **320** para mujeres y $320 + 950/3 \approx \mathbf{637}$ para hombres; primas regionales de 150 (Centro) y 280 (Norte); ruido con DE 450.
- La experiencia sigue la identidad de Mincer: $\text{experiencia} \approx \text{edad} - \text{educacion} - 6$ — quienes estudian más acumulan **menos** experiencia a la misma edad.

Dónde estamos en el flujo econométrico



Flujo iterativo: los diagnósticos pueden llevar a re-especificar

- **Parte 1:** exploración, pruebas de hipótesis, regresión simple (pasos 1–4).
- **Hoy:** especificación múltiple, diagnósticos, correcciones y presentación (pasos 5–8).
- El flujo **no es lineal**: los diagnósticos suelen devolvernos a la especificación.
- Meta de la sesión: terminar con una tabla de modelos, un gráfico de coeficientes y un mini-informe defendible.

Exploración: ¿hay brecha salarial a simple vista?

```
bind_rows(  
  datos %>% group_by(grupo = genero) %>%  
    summarise(n = n(), media = mean(salario),  
              mediana = median(salario), de = sd(salario)),  
  datos %>% group_by(grupo = region) %>%  
    summarise(n = n(), media = mean(salario),  
              mediana = median(salario), de = sd(salario))  
) %>% kable(digits = 0)
```


grupo	n	media	mediana	de
Hombre	134	9105	9264	2002
Mujer	116	9057	8980	1596
Centro	98	9364	9274	1681
Norte	66	8919	8984	1599
Sur	86	8888	9150	2096

La brecha **cruda** de género es de apenas ~50 mil pesos (9.105 vs 9.057) y las medianas casi coinciden. Guarde este dato: la regresión múltiple contará una historia mucho menos tranquilizadora.

Exploración gráfica: educación y salario

```
ggplot(datos,
       aes(x = educacion,
           y = salario)) +
  geom_point(alpha = .5,
             color = celeste) +
  geom_smooth(method = "lm",
             color = rojo) +
  scale_y_continuous(
    labels = scales::comma) +
  labs(x = "Años de educación",
       y = "Salario (miles de $)")
```

Relación positiva y aproximadamente lineal, pero con **mucha dispersión**: la recta simple deja fuera experiencia, género y región.



Punto de partida: el modelo simple (sesión 2)

```
m1 <- lm(salario ~ educacion, data = datos)
tidy(m1) %>% kable(digits = 2)
```

term	estimate	std.error	statistic	p.value
(Intercept)	4291.66	439.61	9.76	0
educacion	380.48	34.10	11.16	0

- La pendiente dice **380** mil pesos por año de educación, con $R^2 = 0.33$: dos tercios de la variación quedan sin explicar.
- ¿Es 380 el retorno de la educación? Solo si `educacion` no se correlaciona con nada más que afecte al salario — y sabemos que sí (la experiencia).

Sesgo de variable omitida en acción

Si el modelo verdadero incluye la experiencia pero la omitimos: $E[\hat{\beta}_{corto}] = \beta_{educ} + \beta_{exper} \cdot \delta$, donde δ es la pendiente de experiencia ~ educacion.

```
corto <- lm(salario ~ educacion, data = datos)
largo <- lm(salario ~ educacion + experiencia, data = datos)
delta <- coef(lm(experiencia ~ educacion, data = datos))["educacion"]
round(c(corto = unname(coef(corto)["educacion"]),
        largo = unname(coef(largo)["educacion"]),
        sesgo_formula = unname(coef(largo)["experiencia"] * delta)), 1)
```

corto	largo	sesgo_formula
380.5	511.6	-131.1

- Cada año extra de educación “cuesta” un año de experiencia ($\delta \approx -1.1$) y la experiencia paga ~124: el corto **subestima** el retorno en ~132 (380 vs 512).

! El sesgo puede ir en **cualquier dirección**: aquí es negativo; si la variable omitida fuera la habilidad, sería positivo. Agregar un control se justifica cuando se correlaciona con el regresor de interés **y** afecta a Y .

El modelo múltiple base: ceteris paribus

```
m2 <- lm(salario ~ educacion + experiencia + edad, data = datos)
tidy(m2) %>% kable(digits = 2)
```

term	estimate	std.error	statistic	p.value
(Intercept)	-35.09	250.66	-0.14	0.89
educacion	511.56	16.26	31.46	0.00
experiencia	123.53	9.15	13.50	0.00
edad	0.05	9.75	0.01	1.00

- Cada β_j es ahora el efecto de X_j **manteniendo constantes** los demás regresores: 512 por año de educación a experiencia y edad fijas.
- edad es ~ 0 y no significativa: en el modelo verdadero no tiene efecto directo (opera solo vía experiencia). Un control puede “sobrar” — la teoría decide, no el R^2 .
- R^2 ajustado = 0.885: penaliza regresores extra; úselo para comparar especificaciones.

Variables dummy: factores y categoría de referencia

```
datos <- datos %>%  
  mutate(genero = factor(genero, levels = c("Mujer", "Hombre")),  
         region = factor(region, levels = c("Sur", "Centro", "Norte")))  
contrasts(datos$region)
```

	Centro	Norte
Sur	0	0
Centro	1	0
Norte	0	1

- R convierte factores en dummies y **omite la primera categoría** (la base): incluir las tres regiones más el intercepto sería colinealidad perfecta (la “trampa de la dummy”).
- Si deja las variables como texto, la base se elige por **orden alfabético** (aquí serían “Centro” y “Hombre”): fije la base con `factor(levels = ...)` para que sea la categoría de comparación relevante.
- Cada coeficiente dummy se lee **contra la base**, no contra el promedio.

Modelo con género y región

```
m3 <- lm(salario ~ educacion + experiencia + edad + genero + region,  
         data = datos)  
tidy(m3) %>% kable(digits = 2)
```

term	estimate	std.error	statistic	p.value
(Intercept)	-302.80	253.16	-1.20	0.23
educacion	515.60	15.93	32.38	0.00
experiencia	123.75	8.95	13.83	0.00
edad	-0.13	9.57	-0.01	0.99
generoHombre	30.91	77.35	0.40	0.69
regionCentro	259.77	89.01	2.92	0.00
regionNorte	382.74	99.25	3.86	0.00

- regionCentro y regionNorte: primas de 260 y 383 mil pesos **respecto del Sur**, a igual educación, experiencia, edad y género.
- generoHombre ≈ 31 y no significativo: condicionando en lo demás, ¿la brecha de género desapareció? Cuidado — un promedio puede esconder heterogeneidad.

Interacción: ¿el retorno difiere por género?

```
m4 <- lm(salario ~ educacion * genero + experiencia + edad + region,
         data = datos)
tidy(m4) %>% filter(str_detect(term, "educacion|genero")) %>%
  kable(digits = 2)
```


term	estimate	std.error	statistic	p.value
educacion	341.21	16.98	20.10	0
generoHombre	-3739.19	270.69	-13.81	0
educacion:generoHombre	299.04	20.99	14.25	0

- `educacion * genero` expande a efectos principales **más** interacción (: estima solo la interacción).
- `educacion` (341) es el retorno para la categoría base (**mujeres**); la interacción (299, $p < 0.001$) es el retorno **adicional** de los hombres.
- `generoHombre` = -3739 **no** es “la brecha de género”: es la brecha extrapolada a `educacion` = 0, fuera del rango de los datos. Con interacciones, las dummies se evalúan donde la otra variable vale cero.

Visualizar la interacción

```
ggplot(datos,
  aes(x = educacion,
      y = salario,
      color = genero)) +
  geom_point(alpha = .45) +
  geom_smooth(method = "lm",
    se = FALSE,
    linewidth = 1.1) +
  labs(x = "Años de educación",
    y = "Salario (miles de $)",
    color = NULL)
```

Dos rectas con **pendientes distintas**: la brecha de género se abre con la educación y se invierte en niveles bajos. Por eso la brecha cruda parecía nula.



Efectos marginales: el retorno para cada grupo

```
b <- coef(m4); V <- vcov(m4)
int <- "educacion:generoHombre"
ret_h <- b["educacion"] + b[int]
se_h <- sqrt(V["educacion", "educacion"] + V[int, int] +
             2 * V["educacion", int])
tibble(grupo = c("Mujeres", "Hombres"),
       retorno = c(b["educacion"], ret_h),
       ee = c(sqrt(V["educacion", "educacion"]), se_h)) %>%
  mutate(ic_95 = paste0("[", round(retorno - 1.96 * ee), "; ",
                                round(retorno + 1.96 * ee), "]")) %>%
  kable(digits = 1)
```

grupo	retorno	ee	ic_95
Mujeres	341.2	17.0	[308; 374]
Hombres	640.2	14.7	[612; 669]

- El EE del retorno masculino ($\hat{\beta}_1 + \hat{\beta}_3$) requiere la **covarianza** de los coeficientes (`vcov()`), no la suma de los EE.
- Los IC recuperan los valores verdaderos (320 y 637). La desigualdad opera vía **retornos**, no como desplazamiento parejo: en la educación media la brecha de nivel es ~26 y no significativa.

¿La interacción mejora el modelo? Prueba F anidada

$H_0: \beta_{educ \times hombre} = 0$ (M3 basta) vs H_1 : la interacción pertenece al modelo.

```
print(anova(m3, m4), signif.stars = FALSE)
```

Analysis of Variance Table

Model 1: salario ~ educacion + experiencia + edad + genero + region

Model 2: salario ~ educacion * genero + experiencia + edad + region

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	243	87685531				
2	242	47681982	1	40003549	203.03	< 2.2e-16

- $F(1, 242) = 203$, $p < 0.001$: se rechaza H_0 — la interacción reduce la suma de cuadrados residual de forma abrumadora.
- Con **una** restricción, $F = t^2$ del coeficiente; la fuerza de `anova()` es contrastar **bloques** de restricciones (p. ej., todas las dummies de región a la vez).
- Requisito: modelos **anidados**, misma muestra y misma Y .


Multicolinealidad: factor de inflación de varianza

```
vif(m3) %>% kable(digits = 2)
```

	GVIF	Df	GVIF ^{^(1/(2*Df))}
educacion	1.34	1	1.16
experiencia	7.11	1	2.67
edad	6.69	1	2.59
genero	1.03	1	1.02
region	1.03	2	1.01

- $VIF_j = 1/(1 - R_j^2)$, con R_j^2 de regresar X_j sobre los demás regresores. Reglas usuales: preocupa sobre 5–10.
- experiencia (7.1) y edad (6.7): casi colineales por la identidad $\text{experiencia} \approx \text{edad} - \text{educacion} - 6$. Consecuencia: **EE inflados** en esos coeficientes — no hay sesgo.
- Remedio aquí: eliminar edad (teóricamente redundante y no significativa). Nota: interacciones y polinomios inflan el VIF **mecánicamente**; por eso se evalúa en M3, no en M4.

Diagnóstico visual: el panel de plot(lm)



`plot(m4)` produce los cuatro clásicos:

- **Residuos vs ajustados:** linealidad y homocedasticidad.
- **QQ normal:** normalidad de los residuos.
- **Scale-Location:** varianza constante (versión estandarizada).
- **Residuos vs leverage:** observaciones influyentes (distancia de Cook).


Los replicaremos con `broom::augment()` + `ggplot2`, que permite personalizar e interactuar.

Residuos vs ajustados: la radiografía del modelo

```
diag_m4 <- augment(m4)


ggplot(diag_m4,
       aes(x = .fitted,
           y = .resid)) +
  geom_point(alpha = .5,
            color = celeste) +
  geom_hline(yintercept = 0,
            linetype = "dashed") +
  geom_smooth(se = FALSE,
            color = rojo) +
  labs(x = "Valores ajustados",
       y = "Residuos")
```

Buscamos una **nube sin forma** en torno a cero: curvatura sugiere forma funcional errada; un embudo, heterocedasticidad.



QQ-plot: ¿residuos aproximadamente normales?

```
qq <- tibble(  
  teorico =  
    qnorm(ppoints(nobs(m4))),  
  muestral = sort(resid(m4)))  
  
ggplot(qq,  
  aes(x = teorico,  
      y = muestral)) +  
  geom_point(alpha = .5,  
    color = celeste) +  
  geom_line(aes(y = sd(muestral) *  
    teorico),  
    color = rojo) +  
  labs(x = "Cuantiles teóricos",  
    y = "Cuantiles muestrales")
```



Puntos sobre la recta (pendiente = DE de los residuos) indican normalidad. Colas que se despegan son el patrón típico con salarios reales — motivo para pasar a $\log(\text{salario})$.

Aquí `shapiro.test(residuals(m4))` da $p = 0.6$: no se rechaza la normalidad. Con $n = 250$, además, la inferencia sobre β descansa en el TCL, no en la normalidad exacta.

Heterocedasticidad: prueba de Breusch-Pagan

H_0 : varianza del error constante (homocedasticidad) vs H_1 : la varianza depende de los regresores.

```
bptest(m4)
```

studentized Breusch-Pagan test

data: m4

BP = 11.181, df = 7, p-value = 0.1309

- $p = 0.13$: no se rechaza H_0 — coherente con un DGP de varianza constante.
- Si se rechazara: $\hat{\beta}$ sigue **insesgado**, pero los EE clásicos quedan mal calculados y toda la inferencia (t, F, IC) pierde validez.
- Con datos reales de salarios la heterocedasticidad es la **norma**, no la excepción: la práctica estándar es reportar errores robustos siempre.

Errores estándar robustos: sandwich + lmtest

```
ct <- coeftest(m4, vcov = vcovHC(m4, type = "HC1"))  
ct[c("educacion", "educacion:generoHombre"), ]
```

	Estimate	Std. Error	t value	Pr(> t)
educacion	341.2062	17.59573	19.39142	3.516223e-51
educacion:generoHombre	299.0384	20.43218	14.63566	3.592063e-35

- `vcovHC()` estima la matriz de varianzas tipo “sándwich” de White, válida con heterocedasticidad de forma desconocida.
- Variantes: HC1 (la de Stata, estándar en economía), HC3 (más conservadora, recomendada con *n* pequeño).
- Los errores robustos cambian EE, *t* y *p* — **jamás** los coeficientes: la estimación MCO es la misma.

SE clásicos vs robustos: la comparación

```
tibble(termino = names(coef(m4)), beta = coef(m4),  
       se_mco = sqrt(diag(vcov(m4))),  
       se_hc1 = sqrt(diag(vcovHC(m4, type = "HC1")))) %>%  
  mutate(razon = se_hc1 / se_mco) %>%  
  filter(str_detect(termino, "educacion|genero|experiencia")) %>%  
  kable(digits = 2)
```

termino	beta	se_mco	se_hc1	razon
educacion	341.21	16.98	17.60	1.04
generoHombre	-3739.19	270.69	258.85	0.96
experiencia	129.54	6.63	6.99	1.06
educacion:generoHombre	299.04	20.99	20.43	0.97

- Razones entre 0.96 y 1.06: clásicos y robustos casi coinciden, como anticipó Breusch-Pagan.
- Una razón lejos de 1 en datos reales es señal de heterocedasticidad relevante (o de mala especificación): reporte los robustos y revise la forma funcional.

La tabla final: tres modelos con modelsummary

```
modelsummary(list("(1) Simple" = m1, "(2) Controles" = m3,  
  "(3) Interacción" = m4),  
  coef_omit = "Intercept|edad|region",  
  gof_map = c("nobs", "r.squared", "adj.r.squared"),  
  stars = TRUE)
```


	(1) Simple	(2) Controles	(3) Interacción
educacion	380.485*** (34.102)	515.600*** (15.926)	341.206*** (16.979)
experiencia		123.751*** (8.950)	129.538*** (6.626)
generoHombre		30.906 (77.345)	-3739.187*** (270.692)
educacion × generoHombre			299.038*** (20.987)
Num.Obs.	250	250	250
R2	0.334	0.894	0.942
R2 Adj.	0.332	0.891	0.941

+ p < 0.1, * p < 0.05, ** p < 0.01, *** p < 0.001

Gráfico de coeficientes: geom_pointrange

```
coefs <- tidy(m4,
              conf.int = TRUE) %>%
  filter(!term %in%
         c("(Intercept)",
           "generoHombre"))

ggplot(coefs,
       aes(x = estimate,
           y = reorder(term,
                       estimate))) +
  geom_vline(xintercept = 0,
             linetype = "dashed") +
  geom_pointrange(
    aes(xmin = conf.low,
        xmax = conf.high),
    color = azul) +
  labs(x = "Coeficiente (IC 95%)",
       y = NULL)
```



Se omite generoHombre (-3739) por escala: recuerde que es la brecha en educacion = 0, no un efecto interpretable.

Escenarios de política con predict()

```
esc <- crossing(genero = c("Mujer", "Hombre"),
               educacion = c(12, 16)) %>%
  mutate(region = "Sur", experiencia = mean(datos$experiencia),
         edad = mean(datos$edad))
esc %>% select(genero, educacion) %>%
  bind_cols(as_tibble(predict(m4, esc, interval = "confidence"))) %>%
  kable(digits = 0)
```

genero	educacion	fit	lwr	upr
Hombre	12	8589	8478	8700
Hombre	16	11150	10997	11304
Mujer	12	8740	8626	8854
Mujer	16	10105	9956	10254

- Pasar de 12 a 16 años de educación se asocia con +1.365 mil para mujeres y +2.561 mil para hombres: una expansión educativa **amplía** la brecha si los retornos difieren.
- `interval = "confidence"` acota la **media condicional**; para un individuo use `"prediction"` (mucho más ancho: incluye el ruido u).

De la asociación a la causalidad

Amenaza	En este caso	Diseño que la enfrenta
Variable omitida no observable	habilidad y redes familiares afectan educación y salario	RCT, loterías de acceso; efectos fijos de panel
Endogeneidad de la educación	costos y preferencias determinan cuánto se estudia	IV: distancia a universidades (Card, 1995)
Selección muestral	solo observamos salarios de quienes trabajan	corrección de Heckman
Reglas de asignación	puntajes de corte en becas y admisión	regresión discontinua

! Nuestros β describen **medias condicionales**. “Controlar por observables” no elimina el sesgo por no observables: sin un diseño de identificación, el retorno estimado no es un parámetro causal — dígalo explícitamente en el informe.

El mini-informe: estructura y párrafo de resultados

- 1 **Pregunta y datos:** qué se estima, con qué muestra y por qué importa.
- 2 **Especificación:** modelo poblacional y justificación teórica de cada control.
- 3 **Resultados:** tabla de 2–3 modelos con EE robustos y estrellas.
- 4 **Diagnósticos:** VIF, residuos, Breusch-Pagan — y qué se hizo al respecto.
- 5 **Magnitudes:** efectos marginales por grupo y escenarios con `predict()`.
- 6 **Limitaciones:** qué diseño haría falta para una lectura causal.



Párrafo de ejemplo: “Un año adicional de educación se asocia con 341 mil pesos más de salario para las mujeres y 640 para los hombres; la diferencia de retornos (299, $p < 0.001$) sobrevive controles de experiencia, edad y región (R^2 aj. = 0.94, $n = 250$). No hay evidencia de heterocedasticidad (BP, $p = 0.13$) y los EE robustos coinciden con los clásicos. Estas cifras describen asociaciones condicionales, no efectos causales.”

Checklist econométrico completo

Antes de dar por cerrado un análisis

- 1 Pregunta y modelo poblacional definidos *antes* de estimar
- 2 Exploración: distribuciones, grupos, correlaciones
- 3 Controles justificados por teoría (lógica del SVO)
- 4 Categorías base explícitas en todos los factores
- 5 Interacciones donde la teoría lo sugiera + efectos marginales
- 6 Especificaciones comparadas con F anidada y R^2 ajustado
- 7 VIF, residuos vs ajustados, QQ, Breusch-Pagan
- 8 EE robustos (HC1/HC3) como estándar de reporte
- 9 Tabla de modelos + gráfico de coeficientes + escenarios
- 10 Limitaciones causales declaradas

Funciones R de esta sesión

`lm()` `factor()` `contrasts()` `tidy()`
`glance()` `augment()` `anova()` `vif()`
`bptest()` `vcovHC()` `coeftest()`
`modelsummary()` `predict()` `crossing()`

Cierre de la nivelación: con este flujo dominado, el paso siguiente son los diseños de identificación — panel, IV, diferencias en diferencias y regresión discontinua.

Ejercicio para practicar (30 min)

Con datos reales: `data(wage1, package = "wooldridge")` (526 trabajadores, EE.UU.).

- 1 Estime `log(wage) ~ educ` y luego agregue `exper` y `tenure`. ¿Cómo y por qué cambia el retorno de la educación? Conéctelo con la fórmula del SVO.
- 2 Agregue `female` y la interacción `educ * female`. Interprete los tres coeficientes clave y calcule el retorno para cada grupo con su EE (use `vcov()`).
- 3 Contraste con `anova()` si la interacción y las dummies adicionales aportan en bloque.
- 4 Ejecute `vif()`, el gráfico de residuos vs ajustados y `bptest()`. ¿Necesita errores robustos? Compare EE clásicos vs HC1 en una tabla.
- 5 Presente 3 especificaciones con `modelsummary()` y un gráfico de coeficientes con `geom_pointrange()`.
- 6 Prediga el salario esperado de una mujer con 16 años de educación (`predict()` con IC) y cierre con un párrafo: ¿qué impediría leer su estimación como causal?

i Referencias: Wooldridge, *Introductory Econometrics* (caps. 3–8) · Stock & Watson, *Introduction to Econometrics* (caps. 4–9) · Angrist & Pischke, *Mostly Harmless Econometrics* (cap. 3) · Card (1995), “Using Geographic Variation in College Proximity”.