Práctica Integradora en R (Parte 2)
Regresión Múltiple y Flujo Econométrico

Amaru Agüero

Doctorado en Ciencias de la Complejidad Social — CICS, UDD

27 de marzo de 2026

Universidad del Desarrollo
Facultad de Gobierno

Agenda de Hoy

- Regresión múltiple: especificación e interpretación
- Variables dummy y factores en R
- Términos de interacción
- Diagnósticos de multicolinealidad (VIF)
- Errores robustos con `sandwich` y `lmtest`
- Tablas de resultados con `stargazer`
- Flujo completo del análisis econométrico
- Ejercicio integrador final

Paquetes necesarios: `lmtest`, `sandwich`, `car`, `stargazer`, `ggplot2`

Regresión Múltiple (I): Modelo y Estimación

Modelo: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_k X_k + u$

```
# Regresi n  m ltiple  simple
modelo1 <- lm(salario ~ educacion + experiencia,
              data=datos)

# M  s  regresores
modelo2 <- lm(salario ~ educacion + experiencia +
                edad + genero, data=datos)

# Sintaxis alternativa (todos excepto una variable)
modelo3 <- lm(salario ~ . - id, data=datos)

# Mostrar resultados
summary(modelo1)
summary(modelo2)
```

Interpretación: β_j mide el cambio en Y cuando X_j aumenta 1 unidad, *ceteris paribus*.

Regresión Múltiple (II): Lectura de Resultados

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)     250.50     120.45   2.080   0.0400 *
educacion       315.80      42.10   7.503  2.1e-11***
experiencia     125.30      28.50   4.398  2.2e-05***
edad             45.20      15.60   2.897   0.0046 **
generoM         180.50      95.20   1.895   0.0610 .
---
Residual std. error: 385 on 95 DF
Multiple R-squared: 0.543, Adjusted R-squared: 0.522
F-statistic: 25.23 on 4 and 95 DF, p-value: 1.8e-14
```

- Un año adicional de educación: \$315.80 más (todo lo demás constante)
- Un año de experiencia: \$125.30 más
- Ser hombre (vs. mujer): \$180.50 más (no significativo a 5%)
- $R^2 = 0.543$: modelo explica 54.3% de variabilidad en salario

Variables Dummy: Creación y Uso

```
# Crear variable dummy manualmente
datos$mujer <- ifelse(datos$genero == "F", 1, 0)
datos$es_profesional <- ifelse(datos$educacion > 12, 1, 0)

# Factor autom tico (R crea dummies)
datos$genero <- factor(datos$genero)
# R crea: genero1 (Female), genero2 (Male)
# La primera es base, se omite (multicolinealidad)

# Especificar categor a base
datos$region <- factor(datos$region,
                       levels=c("Sur", "Centro", "Norte"))
# Sur es base

modelo_dummy <- lm(salario ~ genero + region, data=datos)
summary(modelo_dummy)
```

Nota: R omite automáticamente una categoría para evitar trampa de dummy (multicolinealidad perfecta).

Variables Dummy: Interpretación

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 1800.00     150.20  11.980  < 2e-16***
generoM      220.50      85.30   2.585   0.0109  *
regionCentro 150.00     100.50   1.493   0.1385
regionNorte  320.00     105.20   3.042   0.0030  **
```

- **Intercepto (1800):** Salario de mujer en Sur
- **generoM (220.50):** Hombres ganan $220.50 más que mujeres (Sur)
- **regionCentro (150):** Centro gana $150 más que Sur (mujeres)
- **regionNorte (320):** Norte gana $320 más que Sur (mujeres)

Regla: Categoría base = combinación de categorías omitidas

Interacciones (I): Especificación

Pregunta: ¿Difiere el retorno de educación por género?

```
# Interacci n entre educacion y genero
modelo_inter <- lm(salario ~ educacion * genero,
                   data=datos)

# Equivalente a:
modelo_inter2 <- lm(salario ~ educacion + genero +
                        educacion:genero,
                    data=datos)

# Interacci n entre dos variables continuas
modelo_inter3 <- lm(salario ~ educacion * experiencia,
                    data=datos)

# Acceder a coeficientes
coef(modelo_inter)
```

$*$ expande a efectos principales + interacción; : solo interacción.

Interacciones (II): Interpretación

```
Coefficients:
                  Estimate Std. Error t value Pr(>|t|)
(Intercept)       1200.00     180.50   6.650  1.2e-09***
educacion          280.50      35.20   7.970  1.8e-12***
generoM            150.00     220.30   0.681   0.4975
educacion:generoM  95.30      48.10   1.981   0.0505 .
```

Interpretación:

- **Mujeres:** cada año educación = \$280.50 más
- **Hombres:** cada año educación = \$280.50 + \$95.30 = \$375.80 más
- Diferencia: hombres tienen retorno 2.6% mayor por educación
- Significancia marginal ($p = 0.0505$): casi significativa

Diagnósticos (I): Factor de Inflación de Varianza (VIF)

Problema: ¿Las variables explicativas están muy correlacionadas?

```
library(car)

# VIF para cada regresor
vif(modelo2)
#  educacion  experiencia       edad     generoM
#       1.45        1.82       2.10        1.30

# Regla pr ctica: VIF > 5-10 sugiere multicolinealidad
# En nuestro caso: todo < 3, sin problemas

# Correlaci n entre regresores
cor(datos[, c("educacion", "experiencia", "edad")])
```

VIF bajo (1-2): No correlacionada con otros regresores

VIF alto (>5): Problema de multicolinealidad

Diagnósticos (II): Validación de Supuestos

```
# Gr ficos de diagn stico
par(mfrow=c(2,2))
plot(modelo2)

# Residuos
residuos <- residuals(modelo2)

# Test de normalidad (Shapiro-Wilk)
shapiro.test(residuos)

# Test de homocedasticidad (Breusch-Pagan)
library(lmtest)
bptest(modelo2)

# Test de autocorrelaci n (Durbin-Watson)
dwtest(modelo2)
```

Si p-value *pequeño:* rechazamos supuesto (problema potencial).

Revisar gráficos: residuos vs. ajustados, Q-Q normal.

Errores Robustos (I): Heterocedasticidad

Problema: ¿La varianza de residuos es constante?

```
library(sandwich)
library(lmtest)

# MCO est ndar
summary(modelo2)

# Errores robustos HC1 (White)
coeftest(modelo2, vcov=vcovHC(modelo2, type="HC1"))

# Errores robustos HC3 (m s conservador)
coeftest(modelo2, vcov=vcovHC(modelo2, type="HC3"))

# Alternativa: vcovHAC (heterocedasticidad + autocorrelaci n)
coeftest(modelo2, vcov=vcovHAC(modelo2))
```

Nota: Errores robustos NUNCA aumentan, solo cambian si homocedasticidad falla.

Errores Robustos (II): Extracción y Comparación

```r
# Extraer errores robustos
se_robust <- sqrt(diag(vcovHC(modelo2, type="HC1")))

# Crear tabla comparativa
data.frame(
  Coefficient = coef(modelo2),
  SE_MCO = summary(modelo2)$coefficients[,2],
  SE_Robust = se_robust
)

# Usar stargazer con errores robustos
library(stargazer)
stargazer(modelo2, se=list(se_robust), type="text")
```

Comparar errores estándar MCO vs. robustos para detectar homocedasticidad.

Tablas de Resultados (I): Stargazer

```
library(stargazer)

# Tabla simple
stargazer(modelo1, modelo2, type="text")

# Tabla LaTeX (para documentos)
stargazer(modelo1, modelo2,
          title="Resultados de Regresi n",
          label="tab:regresion",
          type="latex")

# Opciones personalizadas
stargazer(modelo1, modelo2,
          dep.var.labels="Salario (USD)",
          covariate.labels=c("Educaci n (a os)",
                             "Experiencia (a os)"),
          column.labels=c("Modelo 1", "Modelo 2"))
```

type="text" para consola, type="latex" para documentos.

Tablas de Resultados (II): Comparación de Modelos

```
# Comparar tres modelos con criterios de informaci n
stargazer(modelo1, modelo2, modelo3,
          title="Comparaci n: Especificaciones",
          omit.stat=c("LL","ser","f"),
          add.lines=list(c("AIC",
                           round(AIC(modelo1),2),
                           round(AIC(modelo2),2),
                           round(AIC(modelo3),2))),
          notes="Significancia: *** p<0.01, ** p<0.05, * p<0.1",
          type="latex")

# Con errores robustos
stargazer(modelo1, modelo2, modelo3,
          se=list(se_robust1, se_robust2, se_robust3),
          type="latex")
```

Facilita comparación entre especificaciones rivales e identificar modelo mejor especificado.

Flujo Completo del Análisis Econométrico

1. **Formulación teórica:** ¿Qué relación queremos estimar?
2. **Especificación del modelo:** $Y = \beta_0 + \beta_1 X_1 + \cdots + u$
3. **Recopilación y exploración de datos:** Calidad, valores faltantes, outliers
4. **Estimación MCO:** `lm()` y obtener coeficientes
5. **Diagnósticos de supuestos:** Normalidad, homocedasticidad, multicolinealidad
6. **Validación de especificación:** ¿Variables correctas? ¿Forma funcional?
7. **Correcciones:** Errores robustos, variables adicionales, transformaciones
8. **Presentación de resultados:** Tablas, gráficos, interpretación
9. **Robustez:** Verificar resultados con otras especificaciones

No es lineal: iteración es normal entre diagnósticos y especificación.

Flujo Práctico: Ejemplo Completo

```
datos <- read.csv("datos_laborales.csv"); str(datos)
modelo1 <- lm(log(salario) ~ educacion + experiencia, data=datos)
# Diagnostics
shapiro.test(residuals(modelo1)); bptest(modelo1); vif(modelo1)
# Improved model
modelo2 <- lm(log(salario) ~ educacion*genero +
              experiencia + I(experiencia^2), data=datos)
# Robust errors
coeftest(modelo2, vcov=vcovHC(modelo2, "HC1"))
stargazer(modelo1, modelo2, type="latex")
```

Ejercicio Integrador Final

Dataset: 200 individuos con educación, experiencia, género, sector.

Tareas:

1. Especificar modelo inicial: $\log(\text{salario}) = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exp} + u$
2. Estimar y diagnosticar (normalidad, homocedasticidad, VIF)
3. Agregar variables dummy: género, sector (3 sectores)
4. Incluir término de interacción: educación $\times$ género
5. Calcular errores robustos y comparar con MCO
6. Crear tabla en LaTeX con ambos modelos
7. Interpretar: ¿retorno de educación diferente por género?
8. Verificar robustez: cambiar especificación de forma funcional

Entregable: Script R + tabla LaTeX de resultados + 1 página de interpretación.

Resumen Curso: Sesiones 4-5

Competencias: Hypothesis tests, simple/multiple regression, dummy variables, diagnostics, robust errors, professional reporting

Próximos: Nonlinear models (logit/probit), time series, quantile regression, panel methods

¡Gracias! Preguntas...