

Sesión 1 · Estadística Descriptiva

Nivelación Estadística y Probabilidades — Doctorados en Políticas Públicas y en Ciencias de la Complejidad Social · Universidad del Desarrollo

Amaru Agüero Jiménez (a.agueroj@udd.cl)


marzo de 2026

Panorama de la sesión

Bloque	Concepto clave	Herramienta en R
Tipos de variables	Nominal, ordinal, discreta, continua	<code>str()</code> , <code>factor()</code>
Tendencia central	Media, mediana, moda, media recortada	<code>mean()</code> , <code>median()</code>
Dispersión	Varianza, DE, IQR, coeficiente de variación	<code>sd()</code> , <code>IQR()</code>
Posición	Cuartiles, z-scores, outliers	<code>quantile()</code> , <code>scale()</code>
Forma	Sesgo y curtosis	<code>skewness()</code> , <code>kurtosis()</code>
Visualización	Histograma, boxplot, dispersión, violín	<code>ggplot2</code>

i Datos de trabajo: gapminder (142 países, año 2007): esperanza de vida, PIB per cápita y población. En políticas públicas, describir bien los datos precede a cualquier evaluación de impacto.

Tipos de variables: el árbol de decisión



Ejemplos en políticas públicas y estadístico válido:

- **Nominal**: región, tipo de establecimiento → moda, proporciones
- **Ordinal**: quintil de ingreso, nivel educativo → mediana, percentiles
- **Discreta**: n° de hijos, delitos por comuna → media, tasas
- **Continua**: ingreso, esperanza de vida → media, DE y todo lo anterior

Escalas de medición y operaciones válidas

Escala	¿Orden?	¿Distancias?	¿Cero absoluto?	Ejemplo	Operación NO válida
Nominal	No	No	No	Partido político	Promediar categorías
Ordinal	Sí	No	No	Likert 1–5	“4 es el doble de 2”
Intervalo	Sí	Sí	No	Año, temperatura °C	Cocientes (“el doble de”)
Razón	Sí	Sí	Sí	Ingreso, población	—

! La escala determina la técnica: promediar una variable ordinal (p. ej., satisfacción 1–5) asume distancias iguales entre categorías — un supuesto, no un dato. Si la escala es solo ordinal, reporte medianas y proporciones.

El dataset: 142 países en 2007

```
glimpse(datos)
```

Rows: 142

Columns: 6

```
$ country    <fct> "Afghanistan", "Albania", "Algeria", "Angola", "Argentina", ~  
$ continent  <fct> Asia, Europe, Africa, Africa, Americas, Oceania, Europe, Asi~  
$ year       <int> 2007, 2007, 2007, 2007, 2007, 2007, 2007, 2007, 2007, 2007, ~  
$ lifeExp    <dbl> 43.828, 76.423, 72.301, 42.731, 75.320, 81.235, 79.829, 75.6~  
$ pop        <int> 31889923, 3600523, 33333216, 12420476, 40301927, 20434176, 8~  
$ gdpPercap  <dbl> 974.5803, 5937.0295, 6223.3675, 4797.2313, 12779.3796, 34435~
```

- country, continent: **nominales**
- year: cuantitativa de **intervalo**
- lifeExp, gdpPercap: **continuas de razón**
- pop: **discreta de razón**

Tendencia central: tres definiciones de “centro”

Media

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

- Usa toda la información
- Sensible a outliers
- Base de la inferencia

Mediana

$$x_{(n+1)/2}$$

- Parte la muestra en dos mitades
- Robusta a outliers
- Ideal para ingresos

Moda

- Valor más frecuente
- Única medida válida para nominales
- Puede no existir o haber varias


```
c(media = mean(datos$lifeExp), mediana = median(datos$lifeExp),  
  media_recortada_10 = mean(datos$lifeExp, trim = 0.10))
```

media
67.00742

mediana media_recortada_10
71.93550 68.11489

La media es frágil: un solo punto la arrastra

30 sueldos: 29 cercanos a 800 y un gerente con 8.000




Un outlier (3 % de los datos) desplaza la media un 30 %; la mediana casi no se mueve. Por eso los ingresos se reportan con **medianas**.

Media vs mediana: diagnóstico de asimetría

```
media <- mean(datos$lifeExp)
mediana <- median(datos$lifeExp)
round(c(media = media, mediana = mediana,
        diferencia = media - mediana), 2)
```

media	mediana	diferencia
67.01	71.94	-4.93

- Media $<$ mediana $\rightarrow$ cola izquierda (sesgo negativo)
- Media $>$ mediana $\rightarrow$ cola derecha (sesgo positivo)
- Media = mediana $\rightarrow$ distribución simétrica



Medidas de dispersión: cuánto varían los datos

Medida	Fórmula	Unidad	Robusta
Varianza	$s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$	unidades ²	No
Desviación estándar	$s = \sqrt{s^2}$	original	No
Rango	máx – mín	original	No
Rango intercuartílico	$IQR = Q_3 - Q_1$	original	Sí
Coef. de variación	$CV = s/\bar{x} \times 100$	% (adimensional)	No

```
round(c(sd = sd(datos$gdpPercap), IQR = IQR(datos$gdpPercap),  
      rango = diff(range(datos$gdpPercap))), 0)
```

```
sd    IQR rango  
12860 16384 49080
```




Dos poblaciones pueden compartir la media y ser radicalmente distintas en dispersión — y la dispersión es, muchas veces, el problema de política (desigualdad).

Misma media, distinta historia


Ambas comunas tienen media 500

Comuna A (DE = 30) Comuna B (DE = 120)



Una transferencia plana beneficia igual a ambas comunas; una focalizada requiere conocer la **dispersión**.

Cuartiles: la anatomía del boxplot




La caja concentra el 50 % central de los países; todo punto sobre $Q_3 + 1.5 \cdot IQR$ se marca como **outlier**.

Coeficiente de variación: comparar lo incomparable

```
cv <- function(x) sd(x) / mean(x) * 100  
round(c(cv_pib = cv(datos$gdpPerCap),  
        cv_vida = cv(datos$lifeExp)), 1)
```

```
cv_pib cv_vida  
110.1   18.0
```

- La DE del PIB (~12.860 USD) y la DE de la vida (~12 años) **no son comparables**: unidades distintas.
- El CV las vuelve comparables: el PIB varía **7 veces más** en términos relativos.



Z-scores: ¿qué tan lejos del promedio?

$$z_i = \frac{x_i - \bar{x}}{s} \Rightarrow \text{"a cuántas DE está } x_i \text{ de la media"}$$

```
datos <- datos %>% mutate(z_vida = (lifeExp - mean(lifeExp)) / sd(lifeExp))
datos %>% filter(abs(z_vida) > 2) %>%
  select(country, continent, lifeExp, z_vida) %>%
  arrange(z_vida) %>% mutate(z_vida = round(z_vida, 2))
```

A tibble: 6 x 4

	country	continent	lifeExp	z_vida
	<fct>	<fct>	<dbl>	<dbl>
1	Swaziland	Africa	39.6	-2.27
2	Mozambique	Africa	42.1	-2.06
3	Zambia	Africa	42.4	-2.04
4	Sierra Leone	Africa	42.6	-2.02
5	Lesotho	Africa	42.6	-2.02
6	Angola	Africa	42.7	-2.01

Con $|z| > 2$ detectamos los casos extremos: todos los países con esperanza de vida extremadamente baja en 2007 están en África subsahariana.

Outliers por regla IQR: código y resultado

```
Q1 <- quantile(datos$gdpPercap, .25)
Q3 <- quantile(datos$gdpPercap, .75)
lim <- Q3 + 1.5 * IQR(datos$gdpPercap)
datos %>% filter(gdpPercap > lim) %>%
  select(country, gdpPercap) %>%
  arrange(desc(gdpPercap)) %>% head(5)
```

A tibble: 4 x 2

	country	gdpPercap
	<fct>	<dbl>
1	Norway	49357.
2	Kuwait	47307.
3	Singapore	47143.
4	United States	42952.


Protocolo ante un outlier

- 1 **Verificar:** ¿error de digitación o valor real?
- 2 **Documentar:** nunca eliminar en silencio.
- 3 **Analizar con y sin:** reportar sensibilidad.
- 4 **Usar medidas robustas:** mediana, IQR, media recortada.

Histograma: la forma de la distribución

```
ggplot(datos, aes(x = lifeExp)) +  
  geom_histogram(bins = 20,  
                 fill = celeste,  
                 color = "white") +  
  geom_vline(xintercept = media,  
             color = rojo,  
             linetype = "dashed",  
             linewidth = 1) +  
  labs(x = "Esperanza de vida (años)",  
       y = "N° de países")
```


El número de bins cambia la historia: probar 2–3 valores antes de interpretar.



Boxplot comparativo: distribución por grupos

```
ggplot(datos,
  aes(x = continent, y = gdpPerCap,
    fill = continent)) +
  geom_boxplot(alpha = .7,
    outlier.color = rojo) +
  geom_jitter(width = .15, alpha = .3,
    size = 1) +
  scale_y_log10(labels = scales::comma) +
  labs(x = NULL, y = "PIB pc (USD, log)") +
  theme(legend.position = "none")
```


Compara **mediana, dispersión y outliers** de 5 grupos a la vez — imposible con una tabla de medias.



Dispersión: la relación entre dos variables

```
ggplot(datos,
  aes(x = gdpPercap, y = lifeExp,
    size = pop, color = continent)) +
  geom_point(alpha = .7) +
  scale_x_log10(labels = scales::comma) +
  scale_size(range = c(1, 12),
    guide = "none") +
  labs(x = "PIB pc (USD, log)",
    y = "Esperanza de vida (años)",
    color = NULL) +
  theme(legend.position = "bottom")
```


Relación **logarítmica**: cada duplicación del PIB se asocia a una ganancia similar en años de vida.



Violín + boxplot: densidad y resumen a la vez

```
ggplot(datos,
  aes(x = continent, y = lifeExp,
    fill = continent)) +
  geom_violin(alpha = .5, color = NA) +
  geom_boxplot(width = .15,
    fill = "white", alpha = .8) +
  labs(x = NULL,
    y = "Esperanza de vida (años)") +
  theme(legend.position = "none")
```

El violín muestra lo que el boxplot esconde:
bimodalidad dentro de África (dos grupos de
países claramente distintos).



¿Qué gráfico usar? Decisión según tipo de variable

Pregunta	Variables	Gráfico
¿Cómo se distribuye X?	1 continua	Histograma, densidad
¿Difiere X entre grupos?	1 continua + 1 nominal	Boxplot, violín
¿Se asocian X e Y?	2 continuas	Dispersión (+ escala log si hay sesgo)
¿Cómo se reparte una categoría?	1 nominal	Barras (nunca torta con >4 categorías)
¿Cómo evoluciona X?	continua + tiempo	Líneas

 Errores frecuentes: truncar el eje Y en gráficos de barras, usar torta para comparar magnitudes similares, graficar medias sin mostrar dispersión.

Tabla resumen por grupo: el estándar de reporte

```
datos %>% group_by(continent) %>%  
  summarise(n = n(), media = mean(lifeExp), mediana = median(lifeExp),  
            de = sd(lifeExp), iqr = IQR(lifeExp), cv = sd(lifeExp)/mean(lifeExp)*100) %>%  
  mutate(across(where(is.numeric), ~round(.x, 1))) %>%  
  kable()
```

continent	n	media	mediana	de	iqr	cv
Africa	52	54.8	52.9	9.6	11.6	17.6
Americas	25	73.6	72.9	4.4	4.6	6.0
Asia	33	70.7	72.4	8.0	10.2	11.3
Europe	30	77.6	78.6	3.0	4.8	3.8
Oceania	2	80.7	80.7	0.7	0.5	0.9


Oceanía tiene solo **n = 2** países: su DE (0.5) no es comparable con la de África (n = 52). Reportar siempre el **n** junto a cada estadístico.

Sesgo y curtosis: cuantificar la forma


```
round(c(sesgo_pib = skewness(datos$gdpPerCap),  
      curtosis_pib = kurtosis(datos$gdpPerCap),  
      sesgo_vida = skewness(datos$lifeExp)), 2)
```

sesgo_pib	curtosis_pib	sesgo_vida
1.21	3.30	-0.68

- Sesgo > 0 : cola derecha; < 0 : cola izquierda
- Curtosis > 3 : colas más pesadas que la normal
- Normal de referencia: sesgo 0, curtosis 3



Transformación logarítmica: domar el sesgo



El logaritmo comprime la cola derecha y convierte diferencias absolutas en **relativas** — la métrica natural para ingresos y precios.

Correlación: Pearson mide relaciones lineales

```
round(c(
  pearson = cor(datos$gdpPercap, datos$lifeExp),
  pearson_log = cor(log(datos$gdpPercap),
    datos$lifeExp),
  spearman = cor(datos$gdpPercap, datos$lifeExp,
    method = "spearman")), 3)
```

pearson	pearson_log	spearman
0.679	0.809	0.857

! r solo mide asociación **lineal**: $r \approx 0$ no descarta una relación fuerte no lineal (p. ej., una U invertida). Siempre graficar antes de calcular.

- Pearson sube de **0.68 a 0.81** al usar log: la relación es lineal en logs.
- Spearman (rangos) ya la captura sin transformar: robusto a no-linealidad monótona.
- Correlación **no** implica causalidad: países ricos también invierten más en salud y educación.

Caso: brechas entre continentes

```
datos %>% group_by(continent) %>%  
  summarise(vida = mean(lifeExp), pib = mean(gdpPercap)) %>%  
  mutate(brecha_vida = round(vida - max(vida), 1),  
         brecha_pib = round(pib - max(pib), 0),  
         across(c(vida, pib), ~round(.x, 1))) %>% kable()
```

continent	vida	pib	brecha_vida	brecha_pib
Africa	54.8	3089.0	-25.9	-26721
Americas	73.6	11003.0	-7.1	-18807
Asia	70.7	12473.0	-10.0	-17337
Europe	77.6	25054.5	-3.1	-4756
Oceania	80.7	29810.2	0.0	0

África está **29 años** de vida y **28.000 USD** de PIB por debajo de Oceanía: la brecha descriptiva que motiva las preguntas causales de las próximas sesiones.

Errores comunes en estadística descriptiva

Error	Consecuencia	Corrección
Reportar media de ingresos	Sobreestima el “caso típico”	Mediana + IQR
Promediar escalas ordinales	Asume distancias iguales	Mediana, proporciones
Eliminar outliers sin documentar	Resultados no reproducibles	Análisis de sensibilidad
Comparar DE entre unidades distintas	Comparación sin sentido	Coefficiente de variación
Tabla de medias sin n ni DE	Oculto precisión y dispersión	n, media, DE, mediana
Interpretar r como causalidad	Conclusiones de política erradas	Diseños causales (curso de econometría)

Síntesis: qué debe salir en su reporte

Checklist del análisis descriptivo

- 1 Clasificar cada variable (tipo y escala)
- 2 n, media, mediana, DE, IQR **por grupo**
- 3 Histograma o densidad de las variables clave
- 4 Boxplot/violín para comparaciones entre grupos
- 5 Outliers identificados y documentados
- 6 Transformaciones justificadas (log para sesgo)
- 7 Correlaciones acompañadas de su gráfico

Funciones R de esta sesión

mean() median() sd() var() IQR()
quantile() scale() cor() skewness()
kurtosis() summarise() group_by()
geom_histogram() geom_boxplot()
geom_violin() geom_point()

Próxima sesión: probabilidad condicional y Teorema de Bayes.

Ejercicio para practicar (30 min)

Con `gapminder` filtrado al año **1977**:

- 1 Clasifique las 6 variables por tipo y escala.
- 2 Calcule media, mediana, DE, IQR y CV de `gdpPercap` por continente. ¿Qué continente es más desigual en términos relativos?
- 3 Detecte outliers de `pop` con la regla IQR. ¿Elimina o conserva? Justifique.
- 4 Construya el scatter PIB–esperanza de vida con escala log. ¿Se mantiene el patrón de 2007?
- 5 Compare `cor()` de Pearson y Spearman con y sin log. Explique las diferencias.

i Referencias: Wickham & Grolemund, *R for Data Science* (cap. 7, EDA) · Illowsky & Dean, *Introductory Statistics* (caps. 1–2) · Documentación de `gapminder` y `ggplot2`.