Sesión 2: Fundamentos de Probabilidad

Amaru Agüero

Doctorado en Ciencias de la Complejidad Social — CICS, UDD

18 de marzo de 2026

Universidad del Desarrollo
Facultad de Gobierno

Agenda de la Sesión

1. Conceptos Fundamentales
2. Probabilidad Condicional e Independencia
3. Teorema de Bayes
4. Variables Aleatorias
5. Implementación en R
6. Ejercicio Práctico

Experimento Aleatorio y Espacio Muestral

Experimento Aleatorio

Proceso cuyos resultados no pueden predecirse con certeza, pero cuyos resultados posibles son conocidos.

Experimento Aleatorio y Espacio Muestral

Experimento Aleatorio

Proceso cuyos resultados no pueden predecirse con certeza, pero cuyos resultados posibles son conocidos.

- Lanzar una moneda
- Registrar temperatura diaria
- Encuesta sobre intención de voto

Experimento Aleatorio y Espacio Muestral

Experimento Aleatorio

Proceso cuyos resultados no pueden predecirse con certeza, pero cuyos resultados posibles son conocidos.

- Lanzar una moneda
- Registrar temperatura diaria
- Encuesta sobre intención de voto

Espacio Muestral

Conjunto de todos los resultados posibles de un experimento aleatorio: Ω

Ω (Espacio Muestral)

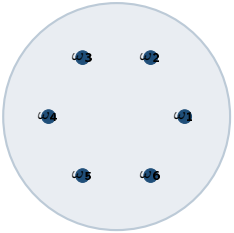

Experimento Aleatorio y Espacio Muestral

Experimento Aleatorio

Proceso cuyos resultados no pueden predecirse con certeza, pero cuyos resultados posibles son conocidos.

- Lanzar una moneda
- Registrar temperatura diaria
- Encuesta sobre intención de voto

Espacio Muestral

Conjunto de todos los resultados posibles de un experimento aleatorio: Ω

Ω (Espacio Muestral)

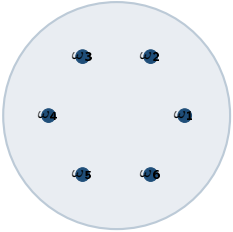

Ejemplo: Lanzar un dado

$$\Omega = \{1, 2, 3, 4, 5, 6\}, \quad |\Omega| = 6$$

Eventos y Operaciones

Evento

Subconjunto del espacio muestral: $A \subseteq \Omega$

Eventos y Operaciones

Evento

Subconjunto del espacio muestral: $A \subseteq \Omega$

- Evento seguro: $A = \Omega$
- Evento imposible: $A = \emptyset$
- Evento elemental: $A = \{\omega\}$

Eventos y Operaciones

Evento

Subconjunto del espacio muestral: $A \subseteq \Omega$

- Evento seguro: $A = \Omega$
- Evento imposible: $A = \emptyset$
- Evento elemental: $A = \{\omega\}$

Operaciones entre Eventos

- Unión: $A \cup B$ (ocurre A o B)
- Intersección: $A \cap B$ (ocurren A y B)
- Complemento: A^c (no ocurre A)

Diagrama de Venn

Eventos y Operaciones

Evento

Subconjunto del espacio muestral: $A \subseteq \Omega$

- Evento seguro: $A = \Omega$
- Evento imposible: $A = \emptyset$
- Evento elemental: $A = \{\omega\}$

Operaciones entre Eventos

- Unión: $A \cup B$ (ocurre A o B)
- Intersección: $A \cap B$ (ocurren A y B)
- Complemento: A^c (no ocurre A)

Diagrama de Venn

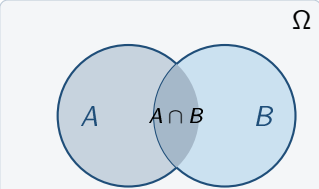

$A \cup B$: toda el área coloreada

Eventos y Operaciones

Evento

Subconjunto del espacio muestral: $A \subseteq \Omega$

- Evento seguro: $A = \Omega$
- Evento imposible: $A = \emptyset$
- Evento elemental: $A = \{\omega\}$

Operaciones entre Eventos

- Unión: $A \cup B$ (ocurre A o B)
- Intersección: $A \cap B$ (ocurren A y B)
- Complemento: A^c (no ocurre A)

Diagrama de Venn

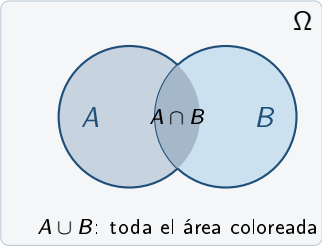

Propiedades (Leyes de De Morgan):

$$(A \cup B)^c = A^c \cap B^c$$
$$(A \cap B)^c = A^c \cup B^c$$

Axiomas de Kolmogorov

Sea $P : \mathcal{F} \to [0, 1]$ una medida de probabilidad sobre Ω.

Axiomas de Kolmogorov

Sea $P : \mathcal{F} \to [0, 1]$ una medida de probabilidad sobre Ω.

Axioma 1: No-negatividad

Para todo evento $A \in \mathcal{F}$: $P(A) \geq 0$

Axiomas de Kolmogorov

Sea $P : \mathcal{F} \to [0, 1]$ una medida de probabilidad sobre Ω.

Axioma 1: No-negatividad

Para todo evento $A \in \mathcal{F}$: $P(A) \geq 0$

Axioma 2: Probabilidad del espacio total

$P(\Omega) = 1$

Axiomas de Kolmogorov

Sea $P : \mathcal{F} \to [0, 1]$ una medida de probabilidad sobre Ω.

Axioma 1: No-negatividad

Para todo evento $A \in \mathcal{F}$: $P(A) \geq 0$

Axioma 2: Probabilidad del espacio total

$P(\Omega) = 1$

Axioma 3: Aditividad (σ-aditividad)

Para eventos disjuntos $A_i \cap A_j = \emptyset$ $(i \neq j)$:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

Axiomas de Kolmogorov

Sea $P : \mathcal{F} \to [0, 1]$ una medida de probabilidad sobre Ω.

Axioma 1: No-negatividad

Para todo evento $A \in \mathcal{F}$: $P(A) \geq 0$

Axioma 2: Probabilidad del espacio total

$P(\Omega) = 1$

Axioma 3: Aditividad (σ-aditividad)

Para eventos disjuntos $A_i \cap A_j = \emptyset$ $(i \neq j)$:

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

Consecuencias

$P(\emptyset) = 0, \quad P(A) \leq 1, \quad P(A_1 \cup \cdots \cup A_n) = \sum_i P(A_i)$ (finitos disjuntos)

Regla de la Suma y del Complemento

Regla de la Suma (Inclusión-Exclusión)

Para dos eventos cualesquiera A y B:

Regla de la Suma y del Complemento

Regla de la Suma (Inclusión-Exclusión)

Para dos eventos cualesquiera A y B:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Regla de la Suma y del Complemento

Regla de la Suma (Inclusión-Exclusión)

Para dos eventos cualesquiera A y B:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Demostración intuitiva

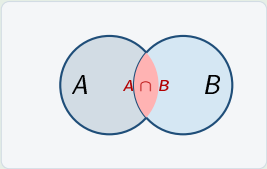

Si contamos $P(A) + P(B)$, la intersección se suma dos veces, por eso restamos $P(A \cap B)$.

Regla de la Suma y del Complemento

Regla de la Suma (Inclusión-Exclusión)

Para dos eventos cualesquiera A y B:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Demostración intuitiva

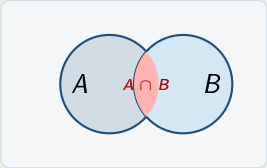

Si contamos $P(A) + P(B)$, la intersección se suma dos veces, por eso restamos $P(A \cap B)$.

Regla del Complemento

$P(A^c) = 1 - P(A)$ **Ejemplo:** Si 35% apoyan una política, $P(\text{no apoyan}) = 0.65$

Probabilidad Condicional

Definición

La probabilidad condicional de evento A dado que ocurrió B es:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

Probabilidad Condicional

Definición

La probabilidad condicional de evento A dado que ocurrió B es:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

Interpretación: Al saber que B ocurrió, el espacio muestral se reduce a B. Preguntamos: ¿cuál es la probabilidad de que A ocurra dentro de ese espacio reducido?

Probabilidad Condicional

Definición

La probabilidad condicional de evento A dado que ocurrió B es:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

Interpretación: Al saber que B ocurrió, el espacio muestral se reduce a B. Preguntamos: ¿cuál es la probabilidad de que A ocurra dentro de ese espacio reducido?

Ejemplo: Género y Educación

En una universidad:

- 40% estudia Ingeniería
- 25% de Ingeniería son mujeres
- $P(\text{Mujer}|\text{Ingeniería}) = 0.25$

Probabilidad Condicional

Definición

La probabilidad condicional de evento A dado que ocurrió B es:

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

Interpretación: Al saber que B ocurrió, el espacio muestral se reduce a B. Preguntamos: ¿cuál es la probabilidad de que A ocurra dentro de ese espacio reducido?

Ejemplo: Género y Educación

En una universidad:

- 40% estudia Ingeniería
- 25% de Ingeniería son mujeres
- $P(\text{Mujer}|\text{Ingeniería}) = 0.25$

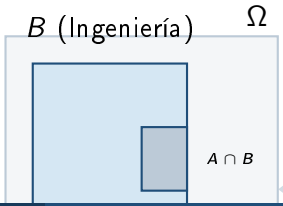

Independencia de Eventos

Definición

Dos eventos A y B son **independientes** si:

$$P(A \cap B) = P(A) \cdot P(B)$$

O equivalentemente: $P(A|B) = P(A)$ y $P(B|A) = P(B)$

Independencia de Eventos

Definición

Dos eventos A y B son **independientes** si:

$$P(A \cap B) = P(A) \cdot P(B)$$

O equivalentemente: $P(A|B) = P(A)$ y $P(B|A) = P(B)$

Interpretación: Saber que B ocurrió no cambia la probabilidad de que A ocurra.

Independencia de Eventos

Definición

Dos eventos A y B son **independientes** si:

$$P(A \cap B) = P(A) \cdot P(B)$$

O equivalentemente: $P(A|B) = P(A)$ y $P(B|A) = P(B)$

Interpretación: Saber que B ocurrió no cambia la probabilidad de que A ocurra.

Ejemplo: Independencia

Lanzar una moneda dos veces: $A =$ "Primera cara", $B =$ "Segunda cara".
$P(A) = 0.5$, $P(B) = 0.5$, $P(A \cap B) = 0.25 = P(A) \cdot P(B)$ ✓
Son independientes: el primer resultado no afecta el segundo.

Independencia de Eventos

Definición

Dos eventos A y B son **independientes** si:

$$P(A \cap B) = P(A) \cdot P(B)$$

O equivalentemente: $P(A|B) = P(A)$ y $P(B|A) = P(B)$

Interpretación: Saber que B ocurrió no cambia la probabilidad de que A ocurra.

Ejemplo: Independencia

Lanzar una moneda dos veces: $A =$ "Primera cara", $B =$ "Segunda cara".
$P(A) = 0.5$, $P(B) = 0.5$, $P(A \cap B) = 0.25 = P(A) \cdot P(B)$ ✓
Son independientes: el primer resultado no afecta el segundo.

Atención: Correlación Espuria

En ciencias sociales, es fácil confundir correlación con causalidad. **Ejemplo:** Celulares y casos de cáncer aumentan juntos, pero dependen de una tercera variable (tiempo).

Regla del Producto

Regla del Producto

$$P(A \cap B) = P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

Para múltiples eventos:

$$P(A_1 \cap \cdots \cap A_n) = P(A_1) \cdot P(A_2|A_1) \cdot P(A_3|A_1 \cap A_2) \cdots$$

Regla del Producto

Regla del Producto

$$P(A \cap B) = P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

Para múltiples eventos:

$$P(A_1 \cap \cdots \cap A_n) = P(A_1) \cdot P(A_2|A_1) \cdot P(A_3|A_1 \cap A_2) \cdots$$

Ejemplo: Muestreo sin reemplazo

Extraer 2 cartas de una baraja (52 cartas):

- $P(\text{As en } 1^{\underline{a}}) = \frac{4}{52}$

Regla del Producto

Regla del Producto

$$P(A \cap B) = P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

Para múltiples eventos:

$$P(A_1 \cap \cdots \cap A_n) = P(A_1) \cdot P(A_2|A_1) \cdot P(A_3|A_1 \cap A_2) \cdots$$

Ejemplo: Muestreo sin reemplazo

Extraer 2 cartas de una baraja (52 cartas):

- $P(\text{As en } 1^{\underline{a}}) = \frac{4}{52}$
- $P(\text{As en } 2^{\underline{a}} | \text{As en } 1^{\underline{a}}) = \frac{3}{51}$

Regla del Producto

Regla del Producto

$$P(A \cap B) = P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

Para múltiples eventos:

$$P(A_1 \cap \cdots \cap A_n) = P(A_1) \cdot P(A_2|A_1) \cdot P(A_3|A_1 \cap A_2) \cdots$$

Ejemplo: Muestreo sin reemplazo

Extraer 2 cartas de una baraja (52 cartas):

- $P(\text{As en } 1^{\underline{a}}) = \frac{4}{52}$
- $P(\text{As en } 2^{\underline{a}} | \text{As en } 1^{\underline{a}}) = \frac{3}{51}$
- $P(\text{Dos ases}) = \frac{4}{52} \times \frac{3}{51} \approx 0.0045$

Regla del Producto

Regla del Producto

$$P(A \cap B) = P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

Para múltiples eventos:

$$P(A_1 \cap \cdots \cap A_n) = P(A_1) \cdot P(A_2|A_1) \cdot P(A_3|A_1 \cap A_2) \cdots$$

Ejemplo: Muestreo sin reemplazo

Extraer 2 cartas de una baraja (52 cartas):

- $P(\text{As en } 1^{\underline{a}}) = \frac{4}{52}$
- $P(\text{As en } 2^{\underline{a}} | \text{As en } 1^{\underline{a}}) = \frac{3}{51}$
- $P(\text{Dos ases}) = \frac{4}{52} \times \frac{3}{51} \approx 0.0045$

Caso especial (independientes): $P(A \cap B) = P(A) \cdot P(B)$

Derivación del Teorema de Bayes

Comenzamos con la regla del producto:

Derivación del Teorema de Bayes

Comenzamos con la regla del producto:

$$P(A \cap B) = P(A|B) \cdot P(B)$$
$$P(A \cap B) = P(B|A) \cdot P(A)$$

Derivación del Teorema de Bayes

Comenzamos con la regla del producto:

$$P(A \cap B) = P(A|B) \cdot P(B)$$
$$P(A \cap B) = P(B|A) \cdot P(A)$$

Igualando ambas:

$$P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

Derivación del Teorema de Bayes

Comenzamos con la regla del producto:

$$P(A \cap B) = P(A|B) \cdot P(B)$$
$$P(A \cap B) = P(B|A) \cdot P(A)$$

Igualando ambas:

$$P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

Despejando:

$$\boxed{P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}}$$

Derivación del Teorema de Bayes

Comenzamos con la regla del producto:

$$P(A \cap B) = P(A|B) \cdot P(B)$$
$$P(A \cap B) = P(B|A) \cdot P(A)$$

Igualando ambas:

$$P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

Despejando:

$$\boxed{P(B|A) = \frac{P(A|B) \cdot P(B)}{P(A)}}$$

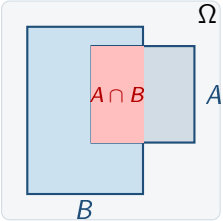

Nomenclatura: $P(B)$=a priori, $P(A|B)$=verosimilitud, $P(A)$=evidencia, $P(B|A)$=a posteriori

Teorema de Bayes Generalizado

Ley de Probabilidad Total

Si $B_1, B_2, \ldots, B_k$ particiona el espacio muestral:

$$P(A) = \sum_{i=1}^{k} P(A|B_i) \cdot P(B_i)$$

Teorema de Bayes Generalizado

Ley de Probabilidad Total

Si $B_1, B_2, \ldots, B_k$ particiona el espacio muestral:

$$P(A) = \sum_{i=1}^{k} P(A|B_i) \cdot P(B_i)$$

Teorema de Bayes (forma general)

$$P(B_j|A) = \frac{P(A|B_j) \cdot P(B_j)}{\sum_{i=1}^{k} P(A|B_i) \cdot P(B_i)}$$

Teorema de Bayes Generalizado

Ley de Probabilidad Total

Si $B_1, B_2, \ldots, B_k$ particiona el espacio muestral:

$$P(A) = \sum_{i=1}^{k} P(A|B_i) \cdot P(B_i)$$

Teorema de Bayes (forma general)

$$P(B_j|A) = \frac{P(A|B_j) \cdot P(B_j)}{\sum_{i=1}^{k} P(A|B_i) \cdot P(B_i)}$$

Idea fundamental: Actualizar creencias previas a luz de nueva evidencia.

Teorema de Bayes Generalizado

Ley de Probabilidad Total

Si $B_1, B_2, \ldots, B_k$ particiona el espacio muestral:

$$P(A) = \sum_{i=1}^{k} P(A|B_i) \cdot P(B_i)$$

Teorema de Bayes (forma general)

$$P(B_j|A) = \frac{P(A|B_j) \cdot P(B_j)}{\sum_{i=1}^{k} P(A|B_i) \cdot P(B_i)}$$

Idea fundamental: Actualizar creencias previas a luz de nueva evidencia.

Aplicación en ciencias sociales

A priori: creencias antes de datos $\rightarrow$ **Datos:** nueva información $\rightarrow$ **A posteriori:** creencias actualizadas. Fundamento del análisis Bayesiano.

Ejemplo Aplicado: Prueba Diagnóstica

Escenario: Un test médico para detectar una enfermedad.

Ejemplo Aplicado: Prueba Diagnóstica

Escenario: Un test médico para detectar una enfermedad.
Información dada:

- Prevalencia: $P(\text{Enfermo}) = 0.01$ (1%)
- Sensibilidad: $P(\text{Positivo}|\text{Enfermo}) = 0.95$
- Especificidad: $P(\text{Negativo}|\text{Sano}) = 0.90$

Ejemplo Aplicado: Prueba Diagnóstica

Escenario: Un test médico para detectar una enfermedad.
Información dada:

- Prevalencia: $P(\text{Enfermo}) = 0.01$ (1%)
- Sensibilidad: $P(\text{Positivo}|\text{Enfermo}) = 0.95$
- Especificidad: $P(\text{Negativo}|\text{Sano}) = 0.90$

Pregunta: Si da positivo, ¿probabilidad de estar realmente enfermo?

Ejemplo Aplicado: Prueba Diagnóstica

Escenario: Un test médico para detectar una enfermedad.
Información dada:

- Prevalencia: $P(\text{Enfermo}) = 0.01$ (1%)
- Sensibilidad: $P(\text{Positivo}|\text{Enfermo}) = 0.95$
- Especificidad: $P(\text{Negativo}|\text{Sano}) = 0.90$

Pregunta: Si da positivo, ¿probabilidad de estar realmente enfermo?
Solución: Probabilidad total: $P(\text{Pos}) = 0.95 \times 0.01 + 0.10 \times 0.99 = 0.1085$

Ejemplo Aplicado: Prueba Diagnóstica

Escenario: Un test médico para detectar una enfermedad.
Información dada:

- Prevalencia: $P(\text{Enfermo}) = 0.01$ (1%)
- Sensibilidad: $P(\text{Positivo}|\text{Enfermo}) = 0.95$
- Especificidad: $P(\text{Negativo}|\text{Sano}) = 0.90$

Pregunta: Si da positivo, ¿probabilidad de estar realmente enfermo?
Solución: Probabilidad total: $P(\text{Pos}) = 0.95 \times 0.01 + 0.10 \times 0.99 = 0.1085$
Aplicamos Bayes: $P(\text{Enf}|\text{Pos}) = \frac{0.95 \times 0.01}{0.1085} \approx 0.0876$

Resultado: Solo 8.76% de probabilidad, a pesar de test con 95% sensibilidad.

Concepto de Variable Aleatoria

Definición

Una **variable aleatoria** es una función que asigna un número real a cada resultado en el espacio muestral:

$$X : \Omega \to \mathbb{R}$$

Concepto de Variable Aleatoria

Definición

Una **variable aleatoria** es una función que asigna un número real a cada resultado en el espacio muestral:

$$X : \Omega \to \mathbb{R}$$

Ejemplos

- Lanzar un dado: $X =$ resultado $= 1, 2, 3, 4, 5, 6$
- Encuesta: $X =$ número de personas que apoyan una medida
- Ingresos familiares: $X =$ ingreso mensual en pesos
- Temperatura diaria: $X =$ temperatura máxima en °C

Concepto de Variable Aleatoria

Definición

Una **variable aleatoria** es una función que asigna un número real a cada resultado en el espacio muestral:

$$X : \Omega \to \mathbb{R}$$

Ejemplos

- Lanzar un dado: $X =$ resultado $= 1, 2, 3, 4, 5, 6$
- Encuesta: $X =$ número de personas que apoyan una medida
- Ingresos familiares: $X =$ ingreso mensual en pesos
- Temperatura diaria: $X =$ temperatura máxima en °C

Variable Aleatoria Discreta

Variable Aleatoria Continua

Distribuciones de Probabilidad: Caso Discreto

Función de Masa de Probabilidad (PMF)

Para variable aleatoria discreta X:

$$P(X = x_i) = p_i, \quad \sum_i p_i = 1$$

Distribuciones de Probabilidad: Caso Discreto

Función de Masa de Probabilidad (PMF)

Para variable aleatoria discreta X:

$$P(X = x_i) = p_i, \quad \sum_i p_i = 1$$

Ejemplo: Lanzar dos dados

Sea X = suma de los dos dados. Valores: 2, 3, ..., 12

x	2	3	4	5	6	7	8	9	10	11	12
$P(X = x)$	1/36	2/36	3/36	4/36	5/36	6/36	5/36	4/36	3/36	2/36	1/36

Distribuciones de Probabilidad: Caso Discreto

Función de Masa de Probabilidad (PMF)

Para variable aleatoria discreta X:

$$P(X = x_i) = p_i, \quad \sum_i p_i = 1$$

Ejemplo: Lanzar dos dados

Sea X = suma de los dos dados. Valores: 2, 3, ..., 12

x	2	3	4	5	6	7	8	9	10	11	12
$P(X = x)$	1/36	2/36	3/36	4/36	5/36	6/36	5/36	4/36	3/36	2/36	1/36

Función de Distribución Acumulada (CDF)

$F(x) = P(X \leq x) = \sum_{x_i \leq x} P(X = x_i)$
F es no-decreciente, $\lim_{x \to -\infty} F(x) = 0$, $\lim_{x \to \infty} F(x) = 1$

Distribuciones de Probabilidad: Caso Continuo

Función de Densidad de Probabilidad (PDF)

Para variable aleatoria continua X:

$$f(x) \geq 0, \quad \int_{-\infty}^{\infty} f(x)\, dx = 1$$

Probabilidad en un intervalo: $P(a \leq X \leq b) = \int_a^b f(x)\, dx$

Distribuciones de Probabilidad: Caso Continuo

Función de Densidad de Probabilidad (PDF)

Para variable aleatoria continua X:

$$f(x) \geq 0, \quad \int_{-\infty}^{\infty} f(x)\, dx = 1$$

Probabilidad en un intervalo: $P(a \leq X \leq b) = \int_a^b f(x)\, dx$

Nota: Para variable continua, $P(X = x) = 0$.

Distribuciones de Probabilidad: Caso Continuo

Función de Densidad de Probabilidad (PDF)

Para variable aleatoria continua X:

$$f(x) \geq 0, \quad \int_{-\infty}^{\infty} f(x)\,dx = 1$$

Probabilidad en un intervalo: $P(a \leq X \leq b) = \int_a^b f(x)\,dx$

Nota: Para variable continua, $P(X = x) = 0$.

Función de Distribución Acumulada (CDF)

$$F(x) = \int_{-\infty}^{x} f(t)\,dt, \quad \frac{dF}{dx} = f(x)$$

Distribuciones de Probabilidad: Caso Continuo

Función de Densidad de Probabilidad (PDF)

Para variable aleatoria continua X:

$$f(x) \geq 0, \quad \int_{-\infty}^{\infty} f(x)\,dx = 1$$

Probabilidad en un intervalo: $P(a \leq X \leq b) = \int_a^b f(x)\,dx$

Nota: Para variable continua, $P(X = x) = 0$.

Función de Distribución Acumulada (CDF)

$$F(x) = \int_{-\infty}^{x} f(t)\,dt, \quad \frac{dF}{dx} = f(x)$$

Ejemplo: Distribución Normal

$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$, parámetros: μ (media), σ (desviación).

Valor Esperado (Esperanza)

Definición: Caso Discreto

$E(X) = \mu = \sum_i x_i \cdot P(X = x_i)$

Valor Esperado (Esperanza)

Definición: Caso Discreto

$E(X) = \mu = \sum_i x_i \cdot P(X = x_i)$

Definición: Caso Continuo

$E(X) = \mu = \int_{-\infty}^{\infty} x \cdot f(x)\, dx$

Valor Esperado (Esperanza)

Definición: Caso Discreto

$E(X) = \mu = \sum_i x_i \cdot P(X = x_i)$

Definición: Caso Continuo

$E(X) = \mu = \int_{-\infty}^{\infty} x \cdot f(x)\, dx$

Interpretación: Valor promedio. Centro de gravedad de la distribución.

Valor Esperado (Esperanza)

Definición: Caso Discreto

$E(X) = \mu = \sum_i x_i \cdot P(X = x_i)$

Definición: Caso Continuo

$E(X) = \mu = \int_{-\infty}^{\infty} x \cdot f(x)\, dx$

Interpretación: Valor promedio. Centro de gravedad de la distribución.

Propiedades

- $E(c) = c$ (constante), $E(aX + b) = aE(X) + b$ (linealidad)
- $E(X + Y) = E(X) + E(Y)$ (aditividad)
- Si X, Y independientes: $E(XY) = E(X)E(Y)$

Valor Esperado (Esperanza)

Definición: Caso Discreto

$E(X) = \mu = \sum_i x_i \cdot P(X = x_i)$

Definición: Caso Continuo

$E(X) = \mu = \int_{-\infty}^{\infty} x \cdot f(x)\, dx$

Interpretación: Valor promedio. Centro de gravedad de la distribución.

Propiedades

- $E(c) = c$ (constante), $E(aX + b) = aE(X) + b$ (linealidad)
- $E(X + Y) = E(X) + E(Y)$ (aditividad)
- Si X, Y independientes: $E(XY) = E(X)E(Y)$

Ejemplo (dado): $E(X) = \frac{1+2+\cdots+6}{6} = 3.5$

Varianza y Desviación Estándar

Varianza

Dispersión alrededor de la media:

$$\mathrm{Var}(X) = \sigma^2 = E[(X-\mu)^2] = E(X^2) - [E(X)]^2$$

Varianza y Desviación Estándar

Varianza

Dispersión alrededor de la media:

$$\mathrm{Var}(X) = \sigma^2 = E[(X-\mu)^2] = E(X^2) - [E(X)]^2$$

Unidades: Cuadradas (si X en pesos, $\mathrm{Var}(X)$ en pesos^2)

Varianza y Desviación Estándar

Varianza

Dispersión alrededor de la media:

$$\mathrm{Var}(X) = \sigma^2 = E[(X-\mu)^2] = E(X^2) - [E(X)]^2$$

Unidades: Cuadradas (si X en pesos, $\mathrm{Var}(X)$ en pesos^2)

Desviación Estándar

$\sigma = \sqrt{\mathrm{Var}(X)}$ — mismo tipo de unidades que X.

Varianza y Desviación Estándar

Varianza

Dispersión alrededor de la media:

$$\mathrm{Var}(X) = \sigma^2 = E[(X-\mu)^2] = E(X^2) - [E(X)]^2$$

Unidades: Cuadradas (si X en pesos, $\mathrm{Var}(X)$ en pesos^2)

Desviación Estándar

$\sigma = \sqrt{\mathrm{Var}(X)}$ — mismo tipo de unidades que X.

Propiedades

- $\mathrm{Var}(c) = 0$
- $\mathrm{Var}(aX + b) = a^2\mathrm{Var}(X)$
- Si independientes: $\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$

Varianza y Desviación Estándar

Varianza

Dispersión alrededor de la media:

$$\mathrm{Var}(X) = \sigma^2 = E[(X-\mu)^2] = E(X^2) - [E(X)]^2$$

Unidades: Cuadradas (si X en pesos, $\mathrm{Var}(X)$ en pesos^2)

Desviación Estándar

$\sigma = \sqrt{\mathrm{Var}(X)}$ — mismo tipo de unidades que X.

Propiedades

- $\mathrm{Var}(c) = 0$
- $\mathrm{Var}(aX + b) = a^2\mathrm{Var}(X)$
- Si independientes: $\mathrm{Var}(X + Y) = \mathrm{Var}(X) + \mathrm{Var}(Y)$

Ejemplo (dado): $E(X) = 3.5$, $E(X^2) \approx 15.17$, $\mathrm{Var}(X) \approx 2.92$, $\sigma \approx 1.71$

Funciones R: Muestreo y Simulación

Muestreo aleatorio con sample()

```r
# Simular 10 lanzamientos de moneda
moneda <- sample(c("Cara", "Cruz"), size=10, replace=TRUE)
print(moneda)

# Simular 100 lanzamientos de dado
dados <- sample(1:6, size=100, replace=TRUE)
prop.table(table(dados))  # Frecuencias relativas
```

Funciones R: Muestreo y Simulación

Muestreo aleatorio con sample()

```r
# Simular 10 lanzamientos de moneda
moneda <- sample(c("Cara", "Cruz"), size=10, replace=TRUE)
print(moneda)

# Simular 100 lanzamientos de dado
dados <- sample(1:6, size=100, replace=TRUE)
prop.table(table(dados))  # Frecuencias relativas
```

Repetición de experimentos con replicate()

```r
# Simular la media de 100 lanzamientos de dado,
# repetido 1000 veces
medias <- replicate(1000, mean(sample(1:6, size=100,
                                      replace=TRUE)))
hist(medias, main="Distribución de medias muestrales")
```

Funciones R: Muestreo y Simulación

Muestreo aleatorio con sample()

```r
# Simular 10 lanzamientos de moneda
moneda <- sample(c("Cara", "Cruz"), size=10, replace=TRUE)
print(moneda)

# Simular 100 lanzamientos de dado
dados <- sample(1:6, size=100, replace=TRUE)
prop.table(table(dados))  # Frecuencias relativas
```

Repetición de experimentos con replicate()

```r
# Simular la media de 100 lanzamientos de dado,
# repetido 1000 veces
medias <- replicate(1000, mean(sample(1:6, size=100,
                                      replace=TRUE)))
hist(medias, main="Distribución de medias muestrales")
```

Simulación del Teorema de Bayes en R (Parte 1)

```r
# Simulación: Prueba diagnóstica
set.seed(123)
n_simulaciones <- 100000

# Generar estado real de enfermedad (1% prevalencia)
enfermo <- rbinom(n_simulaciones, 1, p=0.01)

# Simular resultado de test
resultado_test <- numeric(n_simulaciones)

for(i in 1:n_simulaciones){
  if(enfermo[i] == 1){
    # Si enfermo: 95% positivo
    resultado_test[i] <- rbinom(1, 1, p=0.95)
  } else {
    # Si sano: 10% falso positivo
    resultado_test[i] <- rbinom(1, 1, p=0.10)
  }
}
```

Simulación del Teorema de Bayes en R (Parte 1)

```r
# Simulación: Prueba diagnóstica
set.seed(123)
n_simulaciones <- 100000

# Generar estado real de enfermedad (1% prevalencia)
enfermo <- rbinom(n_simulaciones, 1, p=0.01)

# Simular resultado de test
resultado_test <- numeric(n_simulaciones)

for(i in 1:n_simulaciones){
  if(enfermo[i] == 1){
    # Si enfermo: 95% positivo
    resultado_test[i] <- rbinom(1, 1, p=0.95)
  } else {
    # Si sano: 10% falso positivo
    resultado_test[i] <- rbinom(1, 1, p=0.10)
  }
}
```

Lógica

Generamos 100.000 personas: 1% enfermas (1000), 99% sanas (99.000).

Simulación del Teorema de Bayes en R (Parte 2)

```r
# Continuar desde frame anterior...

# Calcular P(Enfermo | Positivo)
prob_enfermo_dado_positivo <-
  sum(enfermo & resultado_test) /
  sum(resultado_test)

cat("P(Enfermo|Positivo) =",
    prob_enfermo_dado_positivo, "\n")
cat("Valor teórico = 0.0876\n")
```

Simulación del Teorema de Bayes en R (Parte 2)

```r
# Continuar desde frame anterior...

# Calcular P(Enfermo | Positivo)
prob_enfermo_dado_positivo <-
  sum(enfermo & resultado_test) /
  sum(resultado_test)

cat("P(Enfermo|Positivo) =",
    prob_enfermo_dado_positivo, "\n")
cat("Valor teórico = 0.0876\n")
```

Interpretación

El resultado simulado debe coincidir con el teórico ($\approx 8.76\%$).
Esto valida el Teorema de Bayes.

Distribuciones en R

Funciones de distribución

En R, las distribuciones tienen prefijos estándar:

- `d*` — función de densidad/masa
- `p*` — función acumulada (CDF)
- `q*` — función cuantil
- `r*` — números aleatorios

Distribuciones en R

Funciones de distribución

En R, las distribuciones tienen prefijos estándar:

- `d*` — función de densidad/masa
- `p*` — función acumulada (CDF)
- `q*` — función cuantil
- `r*` — números aleatorios

```r
# Distribución normal: X ~ N(100, 15^2)
media <- 100; desv_est <- 15
dnorm(100, mean=100, sd=15)
pnorm(115, mean=100, sd=15)
qnorm(0.95, mean=100, sd=15)
muestra <- rnorm(1000, mean=100, sd=15)
hist(muestra, freq=FALSE)
curve(dnorm(x, mean=100, sd=15),
      add=TRUE, col="blue")
```

Ejercicio Práctico: Análisis de Encuesta

Escenario: Encuesta a 500 ciudadanos sobre intención de voto.

Ejercicio Práctico: Análisis de Encuesta

Escenario: Encuesta a 500 ciudadanos sobre intención de voto.

Datos:

- 210 con intención de voto
- De estos, 140 tienen educación superior
- Sin intención: 180 con educación superior
- Total educación superior: 320

Ejercicio Práctico: Análisis de Encuesta

Escenario: Encuesta a 500 ciudadanos sobre intención de voto.

Datos:

- 210 con intención de voto
- De estos, 140 tienen educación superior
- Sin intención: 180 con educación superior
- Total educación superior: 320

Preguntas:

1. Calcule $P(V)$ y $P(E)$
2. ¿Son independientes?
3. Calcule $P(V|E)$ y $P(E|V)$
4. ¿Relación entre educación e intención de voto?

Ejercicio Práctico: Análisis de Encuesta

Escenario: Encuesta a 500 ciudadanos sobre intención de voto.

Datos:

- 210 con intención de voto
- De estos, 140 tienen educación superior
- Sin intención: 180 con educación superior
- Total educación superior: 320

Preguntas:

1. Calcule $P(V)$ y $P(E)$
2. ¿Son independientes?
3. Calcule $P(V|E)$ y $P(E|V)$
4. ¿Relación entre educación e intención de voto?

Para resolver: Tabla de contingencia, operaciones de probabilidad, verificar independencia.

Solución del Ejercicio (Parte 1)

Tabla de Contingencia

	Educación Sup.	Sin Educación Sup.	Total
Vota	140	70	210
No vota	180	110	290
Total	320	180	500

Solución del Ejercicio (Parte 1)

Tabla de Contingencia

	Educación Sup.	Sin Educación Sup.	Total
Vota	140	70	210
No vota	180	110	290
Total	320	180	500

Probabilidades Marginales

$P(V) = 0.42$, $P(E) = 0.64$, $P(V^c) = 0.58$, $P(E^c) = 0.36$

Solución del Ejercicio (Parte 1)

Tabla de Contingencia

	Educación Sup.	Sin Educación Sup.	Total
Vota	140	70	210
No vota	180	110	290
Total	320	180	500

Probabilidades Marginales

$P(V) = 0.42$, $P(E) = 0.64$, $P(V^c) = 0.58$, $P(E^c) = 0.36$

Verificar Independencia

$$P(V \cap E) = 0.28 \quad \text{vs} \quad P(V) \cdot P(E) = 0.2688$$

No independientes (aunque cercanos).

Solución del Ejercicio (Parte 2)

Probabilidades Condicionales

$$P(V|E) = \frac{140}{320} = 0.4375 \quad P(E|V) = \frac{140}{210} = 0.6667$$

Solución del Ejercicio (Parte 2)

Probabilidades Condicionales

$$P(V|E) = \frac{140}{320} = 0.4375 \quad P(E|V) = \frac{140}{210} = 0.6667$$

Interpretación

- Con educación superior, 43.75% vota
- Votantes, 66.67% con educación superior
- Vs $P(V) = 42\% \rightarrow$ aumenta ligeramente

Solución del Ejercicio (Parte 2)

Probabilidades Condicionales

$$P(V|E) = \frac{140}{320} = 0.4375 \quad P(E|V) = \frac{140}{210} = 0.6667$$

Interpretación

- Con educación superior, 43.75% vota
- Votantes, 66.67% con educación superior
- Vs $P(V) = 42\% \rightarrow$ aumenta ligeramente

Conclusión

Asociación débil pero positiva. Preguntas: ¿Causal? ¿Confundidoras? ¿Regional? ¿Temporal?

Resumen de Conceptos Clave

Fundamentos

- Espacio muestral, eventos
- Axiomas de Kolmogorov
- Regla suma y complemento

Bayes y V.A.

- Teorema de Bayes
- V.A. discretas y continuas
- PMF, PDF, CDF

Condicionalidad

- $P(A|B) = P(A \cap B)/P(B)$
- Independencia: $P(A \cap B) = P(A) \cdot P(B)$
- Regla del producto

Características

- $E(X)$ — valor esperado
- $\mathrm{Var}(X)$ — varianza
- σ — desviación estándar

Resumen de Conceptos Clave

Fundamentos

- Espacio muestral, eventos
- Axiomas de Kolmogorov
- Regla suma y complemento

Bayes y V.A.

- Teorema de Bayes
- V.A. discretas y continuas
- PMF, PDF, CDF

Condicionalidad

- $P(A|B) = P(A \cap B)/P(B)$
- Independencia: $P(A \cap B) = P(A) \cdot P(B)$
- Regla del producto

Características

- $E(X)$ — valor esperado
- $\mathrm{Var}(X)$ — varianza
- σ — desviación estándar

Próxima sesión: Distribuciones comunes (Normal, Binomial, Poisson)