

# Sesión 2 · Probabilidad y Teorema de Bayes

Nivelación Estadística y Probabilidades — Doctorado en Políticas Públicas

Amaru Agüero Jiménez (a.agueroj@udd.cl)

marzo de 2026

# Panorama de la sesión

| Bloque       | Concepto clave                                 | Herramienta en R                                 |
|--------------|------------------------------------------------|--------------------------------------------------|
| Fundamentos  | Espacio muestral, eventos, axiomas             | <code>sample()</code>                            |
| Reglas       | Adición, complemento, multiplicación           | aritmética vectorizada                           |
| Condicional  | Conjunta, marginal, condicional, independencia | <code>table()</code> , <code>prop.table()</code> |
| Bayes        | Prior, verosimilitud, posterior                | cálculo directo, <code>rbinom()</code>           |
| Simulación   | Monte Carlo, ley de grandes números            | <code>set.seed()</code> , <code>cumsum()</code>  |
| Aplicaciones | Diagnóstico, focalización, fraude              | <code>ggplot2</code>                             |

**i** **Idea de la sesión:** la probabilidad es el lenguaje de la incertidumbre. Toda decisión de política — focalizar un subsidio, activar una alerta de fraude, interpretar un test — es una apuesta condicionada a información parcial.


# Experimento aleatorio, espacio muestral y eventos

- **Experimento aleatorio:** proceso cuyo resultado no puede predecirse con certeza, pero cuyos resultados posibles son conocidos.
- **Espacio muestral  $\Omega$ :** conjunto de todos los resultados posibles.
- **Evento  $A \subseteq \Omega$ :** subconjunto de resultados. Evento seguro:  $\Omega$ ; imposible:  $\emptyset$ .

| Experimento              | Espacio muestral $\Omega$                 | Evento de interés $A$      |
|--------------------------|-------------------------------------------|----------------------------|
| Lanzar un dado           | $\{1, 2, 3, 4, 5, 6\}$                    | $\text{par} = \{2, 4, 6\}$ |
| Encuestar un hogar       | $\{\text{recibe subsidio, no recibe}\}$   | recibe                     |
| Fiscalizar una empresa   | $\{\text{cumple, no cumple}\}$            | no cumple                  |
| Seguir a un beneficiario | $\{\text{termina el programa, deserta}\}$ | deserta                    |

💡 Definir  $\Omega$  con precisión es el primer paso de todo modelo: ¿qué cuenta como “deserción”? ¿Quiénes componen la población fiscalizable? Ambigüedad aquí invalida cualquier probabilidad posterior.

# Operaciones entre eventos: el diagrama de Venn



## Álgebra de eventos:

- **Unión**  $A \cup B$ : ocurre  $A$  o  $B$  (o ambos)
- **Intersección**  $A \cap B$ : ocurren  $A$  y  $B$
- **Complemento**  $A^c$ : no ocurre  $A$
- **Disjuntos**:  $A \cap B = \emptyset$  (no pueden ocurrir juntos)

## Leyes de De Morgan:

$$(A \cup B)^c = A^c \cap B^c$$

$$(A \cap B)^c = A^c \cup B^c$$

“No recibe ningún beneficio” = “no recibe  $A$  y no recibe  $B$ ”.

# Axiomas de Kolmogorov: las tres reglas del juego

Una medida de probabilidad es una función  $P$  que asigna un número a cada evento y cumple:

| Axioma            | Enunciado                                                                            |
|-------------------|--------------------------------------------------------------------------------------|
| 1. No negatividad | $P(A) \geq 0$ para todo evento $A$                                                   |
| 2. Normalización  | $P(\Omega) = 1$                                                                      |
| 3. Aditividad     | Si $A_1, A_2, \dots$ son disjuntos:<br>$P\left(\bigcup_i A_i\right) = \sum_i P(A_i)$ |

**Consecuencias inmediatas** (todo lo demás se deriva de estos tres axiomas):

$$P(\emptyset) = 0 \quad P(A^c) = 1 - P(A) \quad A \subseteq B \Rightarrow P(A) \leq P(B) \quad P(A) \leq 1$$

! Si un informe reporta probabilidades que suman más de 1 sobre categorías excluyentes, o “riesgos” negativos, viola los axiomas: el error es de construcción, no de interpretación.

# ¿Qué es una probabilidad? Tres interpretaciones

| Enfoque                           | Definición                                                                                         | Ejemplo en políticas públicas                                            |
|-----------------------------------|----------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------|
| Clásica (Laplace)<br>Frecuentista | casos favorables / casos posibles<br>límite de la frecuencia relativa al<br>repetir el experimento | dado justo: $P(\text{par}) = 3/6$<br>tasa histórica de deserción escolar |
| Subjetiva (bayesiana)             | grado de creencia coherente,<br>actualizable con evidencia                                         | prob. de que una reforma se<br>apruebe este año                          |

- Las tres obedecen los **mismos axiomas**: difieren en qué se puede modelar, no en la matemática.
- Eventos únicos (¿se aprobará la reforma?) no tienen frecuencia: solo admiten lectura bayesiana.
- Esta sesión usa las tres: conteo (tablas), frecuencia (simulación) y actualización (Bayes).

# Reglas de adición y complemento

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A^c) = 1 - P(A)$$

**Ejemplo:** en una comuna, 30 % de los hogares recibe subsidio de vivienda ( $A$ ), 25 % recibe apoyo alimentario ( $B$ ) y 10 % recibe ambos.


```
pA <- 0.30; pB <- 0.25; pAB <- 0.10  
c(al_menos_uno = pA + pB - pAB,  
  solo_vivienda = pA - pAB,  
  ninguno = 1 - (pA + pB - pAB))
```

| al_menos_uno | solo_vivienda | ninguno |
|--------------|---------------|---------|
| 0.45         | 0.20          | 0.55    |

- Sumar  $0.30 + 0.25 = 0.55$  **sobreestima**: cuenta dos veces al 10 % que recibe ambos.
- Solo si  $A$  y  $B$  son disjuntos vale  $P(A \cup B) = P(A) + P(B)$ .
- El complemento es el atajo clásico:  $P(\text{al menos un beneficio}) = 1 - P(\text{ninguno})$ .

# Ley de grandes números: frecuencia $\rightarrow$ probabilidad

```
set.seed(2026)
n <- 10000
dado <- sample(1:6, n,
               replace = TRUE)
frec <- cumsum(dado == 6) / (1:n)
tibble(n = 1:n, frec = frec) %>%
  ggplot(aes(n, frec)) +
  geom_line(color = celeste) +
  geom_hline(yintercept = 1/6,
             color = rojo,
             linetype = "dashed") +
  scale_x_log10(
    labels = scales::comma) +
  labs(x = "N° lanzamientos (log)",
       y = "Frecuencia de 'sale 6'")
```



Con  $n$  pequeño la frecuencia fluctúa violentamente; con  $n$  grande converge a  $1/6 \approx 0.167$ . Este es el puente entre datos y probabilidad — y la base de toda simulación **Monte Carlo**.



# Conjunta, marginal y condicional: el mapa de conceptos

| Concepto    | Notación      | Pregunta que responde              | En una tabla de datos    |
|-------------|---------------|------------------------------------|--------------------------|
| Conjunta    | $P(A \cap B)$ | ¿Ambos a la vez?                   | celda / total            |
| Marginal    | $P(A)$        | ¿ $A$ , ignorando $B$ ?            | total de fila / total    |
| Condicional | $P(A   B)$    | ¿ $A$ , entre quienes tienen $B$ ? | celda / total de columna |

## Conexiones fundamentales:

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0 \qquad P(A) = \sum_i P(A \cap B_i)$$

Condicionar **reduce el espacio muestral**: al saber que  $B$  ocurrió, el universo relevante ya no es  $\Omega$  sino  $B$ .

# Tabla de contingencia: encuesta de 500 ciudadanos

**Escenario:** encuesta sobre intención de voto ( $V$ ) en la elección municipal y educación superior ( $E$ ).

|         | Educación superior | Sin educación superior | Total |
|---------|--------------------|------------------------|-------|
| Vota    | 140                | 70                     | 210   |
| No vota | 180                | 110                    | 290   |
| Total   | 320                | 180                    | 500   |

- La tabla de contingencia es el **estimador empírico** de toda la estructura de probabilidad: conjuntas, marginales y condicionales salen de ella por división.
- Preguntas que responderemos:  $\mathbb{P}(V)$ ?  $\mathbb{P}(V \mid E)$ ? ¿Son  $V$  y  $E$  independientes?

# De conteos a probabilidades: la distribución conjunta

Probabilidades conjuntas: cada celda / 500

|         |                 |                  |
|---------|-----------------|------------------|
| Vota    | 28.0% (n = 140) | 14.0% (n = 70)   |
| No vota | 36.0% (n = 180) | 22.0% (n = 110)  |
|         | Ed. superior    | Sin ed. superior |

Las cuatro conjuntas suman 1. Las **marginales** se obtienen sumando:  $P(V) = 0.28 + 0.14 = 0.42$ ;  $P(E) = 0.28 + 0.36 = 0.64$ .


# Probabilidad condicional: condicionar cambia el universo

$$P(V | E) = \frac{P(V \cap E)}{P(E)} = \frac{140/500}{320/500} = \frac{140}{320} = 0.4375$$

```
round(c(P_V = 210/500,  
        P_V_dado_E = 140/320,  
        P_V_dado_noE = 70/180), 3)
```

| P_V   | P_V_dado_E | P_V_dado_noE |
|-------|------------|--------------|
| 0.420 | 0.438      | 0.389        |

- Condicionar en  $E$  apenas mueve la probabilidad ( $0.42 \rightarrow 0.44$ ): la asociación es **débil**.
- Condicionar no es simétrico:  
 $P(E | V) = 140/210 = 0.667 \neq P(V | E)$ .



# Independencia: definición y verificación empírica

**Definición:**  $A$  y  $B$  son independientes si  $P(A \cap B) = P(A) \cdot P(B)$ , o equivalentemente  $P(A | B) = P(A)$ : saber  $B$  no cambia la probabilidad de  $A$ .

**Verificación en la encuesta:**

$$P(V \cap E) = 0.28 \quad \text{vs} \quad P(V) \cdot P(E) = 0.42 \times 0.64 = 0.2688$$

```
tabla <- matrix(c(140, 70, 180, 110),  
               nrow = 2, byrow = TRUE)  
round(chisq.test(tabla)$p.value, 3)
```

[1] 0.336

- No son exactamente independientes, pero la brecha es pequeña y **compatible con el azar** ( $p \approx 0.34$  con  $n = 500$ ): no hay evidencia contra la independencia.



Asociación no es causalidad, e independencia estadística no implica irrelevancia sustantiva: una tercera variable (edad, ingreso) puede ocultar o inflar la relación observada.

# Regla del producto: muestreo sin reemplazo

$$P(A \cap B) = P(A \mid B) \cdot P(B) = P(B \mid A) \cdot P(A)$$

**Regla en cadena:**  $P(A_1 \cap A_2 \cap A_3) = P(A_1) \cdot P(A_2 \mid A_1) \cdot P(A_3 \mid A_1 \cap A_2)$

**Ejemplo — auditoría:** de 20 expedientes, 4 tienen irregularidades. Se auditan 2 al azar **sin reemplazo**:

$$P(\text{ambos irregulares}) = \frac{4}{20} \times \frac{3}{19} = 0.032$$

```
round(c(dos_irregulares = (4/20) * (3/19),  
        al_menos_uno = 1 - (16/20) * (15/19)), 3)
```

| dos_irregulares | al_menos_uno |
|-----------------|--------------|
| 0.032           | 0.368        |

- La segunda extracción **depende** de la primera: el condicional 3/19 registra que ya salió un irregular.
- Si los eventos fueran independientes:  $P(A \cap B) = P(A) \cdot P(B)$  — caso especial, no regla general.

# Ley de probabilidad total: promediar sobre una partición

Si  $B_1, \dots, B_k$  particionan  $\Omega$  (disjuntos y exhaustivos):

$$P(A) = \sum_{i=1}^k P(A \mid B_i) \cdot P(B_i)$$

**Ejemplo:** deserción ( $D$ ) en un programa nacional implementado en tres regiones.

| Región       | Peso $P(B_i)$ | Deserción $P(D \mid B_i)$ | Aporte $P(D \cap B_i)$ |
|--------------|---------------|---------------------------|------------------------|
| Norte        | 0.20          | 0.15                      | 0.030                  |
| Centro       | 0.50          | 0.08                      | 0.040                  |
| Sur          | 0.30          | 0.12                      | 0.036                  |
| <b>Total</b> | 1.00          | —                         | $P(D) = 0.106$         |

La tasa nacional (10.6 %) es un **promedio ponderado** de las tasas regionales. Y de regalo, ya podemos invertir:  $P(\text{Norte} \mid D) = 0.030/0.106 = 0.28$  — el Norte aporta 28 % de la deserción con solo 20 % de los beneficiarios.

# Teorema de Bayes: derivación en tres pasos

**Paso 1 — la regla del producto, escrita en ambos sentidos:**

$$P(A \cap B) = P(A \mid B) \cdot P(B) \qquad P(A \cap B) = P(B \mid A) \cdot P(A)$$

**Paso 2 — igualar y despejar:**

$$P(B \mid A) = \frac{P(A \mid B) \cdot P(B)}{P(A)}$$

**Paso 3 — expandir  $P(A)$  con probabilidad total** (forma general, con partición  $B_1, \dots, B_k$ ):


$$P(B_j \mid A) = \frac{P(A \mid B_j) \cdot P(B_j)}{\sum_{i=1}^k P(A \mid B_i) \cdot P(B_i)}$$

**Nomenclatura:**  $P(B) = \text{prior}$  ·  $P(A \mid B) = \text{verosimilitud}$  ·  $P(A) = \text{evidencia}$  ·  $P(B \mid A) = \text{posterior}$ . Bayes es la regla para **actualizar creencias con datos**.



# El árbol del test diagnóstico

**Test para una enfermedad:** prevalencia 0.01, sensibilidad 0.95, especificidad 0.90.



Las ramas "Test +" suman la evidencia  $P(+) = 0.0095 + 0.0990 = 0.1085$ : los **falsos positivos superan 10 a 1** a los verdaderos.

# P(Enferma | +): el cálculo completo

**Probabilidad total** (denominador de Bayes):

$$P(+) = 0.95 \times 0.01 + 0.10 \times 0.99 = 0.1085$$

**Teorema de Bayes:**

$$P(\text{Enf} | +) = \frac{0.95 \times 0.01}{0.1085} = 0.0876$$

```
prev <- 0.01; sens <- 0.95; esp <- 0.90
p_pos <- sens * prev + (1 - esp) * (1 - prev)
round(c(P_positivo = p_pos,
        P_enf_dado_pos = sens * prev / p_pos), 4)
```

| P_positivo | P_enf_dado_pos |
|------------|----------------|
| 0.1085     | 0.0876         |

! Un test con 95 % de sensibilidad entrega solo **8.8 % de certeza**: de cada 100 positivos, 91 son falsas alarmas. Ignorar la prevalencia es el error de **negligencia de la tasa base**.

# Frecuencias naturales: la misma respuesta sin fórmulas

Imagine **10.000 personas** con las mismas tasas (prevalencia 1 %, sensibilidad 95 %, especificidad 90 %):


|                | Test + | Test - | Total  |
|----------------|--------|--------|--------|
| Enfermas (100) | 95     | 5      | 100    |
| Sanas (9.900)  | 990    | 8.910  | 9.900  |
| Total          | 1.085  | 8.915  | 10.000 |

$$P(\text{Enf} \mid +) = \frac{95}{95 + 990} = \frac{95}{1.085} = 0.0876$$

- De cada 1.085 alertas positivas, solo 95 son reales: la baja prevalencia hace que las 990 falsas alarmas de la población sana dominen.
- Gigerenzer: presentar riesgos como **frecuencias naturales** (“95 de cada 1.085”) reduce drásticamente los errores de interpretación de médicos, jueces y policymakers.

# Prior → posterior: incluso un test excelente decepciona

Teorema de Bayes: Test Médico




**Un test mejor que el anterior** (sensibilidad 99 %, especificidad 95 %), misma prevalencia de 1 %:

- Prior:  $P(\text{Enf}) = 1 \%$
- Posterior:  $P(\text{Enf} \mid +) \approx 16.6 \%$

**Implicancia de política:** en tamizajes masivos de baja prevalencia (cáncer, fraude, dopaje), la mayoría de los positivos serán falsos **aunque el instrumento sea excelente**.

**Solución bayesiana:** repetir el test solo al grupo positivo. Con prior 16.6 %, un segundo positivo independiente eleva el posterior a  $\approx 80 \%$ : *el posterior de hoy es el prior de mañana*.

# El posterior depende de la prevalencia



Con prevalencia 1 %: posterior de 8.8 % (FP 10 %), 16 % (FP 5 %) y 49 % (FP 1 %). Toda curva sobre la diagonal punteada indica que el test **sí aporta información** — pero cuánto, depende del prior.

# La falacia del fiscal

**El error:** confundir  $P(\text{evidencia} \mid \text{inocente})$  con  $P(\text{inocente} \mid \text{evidencia})$  — la “confusión de la inversa”, el mismo error del test diagnóstico.


**Ejemplo clásico (ADN):** la muestra del sitio coincide con el acusado y el perito declara que la probabilidad de coincidencia por azar es 1 en 1.000.000.

| Cantidad                                                         | Valor                      |
|------------------------------------------------------------------|----------------------------|
| $P(\text{coincidencia} \mid \text{inocente})$                    | 1 / 1.000.000              |
| Población plausible de la ciudad                                 | 5.000.000                  |
| Coincidencias inocentes esperadas                                | $\approx 5$                |
| $P(\text{culpable} \mid \text{coincidencia})$ sin otra evidencia | $\approx 1/6 \approx 17\%$ |

! El fiscal presenta “1 en un millón” como si fuera la probabilidad de inocencia; Bayes muestra que, sin más evidencia, hay  $\approx 6$  personas compatibles y la culpabilidad es  $\approx 17\%$ . El mismo razonamiento aplica a alertas algorítmicas de fraude y a la vigilancia predictiva.

# Aplicación: detección de fraude en programas sociales

```
prev <- 0.02; sens <- 0.90
fp <- c(0.05, 0.02, 0.01, 0.005)
post <- sens * prev /
  (sens * prev + fp * (1 - prev))
et <- scales::percent(fp, 0.1)
tibble(
  tasa = factor(et, levels = et),
  post = post) %>%
  ggplot(aes(tasa, post)) +
  geom_col(fill = celeste,
            width = 0.6) +
  geom_text(aes(label =
    scales::percent(post, 1)),
            vjust = -0.4, color = azul) +
  scale_y_continuous(
    labels = scales::percent,
    limits = c(0, 0.95)) +
  labs(x = "Tasa falsos positivos",
       y = "P(fraude | alerta)")
```



Algoritmo antifraude: 2 % de fraude, sensibilidad 90 %. **Reducir los falsos positivos rinde más que subir la sensibilidad:** cada alerta falsa es un beneficiario legítimo suspendido.

# Verificación Monte Carlo del Teorema de Bayes

Simulamos 100.000 personas con las tasas del test diagnóstico y contamos, entre los positivos, cuántos están realmente enfermos:

```
set.seed(123)
n <- 100000
enfermo <- rbinom(n, 1, 0.01)
p_test <- ifelse(enfermo == 1, 0.95, 0.10)
positivo <- rbinom(n, 1, p_test)
round(c(P_pos_simulada = mean(positivo),
        P_enf_dado_pos_simulada = mean(enfermo[positivo == 1]),
        teorico = 0.0876), 4)
```


| P_pos_simulada | P_enf_dado_pos_simulada | teorico |
|----------------|-------------------------|---------|
| 0.1089         | 0.0898                  | 0.0876  |

- La frecuencia simulada coincide con el valor teórico: la **ley de grandes números** en acción.
- Método general: cuando la fórmula es intratable (modelos jerárquicos, sistemas complejos), **simular es calcular**. Es la base del análisis bayesiano computacional moderno (MCMC).



# De eventos a variables aleatorias

Función de Masa de Probabilidad (PMF)  
Distribución Binomial ( $n=10, p=0.6$ )



**Variable aleatoria:** función que asigna un número a cada resultado,  $X : \Omega \rightarrow \mathbb{R}$ .

**Función de masa de probabilidad (PMF):**

$$P(X = k) \geq 0, \quad \sum_k P(X = k) = 1$$

**Ejemplo:** 10 egresados de un programa de empleo, cada uno consigue trabajo con  $p = 0.6$  de forma independiente.  $X =$  n° de colocados:

$$X \sim \text{Binomial}(10, 0.6), \quad E(X) = np = 6$$

La figura muestra su PMF: el resultado más probable es 6, pero valores entre 4 y 8 concentran casi toda la masa.

# Errores comunes al razonar con incertidumbre

| Error                         | Ejemplo                                                               | Corrección                                          |
|-------------------------------|-----------------------------------------------------------------------|-----------------------------------------------------|
| Negligencia de la tasa base   | “El test es 95 % sensible, luego estoy 95 % enfermo”                  | Teorema de Bayes con el prior                       |
| Falacia del fiscal            | Condenar porque $P(\text{evidencia} \mid \text{inocente})$ es pequeña | Calcular $P(\text{inocente} \mid \text{evidencia})$ |
| Confusión de la inversa       | Reportar $P(A \mid B)$ como si fuera $P(B \mid A)$                    | Tabla de frecuencias naturales                      |
| Asumir independencia          | Multiplicar riesgos correlacionados                                   | Verificar $P(A \cap B) = P(A)P(B)$                  |
| Sumar sin restar intersección | Proporciones que suman más de 100 %                                   | Inclusión-exclusión                                 |
| Asociación leída como causa   | “La educación causa el voto” desde una tabla                          | Diseños causales (econometría)                      |

# Síntesis: qué llevarse de esta sesión

## Checklist para razonar con probabilidades

- 1 Definir  $\Omega$  y los eventos sin ambigüedad
- 2 Distinguir conjunta, marginal y condicional
- 3 Nunca asumir independencia: verificarla
- 4 Ante un condicional invertido, aplicar Bayes
- 5 Comunicar con frecuencias naturales
- 6 Simular (Monte Carlo) para verificar cálculos
- 7 Recordar: el posterior depende del prior

## Funciones R de esta sesión

`sample()` `rbinom()` `cumsum()` `mean()`  
`table()` `prop.table()` `chisq.test()`  
`set.seed()` `ifelse()` `crossing()`

## Fórmula estrella:

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}$$

**Próxima sesión:** distribuciones de probabilidad (Binomial, Poisson, Normal).

## Ejercicio para practicar (30 min)

**Escenario:** test de drogas para conductores de transporte escolar. Prevalencia de consumo: 0.5 %; sensibilidad: 98 %; especificidad: 97 %.

- 1 Dibuje el árbol de probabilidades y calcule  $P(+)$  con la ley de probabilidad total.
- 2 Calcule  $P(\text{consumo} \mid +)$  con el Teorema de Bayes. ¿Le sorprende el resultado?
- 3 Construya la tabla de frecuencias naturales para 100.000 conductores y verifique el valor.
- 4 ¿Desde qué prevalencia el posterior supera 50 %? (Pista: iguale verdaderos y falsos positivos.)
- 5 Simule el escenario en R con `rbinom()` ( $n = 100.000$ , con `set.seed()`) y compare con el valor teórico.
- 6 Discuta: ¿qué protocolo recomendaría tras un positivo — despido inmediato o test confirmatorio? Justifique con los números.

**i Referencias:** Blitzstein & Hwang, *Introduction to Probability* (caps. 1–2) · Gigerenzer, *Calculated Risks* · Illowsky & Dean, *Introductory Statistics* (caps. 3–4).