

Sesión 2 · Probabilidad y Teorema de Bayes

Nivelación Estadística y Probabilidades — Doctorados en Políticas Públicas y en Ciencias de la Complejidad Social · Universidad del Desarrollo

Amaru Agüero Jiménez (a.agueroj@udd.cl)

marzo de 2026

Panorama de la sesión

Bloque	Concepto clave	Herramienta en R
Fundamentos	Espacio muestral, eventos, axiomas	<code>sample()</code>
Reglas	Adición, complemento, multiplicación	aritmética vectorizada
Condicional	Conjunta, marginal, condicional, independencia	<code>table()</code> , <code>prop.table()</code>
Bayes	Prior, verosimilitud, posterior	cálculo directo, <code>rbinom()</code>
Simulación	Monte Carlo, ley de grandes números	<code>set.seed()</code> , <code>cumsum()</code>
Aplicaciones	Diagnóstico, focalización, fraude	<code>ggplot2</code>

i **Idea de la sesión:** la probabilidad es el lenguaje de la incertidumbre. Toda decisión de política — focalizar un subsidio, activar una alerta de fraude, interpretar un test — es una apuesta condicionada a información parcial.

Experimento aleatorio, espacio muestral y eventos


- **Experimento aleatorio:** proceso cuyo resultado no puede predecirse con certeza, pero cuyos resultados posibles son conocidos.
- **Espacio muestral Ω :** conjunto de todos los resultados posibles.
- **Evento $A \subseteq \Omega$:** subconjunto de resultados. Evento seguro: Ω ; imposible: $\emptyset$.

Experimento	Espacio muestral Ω	Evento de interés A
Lanzar un dado	$\{1, 2, 3, 4, 5, 6\}$	par = $\{2, 4, 6\}$
Encuestar un hogar	$\{\text{recibe subsidio, no recibe}\}$	recibe
Fiscalizar una empresa	$\{\text{cumple, no cumple}\}$	no cumple
Seguir a un beneficiario	$\{\text{termina el programa, deserta}\}$	deserta



Definir Ω con precisión es el primer paso de todo modelo: ¿qué cuenta como “deserción”? ¿Quiénes componen la población fiscalizable? Ambigüedad aquí invalida cualquier probabilidad posterior.

Operaciones entre eventos: el diagrama de Venn



Álgebra de eventos:

- **Unión** $A \cup B$: ocurre A o B (o ambos)
- **Intersección** $A \cap B$: ocurren A y B
- **Complemento** A^c : no ocurre A
- **Disjuntos**: $A \cap B = \emptyset$ (no pueden ocurrir juntos)

Leyes de De Morgan:


$$(A \cup B)^c = A^c \cap B^c$$

$$(A \cap B)^c = A^c \cup B^c$$


“No recibe ningún beneficio” = “no recibe A y no recibe B ”.

Las operaciones, una a una


Unión: A o B (o ambos)




Intersección: A y B



Complemento: no ocurre A



Disjuntos: no coexisten



En el ejemplo de la comuna: unión = recibe al menos un beneficio; intersección = recibe ambos; complemento = no recibe vivienda; disjuntos = categorías excluyentes de un registro.



Intuición

Unión: pertenecer a al menos uno de los dos clubes. Intersección: estar inscrito en ambos a la vez. Complemento: todo el resto de la sala. Disjuntos: clubes que no comparten ningún miembro.

Axiomas de Kolmogorov: las tres reglas del juego

Una medida de probabilidad es una función P que asigna un número a cada evento y cumple:

Axioma	Enunciado
1. No negatividad	$P(A) \geq 0$ para todo evento A
2. Normalización	$P(\Omega) = 1$
3. Aditividad	Si $A_1, A_2, \dots$ son disjuntos: $P\left(\bigcup_i A_i\right) = \sum_i P(A_i)$

Consecuencias inmediatas (todo lo demás se deriva de estos tres axiomas):

$$P(\emptyset) = 0 \quad P(A^c) = 1 - P(A) \quad A \subseteq B \Rightarrow P(A) \leq P(B) \quad P(A) \leq 1$$

! Si un informe reporta probabilidades que suman más de 1 sobre categorías excluyentes, o “riesgos” negativos, viola los axiomas: el error es de construcción, no de interpretación.

¿Qué es una probabilidad? Tres interpretaciones

Enfoque	Definición	Ejemplo en políticas públicas
Clásica (Laplace) Frecuentista	casos favorables / casos posibles límite de la frecuencia relativa al repetir el experimento	dado justo: $P(\text{par}) = 3/6$ tasa histórica de deserción escolar
Subjetiva (bayesiana)	grado de creencia coherente, actualizable con evidencia	prob. de que una reforma se apruebe este año

- Las tres obedecen los **mismos axiomas**: difieren en qué se puede modelar, no en la matemática.
- Eventos únicos (¿se aprobará la reforma?) no tienen frecuencia: solo admiten lectura bayesiana.
- Esta sesión usa las tres: conteo (tablas), frecuencia (simulación) y actualización (Bayes).



Intuición

Tres maneras de responder “¿qué tan seguro estoy?”: contar casos como en un juego de mesa, mirar qué pasó las mil veces anteriores, o decidir cuánto apostaríamos hoy y revisarlo al ver los datos.

Reglas de adición y complemento

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$$P(A^c) = 1 - P(A)$$

Ejemplo: en una comuna, 30 % de los hogares recibe subsidio de vivienda (A), 25 % recibe apoyo alimentario (B) y 10 % recibe ambos.


```
pA <- 0.30; pB <- 0.25; pAB <- 0.10  
c(al_menos_uno = pA + pB - pAB,  
  solo_vivienda = pA - pAB,  
  ninguno = 1 - (pA + pB - pAB))
```

al_menos_uno	solo_vivienda	ninguno
0.45	0.20	0.55

- Sumar $0.30 + 0.25 = 0.55$ **sobreestima**: cuenta dos veces al 10 % que recibe ambos.
- Solo si A y B son disjuntos vale $P(A \cup B) = P(A) + P(B)$.
- El complemento es el atajo clásico: $P(\text{al menos un beneficio}) = 1 - P(\text{ninguno})$.

Ley de grandes números: frecuencia $\rightarrow$ probabilidad

```
set.seed(2026)
n <- 10000
dado <- sample(1:6, n,
               replace = TRUE)
frec <- cumsum(dado == 6) / (1:n)
tibble(n = 1:n, frec = frec) %>%
  ggplot(aes(n, frec)) +
  geom_line(color = celeste) +
  geom_hline(yintercept = 1/6,
             color = rojo,
             linetype = "dashed") +
  scale_x_log10(
    labels = scales::comma) +
  labs(x = "N° lanzamientos (log)",
       y = "Frecuencia de 'sale 6'")
```



Con n pequeño la frecuencia fluctúa violentamente; con n grande converge a $1/6 \approx 0.167$. Este es el puente entre datos y probabilidad — y la base de toda simulación **Monte Carlo**.

Laboratorio: ley de los grandes números

Mueva los controles y observe cómo la frecuencia relativa acumulada se adhiere a p cuando crece n . Cada movimiento genera una simulación nueva.

En la versión HTML este laboratorio simula n repeticiones de un evento con probabilidad p (elegidos con deslizadores) y grafica la frecuencia relativa acumulada en vivo:

- Con $n < 100$ la trayectoria fluctúa con violencia: rachas largas alejan la frecuencia de p .
- Con $n \approx 10.000$ la trayectoria queda pegada a la línea de p , cualquiera sea el p elegido.
- Es el mismo fenómeno del dado de la figura anterior y el fundamento de la verificación Monte Carlo del final de la sesión: **simular es calcular**.

Conjunta, marginal y condicional: el mapa de conceptos

Concepto	Notación	Pregunta que responde	En una tabla de datos
Conjunta	$P(A \cap B)$	¿Ambos a la vez?	celda / total
Marginal	$P(A)$	¿ A , ignorando B ?	total de fila / total
Condicional	$P(A \mid B)$	¿ A , entre quienes tienen B ?	celda / total de columna

Conexiones fundamentales:

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0 \qquad P(A) = \sum_i P(A \cap B_i)$$

Condicionar **reduce el espacio muestral**: al saber que B ocurrió, el universo relevante ya no es Ω sino B .

Tabla de contingencia: encuesta de 500 ciudadanos

Escenario: encuesta sobre intención de voto (V) en la elección municipal y educación superior (E).

	Educación superior	Sin educación superior	Total
Vota	140	70	210
No vota	180	110	290
Total	320	180	500

- La tabla de contingencia es el **estimador empírico** de toda la estructura de probabilidad: conjuntas, marginales y condicionales salen de ella por división.
- Preguntas que responderemos: $\mathbb{P}(V)$? $\mathbb{P}(V \mid E)$? ¿Son V y E independientes?

De conteos a probabilidades: la distribución conjunta

Probabilidades conjuntas: cada celda / 500

Vota	28.0% (n = 140)	14.0% (n = 70)
No vota	36.0% (n = 180)	22.0% (n = 110)
	Ed. superior	Sin ed. superior

Las cuatro conjuntas suman 1. Las **marginales** se obtienen sumando: $P(V) = 0.28 + 0.14 = 0.42$; $P(E) = 0.28 + 0.36 = 0.64$.


Probabilidad condicional: condicionar cambia el universo

$$P(V | E) = \frac{P(V \cap E)}{P(E)} = \frac{140/500}{320/500} = \frac{140}{320} = 0.4375$$

```
round(c(P_V = 210/500,  
        P_V_dado_E = 140/320,  
        P_V_dado_noE = 70/180), 3)
```


P_V	P_V_dado_E	P_V_dado_noE
0.420	0.438	0.389

- Condicionar en E apenas mueve la probabilidad ($0.42 \rightarrow 0.44$): la asociación es **débil**.
- Condicionar no es simétrico:
 $P(E | V) = 140/210 = 0.667 \neq P(V | E)$.




Condicionar es restringir el universo

Antes: el universo es Ω



Al saber B: el universo es B



$P(A | B)$ compara el área roja ($A \cap B$) con el área total de B : lo que queda fuera de B deja de contar.



Intuición

Saber que B ocurrió encoge el mundo: la pregunta ya no es “¿qué tan grande es A en todo el universo?” sino “¿qué fracción del territorio de B está ocupada por A ?”.

Independencia: definición y verificación empírica

Definición: A y B son independientes si $P(A \cap B) = P(A) \cdot P(B)$, o equivalentemente $P(A | B) = P(A)$: saber B no cambia la probabilidad de A .

Verificación en la encuesta:

$$P(V \cap E) = 0.28 \quad \text{vs} \quad P(V) \cdot P(E) = 0.42 \times 0.64 = 0.2688$$

```
tabla <- matrix(c(140, 70, 180, 110),  
               nrow = 2, byrow = TRUE)  
round(chisq.test(tabla)$p.value, 3)
```

[1] 0.336

- No son exactamente independientes, pero la brecha es pequeña y **compatible con el azar** ($p \approx 0.34$ con $n = 500$): no hay evidencia contra la independencia.



Asociación no es causalidad, e independencia estadística no implica irrelevancia sustantiva: una tercera variable (edad, ingreso) puede ocultar o inflar la relación observada.

Regla del producto: muestreo sin reemplazo

$$P(A \cap B) = P(A \mid B) \cdot P(B) = P(B \mid A) \cdot P(A)$$

Regla en cadena: $P(A_1 \cap A_2 \cap A_3) = P(A_1) \cdot P(A_2 \mid A_1) \cdot P(A_3 \mid A_1 \cap A_2)$

Ejemplo — auditoría: de 20 expedientes, 4 tienen irregularidades. Se auditan 2 al azar **sin reemplazo**:

$$P(\text{ambos irregulares}) = \frac{4}{20} \times \frac{3}{19} = 0.032$$

```
round(c(dos_irregulares = (4/20) * (3/19),  
        al_menos_uno = 1 - (16/20) * (15/19)), 3)
```

dos_irregulares	al_menos_uno
0.032	0.368

- La segunda extracción **depende** de la primera: el condicional 3/19 registra que ya salió un irregular.
- Si los eventos fueran independientes: $P(A \cap B) = P(A) \cdot P(B)$ — caso especial, no regla general.

Ley de probabilidad total: promediar sobre una partición

Si $B_1, \dots, B_k$ particionan Ω (disjuntos y exhaustivos):


$$P(A) = \sum_{i=1}^k P(A \mid B_i) \cdot P(B_i)$$

Ejemplo: deserción (D) en un programa nacional implementado en tres regiones.

Región	Peso $P(B_i)$	Deserción $P(D \mid B_i)$	Aporte $P(D \cap B_i)$
Norte	0.20	0.15	0.030
Centro	0.50	0.08	0.040
Sur	0.30	0.12	0.036
Total	1.00	—	$P(D) = 0.106$

La tasa nacional (10.6 %) es un **promedio ponderado** de las tasas regionales. Y de regalo, ya podemos invertir: $P(\text{Norte} \mid D) = 0.030/0.106 = 0.28$ — el Norte aporta 28 % de la deserción con solo 20 % de los beneficiarios.

La partición en imágenes: sumar los pedazos de A



Las bandas B_1, B_2, B_3 (las regiones) cubren todo Ω sin traslaparse; el evento A (desertar) queda cortado en tres pedazos y $P(A)$ es la suma de sus áreas.



Intuición

La tasa global es una mezcla: cada región aporta su propia tasa, pesada por su tamaño. Recuperar el total es volver a juntar los pedazos del evento que quedaron en cada banda.

Teorema de Bayes: derivación en tres pasos

Paso 1 — la regla del producto, escrita en ambos sentidos:

$$P(A \cap B) = P(A \mid B) \cdot P(B) \qquad P(A \cap B) = P(B \mid A) \cdot P(A)$$

Paso 2 — igualar y despejar:

$$P(B \mid A) = \frac{P(A \mid B) \cdot P(B)}{P(A)}$$


Paso 3 — expandir $P(A)$ con probabilidad total (forma general, con partición $B_1, \dots, B_k$):

$$P(B_j \mid A) = \frac{P(A \mid B_j) \cdot P(B_j)}{\sum_{i=1}^k P(A \mid B_i) \cdot P(B_i)}$$

Nomenclatura: $P(B) = \text{prior}$ · $P(A \mid B) = \text{verosimilitud}$ · $P(A) = \text{evidencia}$ · $P(B \mid A) = \text{posterior}$. Bayes es la regla para **actualizar creencias con datos**.

El árbol del test diagnóstico

Test para una enfermedad: prevalencia 0.01, sensibilidad 0.95, especificidad 0.90.



Las ramas "Test +" suman la evidencia $P(+) = 0.0095 + 0.0990 = 0.1085$: los **falsos positivos superan 10 a 1** a los verdaderos.

P(Enferma | +): el cálculo completo

Probabilidad total (denominador de Bayes):

$$P(+) = 0.95 \times 0.01 + 0.10 \times 0.99 = 0.1085$$

Teorema de Bayes:

$$P(\text{Enf} | +) = \frac{0.95 \times 0.01}{0.1085} = 0.0876$$

```
prev <- 0.01; sens <- 0.95; esp <- 0.90
p_pos <- sens * prev + (1 - esp) * (1 - prev)
round(c(P_positivo = p_pos,
        P_enf_dado_pos = sens * prev / p_pos), 4)
```

P_positivo	P_enf_dado_pos
0.1085	0.0876



Un test con 95 % de sensibilidad entrega solo **8.8 % de certeza**: de cada 100 positivos, 91 son falsas alarmas. Ignorar la prevalencia es el error de **negligencia de la tasa base**.

Frecuencias naturales: la misma respuesta sin fórmulas

Imagine **10.000 personas** con las mismas tasas (prevalencia 1 %, sensibilidad 95 %, especificidad 90 %):

	Test +	Test -	Total
Enfermas (100)	95	5	100
Sanas (9.900)	990	8.910	9.900
Total	1.085	8.915	10.000

$$P(\text{Enf} \mid +) = \frac{95}{95 + 990} = \frac{95}{1.085} = 0.0876$$

- De cada 1.085 alertas positivas, solo 95 son reales: la baja prevalencia hace que las 990 falsas alarmas de la población sana dominen.
- Gigerenzer: presentar riesgos como **frecuencias naturales** (“95 de cada 1.085”) reduce drásticamente los errores de interpretación de médicos, jueces y policymakers.

Laboratorio: Teorema de Bayes

Mueva los controles del test diagnóstico y observe cómo el posterior $P(\text{Enf} \mid +)$ responde a la prevalencia, la sensibilidad y la especificidad.


En la versión HTML este laboratorio permite mover prevalencia, sensibilidad y especificidad, y compara en vivo el prior con los posteriores tras un test positivo o negativo. Con sensibilidad 95 % y especificidad 90 %:

Prevalencia (prior)	$P(\text{Enf} \mid +)$ (posterior)
0.1 %	0.9 %
1.0 %	8.8 %
5.0 %	33.3 %
20.0 %	70.4 %

La conclusión del laboratorio: el posterior es esclavo del prior. Subir la especificidad rinde más que subir la sensibilidad cuando la prevalencia es baja.

Prior → posterior: incluso un test excelente decepciona

Teorema de Bayes: Test Médico




Un test mejor que el anterior (sensibilidad 99 %, especificidad 95 %), misma prevalencia de 1 %:

- Prior: $P(\text{Enf}) = 1 \%$
- Posterior: $P(\text{Enf} \mid +) \approx 16.6 \%$

Implicancia de política: en tamizajes masivos de baja prevalencia (cáncer, fraude, dopaje), la mayoría de los positivos serán falsos **aunque el instrumento sea excelente**.

Solución bayesiana: repetir el test solo al grupo positivo. Con prior 16.6 %, un segundo positivo independiente eleva el posterior a $\approx 80 \%$: *el posterior de hoy es el prior de mañana*.

El posterior depende de la prevalencia



Con prevalencia 1 %: posterior de 8.8 % (FP 10 %), 16 % (FP 5 %) y 49 % (FP 1 %). Toda curva sobre la diagonal punteada indica que el test **sí aporta información** — pero cuánto, depende del prior.

La falacia del fiscal

El error: confundir $P(\text{evidencia} \mid \text{inocente})$ con $P(\text{inocente} \mid \text{evidencia})$ — la “confusión de la inversa”, el mismo error del test diagnóstico.


Ejemplo clásico (ADN): la muestra del sitio coincide con el acusado y el perito declara que la probabilidad de coincidencia por azar es 1 en 1.000.000.

Cantidad	Valor
$P(\text{coincidencia} \mid \text{inocente})$	1 / 1.000.000
Población plausible de la ciudad	5.000.000
Coincidencias inocentes esperadas	≈ 5
$P(\text{culpable} \mid \text{coincidencia})$ sin otra evidencia	$\approx 1/6 \approx 17\%$

! El fiscal presenta “1 en un millón” como si fuera la probabilidad de inocencia; Bayes muestra que, sin más evidencia, hay ≈ 6 personas compatibles y la culpabilidad es $\approx 17\%$. El mismo razonamiento aplica a alertas algorítmicas de fraude y a la vigilancia predictiva.

Aplicación: detección de fraude en programas sociales

```
prev <- 0.02; sens <- 0.90
fp <- c(0.05, 0.02, 0.01, 0.005)
post <- sens * prev /
  (sens * prev + fp * (1 - prev))
et <- scales::percent(fp, 0.1)
tibble(
  tasa = factor(et, levels = et),
  post = post) %>%
  ggplot(aes(tasa, post)) +
  geom_col(fill = celeste,
    width = 0.6) +
  geom_text(aes(label =
    scales::percent(post, 1)),
    vjust = -0.4, color = azul) +
  scale_y_continuous(
    labels = scales::percent,
    limits = c(0, 0.95)) +
  labs(x = "Tasa falsos positivos",
    y = "P(fraude | alerta)")
```



Algoritmo antifraude: 2 % de fraude, sensibilidad 90 %. **Reducir los falsos positivos rinde más que subir la sensibilidad:** cada alerta falsa es un beneficiario legítimo suspendido.

Verificación Monte Carlo del Teorema de Bayes

Simulamos 100.000 personas con las tasas del test diagnóstico y contamos, entre los positivos, cuántos están realmente enfermos:


```
set.seed(123)
n <- 100000
enfermo <- rbinom(n, 1, 0.01)
p_test <- ifelse(enfermo == 1, 0.95, 0.10)
positivo <- rbinom(n, 1, p_test)
round(c(P_pos_simulada = mean(positivo),
        P_enf_dado_pos_simulada = mean(enfermo[positivo == 1]),
        teorico = 0.0876), 4)
```

P_pos_simulada	P_enf_dado_pos_simulada	teorico
0.1089	0.0898	0.0876

- La frecuencia simulada coincide con el valor teórico: la **ley de grandes números** en acción.
- Método general: cuando la fórmula es intratable (modelos jerárquicos, sistemas complejos), **simular es calcular**. Es la base del análisis bayesiano computacional moderno (MCMC).

De eventos a variables aleatorias

Función de Masa de Probabilidad (PMF)
Distribución Binomial ($n=10, p=0.6$)



Variable aleatoria: función que asigna un número a cada resultado, $X : \Omega \rightarrow \mathbb{R}$.

Función de masa de probabilidad (PMF):

$$P(X = k) \geq 0, \quad \sum_k P(X = k) = 1$$

Ejemplo: 10 egresados de un programa de empleo, cada uno consigue trabajo con $p = 0.6$ de forma independiente. $X =$ n° de colocados:

$$X \sim \text{Binomial}(10, 0.6), \quad E(X) = np = 6$$

La figura muestra su PMF: el resultado más probable es 6, pero valores entre 4 y 8 concentran casi toda la masa.

Errores comunes al razonar con incertidumbre

Error	Ejemplo	Corrección
Negligencia de la tasa base	“El test es 95 % sensible, luego estoy 95 % enfermo”	Teorema de Bayes con el prior
Falacia del fiscal	Condenar porque $P(\text{evidencia} \mid \text{inocente})$ es pequeña	Calcular $P(\text{inocente} \mid \text{evidencia})$
Confusión de la inversa	Reportar $P(A \mid B)$ como si fuera $P(B \mid A)$	Tabla de frecuencias naturales
Asumir independencia	Multiplicar riesgos correlacionados	Verificar $P(A \cap B) = P(A)P(B)$
Sumar sin restar intersección	Proporciones que suman más de 100 %	Inclusión-exclusión
Asociación leída como causa	“La educación causa el voto” desde una tabla	Diseños causales (econometría)

Síntesis: qué llevarse de esta sesión

Checklist para razonar con probabilidades

- 1 Definir Ω y los eventos sin ambigüedad
- 2 Distinguir conjunta, marginal y condicional
- 3 Nunca asumir independencia: verificarla
- 4 Ante un condicional invertido, aplicar Bayes
- 5 Comunicar con frecuencias naturales
- 6 Simular (Monte Carlo) para verificar cálculos
- 7 Recordar: el posterior depende del prior

Funciones R de esta sesión

`sample()` `rbinom()` `cumsum()` `mean()`
`table()` `prop.table()` `chisq.test()`
`set.seed()` `ifelse()` `crossing()`

Fórmula estrella:

$$P(B | A) = \frac{P(A | B)P(B)}{P(A)}$$

Próxima sesión: distribuciones de probabilidad (Binomial, Poisson, Normal).

Ejercicio para practicar (30 min)

Escenario: test de drogas para conductores de transporte escolar. Prevalencia de consumo: 0.5 %; sensibilidad: 98 %; especificidad: 97 %.

- 1 Dibuje el árbol de probabilidades y calcule $P(+)$ con la ley de probabilidad total.
- 2 Calcule $P(\text{consumo} \mid +)$ con el Teorema de Bayes. ¿Le sorprende el resultado?
- 3 Construya la tabla de frecuencias naturales para 100.000 conductores y verifique el valor.
- 4 ¿Desde qué prevalencia el posterior supera 50 %? (Pista: iguale verdaderos y falsos positivos.)
- 5 Simule el escenario en R con `rbinom()` ($n = 100.000$, con `set.seed()`) y compare con el valor teórico.
- 6 Discuta: ¿qué protocolo recomendaría tras un positivo — despido inmediato o test confirmatorio? Justifique con los números.

i Referencias: Blitzstein & Hwang, *Introduction to Probability* (caps. 1–2) · Gigerenzer, *Calculated Risks* · Illowsky & Dean, *Introductory Statistics* (caps. 3–4).