

Sesión 3 · Distribuciones de Probabilidad

Nivelación Estadística y Probabilidades — Doctorados en Políticas Públicas y en Ciencias de la Complejidad Social · Universidad del Desarrollo

Amaru Agüero Jiménez (a.agueroj@udd.cl)

marzo de 2026

Panorama de la sesión

Bloque	Concepto clave	Herramienta en R
Variable aleatoria	Discreta vs continua; PMF, PDF, CDF	<code>dbinom()</code> , <code>pnorm()</code>
Esperanza y varianza	$E(X)$, $Var(X)$ de una v.a.	<code>sum(x * p)</code>
Discretas	Bernoulli, Binomial, Poisson	<code>dbinom()</code> , <code>dpois()</code>
Continuas	Normal, estandarización Z, t de Student	<code>pnorm()</code> , <code>qt()</code>
Familia d/p/q/r	densidad, acumulada, cuantil, simulación	<code>qnorm()</code> , <code>rnorm()</code>
TLC	distribución muestral y error estándar	<code>replicate()</code>

i **Idea de la sesión:** las distribuciones son los *modelos generadores* de los datos de política pública: encuestas (Binomial), delitos por comuna (Poisson), ingresos (log-normal), medias muestrales (Normal, gracias al TLC). Elegir bien la distribución es elegir bien el error estándar.

Variable aleatoria: del fenómeno social al número

Una **variable aleatoria** asigna un número a cada resultado de un fenómeno incierto: $X : \Omega \rightarrow \mathbb{R}$.

- **Discreta**: valores contables (0, 1, 2, ...) — se describe con una PMF.
- **Continua**: cualquier valor en un intervalo — se describe con una PDF.

Fenómeno de política pública	Valores de X	Tipo	Modelo natural
Un hogar apoya (o no) una reforma	0, 1	Discreta binaria	Bernoulli
Apoyos en una muestra de n hogares	0, 1, ..., n	Discreta acotada	Binomial
Delitos en una comuna por semana	0, 1, 2, ... (sin tope)	Discreta de conteo	Poisson
Ingreso de un hogar	reales positivos	Continua	Normal (en log)
Media de una encuesta	reales	Continua	Normal (por el TLC)


PMF, PDF y CDF: tres formas de describir una v.a.

Función	Aplica a	Qué entrega	En R
PMF: $P(X = x)$	Discretas	Probabilidad de cada valor exacto	<code>dbinom()</code> , <code>dpois()</code>
PDF: $f(x)$	Continuas	Densidad: la probabilidad es un área	<code>dnorm()</code> , <code>dt()</code>
CDF: $F(x) = P(X \leq x)$	Ambas	Probabilidad acumulada hasta x	<code>pnorm()</code> , <code>pbinom()</code>

! En una v.a. continua $P(X = x) = 0$ para cualquier valor puntual: solo las áreas tienen probabilidad, $P(a < X < b) = F(b) - F(a)$. Por eso `dnorm()` entrega *alturas de densidad*, no probabilidades.

Anatomía de una PMF: Binomial(10, 0.6)


Función de Masa de Probabilidad (PMF)
Distribución Binomial ($n=10, p=0.6$)



Lectura de la figura (X = personas que aprueban una política entre 10 encuestadas, $p = 0.6$):

- Cada barra es $P(X = k)$: una probabilidad entre 0 y 1.
- Las 11 barras **suman exactamente 1**.
- El máximo está cerca de $E(X) = np = 6$.
- En R: `dbinom(6, 10, 0.6) = 0.251`.

PDF vs CDF: dos vistas de la misma probabilidad



Con ingresos $\sim N(800, 200^2)$: el área a la izquierda de 600 en la PDF es la altura de la CDF en 600. `pnorm()` calcula siempre esa área izquierda.

Esperanza y varianza de una variable aleatoria

$$E(X) = \sum_x x P(X = x), \quad Var(X) = \sum_x (x - \mu)^2 P(X = x)$$

En continuas se reemplaza la suma por una integral. La esperanza es el **promedio poblacional de largo plazo**; la varianza, su incertidumbre.

```
x <- 0:3 # atenciones anuales por beneficiario
p <- c(0.20, 0.35, 0.30, 0.15) # sus probabilidades
mu <- sum(x * p)
round(c(esperanza = mu, varianza = sum((x - mu)^2 * p),
        de = sqrt(sum((x - mu)^2 * p))), 2)
```

esperanza	varianza	de
1.40	0.94	0.97


Con 10.000 beneficiarios, el programa espera unas 14.000 atenciones al año: la **esperanza dimensiona el presupuesto**; la varianza, el margen de seguridad.

Bernoulli: el ensayo sí/no de las encuestas

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\}$$

$$E(X) = p, \quad \text{Var}(X) = p(1 - p)$$

- Un solo ensayo con dos resultados: apoya / no apoya, ocupado / desocupado, aprueba / reprueba.
- Es el **ladrillo básico**: la Binomial suma n Bernoullis independientes.
- Si $p = 0.6$: $P(X = 1) = 0.6$, $P(X = 0) = 0.4$.



Por eso las encuestas reportan su margen de error en el “peor caso” $p = 0.5$.

Binomial: contar éxitos en n ensayos

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad E(X) = np, \quad Var(X) = np(1 - p)$$

Supuestos: n fijo y conocido, ensayos independientes, p constante entre ensayos.

```
n <- 30; p <- 0.7      # 30 hogares; 70% con acceso a internet
round(c(esperanza = n * p, de = sqrt(n * p * (1 - p)),
        p_igual_20 = dbinom(20, n, p),
        p_25_o_mas = 1 - pbinom(24, n, p)), 3)
```


esperanza	de	p_igual_20	p_25_o_mas
21.000	2.510	0.142	0.077

En una muestra de 30 hogares esperamos 21 con acceso ($DE = 2.5$); observar 25 o más ocurre solo el 8 % de las veces si p realmente es 0.7.


La PMF Binomial en R: dbinom()

```
n <- 30; p <- 0.7
df <- tibble(k = 0:n,
             prob = dbinom(k, n, p))
ggplot(df, aes(k, prob)) +
  geom_col(fill = "celeste",
           color = "white") +
  geom_vline(xintercept = n * p,
             color = "rojo",
             linetype = "dashed",
             linewidth = 1) +
  labs(x = "Hogares con internet (k)",
       y = "P(X = k)")
```

`dbinom(k, n, p)` evalúa la PMF en cada valor de k ; la línea roja marca $E(X) = np = 21$.



Binomial: el efecto de n y p





p controla la **asimetría** (lejos de 0.5, la PMF se sesga) y n la **concentración**: al crecer n , la distribución se centra en np y toma forma de campana — un anticipo del TLC.

Poisson: la distribución de los eventos raros

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

$$E(X) = Var(X) = \lambda$$

- Cuenta eventos en un intervalo fijo de tiempo o espacio, con **tasa constante** λ y eventos independientes.
- No hay un n máximo: el conteo es abierto.
- **Aplicaciones:** delitos por comuna-semana, accidentes de tránsito, llegadas a una urgencia, brotes epidémicos.



Dos modelos de conteo: la Binomial está acotada por n ; la Poisson solo depende de la tasa λ .


Poisson en R: delitos por comuna

```
lambda <- 3 # delitos por semana
round(c(p_0 = dpois(0, lambda),
        p_3 = dpois(3, lambda),
        p_6_o_mas =
          1 - ppois(5, lambda)), 3)
```


p_0	p_3	p_6_o_mas
0.050	0.224	0.084

Una semana con **6 o más delitos** ocurre el 8.4 % de las veces aun si nada cambió. Antes de anunciar una “ola delictual” (o un refuerzo policial), hay que descartar la fluctuación esperable.

Poisson(3): la cola de semanas malas




Poisson al variar la tasa λ



Al crecer λ la distribución se desplaza, se ensancha (recordar: $\text{varianza} = \lambda$) y se vuelve casi simétrica. La igualdad $\text{media} = \text{varianza}$ (**equidispersión**) es un supuesto verificable: los delitos suelen estar *sobredispersos*, lo que motiva la binomial negativa en el curso de econometría.

De la Binomial a la Poisson: la ley de eventos raros



Si $n \rightarrow \infty$ y $p \rightarrow 0$ con $np = \lambda$ fijo, la Binomial converge a $\text{Poisson}(\lambda)$. Ejemplo: 1.000 licitaciones con probabilidad 0.005 de irregularidad — el número de casos es $\text{Poisson}(5)$: **un parámetro en vez de dos**, sin necesidad de conocer n .


Normal: definición y parámetros

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$


Notación: $X \sim N(\mu, \sigma^2)$

- Simétrica y unimodal: media = mediana = moda.
- μ **desplaza** la curva; σ la **ensancha**.
- Surge cuando muchas causas pequeñas e independientes se *suman* — por eso reaparece en el TLC.

mu desplaza, sigma ensancha



La regla empírica 68-95-99.7



Para cualquier $N(\mu, \sigma^2)$:

- **68 %** de los casos en $[\mu - \sigma, \mu + \sigma]$
- **95 %** en $[\mu - 2\sigma, \mu + 2\sigma]$
- **99.7 %** en $[\mu - 3\sigma, \mu + 3\sigma]$

Con ingresos $\sim N(800, 200^2)$: el 95 % de los hogares está entre 400 y 1.200 mil \$.

Un valor a más de 3σ es rarísimo: en datos administrativos, primero sospeche **error de digitación**.

Estandarización: todo se compara en unidades Z

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1) \Rightarrow \text{"a cuántas DE está } x \text{ de la media"}$$

- Lleva cualquier normal a la **normal estándar** $N(0, 1)$: una sola escala de referencia.
- Permite comparar variables con unidades distintas: puntaje de un test vs ingreso.

```
# Puntaje municipal ~ N(500, 100); un municipio obtiene 620
round(c(z = (620 - 500) / 100,
      via_original = pnorm(620, mean = 500, sd = 100),
      via_z = pnorm(1.2)), 3)
```

	z	via_original	via_z
	1.200	0.885	0.885


Ambas vías coinciden: el municipio supera al **88.5 %** de los municipios. Estandarizar no cambia la probabilidad, solo la unidad de medida.

pnorm(): probabilidades como áreas

```
mu <- 800; s <- 200
round(c(
  bajo_600 = pnorm(600, mu, s),
  sobre_1000 =
    1 - pnorm(1000, mu, s),
  entre = pnorm(1000, mu, s) -
    pnorm(600, mu, s)), 3)
```

bajo_600	sobre_1000	entre
0.159	0.159	0.683

pnorm() entrega **siempre el área a la izquierda**: la cola derecha es $1 - \text{pnorm}()$ y un tramo es la resta de dos acumuladas.



La familia d / p / q / r: una gramática para toda distribución

Prefijo	Pregunta	Normal	Binomial	Poisson
d	$P(X = k)$ / densidad	dnorm()	dbinom()	dpois()
p	$P(X \leq x)$ (CDF)	pnorm()	pbinom()	ppois()
q	cuantil de prob. p	qnorm()	qbinom()	qpois()
r	simular n valores	rnorm()	rbinom()	rpois()

```
set.seed(42)
round(c(d = dnorm(0), p = pnorm(1.96), q = qnorm(0.975), r = rnorm(1)), 3)
```

```
      d      p      q      r
0.399 0.975 1.960 1.371
```


La misma lógica cubre la t (dt, pt, qt, rt) y toda distribución de R; p y q son **inversas** entre sí.

qnorm(): del porcentaje al umbral de focalización

```
mu <- 800; s <- 200
# Umbral del 20% mas pobre
q20 <- qnorm(0.20, mu, s)
# pnorm invierte a qnorm
round(c(umbral = q20,
        check = pnorm(q20, mu, s)),
      3)
```

umbral	check
631.676	0.200


La pregunta de focalización — *¿bajo qué ingreso está el 20 % más pobre?* — es exactamente un **cuantil**: el umbral de elegibilidad del programa es 632 mil \$.



t de Student: la normal con colas pesadas


$$T = \frac{Z}{\sqrt{V/\nu}} \sim t_{\nu}, \quad Z \sim N(0,1), \quad V \sim \chi_{\nu}^2$$

- Aparece al estimar μ con σ **desconocida**:
 $\frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t_{n-1}.$
- Simétrica en 0, pero con **colas más pesadas**:
reconoce la incertidumbre extra de estimar s .
- ν = grados de libertad; si $\nu \rightarrow \infty$, $t_{\nu} \rightarrow N(0,1)$.
- Uso típico: pilotos y programas nuevos con **muestras pequeñas**.



Con pocos grados de libertad, los valores extremos son mucho más probables que bajo la normal.

t vs normal: cuánto pesan las colas



```
round(c(t_df3 = qt(.975, 3), t_df10 = qt(.975, 10),  
        t_df30 = qt(.975, 30), normal = qnorm(.975)), 2)
```

t_df3	t_df10	t_df30	normal
3.18	2.23	2.04	1.96

Con $df = 3$ el valor crítico al 95 % es **3.18**, no 1.96: con muestras pequeñas los intervalos deben ser más anchos.

Teorema del Límite Central: el enunciado


Si $X_1, \dots, X_n$ son iid con media μ y varianza σ^2 finitas:

$$\bar{X}_n \xrightarrow{d} N\left(\mu, \frac{\sigma^2}{n}\right)$$

sin importar la forma de la distribución original.

- Justifica usar la normal para medias de encuestas, aunque los ingresos sean sesgados o los datos sean conteos.
- Base de los intervalos de confianza y tests de la Sesión 4.
- Requiere independencia y varianza finita — no es magia.

Teorema del Límite Central (Distribución Original: Uniforme)




Población uniforme (nada normal) y, aun así, las medias muestrales se acampanan al crecer n .

TLC en acción: simulación desde una población sesgada

```
set.seed(123)
sim <- crossing(n = c(2, 10, 50),
               rep = 1:3000) %>%
  mutate(
    media = map_dbl(n, \(k)
      mean(rexp(k, rate = 1/5))),
    etq = fct_inorder(
      paste0("n = ", n)))
ggplot(sim, aes(media)) +
  geom_histogram(bins = 40,
                fill = "celeste",
                color = "white") +
  facet_wrap(~ etq,
             scales = "free") +
  labs(x = "Media muestral",
       y = "Frecuencia")
```


Población: tiempos de espera Exponencial
(media 5 días), fuertemente sesgada.



Con $n = 2$ las medias heredan el sesgo; con $n = 50$ ya son campanas centradas en 5. Es el TLC operando sobre una población **nada** normal.


Distribución muestral de la media y error estándar

Población Original ($\mu=100, \sigma=15$)



↓ Muestras aleatorias (n=30) ↓

Distribución Muestral del Promedio (n=30)



La media muestral es una **variable aleatoria**: cambia de muestra en muestra. Su DE se llama **error estándar**:

$$EE(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

- Mide la precisión del *estimador*, no la dispersión de los individuos.
- Cae con $\sqrt{n}$: **cuadruplicar** la encuesta solo reduce el EE a la **mitad** — el costo de la precisión crece rápido.
- Margen de error al 95 %: $\pm 1.96 \cdot EE$.

¿Qué distribución para qué problema de política pública?

Pregunta	Variable	Distribución	Función R
Hogar apoya la reforma (sí/no)	binaria 0/1	Bernoulli	<code>rbinom(size = 1)</code>
Apoyos entre n encuestados	conteo acotado	Binomial	<code>dbinom()</code>
Delitos por comuna-semana	conteo sin tope	Poisson	<code>dpois()</code>
Ingreso o puntaje individual	continua	Normal (o log-normal)	<code>pnorm()</code>
Media, n pequeño, σ desconocida	continua	t de Student	<code>qt()</code>
Media, n grande	continua	Normal (por TLC)	<code>qnorm()</code>



La distribución elegida determina el **error estándar**: tratar un conteo Poisson como normal subestima la probabilidad de semanas extremas.

Síntesis: qué debe quedar de esta sesión

Checklist conceptual

- 1 Clasificar la v.a.: ¿discreta o continua?
- 2 Elegir la distribución y **justificar sus supuestos** (independencia, p constante, tasa constante).
- 3 Reportar $E(X)$ y $Var(X)$ del modelo.
- 4 Calcular probabilidades con d/p , umbrales con q , simular con r .
- 5 Estandarizar (Z) para comparar escalas distintas.
- 6 Usar t si n es pequeño y σ desconocida.
- 7 Invocar el TLC para medias: $EE = \sigma/\sqrt{n}$.

Funciones R de esta sesión

`dbinom()` `pbinom()` `rbinom()` `dpois()`
`ppois()` `rpois()` `dnorm()` `pnorm()`
`qnorm()` `rnorm()` `qt()` `rt()` `rexp()`
`replicate()` `set.seed()`

Próxima sesión: estimación puntual e intervalos de confianza — usaremos la distribución muestral y el error estándar como materia prima.

Ejercicio para practicar (30 min)

Con las herramientas de hoy (use `set.seed(2026)`):

- 1 Puntajes de un test docente $\sim N(70, 10^2)$: calcule $P(X > 85)$ y el percentil 90 con `pnorm()` y `qnorm()`.
- 2 Para muestras de $n = 25$ docentes: escriba la distribución de $\bar{X}$, su EE, y calcule $P(\bar{X} > 74)$.
- 3 Delitos comunales $\sim \text{Poisson}(4)$: calcule $P(X = 0)$ y $P(X \geq 8)$; simule 52 semanas con `rpois()` y compare media y varianza muestrales con λ .
- 4 Encuesta de $n = 200$ con $p = 0.55$ de apoyo: obtenga $E(X)$, DE y $P(X \geq 110)$ con `pbinom()`. ¿Le parece razonable aproximar con una normal? Justifique con la forma de la PMF.
- 5 Repita la simulación del TLC reemplazando `rexp()` por `rpois(k, 4)`. ¿Con qué n las medias ya se ven normales?

i Referencias: Wasserman, *All of Statistics* (caps. 2–5) · Illowsky & Dean, *Introductory Statistics* (caps. 4–7) · Wickham & Grolemund, *R for Data Science* · Cheatsheet “Distributions in R” (Posit).