Sesión 3: Distribuciones de Probabilidad

Amaru Agüero

Doctorado en Ciencias de la Complejidad Social — CICS, UDD

19 de marzo de 2026

Universidad del Desarrollo
Facultad de Gobierno

Agenda de la sesión

1. Distribuciones Discretas
2. Distribución Normal
3. Teorema del Límite Central
4. Distribuciones Derivadas
5. Funciones en R
6. Ejercicio Práctico

Distribuciones Discretas

- Las distribuciones discretas modelan variables aleatorias que toman un número finito o contable de valores.

Distribuciones Discretas

- Las distribuciones discretas modelan variables aleatorias que toman un número finito o contable de valores.
- Características:
  - Función de Masa de Probabilidad (PMF): $P(X = x)$
  - Probabilidades suman 1
  - Aplicaciones: conteos, eventos sí/no

Distribuciones Discretas

- Las distribuciones discretas modelan variables aleatorias que toman un número finito o contable de valores.
- Características:
  - Función de Masa de Probabilidad (PMF): $P(X = x)$
  - Probabilidades suman 1
  - Aplicaciones: conteos, eventos sí/no
- Principales distribuciones:
  - Distribución de Bernoulli
  - Distribución Binomial
  - Distribución de Poisson

Distribución de Bernoulli

Definición

Experimento con dos resultados posibles: éxito (1) o fracaso (0).

Distribución de Bernoulli

Definición

Experimento con dos resultados posibles: éxito (1) o fracaso (0).

Función de Masa de Probabilidad:

$$P(X = x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}$$

donde p es la probabilidad de éxito, $0 < p < 1$.

Distribución de Bernoulli

Definición

Experimento con dos resultados posibles: éxito (1) o fracaso (0).

Función de Masa de Probabilidad:

$$P(X = x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}$$

donde p es la probabilidad de éxito, $0 < p < 1$.

Parámetros:

$$\begin{aligned} \text{Media:} \quad & \mu = p \\ \text{Varianza:} \quad & \sigma^2 = p(1-p) \end{aligned}$$

Ejemplo:

- Lanzar una moneda
- Resultado de una pregunta sí/no
- Votación sobre una propuesta

Distribución de Bernoulli

Definición

Experimento con dos resultados posibles: éxito (1) o fracaso (0).

Función de Masa de Probabilidad:

$$P(X = x) = p^x(1-p)^{1-x}, \quad x \in \{0, 1\}$$

donde p es la probabilidad de éxito, $0 < p < 1$.

Parámetros:

$$\begin{aligned} \text{Media:} \quad & \mu = p \\ \text{Varianza:} \quad & \sigma^2 = p(1-p) \end{aligned}$$

Ejemplo:

- Lanzar una moneda
- Resultado de una pregunta sí/no
- Votación sobre una propuesta

Si $p = 0.6$:

$$P(X = 1) = 0.6$$
$$P(X = 0) = 0.4$$

Distribución Binomial

Definición

Suma de n ensayos de Bernoulli independientes, cada uno con probabilidad de éxito p.

Distribución Binomial

Definición

Suma de n ensayos de Bernoulli independientes, cada uno con probabilidad de éxito p.

Función de Masa de Probabilidad:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

donde $k = 0, 1, \ldots, n$.

Distribución Binomial

Definición

Suma de n ensayos de Bernoulli independientes, cada uno con probabilidad de éxito p.

Función de Masa de Probabilidad:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

donde $k = 0, 1, \ldots, n$.
Parámetros: Media: $\mu = np$, Varianza: $\sigma^2 = np(1-p)$

Aplicaciones:

- Encuestas: número de personas a favor
- Votaciones: cantidad de votos
- Control de calidad: defectos en lote

Distribución Binomial

Definición

Suma de n ensayos de Bernoulli independientes, cada uno con probabilidad de éxito p.

Función de Masa de Probabilidad:

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

donde $k = 0, 1, \ldots, n$.
Parámetros: Media: $\mu = np$, Varianza: $\sigma^2 = np(1-p)$

Aplicaciones:

- Encuestas: número de personas a favor
- Votaciones: cantidad de votos
- Control de calidad: defectos en lote

Ejemplo numérico: Si $n = 10$, $p = 0.5$:

$$P(X = 5) = \binom{10}{5} (0.5)^5 (0.5)^5 \approx 0.246$$

Distribución Binomial: Ejemplo

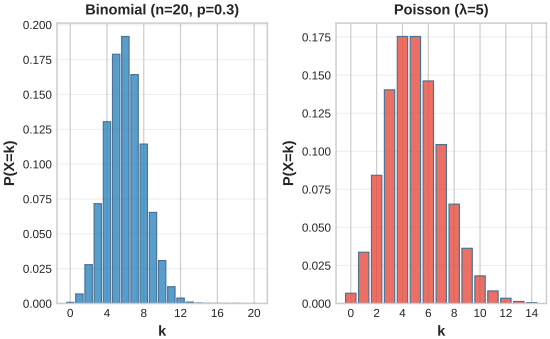

Distribución Binomial: Ejemplo

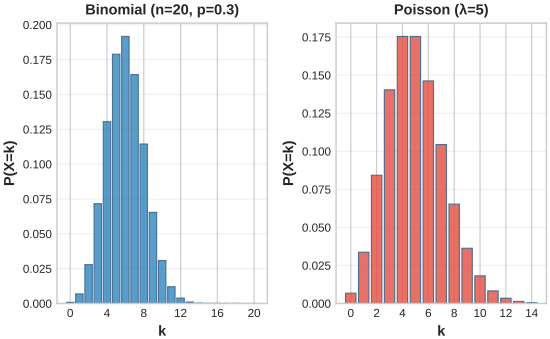

Interpretación: Dado $n = 20$ ensayos con $p = 0.4$, la probabilidad máxima ocurre alrededor de $k = 8$ éxitos.

Distribución de Poisson

Definición

Modela el número de eventos en un intervalo fijo de tiempo o espacio, con tasa promedio λ.

Distribución de Poisson

Definición

Modela el número de eventos en un intervalo fijo de tiempo o espacio, con tasa promedio λ.

Función de Masa de Probabilidad:

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \quad k = 0, 1, 2, \ldots$$

donde $\lambda > 0$ es el parámetro de tasa.

Distribución de Poisson

Definición

Modela el número de eventos en un intervalo fijo de tiempo o espacio, con tasa promedio λ.

Función de Masa de Probabilidad:

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \quad k = 0, 1, 2, \ldots$$

donde $\lambda > 0$ es el parámetro de tasa.

Parámetros: Media: $\mu = \lambda$, Varianza: $\sigma^2 = \lambda$

Aplicaciones:

- Crímenes por zona en un período
- Llamadas telefónicas por hora
- Accidentes por día
- Llegadas a una cola

Distribución de Poisson

Definición

Modela el número de eventos en un intervalo fijo de tiempo o espacio, con tasa promedio λ.

Función de Masa de Probabilidad:

$$P(X = k) = \frac{e^{-\lambda}\lambda^k}{k!}, \quad k = 0, 1, 2, \ldots$$

donde $\lambda > 0$ es el parámetro de tasa.

Parámetros: Media: $\mu = \lambda$, Varianza: $\sigma^2 = \lambda$

Aplicaciones:

- Crímenes por zona en un período
- Llamadas telefónicas por hora
- Accidentes por día
- Llegadas a una cola

Ejemplo: Si $\lambda = 3$ crímenes/semana:

$$P(X = 2) = \frac{e^{-3} \cdot 3^2}{2!} \approx 0.224$$

Distribución de Poisson: Ejemplo

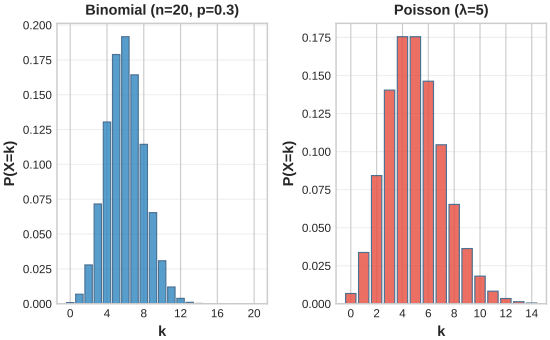

Distribución de Poisson: Ejemplo

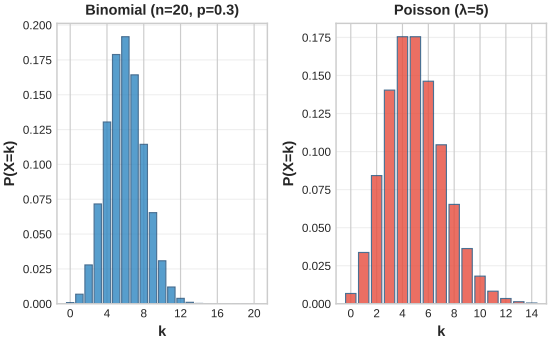

Interpretación: Para $\lambda = 4$, la probabilidad se concentra alrededor de 4 eventos, con cola decreciente.

Distribución de Poisson: Ejemplo

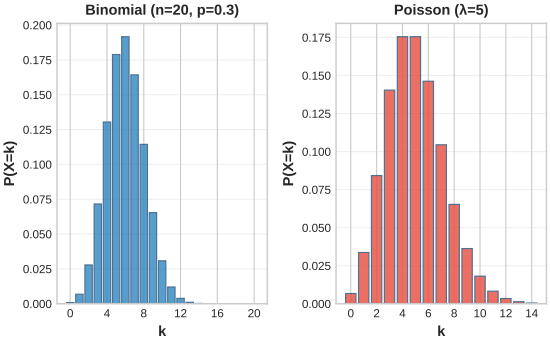

Interpretación: Para $\lambda = 4$, la probabilidad se concentra alrededor de 4 eventos, con cola decreciente.

Nota: La distribución de Poisson es el límite de la Binomial cuando $n \to \infty$, $p \to 0$ y $np = \lambda$.

Distribución Normal

Definición

La distribución normal (o gaussiana) es la más importante en estadística. Describe muchos fenómenos naturales.

Distribución Normal

Definición

La distribución normal (o gaussiana) es la más importante en estadística. Describe muchos fenómenos naturales.

Función de Densidad de Probabilidad (PDF):

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Parámetros:

- μ = media (desplaza la curva)
- σ = desviación estándar (controla amplitud)

Distribución Normal

Definición

La distribución normal (o gaussiana) es la más importante en estadística. Describe muchos fenómenos naturales.

Función de Densidad de Probabilidad (PDF):

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Parámetros:

- μ = media (desplaza la curva)
- σ = desviación estándar (controla amplitud)

Notación: $X \sim N(\mu, \sigma^2)$

Propiedades:

- Forma de campana simétrica
- Unimodal (un pico)
- Media = Mediana = Moda
- Asintótica en los extremos

Distribución Normal

Definición

La distribución normal (o gaussiana) es la más importante en estadística. Describe muchos fenómenos naturales.

Función de Densidad de Probabilidad (PDF):

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

Parámetros:

- μ = media (desplaza la curva)
- σ = desviación estándar (controla amplitud)

Notación: $X \sim N(\mu, \sigma^2)$

Propiedades:

- Forma de campana simétrica
- Unimodal (un pico)
- Media = Mediana = Moda
- Asintótica en los extremos

Aplicaciones:

- Altura, peso
- Errores de medición
- Calificaciones

Distribución Normal: Forma y Propiedades

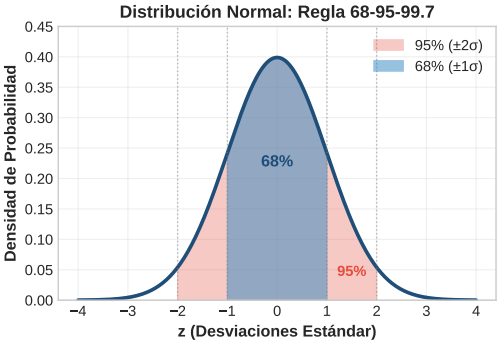

Distribución Normal: Forma y Propiedades

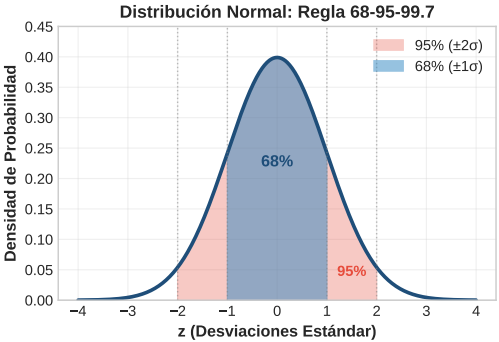

Cambios en μ y σ afectan la posición y amplitud de la curva.

Regla Empírica (68-95-99.7)

Para una distribución normal $N(\mu, \sigma^2)$:

- **68%** de los datos caen en $[\mu - \sigma, \mu + \sigma]$
- **95%** de los datos caen en $[\mu - 2\sigma, \mu + 2\sigma]$
- **99.7%** de los datos caen en $[\mu - 3\sigma, \mu + 3\sigma]$

Implicaciones:

- Observaciones $> 3\sigma$ de la media son muy raras
- Esta regla es aproximada pero muy útil en la práctica

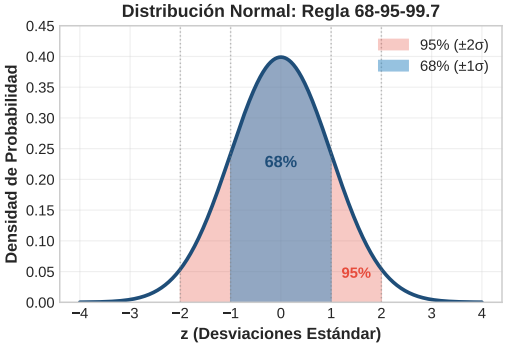

Distribución Normal Estándar y Estandarización

Estandarización (Z-score)

Convertir $X \sim N(\mu, \sigma^2)$ a la estándar $N(0,1)$: $$Z = \frac{X - \mu}{\sigma}$$

Distribución Normal Estándar y Estandarización

Estandarización (Z-score)

Convertir $X \sim N(\mu, \sigma^2)$ a la estándar $N(0,1)$: $$Z = \frac{X - \mu}{\sigma}$$

Ventajas:

- Una sola tabla de referencias
- Comparabilidad entre variables diferentes
- $P(X \leq x) = P(Z \leq z)$

Distribución Normal Estándar y Estandarización

Estandarización (Z-score)

Convertir $X \sim N(\mu, \sigma^2)$ a la estándar $N(0,1)$: $\quad Z = \dfrac{X - \mu}{\sigma}$

Ventajas:

- Una sola tabla de referencias
- Comparabilidad entre variables diferentes
- $P(X \leq x) = P(Z \leq z)$

Ejemplo: Si $X \sim N(100, 15^2)$ y queremos $P(X \leq 115)$:
$Z = \frac{115-100}{15} = 1, \quad$ luego
$P(X \leq 115) = P(Z \leq 1) \approx 0.841$

En R:

```
Cuantil (inversa) qnorm(0.841)
~1
```

Distribución Normal Estándar y Estandarización

Estandarización (Z-score)

Convertir $X \sim N(\mu, \sigma^2)$ a la estándar $N(0,1)$: $\quad Z = \dfrac{X - \mu}{\sigma}$

Ventajas:

- Una sola tabla de referencias
- Comparabilidad entre variables diferentes
- $P(X \leq x) = P(Z \leq z)$

Ejemplo: Si $X \sim N(100, 15^2)$ y queremos $P(X \leq 115)$:
$Z = \frac{115-100}{15} = 1, \quad$ luego
$P(X \leq 115) = P(Z \leq 1) \approx 0.841$

En R:

```
Cuantil (inversa) qnorm(0.841)
~1
```

Interpretación: El 84.1% de los datos está bajo $x = 115$.

Funciones R: Distribución Normal

pnorm(): Función acumulada (CDF)

```
# P(X     1) para N(0,1)
pnorm(1)

# P(X     115) para N(100,15)
pnorm(115, mean=100, sd=15)

# Prob. cola superior
1 - pnorm(1)
```

Funciones R: Distribución Normal

pnorm(): Función acumulada (CDF)

```
# P(X     1) para N(0,1)
pnorm(1)

# P(X     115) para N(100,15)
pnorm(115, mean=100, sd=15)

# Prob. cola superior
1 - pnorm(1)
```

qnorm(): Cuantiles (inversa CDF)

```
# Encontrar z tal que P(Z     z) = 0.975
qnorm(0.975)

# Percentil 95 de N(100, 15  )
qnorm(0.95, mean=100, sd=15)

# Intervalo de confianza 95%
qnorm(c(0.025, 0.975))
```

Funciones R: Distribución Normal

pnorm(): Función acumulada (CDF)

```
# P(X     1) para N(0,1)
pnorm(1)

# P(X     115) para N(100,15)
pnorm(115, mean=100, sd=15)

# Prob. cola superior
1 - pnorm(1)
```

qnorm(): Cuantiles (inversa CDF)

```
# Encontrar z tal que P(Z     z) = 0.975
qnorm(0.975)

# Percentil 95 de N(100, 15  )
qnorm(0.95, mean=100, sd=15)

# Intervalo de confianza 95%
qnorm(c(0.025, 0.975))
```

Importante

`pnorm()` da probabilidades (área bajo la curva). `qnorm()` da valores de la variable.

Teorema del Límite Central (TLC)

Enunciado

Si $X_1, X_2, \ldots, X_n$ son v.a. iid con media μ y varianza σ^2 finitas, entonces la media muestral $\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ converge a una distribución normal con media μ y varianza σ^2/n cuando $n \to \infty$.

Teorema del Límite Central (TLC)

Enunciado

Si $X_1, X_2, \ldots, X_n$ son v.a. iid con media μ y varianza σ^2 finitas, entonces la media muestral $\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ converge a una distribución normal con media μ y varianza σ^2/n cuando $n \to \infty$.

En símbolos:

$$\overline{X}_n \xrightarrow{d} N\left(\mu, \frac{\sigma^2}{n}\right)$$

Teorema del Límite Central (TLC)

Enunciado

Si $X_1, X_2, \ldots, X_n$ son v.a. iid con media μ y varianza σ^2 finitas, entonces la media muestral $\overline{X}_n = \frac{1}{n}\sum_{i=1}^{n} X_i$ converge a una distribución normal con media μ y varianza σ^2/n cuando $n \to \infty$.

En símbolos:

$$\overline{X}_n \xrightarrow{d} N\left(\mu, \frac{\sigma^2}{n}\right)$$

Implicación clave: *La distribución de la media es aproximadamente normal, incluso si la población original no lo es.*

¿Por qué es tan importante?

¿Por qué es tan importante?

- La media de una muestra es más estable que observaciones individuales
- A mayor tamaño de muestra n, más normal es $\overline{X}_n$
- La varianza de $\overline{X}_n$ es σ^2/n (disminuye con n)

¿Por qué es tan importante?

- La media de una muestra es más estable que observaciones individuales
- A mayor tamaño de muestra n, más normal es $\overline{X}_n$
- La varianza de $\overline{X}_n$ es σ^2/n (disminuye con n)

Consecuencias para la Inferencia:

- Justifica el uso de la distribución normal
- Base para intervalos de confianza
- Fundamental en pruebas de hipótesis

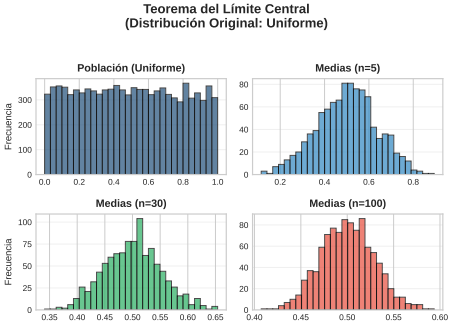

¿Por qué es tan importante?

- La media de una muestra es más estable que observaciones individuales
- A mayor tamaño de muestra n, más normal es $\overline{X}_n$
- La varianza de $\overline{X}_n$ es σ^2/n (disminuye con n)

Consecuencias para la Inferencia:

- Justifica el uso de la distribución normal
- Base para intervalos de confianza
- Fundamental en pruebas de hipótesis

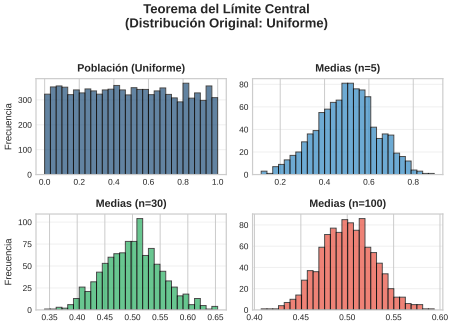

A medida que n aumenta, la distribución de $\overline{X}_n$ se vuelve más normal.

Teorema del Límite Central: Simulación en R

```r
# Simular muestras de distribuci n no-normal
set.seed(123)
n_muestras <- 10000
n <- 30

medias <- replicate(n_muestras, {
  muestra <- runif(n, min=0, max=10)  # Uniforme
  mean(muestra)
})

# Visualizar
hist(medias, breaks=50, main="Distribuci n de medias",
     xlab="Media muestral", probability=TRUE)

# Superponer normal te rica
x <- seq(4, 6, by=0.01)
lines(x, dnorm(x, mean=5, sd=sqrt(100/12/n)),
      col="red", lwd=2)
```

Resultado: Distribución uniforme $\rightarrow$ Medias distribuidas normalmente (Teorema del Límite Central confirmado).

Distribuciones Derivadas de la Normal

Cuando trabajamos con estadísticos muestrales (media, varianza), aparecen distribuciones especiales:

Distribuciones Derivadas de la Normal

Cuando trabajamos con estadísticos muestrales (media, varianza), aparecen distribuciones especiales:

- **Distribución t de Student:** Cuando estimamos σ con s

Distribuciones Derivadas de la Normal

Cuando trabajamos con estadísticos muestrales (media, varianza), aparecen distribuciones especiales:

- **Distribución t de Student:** Cuando estimamos σ con s
- **Distribución χ^2 (chi-cuadrado):** Suma de normales al cuadrado

Distribuciones Derivadas de la Normal

Cuando trabajamos con estadísticos muestrales (media, varianza), aparecen distribuciones especiales:

- **Distribución t de Student:** Cuando estimamos σ con s
- **Distribución χ^2 (chi-cuadrado):** Suma de normales al cuadrado
- **Distribución F de Fisher:** Razón de varianzas

Distribuciones Derivadas de la Normal

Cuando trabajamos con estadísticos muestrales (media, varianza), aparecen distribuciones especiales:

- **Distribución t de Student:** Cuando estimamos σ con s
- **Distribución χ^2 (chi-cuadrado):** Suma de normales al cuadrado
- **Distribución F de Fisher:** Razón de varianzas

Relación con la Normal

Todas estas distribuciones se derivan de variables normales estándar y son fundamentales para la inferencia estadística.

Distribución t de Student

Definición

Si $Z \sim N(0,1)$ y $V \sim \chi^2_\nu$ independientes: $T = \frac{Z}{\sqrt{V/\nu}} \sim t_\nu$, donde ν = grados de libertad.

Distribución t de Student

Definición

Si $Z \sim N(0,1)$ y $V \sim \chi^2_\nu$ independientes: $T = \frac{Z}{\sqrt{V/\nu}} \sim t_\nu$, donde ν = grados de libertad.

Características:

- Simétrica alrededor de 0
- Colas más pesadas que la normal
- Parámetro: ν (grados de libertad)
- $\nu \to \infty \Rightarrow t_\nu \to N(0,1)$

Distribución t de Student

Definición

Si $Z \sim N(0,1)$ y $V \sim \chi^2_\nu$ independientes: $T = \frac{Z}{\sqrt{V/\nu}} \sim t_\nu$, donde ν = grados de libertad.

Características:

- Simétrica alrededor de 0
- Colas más pesadas que la normal
- Parámetro: ν (grados de libertad)
- $\nu \to \infty \Rightarrow t_\nu \to N(0,1)$

Aplicación:

- IC para μ con σ desconocida
- Pruebas t de Student
- Muestras pequeñas

Ejemplo: $\nu = 5, 10, 30$ g.l.

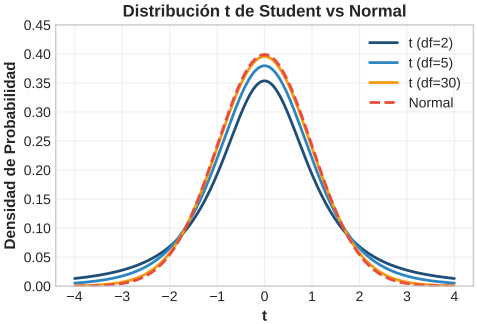

Distribución t de Student

Definición

Si $Z \sim N(0,1)$ y $V \sim \chi^2_\nu$ independientes: $T = \frac{Z}{\sqrt{V/\nu}} \sim t_\nu$, donde ν = grados de libertad.

Características:

- Simétrica alrededor de 0
- Colas más pesadas que la normal
- Parámetro: ν (grados de libertad)
- $\nu \to \infty \Rightarrow t_\nu \to N(0,1)$

Aplicación:

- IC para μ con σ desconocida
- Pruebas t de Student
- Muestras pequeñas

Ejemplo: $\nu = 5, 10, 30$ g.l.

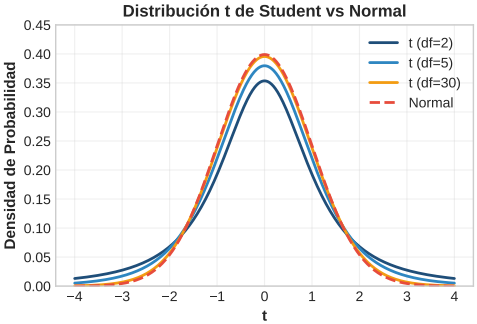

La t con pocos g.l. tiene colas más pesadas.

Definición

Si $Z_1, Z_2, \ldots, Z_k$ son normales estándar independientes, entonces

$$\chi_k^2 = \sum_{i=1}^{k} Z_i^2 \sim \chi_k^2$$

Definición

Si $Z_1, Z_2, \ldots, Z_k$ son normales estándar independientes, entonces

$$\chi_k^2 = \sum_{i=1}^{k} Z_i^2 \sim \chi_k^2$$

Características:

- Solo toma valores positivos
- Asimétrica a la derecha
- Parámetro: k (grados de libertad)
- Media: k, Varianza: $2k$

Definición

Si $Z_1, Z_2, \ldots, Z_k$ son normales estándar independientes, entonces

$$\chi_k^2 = \sum_{i=1}^{k} Z_i^2 \sim \chi_k^2$$

Características:

- Solo toma valores positivos
- Asimétrica a la derecha
- Parámetro: k (grados de libertad)
- Media: k, Varianza: $2k$

Aplicación:

- Pruebas de bondad de ajuste
- Pruebas de independencia
- Construcción de intervalos para varianza

Comportamiento con distintos k:

A mayor k, la distribución se vuelve más simétrica (acercándose a la normal).

Definición

Si $U \sim \chi^2_{\nu_1}$ y $V \sim \chi^2_{\nu_2}$ independientes: $F = \frac{U/\nu_1}{V/\nu_2} \sim F_{\nu_1,\nu_2}$

Definición

Si $U \sim \chi^2_{\nu_1}$ y $V \sim \chi^2_{\nu_2}$ independientes: $F = \frac{U/\nu_1}{V/\nu_2} \sim F_{\nu_1,\nu_2}$

Características:

- Solo valores positivos
- Asimétrica a la derecha
- Parámetros: ν_1 (num.), ν_2 (den.)
- Razón de dos varianzas muestrales

Definición

Si $U \sim \chi^2_{\nu_1}$ y $V \sim \chi^2_{\nu_2}$ independientes: $F = \frac{U/\nu_1}{V/\nu_2} \sim F_{\nu_1,\nu_2}$

Características:

- Solo valores positivos
- Asimétrica a la derecha
- Parámetros: ν_1 (num.), ν_2 (den.)
- Razón de dos varianzas muestrales

Aplicación:

- Pruebas F (ANOVA)
- Comparación de varianzas
- Regresión lineal

Relación entre distribuciones:

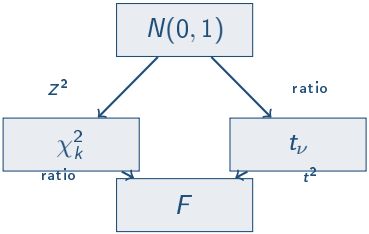

Generación de Variables Aleatorias en R

Patrón general: `r*` (random), `d*` (density), `p*` (probability), `q*` (quantile)

Generación de Variables Aleatorias en R

Patrón general: `r*` (random), `d*` (density), `p*` (probability), `q*` (quantile)

Distribuciones Discretas

```r
# Bernoulli (rbinom con n=1)
rbinom(n=100, size=1, prob=0.6)

# Binomial
rbinom(n=50, size=20, prob=0.4)

# Poisson
rpois(n=100, lambda=3)
```

Distribuciones Continuas

```r
# Normal
rnorm(n=100, mean=0, sd=1)

# t de Student
rt(n=50, df=10)

# Chi-cuadrado
rchisq(n=100, df=5)

# F de Fisher
rf(n=100, df1=5, df2=20)
```

Generación de Variables Aleatorias en R

Patrón general: `r*` (random), `d*` (density), `p*` (probability), `q*` (quantile)

Distribuciones Discretas

```r
# Bernoulli (rbinom con n=1)
rbinom(n=100, size=1, prob=0.6)

# Binomial
rbinom(n=50, size=20, prob=0.4)

# Poisson
rpois(n=100, lambda=3)
```

Distribuciones Continuas

```r
# Normal
rnorm(n=100, mean=0, sd=1)

# t de Student
rt(n=50, df=10)

# Chi-cuadrado
rchisq(n=100, df=5)

# F de Fisher
rf(n=100, df1=5, df2=20)
```

Nota

La función `set.seed()` fija la semilla para reproducibilidad.

Función p*(): CDF (Acumulada)

```
# P(X     1) para N(0,1)
pnorm(1)

# P(X     10) para Poisson(5)
ppois(10, lambda=5)

# P(X     2.5) para t con 10 gl
pt(2.5, df=10)

# Cola superior
1 - pnorm(1)
```

Función p*(): CDF (Acumulada)

```r
# P(X     1) para N(0,1)
pnorm(1)

# P(X     10) para Poisson(5)
ppois(10, lambda=5)

# P(X     2.5) para t con 10 gl
pt(2.5, df=10)

# Cola superior
1 - pnorm(1)
```

Función q*(): Cuantiles (CDF inversa)

```r
# Hallar q tal que P(Z     q) = 0.95
qnorm(0.95)

# Percentil 90 de N(100, 225)
qnorm(0.90, mean=100, sd=15)

# Intervalo de confianza 95%
qnorm(c(0.025, 0.975))

# Cuartiles de una t
qt(c(0.25, 0.5, 0.75), df=15)
```

Función p*(): CDF (Acumulada)

```r
# P(X     1) para N(0,1)
pnorm(1)

# P(X     10) para Poisson(5)
ppois(10, lambda=5)

# P(X     2.5) para t con 10 gl
pt(2.5, df=10)

# Cola superior
1 - pnorm(1)
```

Función q*(): Cuantiles (CDF inversa)

```r
# Hallar q tal que P(Z     q) = 0.95
qnorm(0.95)

# Percentil 90 de N(100, 225)
qnorm(0.90, mean=100, sd=15)

# Intervalo de confianza 95%
qnorm(c(0.025, 0.975))

# Cuartiles de una t
qt(c(0.25, 0.5, 0.75), df=15)
```

Regla Mnemotécnica

p = Prob. acumulada; q = Quantile (inversa); r = Random; d = Density/Probability

Visualización de Distribuciones

```r
# Histograma con curva te rica
set.seed(42)
datos <- rnorm(10000, mean=100, sd=15)
hist(datos, breaks=50, probability=TRUE,
     main="Normal(100, 225)", xlab="Valores")

# Superponer densidad te rica
x <- seq(50, 150, by=1)
lines(x, dnorm(x, mean=100, sd=15), col="red", lwd=2)

# Q-Q plot para verificar normalidad
qqnorm(datos)
qqline(datos, col="red")
```

Visualización de Distribuciones

```r
# Histograma con curva te rica
set.seed(42)
datos <- rnorm(10000, mean=100, sd=15)
hist(datos, breaks=50, probability=TRUE,
     main="Normal(100, 225)", xlab="Valores")

# Superponer densidad te rica
x <- seq(50, 150, by=1)
lines(x, dnorm(x, mean=100, sd=15), col="red", lwd=2)

# Q-Q plot para verificar normalidad
qqnorm(datos)
qqline(datos, col="red")
```

Funciones útiles:

- `hist()` para histogramas; `plot()` y `lines()` para curvas
- `qqnorm()` para Q-Q plots (evaluar normalidad); `curve()` para funciones

Ejercicio Práctico: Análisis de Calificaciones

Escenario

Calificaciones $\sim N(\mu = 70, \sigma = 10)$.

Ejercicio Práctico: Análisis de Calificaciones

Escenario

Calificaciones $\sim N(\mu = 70, \sigma = 10)$.

Preguntas:

1. ¿Probabilidad de calificación mayor a 85?

Ejercicio Práctico: Análisis de Calificaciones

Escenario

Calificaciones $\sim N(\mu = 70, \sigma = 10)$.

Preguntas:

1. ¿Probabilidad de calificación mayor a 85?
   $P(X > 85) = P\left(Z > \frac{85-70}{10}\right) = P(Z > 1.5) = 1 - \Phi(1.5)$

Ejercicio Práctico: Análisis de Calificaciones

Escenario

Calificaciones $\sim N(\mu = 70, \sigma = 10)$.

Preguntas:

1. ¿Probabilidad de calificación mayor a 85?
   $P(X > 85) = P\left(Z > \frac{85-70}{10}\right) = P(Z > 1.5) = 1 - \Phi(1.5)$
2. ¿Percentil 90 de las calificaciones?

Ejercicio Práctico: Análisis de Calificaciones

Escenario

Calificaciones $\sim N(\mu = 70, \sigma = 10)$.

Preguntas:

1. ¿Probabilidad de calificación mayor a 85?
   $P(X > 85) = P\left(Z > \frac{85-70}{10}\right) = P(Z > 1.5) = 1 - \Phi(1.5)$
2. ¿Percentil 90 de las calificaciones? $x_{90} = \mu + z_{90} \cdot \sigma = 70 + 1.28 \times 10 = 82.8$

Ejercicio Práctico: Análisis de Calificaciones

Escenario

Calificaciones $\sim N(\mu = 70, \sigma = 10)$.

Preguntas:

1. ¿Probabilidad de calificación mayor a 85?
   $P(X > 85) = P\left(Z > \frac{85-70}{10}\right) = P(Z > 1.5) = 1 - \Phi(1.5)$
2. ¿Percentil 90 de las calificaciones? $x_{90} = \mu + z_{90} \cdot \sigma = 70 + 1.28 \times 10 = 82.8$
3. Si $n = 25$, ¿distribución de $\overline{X}$?

Ejercicio Práctico: Análisis de Calificaciones

Escenario

Calificaciones $\sim N(\mu = 70, \sigma = 10)$.

Preguntas:

1. ¿Probabilidad de calificación mayor a 85?
   $P(X > 85) = P\left(Z > \frac{85-70}{10}\right) = P(Z > 1.5) = 1 - \Phi(1.5)$
2. ¿Percentil 90 de las calificaciones? $x_{90} = \mu + z_{90} \cdot \sigma = 70 + 1.28 \times 10 = 82.8$
3. Si $n = 25$, ¿distribución de $\overline{X}$? $\overline{X} \sim N(70,\ 10^2/25) = N(70,\ 4) \implies \text{sd}(\overline{X}) = 2$

Solución en R

```r
# Par metros
mu <- 70; sigma <- 10

# 1. P(X > 85)
p_mayor_85 <- 1 - pnorm(85, mean=mu, sd=sigma)
print(p_mayor_85)  # 0.0668

# 2. Percentil 90
percentil_90 <- qnorm(0.90, mean=mu, sd=sigma)
print(percentil_90)  # 82.82

# 3. Desv. est. de media muestral (n=25)
n <- 25
se_media <- sigma / sqrt(n)
print(se_media)  # 2

# Simular y verificar
set.seed(123)
medias <- replicate(10000, mean(rnorm(n, mean=mu, sd=sigma)))
sd(medias)  # ~2
```

Solución en R

```r
# Par metros
mu <- 70; sigma <- 10

# 1. P(X > 85)
p_mayor_85 <- 1 - pnorm(85, mean=mu, sd=sigma)
print(p_mayor_85)  # 0.0668

# 2. Percentil 90
percentil_90 <- qnorm(0.90, mean=mu, sd=sigma)
print(percentil_90)  # 82.82

# 3. Desv. est. de media muestral (n=25)
n <- 25
se_media <- sigma / sqrt(n)
print(se_media)  # 2

# Simular y verificar
set.seed(123)
medias <- replicate(10000, mean(rnorm(n, mean=mu, sd=sigma)))
sd(medias)  # ~2
```

Interpretación: El 6.68% de estudiantes obtiene más de 85 puntos.

Resumen de la Sesión

1. **Distribuciones Discretas**: Bernoulli, Binomial, Poisson modelan conteos y eventos binarios.

Resumen de la Sesión

1. **Distribuciones Discretas**: Bernoulli, Binomial, Poisson modelan conteos y eventos binarios.
2. **Distribución Normal**: La más importante; caracterizada por μ y σ.

Resumen de la Sesión

1. **Distribuciones Discretas**: Bernoulli, Binomial, Poisson modelan conteos y eventos binarios.
2. **Distribución Normal**: La más importante; caracterizada por μ y σ.
3. **Teorema del Límite Central**: La media muestral es aproximadamente normal, fundamental para inferencia.

Resumen de la Sesión

1. **Distribuciones Discretas**: Bernoulli, Binomial, Poisson modelan conteos y eventos binarios.
2. **Distribución Normal**: La más importante; caracterizada por μ y σ.
3. **Teorema del Límite Central**: La media muestral es aproximadamente normal, fundamental para inferencia.
4. **Distribuciones Derivadas**: t, χ^2, F son estadísticos de muestras normales.

Resumen de la Sesión

1. **Distribuciones Discretas**: Bernoulli, Binomial, Poisson modelan conteos y eventos binarios.
2. **Distribución Normal**: La más importante; caracterizada por μ y σ.
3. **Teorema del Límite Central**: La media muestral es aproximadamente normal, fundamental para inferencia.
4. **Distribuciones Derivadas**: t, χ^2, F son estadísticos de muestras normales.
5. **R**: Funciones `r*`, `d*`, `p*`, `q*` para generar y analizar distribuciones.

Resumen de la Sesión

1. **Distribuciones Discretas**: Bernoulli, Binomial, Poisson modelan conteos y eventos binarios.
2. **Distribución Normal**: La más importante; caracterizada por μ y σ.
3. **Teorema del Límite Central**: La media muestral es aproximadamente normal, fundamental para inferencia.
4. **Distribuciones Derivadas**: t, χ^2, F son estadísticos de muestras normales.
5. **R**: Funciones `r*`, `d*`, `p*`, `q*` para generar y analizar distribuciones.

Siguiente sesión

Estimación puntual e intervalos de confianza usando estas distribuciones.

Recursos Adicionales

- **R packages:**
  - Base R: funciones de distribuciones
  - `ggplot2`: visualización avanzada
  - `tidyverse`: manipulación de datos

Recursos Adicionales

- **R packages:**
  - Base R: funciones de distribuciones
  - `ggplot2`: visualización avanzada
  - `tidyverse`: manipulación de datos
- **Referencias:**
  - Wasserman, L. (2004). *All of Statistics*. Springer.
  - Wickham, H., & Grolemund, G. (2016). *R for Data Science*. O'Reilly.

Recursos Adicionales

- **R packages:**
  - Base R: funciones de distribuciones
  - `ggplot2`: visualización avanzada
  - `tidyverse`: manipulación de datos
- **Referencias:**
  - Wasserman, L. (2004). *All of Statistics*. Springer.
  - Wickham, H., & Grolemund, G. (2016). *R for Data Science*. O'Reilly.
- **En línea:**
  - CRAN Task Views
  - RStudio Cheatsheets

Recursos Adicionales

- **R packages:**
  - Base R: funciones de distribuciones
  - `ggplot2`: visualización avanzada
  - `tidyverse`: manipulación de datos
- **Referencias:**
  - Wasserman, L. (2004). *All of Statistics*. Springer.
  - Wickham, H., & Grolemund, G. (2016). *R for Data Science*. O'Reilly.
- **En línea:**
  - CRAN Task Views
  - RStudio Cheatsheets

¿Preguntas?