

# Sesión 3 · Distribuciones de Probabilidad

Nivelación Estadística y Probabilidades — Doctorado en Políticas Públicas

Amaru Agüero Jiménez (a.agueroj@udd.cl)

marzo de 2026

# Panorama de la sesión

| Bloque               | Concepto clave                           | Herramienta en R                             |
|----------------------|------------------------------------------|----------------------------------------------|
| Variable aleatoria   | Discreta vs continua; PMF, PDF, CDF      | <code>dbinom()</code> , <code>pnorm()</code> |
| Esperanza y varianza | $E(X)$ , $Var(X)$ de una v.a.            | <code>sum(x * p)</code>                      |
| Discretas            | Bernoulli, Binomial, Poisson             | <code>dbinom()</code> , <code>dpois()</code> |
| Continuas            | Normal, estandarización Z, t de Student  | <code>pnorm()</code> , <code>qt()</code>     |
| Familia d/p/q/r      | densidad, acumulada, cuantil, simulación | <code>qnorm()</code> , <code>rnorm()</code>  |
| TLC                  | distribución muestral y error estándar   | <code>replicate()</code>                     |

**i** **Idea de la sesión:** las distribuciones son los *modelos generadores* de los datos de política pública: encuestas (Binomial), delitos por comuna (Poisson), ingresos (log-normal), medias muestrales (Normal, gracias al TLC). Elegir bien la distribución es elegir bien el error estándar.

# Variable aleatoria: del fenómeno social al número

Una **variable aleatoria** asigna un número a cada resultado de un fenómeno incierto:  $X : \Omega \rightarrow \mathbb{R}$ .

- **Discreta**: valores contables (0, 1, 2, ...) — se describe con una PMF.
- **Continua**: cualquier valor en un intervalo — se describe con una PDF.

| Fenómeno de política pública         | Valores de $X$          | Tipo               | Modelo natural      |
|--------------------------------------|-------------------------|--------------------|---------------------|
| Un hogar apoya (o no) una reforma    | 0, 1                    | Discreta binaria   | Bernoulli           |
| Apoyos en una muestra de $n$ hogares | 0, 1, ..., $n$          | Discreta acotada   | Binomial            |
| Delitos en una comuna por semana     | 0, 1, 2, ... (sin tope) | Discreta de conteo | Poisson             |
| Ingreso de un hogar                  | reales positivos        | Continua           | Normal (en log)     |
| Media de una encuesta                | reales                  | Continua           | Normal (por el TLC) |


# PMF, PDF y CDF: tres formas de describir una v.a.

| Función                   | Aplica a  | Qué entrega                          | En R                                         |
|---------------------------|-----------|--------------------------------------|----------------------------------------------|
| PMF: $P(X = x)$           | Discretas | Probabilidad de cada valor exacto    | <code>dbinom()</code> , <code>dpois()</code> |
| PDF: $f(x)$               | Continuas | Densidad: la probabilidad es un área | <code>dnorm()</code> , <code>dt()</code>     |
| CDF: $F(x) = P(X \leq x)$ | Ambas     | Probabilidad acumulada hasta $x$     | <code>pnorm()</code> , <code>pbinom()</code> |

! En una v.a. continua  $P(X = x) = 0$  para cualquier valor puntual: solo las áreas tienen probabilidad,  $P(a < X < b) = F(b) - F(a)$ . Por eso `dnorm()` entrega *alturas de densidad*, no probabilidades.

# Anatomía de una PMF: Binomial(10, 0.6)


Función de Masa de Probabilidad (PMF)  
Distribución Binomial ( $n=10, p=0.6$ )



**Lectura de la figura** ( $X$  = personas que aprueban una política entre 10 encuestadas,  $p = 0.6$ ):

- Cada barra es  $P(X = k)$ : una probabilidad entre 0 y 1.
- Las 11 barras **suman exactamente 1**.
- El máximo está cerca de  $E(X) = np = 6$ .
- En R: `dbinom(6, 10, 0.6) = 0.251`.

# PDF vs CDF: dos vistas de la misma probabilidad



Con ingresos  $\sim N(800, 200^2)$ : el área a la izquierda de 600 en la PDF es la altura de la CDF en 600. `pnorm()` calcula siempre esa área izquierda.

# Esperanza y varianza de una variable aleatoria

$$E(X) = \sum_x x P(X = x), \quad Var(X) = \sum_x (x - \mu)^2 P(X = x)$$

En continuas se reemplaza la suma por una integral. La esperanza es el **promedio poblacional de largo plazo**; la varianza, su incertidumbre.

```
x <- 0:3 # atenciones anuales por beneficiario
p <- c(0.20, 0.35, 0.30, 0.15) # sus probabilidades
mu <- sum(x * p)
round(c(esperanza = mu, varianza = sum((x - mu)^2 * p),
        de = sqrt(sum((x - mu)^2 * p))), 2)
```

| esperanza | varianza | de   |
|-----------|----------|------|
| 1.40      | 0.94     | 0.97 |


Con 10.000 beneficiarios, el programa espera unas 14.000 atenciones al año: la **esperanza dimensiona el presupuesto**; la varianza, el margen de seguridad.

# Bernoulli: el ensayo sí/no de las encuestas

$$P(X = x) = p^x(1 - p)^{1-x}, \quad x \in \{0, 1\}$$

$$E(X) = p, \quad \text{Var}(X) = p(1 - p)$$

- Un solo ensayo con dos resultados: apoya / no apoya, ocupado / desocupado, aprueba / reprueba.
- Es el **ladrillo básico**: la Binomial suma  $n$  Bernoullis independientes.
- Si  $p = 0.6$ :  $P(X = 1) = 0.6$ ,  $P(X = 0) = 0.4$ .



Por eso las encuestas reportan su margen de error en el “peor caso”  $p = 0.5$ .



# Binomial: contar éxitos en $n$ ensayos

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, \quad E(X) = np, \quad Var(X) = np(1 - p)$$

**Supuestos:**  $n$  fijo y conocido, ensayos independientes,  $p$  constante entre ensayos.

```
n <- 30; p <- 0.7      # 30 hogares; 70% con acceso a internet
round(c(esperanza = n * p, de = sqrt(n * p * (1 - p)),
        p_igual_20 = dbinom(20, n, p),
        p_25_o_mas = 1 - pbinom(24, n, p)), 3)
```


| esperanza | de    | p_igual_20 | p_25_o_mas |
|-----------|-------|------------|------------|
| 21.000    | 2.510 | 0.142      | 0.077      |

En una muestra de 30 hogares esperamos 21 con acceso ( $DE = 2.5$ ); observar 25 o más ocurre solo el 8 % de las veces si  $p$  realmente es 0.7.


# La PMF Binomial en R: dbinom()

```
n <- 30; p <- 0.7
df <- tibble(k = 0:n,
             prob = dbinom(k, n, p))
ggplot(df, aes(k, prob)) +
  geom_col(fill = "celeste",
           color = "white") +
  geom_vline(xintercept = n * p,
             color = "rojo",
             linetype = "dashed",
             linewidth = 1) +
  labs(x = "Hogares con internet (k)",
       y = "P(X = k)")
```

`dbinom(k, n, p)` evalúa la PMF en cada valor de  $k$ ; la línea roja marca  $E(X) = np = 21$ .



# Binomial: el efecto de $n$ y $p$





$p$  controla la **asimetría** (lejos de 0.5, la PMF se sesga) y  $n$  la **concentración**: al crecer  $n$ , la distribución se centra en  $np$  y toma forma de campana — un anticipo del TLC.

# Poisson: la distribución de los eventos raros

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k = 0, 1, 2, \dots$$

$$E(X) = Var(X) = \lambda$$

- Cuenta eventos en un intervalo fijo de tiempo o espacio, con **tasa constante**  $\lambda$  y eventos independientes.
- No hay un  $n$  máximo: el conteo es abierto.
- **Aplicaciones:** delitos por comuna-semana, accidentes de tránsito, llegadas a una urgencia, brotes epidémicos.



Dos modelos de conteo: la Binomial está acotada por  $n$ ; la Poisson solo depende de la tasa  $\lambda$ .


# Poisson en R: delitos por comuna

```
lambda <- 3 # delitos por semana
round(c(p_0 = dpois(0, lambda),
        p_3 = dpois(3, lambda),
        p_6_o_mas =
          1 - ppois(5, lambda)), 3)
```


| p_0   | p_3   | p_6_o_mas |
|-------|-------|-----------|
| 0.050 | 0.224 | 0.084     |

Una semana con **6 o más delitos** ocurre el 8.4 % de las veces aun si nada cambió. Antes de anunciar una “ola delictual” (o un refuerzo policial), hay que descartar la fluctuación esperable.

Poisson(3): la cola de semanas malas




# Poisson al variar la tasa $\lambda$



Al crecer  $\lambda$  la distribución se desplaza, se ensancha (recordar:  $\text{varianza} = \lambda$ ) y se vuelve casi simétrica. La igualdad  $\text{media} = \text{varianza}$  (**equidispersión**) es un supuesto verificable: los delitos suelen estar *sobredispersos*, lo que motiva la binomial negativa en el curso de econometría.

# De la Binomial a la Poisson: la ley de eventos raros



Si  $n \rightarrow \infty$  y  $p \rightarrow 0$  con  $np = \lambda$  fijo, la Binomial converge a  $\text{Poisson}(\lambda)$ . Ejemplo: 1.000 licitaciones con probabilidad 0.005 de irregularidad — el número de casos es  $\text{Poisson}(5)$ : **un parámetro en vez de dos**, sin necesidad de conocer  $n$ .


# Normal: definición y parámetros

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

**Notación:**  $X \sim N(\mu, \sigma^2)$


- Simétrica y unimodal: media = mediana = moda.
- $\mu$  **desplaza** la curva;  $\sigma$  la **ensancha**.
- Surge cuando muchas causas pequeñas e independientes se *suman* — por eso reaparece en el TLC.

mu desplaza, sigma ensancha





# La regla empírica 68-95-99.7



Para cualquier  $N(\mu, \sigma^2)$ :

- **68 %** de los casos en  $[\mu - \sigma, \mu + \sigma]$
- **95 %** en  $[\mu - 2\sigma, \mu + 2\sigma]$
- **99.7 %** en  $[\mu - 3\sigma, \mu + 3\sigma]$

Con ingresos  $\sim N(800, 200^2)$ : el 95 % de los hogares está entre 400 y 1.200 mil \$.

Un valor a más de  $3\sigma$  es rarísimo: en datos administrativos, primero sospeche **error de digitación**.

# Estandarización: todo se compara en unidades Z

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1) \Rightarrow \text{"a cuántas DE está } x \text{ de la media"}$$

- Lleva cualquier normal a la **normal estándar**  $N(0, 1)$ : una sola escala de referencia.
- Permite comparar variables con unidades distintas: puntaje de un test vs ingreso.

```
# Puntaje municipal ~ N(500, 100); un municipio obtiene 620
round(c(z = (620 - 500) / 100,
      via_original = pnorm(620, mean = 500, sd = 100),
      via_z = pnorm(1.2)), 3)
```

|  | z     | via_original | via_z |
|--|-------|--------------|-------|
|  | 1.200 | 0.885        | 0.885 |


Ambas vías coinciden: el municipio supera al **88.5 %** de los municipios. Estandarizar no cambia la probabilidad, solo la unidad de medida.

# pnorm(): probabilidades como áreas

```
mu <- 800; s <- 200  
round(c(  
  bajo_600 = pnorm(600, mu, s),  
  sobre_1000 =  
    1 - pnorm(1000, mu, s),  
  entre = pnorm(1000, mu, s) -  
    pnorm(600, mu, s)), 3)
```

| bajo_600 | sobre_1000 | entre |
|----------|------------|-------|
| 0.159    | 0.159      | 0.683 |

pnorm() entrega **siempre el área a la izquierda**: la cola derecha es  $1 - \text{pnorm}()$  y un tramo es la resta de dos acumuladas.



# La familia d / p / q / r: una gramática para toda distribución

| Prefijo | Pregunta              | Normal               | Binomial              | Poisson              |
|---------|-----------------------|----------------------|-----------------------|----------------------|
| d       | $P(X = k)$ / densidad | <code>dnorm()</code> | <code>dbinom()</code> | <code>dpois()</code> |
| p       | $P(X \leq x)$ (CDF)   | <code>pnorm()</code> | <code>pbinom()</code> | <code>ppois()</code> |
| q       | cuantil de prob. $p$  | <code>qnorm()</code> | <code>qbinom()</code> | <code>qpois()</code> |
| r       | simular $n$ valores   | <code>rnorm()</code> | <code>rbinom()</code> | <code>rpois()</code> |

```
set.seed(42)
round(c(d = dnorm(0), p = pnorm(1.96), q = qnorm(0.975), r = rnorm(1)), 3)
```

```
      d      p      q      r
0.399 0.975 1.960 1.371
```


La misma lógica cubre la t (dt, pt, qt, rt) y toda distribución de R; p y q son **inversas** entre sí.

## qnorm(): del porcentaje al umbral de focalización

```
mu <- 800; s <- 200
# Umbral del 20% mas pobre
q20 <- qnorm(0.20, mu, s)
# pnorm invierte a qnorm
round(c(umbral = q20,
        check = pnorm(q20, mu, s)),
      3)
```

| umbral  | check |
|---------|-------|
| 631.676 | 0.200 |


La pregunta de focalización — *¿bajo qué ingreso está el 20 % más pobre?* — es exactamente un **cuantil**: el umbral de elegibilidad del programa es 632 mil \$.



# t de Student: la normal con colas pesadas


$$T = \frac{Z}{\sqrt{V/\nu}} \sim t_{\nu}, \quad Z \sim N(0,1), \quad V \sim \chi_{\nu}^2$$

- Aparece al estimar  $\mu$  con  $\sigma$  **desconocida**:  
 $\frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t_{n-1}.$
- Simétrica en 0, pero con **colas más pesadas**: reconoce la incertidumbre extra de estimar  $s$ .
- $\nu$  = grados de libertad; si  $\nu \rightarrow \infty$ ,  $t_{\nu} \rightarrow N(0,1)$ .
- Uso típico: pilotos y programas nuevos con **muestras pequeñas**.



Con pocos grados de libertad, los valores extremos son mucho más probables que bajo la normal.

## t vs normal: cuánto pesan las colas



```
round(c(t_df3 = qt(.975, 3), t_df10 = qt(.975, 10),  
        t_df30 = qt(.975, 30), normal = qnorm(.975)), 2)
```

| t_df3 | t_df10 | t_df30 | normal |
|-------|--------|--------|--------|
| 3.18  | 2.23   | 2.04   | 1.96   |

Con  $df = 3$  el valor crítico al 95 % es **3.18**, no 1.96: con muestras pequeñas los intervalos deben ser más anchos.

# Teorema del Límite Central: el enunciado


Si  $X_1, \dots, X_n$  son iid con media  $\mu$  y varianza  $\sigma^2$  finitas:

$$\bar{X}_n \xrightarrow{d} N\left(\mu, \frac{\sigma^2}{n}\right)$$

**sin importar la forma** de la distribución original.

- Justifica usar la normal para medias de encuestas, aunque los ingresos sean sesgados o los datos sean conteos.
- Base de los intervalos de confianza y tests de la Sesión 4.
- Requiere independencia y varianza finita — no es magia.

## Teorema del Límite Central (Distribución Original: Uniforme)




Población uniforme (nada normal) y, aun así, las medias muestrales se acampanan al crecer  $n$ .



# TLC en acción: simulación desde una población sesgada

```
set.seed(123)
sim <- crossing(n = c(2, 10, 50),
               rep = 1:3000) %>%
  mutate(
    media = map_dbl(n, \(k)
      mean(rexp(k, rate = 1/5))),
    etq = fct_inorder(
      paste0("n = ", n)))
ggplot(sim, aes(media)) +
  geom_histogram(bins = 40,
                fill = "celeste",
                color = "white") +
  facet_wrap(~ etq,
             scales = "free") +
  labs(x = "Media muestral",
       y = "Frecuencia")
```


Población: tiempos de espera Exponencial  
(media 5 días), fuertemente sesgada.



Con  $n = 2$  las medias heredan el sesgo; con  $n = 50$  ya son campanas centradas en 5. Es el TLC operando sobre una población **nada** normal.


# Distribución muestral de la media y error estándar

Población Original ( $\mu=100, \sigma=15$ )



↓ Muestras aleatorias (n=30) ↓

Distribución Muestral del Promedio (n=30)



La media muestral es una **variable aleatoria**: cambia de muestra en muestra. Su DE se llama **error estándar**:

$$EE(\bar{X}) = \frac{\sigma}{\sqrt{n}}$$

- Mide la precisión del *estimador*, no la dispersión de los individuos.
- Cae con  $\sqrt{n}$ : **cuadruplicar** la encuesta solo reduce el EE a la **mitad** — el costo de la precisión crece rápido.
- Margen de error al 95 %:  $\pm 1.96 \cdot EE$ .

# ¿Qué distribución para qué problema de política pública?

| Pregunta                                 | Variable        | Distribución          | Función R                     |
|------------------------------------------|-----------------|-----------------------|-------------------------------|
| Hogar apoya la reforma (sí/no)           | binaria 0/1     | Bernoulli             | <code>rbinom(size = 1)</code> |
| Apoyos entre $n$ encuestados             | conteo acotado  | Binomial              | <code>dbinom()</code>         |
| Delitos por comuna-semana                | conteo sin tope | Poisson               | <code>dpois()</code>          |
| Ingreso o puntaje individual             | continua        | Normal (o log-normal) | <code>pnorm()</code>          |
| Media, $n$ pequeño, $\sigma$ desconocida | continua        | t de Student          | <code>qt()</code>             |
| Media, $n$ grande                        | continua        | Normal (por TLC)      | <code>qnorm()</code>          |

! La distribución elegida determina el **error estándar**: tratar un conteo Poisson como normal subestima la probabilidad de semanas extremas.

# Síntesis: qué debe quedar de esta sesión

## Checklist conceptual

- 1 Clasificar la v.a.: ¿discreta o continua?
- 2 Elegir la distribución y **justificar sus supuestos** (independencia,  $p$  constante, tasa constante).
- 3 Reportar  $E(X)$  y  $Var(X)$  del modelo.
- 4 Calcular probabilidades con  $d/p$ , umbrales con  $q$ , simular con  $r$ .
- 5 Estandarizar ( $Z$ ) para comparar escalas distintas.
- 6 Usar  $t$  si  $n$  es pequeño y  $\sigma$  desconocida.
- 7 Invocar el TLC para medias:  $EE = \sigma/\sqrt{n}$ .

## Funciones R de esta sesión

`dbinom()` `pbinom()` `rbinom()` `dpois()`  
`ppois()` `rpois()` `dnorm()` `pnorm()`  
`qnorm()` `rnorm()` `qt()` `rt()` `rexp()`  
`replicate()` `set.seed()`

**Próxima sesión:** estimación puntual e intervalos de confianza — usaremos la distribución muestral y el error estándar como materia prima.

## Ejercicio para practicar (30 min)

Con las herramientas de hoy (use `set.seed(2026)`):

- 1 Puntajes de un test docente  $\sim N(70, 10^2)$ : calcule  $P(X > 85)$  y el percentil 90 con `pnorm()` y `qnorm()`.
- 2 Para muestras de  $n = 25$  docentes: escriba la distribución de  $\bar{X}$ , su EE, y calcule  $P(\bar{X} > 74)$ .
- 3 Delitos comunales  $\sim \text{Poisson}(4)$ : calcule  $P(X = 0)$  y  $P(X \geq 8)$ ; simule 52 semanas con `rpois()` y compare media y varianza muestrales con  $\lambda$ .
- 4 Encuesta de  $n = 200$  con  $p = 0.55$  de apoyo: obtenga  $E(X)$ , DE y  $P(X \geq 110)$  con `pbinom()`. ¿Le parece razonable aproximar con una normal? Justifique con la forma de la PMF.
- 5 Repita la simulación del TLC reemplazando `rexp()` por `rpois(k, 4)`. ¿Con qué  $n$  las medias ya se ven normales?

**i Referencias:** Wasserman, *All of Statistics* (caps. 2–5) · Illowsky & Dean, *Introductory Statistics* (caps. 4–7) · Wickham & Grolemund, *R for Data Science* · Cheatsheet “Distributions in R” (Posit).