ewcommand×

# Sesión 4: Inferencia Estadística — Estimación

Amaru Agüero

Doctorado en Ciencias de la Complejidad Social — CICS, UDD

19 de marzo de 2026

Universidad del Desarrollo
Facultad de Gobierno

# Agenda


1. Lógica de la Inferencia
2. Estimación Puntual
3. Intervalos de Confianza
4. Interpretación Correcta del IC
5. Implementación en R
6. Ejercicio Práctico

# ¿Por qué hacemos inferencia estadística?

- Raramente podemos observar toda la **población**

# ¿Por qué hacemos inferencia estadística?

- Raramente podemos observar toda la **población**
- Estudiamos una **muestra** para aprender sobre el todo

# ¿Por qué hacemos inferencia estadística?

- Raramente podemos observar toda la **población**
- Estudiamos una **muestra** para aprender sobre el todo
- La pregunta central: ¿Qué podemos decir sobre la población con base en la muestra?

# ¿Por qué hacemos inferencia estadística?

- Raramente podemos observar toda la **población**
- Estudiamos una **muestra** para aprender sobre el todo
- La pregunta central: ¿Qué podemos decir sobre la población con base en la muestra?
- **Dos enfoques principales:**
  1. Estimación puntual: Proponer un único valor para el parámetro
  2. Estimación por intervalo: Construir un rango plausible

# Parámetro vs. Estadístico

**Parámetro** (población)

- $\mu$ = media poblacional
- $\sigma$ = desv. estándar poblacional
- $\sigma^2$ = varianza poblacional
- $p$ = proporción poblacional
- $\rho$ = correlación poblacional

# Parámetro vs. Estadístico

**Parámetro** (población)

- $\mu$ = media poblacional
- $\sigma$ = desv. estándar poblacional
- $\sigma^2$ = varianza poblacional
- $p$ = proporción poblacional
- $\rho$ = correlación poblacional
- Desconocido (típicamente)
- Fijo

**Estadístico** (muestra)

- $\bar{x}$ = media muestral
- $s$ = desv. estándar muestral
- $s^2$ = varianza muestral
- $\hat{p}$ = proporción muestral
- $r$ = correlación muestral

# Parámetro vs. Estadístico

**Parámetro** (población)

- $\mu$ = media poblacional
- $\sigma$ = desv. estándar poblacional
- $\sigma^2$ = varianza poblacional
- $p$ = proporción poblacional
- $\rho$ = correlación poblacional
- Desconocido (típicamente)
- Fijo

**Estadístico** (muestra)

- $\bar{x}$ = media muestral
- $s$ = desv. estándar muestral
- $s^2$ = varianza muestral
- $\hat{p}$ = proporción muestral
- $r$ = correlación muestral
- Conocido (calculado)
- Varía entre muestras

# Distribución Muestral: El Concepto Clave

## ¿Qué es?

La distribución de probabilidad de un estadístico (ej. $\bar{x}$) calculado en todas las posibles muestras de tamaño $n$.

# Distribución Muestral: El Concepto Clave

## ¿Qué es?

La distribución de probabilidad de un estadístico (ej. $\bar{x}$) calculado en todas las posibles muestras de tamaño $n$.

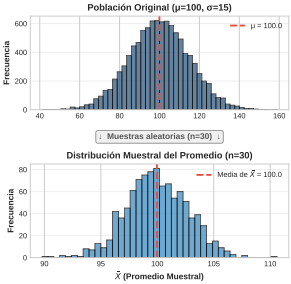

# Distribución Muestral: El Concepto Clave

## ¿Qué es?

La distribución de probabilidad de un estadístico (ej. $\bar{x}$) calculado en todas las posibles muestras de tamaño $n$.

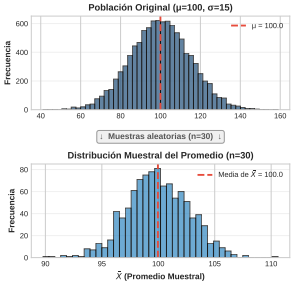


- La distribución muestral es más **concentrada** que la poblacional
- Su centro es el parámetro poblacional; su dispersión depende de $n$

# Error Estándar

## Definición

El error estándar (SE) es la desviación estándar de la distribución muestral de un estadístico.

# Error Estándar

## Definición

El error estándar (SE) es la desviación estándar de la distribución muestral de un estadístico.

**Para la media muestral:** $SE_{\bar{x}} = \frac{\sigma}{\sqrt{n}}$

# Error Estándar

## Definición

El error estándar (SE) es la desviación estándar de la distribución muestral de un estadístico.

**Para la media muestral:** $SE_{\bar{x}} = \dfrac{\sigma}{\sqrt{n}}$

**Implicaciones:**

- El SE disminuye con $\sqrt{n}$ (no es lineal)
- Muestras más grandes $\Rightarrow$ estimadores más precisos
- Duplicar $n$ reduce el SE en $\approx 30\%$; el SE aumenta con $\sigma$

# Error Estándar

## Definición

El error estándar (SE) es la desviación estándar de la distribución muestral de un estadístico.

**Para la media muestral:** $SE_{\bar{x}} = \dfrac{\sigma}{\sqrt{n}}$

**Implicaciones:**

- El SE disminuye con $\sqrt{n}$ (no es lineal)
- Muestras más grandes $\Rightarrow$ estimadores más precisos
- Duplicar $n$ reduce el SE en $\approx 30\%$; el SE aumenta con $\sigma$

## Nota importante

En la práctica, $\sigma$ es desconocida. Estimamos $SE$ usando $s$ (desv. est. muestral).

# ¿Qué es un buen estimador?

## Propiedades deseables

1. **Insesgamiento:** $E[\hat{\theta}] = \theta$ (en promedio, acertamos)

# ¿Qué es un buen estimador?

## Propiedades deseables

1. **Insesgamiento:** $E[\hat{\theta}] = \theta$ (en promedio, acertamos)
2. **Eficiencia:** Varianza pequeña (precisión)

# ¿Qué es un buen estimador?

## Propiedades deseables

1. **Insesgamiento:** $E[\hat{\theta}] = \theta$ (en promedio, acertamos)
2. **Eficiencia:** Varianza pequeña (precisión)
3. **Consistencia:** Conforme $n \to \infty$, $\hat{\theta} \to \theta$

# ¿Qué es un buen estimador?

## Propiedades deseables

1. **Insesgamiento:** $E[\hat{\theta}] = \theta$ (en promedio, acertamos)
2. **Eficiencia:** Varianza pequeña (precisión)
3. **Consistencia:** Conforme $n \to \infty$, $\hat{\theta} \to \theta$

### Insesgado pero ineficiente

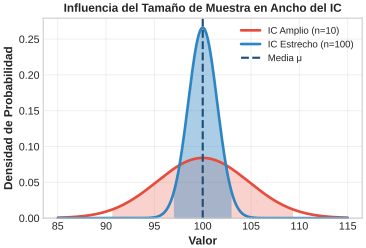


### Eficiente e insesgado

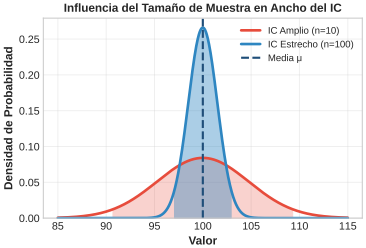

# La Media Muestral como Estimador

## Propiedades de $\bar{x}$

- **Insesgado**: $E[\bar{x}] = \mu$

# La Media Muestral como Estimador

## Propiedades de $\bar{x}$

- **Insesgado**: $E[\bar{x}] = \mu$
- **Consistente**: $\bar{x} \xrightarrow{p} \mu$ (ley de los grandes números)

# La Media Muestral como Estimador

## Propiedades de $\bar{x}$

- **Insesgado**: $E[\bar{x}] = \mu$
- **Consistente**: $\bar{x} \xrightarrow{p} \mu$ (ley de los grandes números)
- **Distribución muestral**: $\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$

# La Media Muestral como Estimador

## Propiedades de $\bar{x}$

- **Insesgado**: $E[\bar{x}] = \mu$
- **Consistente**: $\bar{x} \xrightarrow{p} \mu$ (ley de los grandes números)
- **Distribución muestral**: $\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$
- **TLC**: Incluso si $X$ no es normal, $\bar{x}$ es aprox. normal para $n$ grande

# La Media Muestral como Estimador

## Propiedades de $\bar{x}$

- **Insesgado**: $E[\bar{x}] = \mu$
- **Consistente**: $\bar{x} \xrightarrow{p} \mu$ (ley de los grandes números)
- **Distribución muestral**: $\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$
- **TLC**: Incluso si $X$ no es normal, $\bar{x}$ es aprox. normal para $n$ grande

## Ejemplo

Si $\mu = 100$, $\sigma = 15$, $n = 100$: $SE_{\bar{x}} = 1.5$. El 95% de las medias caerán en (97.06, 102.94).

# La Proporción Muestral como Estimador

## Propiedades de $\hat{p}$

- **Insesgado**: $E[\hat{p}] = p$

# La Proporción Muestral como Estimador

## Propiedades de $\hat{p}$

- **Insesgado**: $E[\hat{p}] = p$
- Distribución muestral (aprox.): $\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$

# La Proporción Muestral como Estimador

## Propiedades de $\hat{p}$

- **Insesgado**: $E[\hat{p}] = p$
- Distribución muestral (aprox.): $\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$
- Error estándar: $SE_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$

# La Proporción Muestral como Estimador

## Propiedades de $\hat{p}$

- **Insesgado**: $E[\hat{p}] = p$
- Distribución muestral (aprox.): $\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$
- Error estándar: $SE_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$
- Condición: $np > 5$ y $n(1-p) > 5$

# La Proporción Muestral como Estimador

## Propiedades de $\hat{p}$

- **Insesgado**: $E[\hat{p}] = p$
- Distribución muestral (aprox.): $\hat{p} \sim N\left(p, \frac{p(1-p)}{n}\right)$
- Error estándar: $SE_{\hat{p}} = \sqrt{\frac{p(1-p)}{n}}$
- Condición: $np > 5$ y $n(1-p) > 5$

## Ejemplo

Muestra de 500 personas, 280 apoyan cierta política: $\hat{p} = 0.56$, $SE_{\hat{p}} = \sqrt{\frac{0.56 \times 0.44}{500}} = 0.022$.

# Máxima Verosimilitud: Intuición

## Idea central

Elegir el parámetro $\hat{\theta}$ que hace *más probable* observar los datos que tenemos.

# Máxima Verosimilitud: Intuición

## Idea central

Elegir el parámetro $\hat{\theta}$ que hace *más probable* observar los datos que tenemos.

## Example

Lanzamos una moneda 10 veces y observamos 8 caras. ¿Es justa?

- Si $p = 0.5$ (justa): $P(8 \text{ caras}) = 0.044$
- Si $p = 0.8$: $P(8 \text{ caras}) = 0.302$

# Máxima Verosimilitud: Intuición

## Idea central

Elegir el parámetro $\hat{\theta}$ que hace *más probable* observar los datos que tenemos.

## Example

Lanzamos una moneda 10 veces y observamos 8 caras. ¿Es justa?

- Si $p = 0.5$ (justa): $P(8 \text{ caras}) = 0.044$
- Si $p = 0.8$: $P(8 \text{ caras}) = 0.302$
- **Estimador MV:** $\hat{p}_{MV} = 8/10 = 0.8$ (hace más probable lo observado)

# Máxima Verosimilitud: Intuición

## Idea central

Elegir el parámetro $\hat{\theta}$ que hace *más probable* observar los datos que tenemos.

## Example

Lanzamos una moneda 10 veces y observamos 8 caras. ¿Es justa?

- Si $p = 0.5$ (justa): $P(8 \text{ caras}) = 0.044$
- Si $p = 0.8$: $P(8 \text{ caras}) = 0.302$
- **Estimador MV:** $\hat{p}_{MV} = 8/10 = 0.8$ (hace más probable lo observado)

## Conexión

Para $\bar{x}$ y $\hat{p}$, el estimador de MV coincide con el estimador insesgado.

# Construcción General de un IC

## Fórmula

$$\text{IC} = \text{Estimador} \pm z^* \times SE$$

# Construcción General de un IC

## Fórmula

$$\text{IC} = \text{Estimador} \pm z^* \times SE$$

- **Estimador**: $\bar{x}$, $\hat{p}$, $\hat{\beta}$, etc.

# Construcción General de un IC

## Fórmula

$$\text{IC} = \text{Estimador} \pm z^* \times SE$$

- **Estimador**: $\bar{x}$, $\hat{p}$, $\hat{\beta}$, etc.
- $z^*$: Valor crítico
  - 95% con $Z$: $z^* = 1.96$
  - 99% con $Z$: $z^* = 2.576$
  - 95% con $t$: $z^* = t_{\alpha/2, n-1}$

# Construcción General de un IC

## Fórmula

$$\text{IC} = \text{Estimador} \pm z^* \times SE$$

- **Estimador**: $\bar{x}$, $\hat{p}$, $\hat{\beta}$, etc.
- $z^*$: Valor crítico
  - 95% con $Z$: $z^* = 1.96$
  - 99% con $Z$: $z^* = 2.576$
  - 95% con $t$: $z^* = t_{\alpha/2, n-1}$
- **SE**: Error estándar del estimador

# Construcción General de un IC

## Fórmula

$$\text{IC} = \text{Estimador} \pm z^* \times SE$$

- **Estimador**: $\bar{x}$, $\hat{p}$, $\hat{\beta}$, etc.
- $z^*$: Valor crítico
  - 95% con $Z$: $z^* = 1.96$
  - 99% con $Z$: $z^* = 2.576$
  - 95% con $t$: $z^* = t_{\alpha/2,n-1}$
- **SE**: Error estándar del estimador

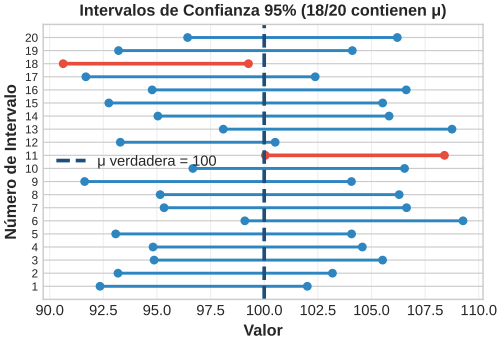

# IC para la Media: $\sigma$ Conocida

## Supuestos

Muestra aleatoria de población normal (o $n$ grande); $\sigma$ conocida (raro en la práctica).

# IC para la Media: $\sigma$ Conocida

## Supuestos

Muestra aleatoria de población normal (o $n$ grande); $\sigma$ conocida (raro en la práctica).

## IC al $(1-\alpha)\times 100\%$

$\bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$

# IC para la Media: $\sigma$ Conocida

## Supuestos

Muestra aleatoria de población normal (o $n$ grande); $\sigma$ conocida (raro en la práctica).

## IC al $(1-\alpha)\times 100\%$

$\bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$

## Ejemplo

$n = 100$, $\bar{x} = 45.2$, $\sigma = 8$. IC 95%: $45.2 \pm 1.96 \times \frac{8}{\sqrt{100}} = 45.2 \pm 1.568 = (43.63,\ 46.77)$

# IC para la Media: $\sigma$ Conocida

## Supuestos

Muestra aleatoria de población normal (o $n$ grande); $\sigma$ conocida (raro en la práctica).

## IC al $(1-\alpha)\times 100\%$

$\bar{x} \pm z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}}$

## Ejemplo

$n = 100$, $\bar{x} = 45.2$, $\sigma = 8$. IC 95%: $45.2 \pm 1.96 \times \frac{8}{\sqrt{100}} = 45.2 \pm 1.568 = (43.63,\ 46.77)$

## En la práctica: $\sigma$ desconocida

Reemplazamos $\sigma$ por $s$ y usamos distribución $t$: $\quad \bar{x} \pm t_{\alpha/2,n-1} \cdot \frac{s}{\sqrt{n}}$

# IC para la Media: $\sigma$ Desconocida (caso usual)

## Supuestos

Muestra aleatoria de población normal (importante si $n < 30$); $\sigma$ desconocida (típico).

# IC para la Media: $\sigma$ Desconocida (caso usual)

## Supuestos

Muestra aleatoria de población normal (importante si $n < 30$); $\sigma$ desconocida (típico).

## IC al $(1-\alpha) \times 100\%$

$\bar{x} \pm t_{\alpha/2,n-1} \cdot \frac{s}{\sqrt{n}}$

# IC para la Media: $\sigma$ Desconocida (caso usual)

## Supuestos

Muestra aleatoria de población normal (importante si $n < 30$); $\sigma$ desconocida (típico).

## IC al $(1-\alpha) \times 100\%$

$\bar{x} \pm t_{\alpha/2,n-1} \cdot \frac{s}{\sqrt{n}}$

- $t$ tiene colas más pesadas que la normal; $n \to \infty \Rightarrow t_{n-1} \to Z$

# IC para la Media: $\sigma$ Desconocida (caso usual)

## Supuestos

Muestra aleatoria de población normal (importante si $n < 30$); $\sigma$ desconocida (típico).

## IC al $(1-\alpha) \times 100\%$

$\bar{x} \pm t_{\alpha/2,n-1} \cdot \frac{s}{\sqrt{n}}$

- $t$ tiene colas más pesadas que la normal; $n \to \infty \Rightarrow t_{n-1} \to Z$
- Para $n \geq 30$, la aproximación normal es aceptable

# IC para la Media: $\sigma$ Desconocida (caso usual)

## Supuestos

Muestra aleatoria de población normal (importante si $n < 30$); $\sigma$ desconocida (típico).

## IC al $(1-\alpha) \times 100\%$

$\bar{x} \pm t_{\alpha/2,n-1} \cdot \frac{s}{\sqrt{n}}$

- $t$ tiene colas más pesadas que la normal; $n \to \infty \Rightarrow t_{n-1} \to Z$
- Para $n \geq 30$, la aproximación normal es aceptable

## Ejemplo

$n = 25$, $\bar{x} = 52.3$, $s = 6.5$, $t_{0.025,24} = 2.064$. IC 95%:
$52.3 \pm 2.064 \times \frac{6.5}{\sqrt{25}} = 52.3 \pm 2.68 = (49.62,\ 54.98)$

# IC para una Proporción

## Método de Wald (simple)

$$\hat{p} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

# IC para una Proporción

## Método de Wald (simple)

$$\hat{p} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

## Limitación del Wald

Funciona mal cuando $\hat{p}$ es cercana a 0 o 1 (intervalos negativos o $> 1$).

# IC para una Proporción

## Método de Wald (simple)

$$\hat{p} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

## Limitación del Wald

Funciona mal cuando $\hat{p}$ es cercana a 0 o 1 (intervalos negativos o $> 1$).

## Método de Wilson (corrección recomendada)

$$\frac{\hat{p}+\frac{z^2_{\alpha/2}}{2n}}{1+\frac{z^2_{\alpha/2}}{n}} \pm \frac{z_{\alpha/2}}{1+\frac{z^2_{\alpha/2}}{n}}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}+\frac{z^2_{\alpha/2}}{4n^2}}$$

# IC para una Proporción

## Método de Wald (simple)

$$\hat{p} \pm z_{\alpha/2} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

## Limitación del Wald

Funciona mal cuando $\hat{p}$ es cercana a 0 o 1 (intervalos negativos o $> 1$).

## Método de Wilson (corrección recomendada)

$$\frac{\hat{p}+\frac{z^2_{\alpha/2}}{2n}}{1+\frac{z^2_{\alpha/2}}{n}} \pm \frac{z_{\alpha/2}}{1+\frac{z^2_{\alpha/2}}{n}}\sqrt{\frac{\hat{p}(1-\hat{p})}{n}+\frac{z^2_{\alpha/2}}{4n^2}}$$

## Ejemplo

$n = 200$, $\hat{p} = 0.175$. Wald IC 95%: $0.175 \pm 1.96\sqrt{\frac{0.175\times 0.825}{200}} = (0.105,\ 0.245)$. Wilson es más preciso para $\hat{p}$ extremas.

# IC para Diferencia de Dos Medias

**Supuesto: Varianzas iguales**

$$(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2, n_1+n_2-2} \cdot SE$$

donde

$$SE = s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

**Supuesto: Varianzas desiguales**

$$(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2, df} \cdot SE$$

donde

$$SE = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

# IC para Diferencia de Dos Medias

**Supuesto: Varianzas iguales**

$$(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2, n_1+n_2-2} \cdot SE$$

donde

$$SE = s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}$$

**Supuesto: Varianzas desiguales**

$$(\bar{x}_1 - \bar{x}_2) \pm t_{\alpha/2, df} \cdot SE$$

donde

$$SE = \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$$

**Interpretación**

Si el IC contiene 0, no hay diferencia significativa entre los grupos.

# ¿Qué significa realmente un IC 95%?

## Interpretación frecuentista CORRECTA

"Si repitiéramos el muestreo muchas veces, aproximadamente el 95% de los IC contendrían al parámetro verdadero."

# ¿Qué significa realmente un IC 95%?

## Interpretación frecuentista CORRECTA

"Si repitiéramos el muestreo muchas veces, aproximadamente el 95% de los IC contendrían al parámetro verdadero."

## Interpretación INCORRECTA (muy común)

- "Hay 95% de probabilidad de que $\mu$ esté en este intervalo"
- "El parámetro tiene 95% de probabilidad de estar aquí"
- "El 95% de los datos cae en este intervalo"

# ¿Qué significa realmente un IC 95%?

## Interpretación frecuentista CORRECTA

"Si repitiéramos el muestreo muchas veces, aproximadamente el 95% de los IC contendrían al parámetro verdadero."

## Interpretación INCORRECTA (muy común)

- "Hay 95% de probabilidad de que $\mu$ esté en este intervalo"
- "El parámetro tiene 95% de probabilidad de estar aquí"
- "El 95% de los datos cae en este intervalo"

## ¿Por qué es incorrecta?

Una vez construido el IC, $\mu$ está **dentro** o **fuera**. La probabilidad 0.95 se refiere al proceso de muestreo repetido, no al intervalo específico.

# Factores que Afectan el Ancho del IC

**Aumentan el ancho:**

- Menor $n$
- Mayor variabilidad ($\sigma \uparrow$)
- Mayor confianza (95% vs 90%)

**Disminuyen el ancho:**

- Mayor $n$
- Menor variabilidad ($\sigma \downarrow$)
- Menor confianza (90% vs 95%)

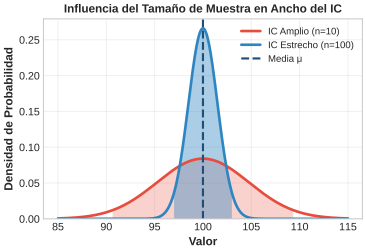


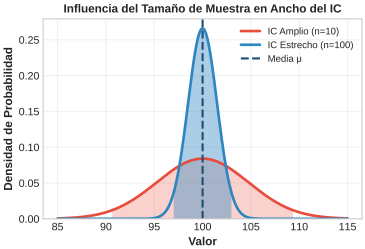

# Factores que Afectan el Ancho del IC

**Aumentan el ancho:**

- Menor $n$
- Mayor variabilidad ($\sigma \uparrow$)
- Mayor confianza (95% vs 90%)

**Disminuyen el ancho:**

- Mayor $n$
- Menor variabilidad ($\sigma \downarrow$)
- Menor confianza (90% vs 95%)

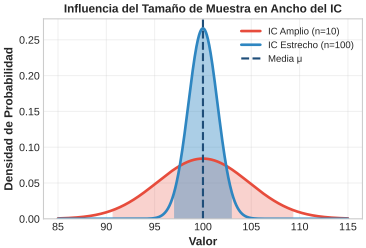


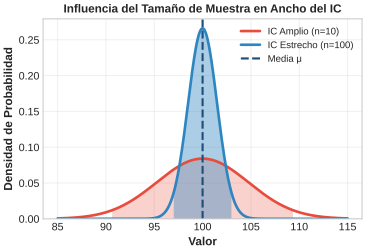


**Trade-off**

Más confianza $\Leftrightarrow$ intervalo más amplio. No podemos tener ambas sin más datos.

# Intervalo de Confianza para la Media: t.test()

```r
# Datos de ejemplo
datos <- c(23.5, 24.1, 22.8, 25.3, 23.9, 24.6, 23.2)

# IC 95% para la media (con sigma desconocida)
resultado <- t.test(datos, conf.level = 0.95)
resultado$estimate       # Media muestral
resultado$conf.int       # Intervalo de confianza
resultado$statistic      # Estad stico t
resultado$p.value        # Valor p

# IC 99%
t.test(datos, conf.level = 0.99)$conf.int
```

# Intervalo de Confianza para la Media: t.test()

```r
# Datos de ejemplo
datos <- c(23.5, 24.1, 22.8, 25.3, 23.9, 24.6, 23.2)

# IC 95% para la media (con sigma desconocida)
resultado <- t.test(datos, conf.level = 0.95)
resultado$estimate       # Media muestral
resultado$conf.int       # Intervalo de confianza
resultado$statistic      # Estad stico t
resultado$p.value        # Valor p

# IC 99%
t.test(datos, conf.level = 0.99)$conf.int
```

**Salida típica**

```
95 percent confidence interval:  22.88571 25.01429
```

# Intervalo de Confianza para una Proporción

```
# Proporci n de  xitos : 35 de 200
prop.test(x = 35, n = 200, conf.level = 0.95)

# Resultado incluye IC usando m todo de Wilson
# $estimate: 0.175
# $conf.int: [0.1241, 0.2359] (aproximadamente)

# Para una sola proporci n (m s flexible)
binom.test(x = 35, n = 200, p = 0.5,
           conf.level = 0.95)
# Usa distribuci n binomial exacta

# IC directa (Clopper-Pearson, exacta)
binom.confint(x = 35, n = 200,
              method = "clopper-pearson")
```

# Intervalo de Confianza para una Proporción

```
# Proporci n de  xitos : 35 de 200
prop.test(x = 35, n = 200, conf.level = 0.95)

# Resultado incluye IC usando m todo de Wilson
# $estimate: 0.175
# $conf.int: [0.1241, 0.2359] (aproximadamente)

# Para una sola proporci n (m s flexible)
binom.test(x = 35, n = 200, p = 0.5,
           conf.level = 0.95)
# Usa distribuci n binomial exacta

# IC directa (Clopper-Pearson, exacta)
binom.confint(x = 35, n = 200,
              method = "clopper-pearson")
```

**Nota**

`prop.test()` usa Wilson. `binom.test()` usa exacta (Clopper-Pearson).

# Simulación: Distribución de Intervalos

```r
# Simular 1000 muestras y sus IC 95%
set.seed(123)
n_sim <- 1000; n <- 50; mu <- 100; sigma <- 15

# Almacenar IC
ics <- matrix(NA, n_sim, 2)

for (i in 1:n_sim) {
  muestra <- rnorm(n, mu, sigma)
  ic <- t.test(muestra)$conf.int
  ics[i, ] <- ic
}

# Contar cu ntos IC contienen mu
cubiertos <- sum(ics[, 1] <= mu & mu <= ics[, 2])
cat("IC que contienen mu:", cubiertos/n_sim)
# Esperado: aprox 0.95
```

# Simulación: Distribución de Intervalos

```r
# Simular 1000 muestras y sus IC 95%
set.seed(123)
n_sim <- 1000; n <- 50; mu <- 100; sigma <- 15

# Almacenar IC
ics <- matrix(NA, n_sim, 2)

for (i in 1:n_sim) {
  muestra <- rnorm(n, mu, sigma)
  ic <- t.test(muestra)$conf.int
  ics[i, ] <- ic
}

# Contar cu ntos IC contienen mu
cubiertos <- sum(ics[, 1] <= mu & mu <= ics[, 2])
cat("IC que contienen mu:", cubiertos/n_sim)
# Esperado: aprox 0.95
```

## Verificación

Demuestra que el 95% de los intervalos contiene realmente el parámetro.

# IC para Diferencia de Medias: t.test()

```r
# Dos muestras independientes
grupo1 <- c(23.5, 24.1, 22.8, 25.3, 23.9)
grupo2 <- c(28.3, 29.1, 27.8, 30.2, 28.9)

# IC 95% para la diferencia de medias
t.test(grupo1, grupo2, conf.level = 0.95)

# Si varianzas desiguales (Welch)
t.test(grupo1, grupo2, var.equal = FALSE)

# Si varianzas iguales
t.test(grupo1, grupo2, var.equal = TRUE)

# Muestras pareadas
pre <- c(100, 95, 110, 105, 98)
post <- c(105, 100, 115, 110, 103)
t.test(pre, post, paired = TRUE)
```

# Ejercicio Práctico

## Contexto

Se desea estimar el promedio de **ingresos mensuales** de egresados del programa de Doctorado en Ciencias de la Complejidad Social. Se toma una muestra aleatoria de 40 egresados.

# Ejercicio Práctico

## Contexto

Se desea estimar el promedio de **ingresos mensuales** de egresados del programa de Doctorado en Ciencias de la Complejidad Social. Se toma una muestra aleatoria de 40 egresados.

## Datos (simulados)

- Muestra: $n = 40$
- Media muestral: $\bar{x} = \$2,450,000$ (CLP)
- Desviación estándar muestral: $s = \$380,000$

# Ejercicio Práctico

## Contexto

Se desea estimar el promedio de **ingresos mensuales** de egresados del programa de Doctorado en Ciencias de la Complejidad Social. Se toma una muestra aleatoria de 40 egresados.

## Datos (simulados)

- Muestra: $n = 40$
- Media muestral: $\bar{x} = \$2,450,000$ (CLP)
- Desviación estándar muestral: $s = \$380,000$

**Preguntas:**

1. Construya un IC 95% para el ingreso promedio poblacional
2. Interprete el intervalo correctamente
3. ¿Qué tamaño de muestra sería necesario para un IC con ancho de $\pm\$100,000$?
4. ¿Cómo cambiaría el IC si usara confianza 99%?

# Solución en R

```r
# Datos
n <- 40; x_barra <- 2450000; s <- 380000

# IC 95% (usando distribuci n t)
alpha <- 0.05
t_crit <- qt(1 - alpha/2, df = n - 1)
SE <- s / sqrt(n)
margen <- t_crit * SE

ic_lower <- x_barra - margen
ic_upper <- x_barra + margen
cat("IC 95%: [", ic_lower, ",", ic_upper, "]", "\n")

# O usando t.test con datos simulados
set.seed(42)
datos_ingresos <- rnorm(n, x_barra, s)
t.test(datos_ingresos, conf.level = 0.95)$conf.int
```

# Solución en R

```r
# Datos
n <- 40; x_barra <- 2450000; s <- 380000

# IC 95% (usando distribuci n t)
alpha <- 0.05
t_crit <- qt(1 - alpha/2, df = n - 1)
SE <- s / sqrt(n)
margen <- t_crit * SE

ic_lower <- x_barra - margen
ic_upper <- x_barra + margen
cat("IC 95%: [", ic_lower, ",", ic_upper, "]", "\n")

# O usando t.test con datos simulados
set.seed(42)
datos_ingresos <- rnorm(n, x_barra, s)
t.test(datos_ingresos, conf.level = 0.95)$conf.int
```

## Respuesta

IC 95% $\approx$ [\$2,327,549, \$2,572,451]

# Reflexión: ¿Por qué importa la inferencia?

- **Muestreo**: Casi nunca podemos estudiar la población completa

# Reflexión: ¿Por qué importa la inferencia?

- **Muestreo**: Casi nunca podemos estudiar la población completa
- **Incertidumbre cuantificable**: Los IC nos dicen qué tan precisas son nuestras estimaciones

# Reflexión: ¿Por qué importa la inferencia?

- **Muestreo**: Casi nunca podemos estudiar la población completa
- **Incertidumbre cuantificable**: Los IC nos dicen qué tan precisas son nuestras estimaciones
- **Decisiones informadas**: Podemos distinguir entre variabilidad muestral y efectos reales

# Reflexión: ¿Por qué importa la inferencia?

- **Muestreo**: Casi nunca podemos estudiar la población completa
- **Incertidumbre cuantificable**: Los IC nos dicen qué tan precisas son nuestras estimaciones
- **Decisiones informadas**: Podemos distinguir entre variabilidad muestral y efectos reales
- **Reproducibilidad**: Reportar IC (no solo estimadores) permite evaluar la confiabilidad

# Reflexión: ¿Por qué importa la inferencia?

- **Muestreo**: Casi nunca podemos estudiar la población completa
- **Incertidumbre cuantificable**: Los IC nos dicen qué tan precisas son nuestras estimaciones
- **Decisiones informadas**: Podemos distinguir entre variabilidad muestral y efectos reales
- **Reproducibilidad**: Reportar IC (no solo estimadores) permite evaluar la confiabilidad

**En la próxima sesión**

Haremos **pruebas de hipótesis**: contrastar afirmaciones sobre parámetros poblacionales usando muestras.

¿Preguntas?