

Sesión 4 · Inferencia Estadística

Nivelación Estadística y Probabilidades — Doctorado en Políticas Públicas

Amaru Agüero Jiménez (a.agueroj@udd.cl)

marzo de 2026

Panorama de la sesión

Bloque	Concepto clave	Herramienta en R
Fundamentos	Población vs muestra, distribución muestral, SE	<code>sample()</code> , <code>replicate()</code>
Estimación	IC para media y proporción, con z y con t	<code>qt()</code> , <code>t.test()</code> , <code>prop.test()</code>
Interpretación	Cobertura, ancho del IC, lecturas correctas	simulación
Contraste	H_0/H_1 , valor- p , errores I y II, potencia	<code>t.test()</code> , <code>power.t.test()</code>
Comparación	Dos grupos independientes y pareados	<code>t.test()</code> , <code>paired = TRUE</code>
Relevancia	Tamaño del efecto, d de Cohen	cálculo manual, <code>broom::tidy()</code>

i Escenario de trabajo: evaluación de un programa de empleo: encuesta de ingresos ($n = 200$), tratados vs control (120 y 120) y 35 municipios antes/después. Datos simulados con `set.seed()` — todo es reproducible.


Población vs muestra, parámetro vs estadístico

	Población	Muestra
Objeto	Todos los hogares del país	Los n hogares encuestados
Media	μ (parámetro)	$\bar{x}$ (estadístico)
Desviación estándar	σ	s
Proporción	p	$\hat{p}$
Naturaleza	Fijos y desconocidos	Aleatorios: cambian con cada muestra
Papel en la inferencia	Lo que queremos conocer	Lo que efectivamente calculamos

i Inferencia estadística = usar el estadístico (conocido) para aprender del parámetro (desconocido), cuantificando la incertidumbre. La CASEN entrevista ~70 mil hogares para hablar de ~6,5 millones: toda cifra oficial de pobreza es un estadístico, no un parámetro.


La distribución muestral: el concepto clave

Población Original ($\mu=100, \sigma=15$)



↓ Muestras aleatorias ($n=30$) ↓

Distribución Muestral del Promedio ($n=30$)




Es la distribución del estadístico $\bar{x}$ a través de todas las muestras posibles de tamaño n .

- Su centro es el parámetro: $E[\bar{x}] = \mu$ (la media muestral es un estimador **insesgado**)
- Es mucho más concentrada que la distribución de los datos
- Su desviación estándar tiene nombre propio: **error estándar**
- No confundir: distribución de los **datos** (arriba) vs distribución de las **medias** (abajo)

Teorema del Límite Central: la garantía

Teorema del Límite Central (Distribución Original: Uniforme)




$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \text{ (aprox., } n \text{ grande)}$$

- Vale **aunque la población no sea normal** (aquí: uniforme)
- Regla práctica: $n \geq 30$ suele bastar; con asimetría fuerte, se necesita más
- Es lo que autoriza usar z y t con variables de encuesta (ingreso, gasto), que casi nunca son normales


Error estándar: la precisión de la media muestral

$$SE_{\bar{x}} = \frac{\sigma}{\sqrt{n}} \quad \widehat{SE}_{\bar{x}} = \frac{s}{\sqrt{n}}$$

- Decrece con $\sqrt{n}$: rendimientos decrecientes
- $n = 25 \rightarrow SE = \sigma/5$; $n = 100 \rightarrow \sigma/10$;
 $n = 400 \rightarrow \sigma/20$
- **Reducir el SE a la mitad exige cuadruplicar la muestra:** la precisión cuesta presupuesto
- Como σ es desconocida, en la práctica se estima con s



Simulación: ingresos sesgados, medias normales



SE teórico $\sigma/\sqrt{100} = 29.7$; SE simulado = 30. Con $n = 100$, la distribución de $\bar{x}$ es normal y está centrada en $\mu = 558$ aunque los ingresos tengan sesgo 1.7.


Anatomía del intervalo de confianza

$$IC = \underbrace{\bar{x}}_{\text{estimador}} \pm \underbrace{z^* \text{ o } t^*}_{\text{crítico}} \times \underbrace{SE}_{\text{precisión}}$$

Valores críticos z^* según confianza:

- 90 % $\rightarrow z^* = 1.645$
- 95 % $\rightarrow z^* = 1.96$
- 99 % $\rightarrow z^* = 2.576$


Más confianza $\rightarrow$ crítico mayor $\rightarrow$ intervalo más ancho.



Cada muestra produce un intervalo distinto: la “confianza” es una propiedad del **procedimiento**, no de un intervalo particular.

¿Crítico z o t ? Depende de si conocemos la varianza

- σ **conocida** (caso de libro): usar z ; casi nunca ocurre
- σ **desconocida** (caso real): estimarla con s y usar t con $n - 1$ grados de libertad
- La t tiene **colas más pesadas**: paga la incertidumbre extra de estimar σ
- Con $n \geq 30$ son casi iguales: $t_{29}^* = 2.045$ vs $z^* = 1.96$



IC para la media en R: a mano con qt() y con t.test()

```
n <- length(encuesta)           # 200 beneficiarios encuestados
media <- mean(encuesta); s <- sd(encuesta)
t_crit <- qt(0.975, df = n - 1)
round(c(media = media, SE = s / sqrt(n), t_critico = t_crit), 2)
```

media	SE	t_critico
571.89	20.84	1.97

```
round(media + c(-1, 1) * t_crit * s / sqrt(n), 1) # IC 95% manual
```

```
[1] 530.8 613.0
```

```
round(as.numeric(t.test(encuesta)$conf.int), 1) # IC 95% con t.test()
```

```
[1] 530.8 613.0
```

- Con 95 % de confianza, el ingreso medio de los beneficiarios está entre 531 y 613 mil \$: mismo resultado a mano y con t.test().
- Para otro nivel: t.test(encuesta, conf.level = 0.99) ensancha el intervalo.


Interpretación del IC 95 %: una correcta, tres incorrectas

Afirmación sobre un IC 95 % = (a, b)	Veredicto
“El 95 % de los intervalos contruidos con este procedimiento contiene μ ”	Correcta
“Hay 95 % de probabilidad de que μ esté entre a y b”	Incorrecta: μ es fijo; este intervalo ya lo contiene o no
“El 95 % de los hogares tiene ingreso entre a y b”	Incorrecta: confunde el IC con la dispersión de los datos
“El 95 % de las medias de futuras muestras caerá entre a y b”	Incorrecta: eso requeriría un intervalo distinto (de predicción)

! La probabilidad vive en el **procedimiento de muestreo**, no en el intervalo ya calculado. La frase “con 95 % de confianza, μ está en (a, b)” es la convención aceptada para comunicar exactamente eso.

Cobertura: 100 intervalos al 95 %

Cada segmento es el IC 95% de una muestra distinta




En esta corrida, 94 de 100 intervalos contienen μ (línea azul). Repetido indefinidamente, el porcentaje converge a 95: eso —y solo eso— significa “95 % de confianza”.

El ancho del IC: efecto de n y del nivel de confianza

```
g <- crossing(  
  n = seq(10, 500, 5),  
  conf = c(.90, .95, .99)) %>%  
mutate(  
  t_c = qt(1 - (1 - conf)/2,  
    df = n - 1),  
  ancho = 2 * t_c *  
    sigma_pob / sqrt(n))  
ggplot(g, aes(n, ancho,  
  color = factor(conf))) +  
  geom_line(linewidth = 1) +  
  labs(x = "Tamaño muestral n",  
    y = "Ancho del IC",  
    color = "Confianza")
```

El ancho cae con $\sqrt{n}$: pasar de $n = 100$ a $n = 400$ apenas lo reduce a la mitad. Y exigir 99 % en vez de 90 % lo ensancha ~57 %.



IC para una proporción: el margen de error de las encuestas

$$\hat{p} \pm z^* \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

```
x <- 280; n <- 500           # 280 de 500 apoyan la reforma
p_hat <- x / n
ee <- sqrt(p_hat * (1 - p_hat) / n)
round(c(p_hat = p_hat, SE = ee, margen_95 = 1.96 * ee), 3)
```

p_hat	SE	margen_95
0.560	0.022	0.044

```
round(as.numeric(prop.test(x, n)$conf.int), 3)  # IC de Wilson
```

```
[1] 0.515 0.604
```




El “margen de error de ± 3 puntos” que reportan las encuestas es este IC al 95 % en el peor caso ($\hat{p} = 0.5$): exige $n = (1.96/0.03)^2 \times 0.25 \approx 1067$ casos. `prop.test()` usa el método de Wilson, más preciso que Wald cuando $\hat{p}$ se acerca a 0 o 1.

La lógica de la prueba de hipótesis en cuatro pasos

Paso	Qué se hace	Ejemplo (programa de empleo)
1. Hipótesis	H_0 : no hay efecto; H_1 : sí lo hay	$H_0 : \mu = 500$ vs $H_1 : \mu \neq 500$
2. Nivel α	Fijar la tasa tolerada de falsos positivos antes de ver los datos	$\alpha = 0.05$
3. Estadístico	Medir a cuántos SE está el dato de lo que dice H_0	$t = (\bar{x} - 500)/(s/\sqrt{n})$
4. Valor-p y decisión	Probabilidad de algo tan extremo si H_0 fuera cierta	$p < \alpha \rightarrow$ rechazar H_0

i H_0 es la hipótesis del escepticismo (“el programa no cambió nada”). La carga de la prueba recae en los datos: solo la abandonamos cuando lo observado sería suficientemente improbable bajo ella.

El valor-p en un dibujo



El valor- p es el área en las colas más allá del estadístico observado, calculada **bajo** H_0 . Ejemplo: $t = 2.2$ con 199 gl da $p = 0.029$: si H_0 fuera cierta, solo el 3 % de las muestras daría algo tan extremo.

Prueba t de una muestra: ¿superó el programa la línea base?

Antes del programa, el ingreso medio era **500 mil \$**. Encuesta a 200 beneficiarios:

```
tt1 <- t.test(encuesta, mu = 500)
tt1
```

One Sample t-test

```
data: encuesta
t = 3.4499, df = 199, p-value = 0.0006845
alternative hypothesis: true mean is not equal to 500
95 percent confidence interval:
 530.7973 612.9782
sample estimates:
mean of x
 571.8877
```

$t = 3.45$: la media observada está a 3.45 SE de 500; $p < 0.001 \rightarrow$ se rechaza H_0 . El IC (531, 613) **excluye** 500: prueba e intervalo cuentan la misma historia.

Qué es y qué NO es el valor-p

Afirmación	Veredicto
Probabilidad de datos tan extremos como los observados, si H_0 es cierta	Eso es exactamente el valor-p
Probabilidad de que H_0 sea cierta	No: H_0 no tiene probabilidad frecuentista
Probabilidad de que el hallazgo se deba al azar	No: esa lectura invierte el condicional
$1 - p$ = probabilidad de que H_1 sea cierta	No
$p > 0.05$ demuestra que no hay efecto	No: ausencia de evidencia no es evidencia de ausencia
$p < 0.05$ implica un efecto grande o importante	No: con n enorme, efectos triviales dan p diminutos

! Declaración de la ASA (Wasserstein & Lazar, 2016): el valor-p **no mide** el tamaño ni la importancia de un efecto, y ninguna decisión de política debería basarse solo en si p cruza 0.05.

Dos muestras independientes: tratados vs control


Evaluación con grupo de comparación: 120 tratados y 120 controles; resultado = ingreso mensual (miles de \$).

```
tt2 <- t.test(ingreso ~ grupo, data = programa) # Welch por defecto
tidy(tt2) %>%
  transmute(dif = estimate, t = statistic, gl = parameter,
            p = p.value, ic_inf = conf.low, ic_sup = conf.high) %>%
  kable(digits = 3)
```

dif	t	gl	p	ic_inf	ic_sup
-34.983	-3.164	237.912	0.002	-56.763	-13.202

- $\text{dif} = \text{media}(\text{Control}) - \text{media}(\text{Tratado}) = -35$: R resta en el orden de los niveles del factor; los tratados ganan en promedio 35 mil \$ más.
- El IC de la diferencia excluye el 0 $\rightarrow$ diferencia significativa al 5 %. El test de Welch (default) no exige varianzas iguales.

Ver la comparación: distribuciones y diferencia con su IC



El panel derecho es el resumen inferencial completo: no solo dice “ $p = 0.002$ ”, muestra la **magnitud** (35 mil \$) y su **incertidumbre** (IC 13 a 57). Si el IC tocara el 0, la diferencia no sería distinguible del azar muestral.

Prueba pareada: los mismos municipios antes y después


```
tp <- t.test(gestion$despues,  
            gestion$antes,  
            paired = TRUE)  
round(c(dif = unname(tp$estimate),  
        as.numeric(tp$conf.int)), 2)
```

```
dif  
4.01 2.45 5.57
```

```
signif(tp$p.value, 2)
```

```
[1] 8.6e-06
```

- Cada municipio es su **propio control**: se analizan las 35 diferencias internas
- Elimina la variabilidad entre municipios → SE menor, más potencia
- Equivale a una prueba t de una muestra sobre las diferencias




Errores Tipo I y Tipo II: la tabla de decisiones

Decisión	H_0 cierta (programa sin efecto)	H_0 falsa (programa con efecto)
Rechazar H_0	Error Tipo I — prob. α (falso positivo)	Acierto: potencia $= 1 - \beta$
No rechazar H_0	Acierto — prob. $1 - \alpha$	Error Tipo II — prob. β (falso negativo)

! En política pública los costos son asimétricos: el Tipo I **financia y escala un programa inútil**; el Tipo II **cancela uno efectivo**. α se fija por convención (0.05); β depende del tamaño del efecto, de n y de α , y se controla **diseñando** el estudio.


Error I, error II y potencia en un dibujo



Contraste unilateral con $\alpha = 0.05$. Mover el crítico a la izquierda reduce β pero infla los falsos positivos: la única forma de bajar **ambos** errores a la vez es aumentar n o estudiar efectos más grandes.

Curva de potencia: qué efectos podemos detectar

```
curvas <- crossing(  
  d = seq(0.1, 1.2, 0.02),  
  n = c(30, 64, 120)) %>%  
  mutate(pow = map2_dbl(d, n,  
    ~power.t.test(n = .y,  
      delta = .x,  
      sd = 1)$power))  
ggplot(curvas, aes(d, pow,  
  color = factor(n))) +  
  geom_line(linewidth = 1) +  
  geom_hline(yintercept = 0.8,  
    linetype = "dashed") +  
  labs(x = "Efecto (d de Cohen)",  
    y = "Potencia",  
    color = "n por grupo")
```



Con $n = 64$ por grupo hay 80 % de potencia para $d = 0.5$; con $n = 30$, solo efectos $d \geq 0.75$ se detectan con esa seguridad.

Significancia no es relevancia: el tamaño del efecto

$$d = \frac{\bar{x}_1 - \bar{x}_2}{s_{\text{combinada}}}$$

```
resumen <- programa %>% group_by(grupo) %>%  
  summarise(m = mean(ingreso), s = sd(ingreso))  
s_pool <- sqrt(mean(resumen$s^2))  
round(c(dif = diff(resumen$m), s_comb = s_pool,  
        d_cohen = diff(resumen$m) / s_pool), 2)
```


dif	s_comb	d_cohen
34.98	85.64	0.41

d	Convención	Lectura en evaluación
0.2	Pequeño	Real, pero exige muestras grandes
0.5	Mediano	Diferencia apreciable
0.8	Grande	Raro en programas sociales

El programa logra $d = 0.41$ con $p = 0.002$: significativo **y** de magnitud reportable.

Con n suficiente, todo se vuelve “significativo”

Valor- p si la diferencia observada igualara a la verdadera



Un efecto trivial de $d = 0.05$ cruza $p < 0.05$ con ~ 3.100 casos por grupo. El valor- p mezcla tamaño del efecto con tamaño muestral: repórtelo siempre junto a d y su IC.

Inferencia y evaluación de políticas públicas

Pregunta de política	Herramienta de esta sesión	Cuidado principal
¿Cuál es el ingreso medio de los beneficiarios?	IC para la media	Representatividad y no respuesta
¿Qué apoyo ciudadano tiene la reforma?	IC para proporción	Margen de error y diseño muestral
¿El programa cambió el resultado?	t de dos muestras + d de Cohen	Significancia no es causalidad
¿Mejoraron las mismas unidades?	Prueba pareada	Regresión a la media; falta contrafactual
¿Cuántos casos necesita el piloto?	Análisis de potencia	Hacerlo antes de recolectar datos

⚠ Rechazar H_0 solo dice que la diferencia no es atribuible al azar muestral; **no** dice que el programa la causó. Atribuir causalidad exige diseño (aleatorización, grupo de control válido): el puente hacia el curso de econometría.

Errores comunes en inferencia

Error	Consecuencia	Corrección
Leer p como $P(H_0 \text{ cierta})$ "No significativo" = "sin efecto"	Sobreconfianza en el hallazgo Cancelar programas mal evaluados	$p = P(\text{datos extremos dado } H_0)$ Reportar potencia e IC
Probar hasta lograr $p < 0.05$ (p-hacking)	Falsos positivos inflados	Preregistro; corrección por pruebas múltiples
Leer el IC como rango de los datos	Confunde precisión con dispersión	El IC habla de μ , no de individuos
Ignorar el diseño muestral complejo	SE subestimados	Ponderadores y errores por conglomerado
Reportar solo p , sin tamaño de efecto	Relevancia desconocida	d de Cohen + IC de la diferencia

Síntesis: qué debe salir en su reporte

Checklist inferencial

- 1 Toda estimación puntual acompañada de su IC
- 2 Cobertura interpretada sobre el procedimiento, no el intervalo
- 3 Hipótesis y α definidos antes de ver los datos
- 4 Valor-p junto a tamaño de efecto (d) e IC de la diferencia
- 5 Potencia calculada en la etapa de diseño, no después
- 6 Distinguir: significancia estadística, relevancia práctica, causalidad

Funciones R de esta sesión

`t.test()` `prop.test()` `qt()` `qnorm()` `pt()`
`power.t.test()` `broom::tidy()` `sample()`
`replicate()` `crossing()`

Próxima sesión: taller práctico integrador —
de los datos crudos al reporte inferencial
completo en R.

Ejercicio para practicar (30 min)

Con `gapminder` filtrado al año **2007**:

- 1 Construya el IC 95 % para la esperanza de vida media en África. Redacte su interpretación con la cobertura correcta.
- 2 Pruebe $H_0 : \mu = 60$ años para África con `t.test()`. Reporte `t`, valor-`p` e IC: ¿son coherentes entre sí?
- 3 Compare América vs Asia en `lifeExp` con una prueba `t` de dos muestras y calcule la `d` de Cohen. ¿La diferencia es relevante además de significativa?
- 4 Estime la proporción de países del mundo con `lifeExp > 70` y su IC 95 % con `prop.test()`.
- 5 Con `power.t.test()`: ¿cuántos países por grupo se necesitan para detectar $d = 0.4$ con potencia 80 %?

i Referencias: Illowsky & Dean, *Introductory Statistics* (caps. 8–10) · Wasserstein & Lazar (2016), “The ASA Statement on p-Values”, *The American Statistician* · Diez, Barr & Çetinkaya-Rundel, *OpenIntro Statistics* (caps. 5–7).