

Sesión 5 · Práctica Integradora en R

Nivelación Estadística y Probabilidades — Doctorados en Políticas Públicas y en Ciencias de la Complejidad Social · Universidad del Desarrollo

Amaru Agüero Jiménez (a.agueroj@udd.cl)


marzo de 2026

Panorama de la sesión

Bloque	Pasos	Integra	Herramientas en R
Pregunta y datos	1–2	Sesión 1	<code>glimpse()</code> , <code>summary()</code>
Preparación	3	Sesión 1	<code>filter()</code> , <code>mutate()</code> , <code>log()</code>
Descripción y gráficos	4–5	Sesión 1	<code>group_by()</code> , <code>ggplot2</code> + <code>plotly</code>
Outliers y supuestos	6–7	Sesiones 1–3	regla IQR, QQ-plot, <code>shapiro.test()</code>
Inferencia	8–10	Sesión 4	<code>t.test()</code> , d de Cohen
Reporte	11–13	Todas	<code>kable()</code> , conclusiones, reproducibilidad

i Formato de hoy: práctica guiada. Un análisis completo con `gapminder` (142 países, 2007), de la pregunta de política al informe final. Cada slide es un paso ejecutable: código, salida e interpretación.

El mapa completo: de los datos crudos al informe



Cada fase depende de las anteriores para obtener conclusiones robustas

Pipeline: datos $\rightarrow$ exploración $\rightarrow$ descriptiva $\rightarrow$ supuestos $\rightarrow$ inferencia $\rightarrow$ conclusiones.

Paso 1 · La pregunta en términos de política pública

De la política a la estadística

- **Pregunta de política:** ¿cuán grande es la brecha de longevidad entre países ricos y pobres, y se alcanzó la meta internacional de 70 años de vida?
- **Pregunta estadística 1:** ¿la esperanza de vida media mundial en 2007 difiere de 70 años?
- **Pregunta estadística 2:** ¿difiere la esperanza de vida media entre países de PIB alto y PIB bajo?

Hipótesis declaradas ANTES de mirar los datos

- Prueba 1: $H_0 : \mu = 70$ vs $H_1 : \mu \neq 70$
- Prueba 2: $H_0 : \mu_{alto} = \mu_{bajo}$ vs $H_1 : \mu_{alto} \neq \mu_{bajo}$
- Nivel de significancia: $\alpha = 0.05$
- Estimador central: media muestral con IC 95 %

! Hipótesis y α se fijan **antes** del análisis. Elegir la prueba después de ver los resultados invalida el p-valor (Sesión 4).

Paso 2 · Carga e inspección de datos

```
library(gapminder)
glimpse(gapminder)
```

Rows: 1,704

Columns: 6

```
$ country    <fct> "Afghanistan", "Afghanistan", "Afghanistan", "Afghanistan", ~
$ continent  <fct> Asia, Asia, Asia, Asia, Asia, Asia, Asia, Asia, Asia, Asia, ~
$ year       <int> 1952, 1957, 1962, 1967, 1972, 1977, 1982, 1987, 1992, 1997, ~
$ lifeExp    <dbl> 28.801, 30.332, 31.997, 34.020, 36.088, 38.438, 39.854, 40.8~
$ pop        <int> 8425333, 9240934, 10267083, 11537966, 13079460, 14880372, 12~
$ gdpPercap  <dbl> 779.4453, 820.8530, 853.1007, 836.1971, 739.9811, 786.1134, ~
```

- 1.704 filas = 142 países $\times$ 12 años (panel balanceado)
- country, continent: **nominales** (factores)
- lifeExp, gdpPercap: **continuas de razón**
- pop: **discreta de razón**; year: intervalo

Paso 2 · Control de calidad antes de analizar

```
c(filas = nrow(gapminder),  
  paises = n_distinct(gapminder$country),  
  años = n_distinct(gapminder$year),  
  na_total = sum(is.na(gapminder)))
```

filas	paises	años	na_total
1704	142	12	0

```
range(gapminder$year)
```

```
[1] 1952 2007
```

```
summary(gapminder$lifeExp)[c(1, 6)]
```

Min.	Max.
23.599	82.603

Sin valores faltantes y sin valores imposibles (mínimo 23.6 años corresponde a Ruanda 1992, un valor real documentado). Fijamos el corte transversal en **2007**.

Paso 3 · Limpieza y transformación

```
datos <- gapminder %>%  
  filter(year == 2007) %>%  
  mutate(log_pib = log(gdpPercap),  
         grupo_pib = if_else(  
           gdpPercap >= median(gdpPercap),  
           "PIB alto", "PIB bajo"))  
datos %>% count(grupo_pib)
```

A tibble: 2 x 2

	grupo_pib	n
	<chr>	<int>
1	PIB alto	71
2	PIB bajo	71

- `filter()`: solo el año 2007 ($n = 142$ países)
- `log()`: doma el sesgo derecho del PIB (Sesión 1)
- `grupo_pib`: corte por la **mediana** (6.124 USD) → dos grupos de 71 países; la mediana es robusta a los outliers de PIB

Paso 4 · Descriptivos por grupo

```
datos %>% group_by(continent) %>%  
  summarise(n = n(), media = mean(lifeExp), de = sd(lifeExp),  
            mediana = median(lifeExp), iqr = IQR(lifeExp)) %>%  
  mutate(across(where(is.numeric), ~round(.x, 1))) %>% kable()
```


continent	n	media	de	mediana	iqr
Africa	52	54.8	9.6	52.9	11.6
Americas	25	73.6	4.4	72.9	4.6
Asia	33	70.7	8.0	72.4	10.2
Europe	30	77.6	3.0	78.6	4.8
Oceania	2	80.7	0.7	80.7	0.5

África queda **20+ años** por debajo del resto y además es el continente más heterogéneo ($DE = 9.6$). Reportar siempre **n**, **media**, **DE**, **mediana** e **IQR** por grupo antes de cualquier prueba.

Paso 5 · Gráfico 1: la distribución de la variable clave

```
p <- ggplot(datos, aes(x = lifeExp)) +  
  geom_histogram(bins = 18,  
                fill = celeste,  
                color = "white") +  
  geom_vline(  
    xintercept = mean(datos$lifeExp),  
    color = rojo, linewidth = 1,  
    linetype = "dashed") +  
  labs(x = "Esperanza de vida (años)",  
       y = "N° de países")  
ggplotly(p) # interactivo en HTML
```


ggplotly(p) vuelve interactivo cualquier ggplot en HTML; en PDF queda estático. Cola izquierda: media (67.0) < mediana (71.9).



Paso 5 · Gráfico 2: comparación entre continentes

```
ggplot(datos,
  aes(x = reorder(continent,
    lifeExp, median),
    fill = continent)) +
  geom_boxplot(alpha = .7,
    outlier.color = rojo) +
  geom_jitter(width = .12,
    alpha = .3, size = 1) +
  labs(x = NULL,
    y = "Esperanza de vida (años)") +
  theme(legend.position = "none")
```


Ordenar por mediana facilita la lectura. África muestra la mayor dispersión y solapa poco con Europa.



Paso 5 · Gráfico 3: la relación PIB–vida

```
ggplot(datos,
       aes(x = log_pib, y = lifeExp)) +
  geom_point(aes(color = grupo_pib),
            alpha = .7, size = 2) +
  geom_smooth(method = "lm",
            color = azul) +
  scale_color_manual(
    values = c(celeste, naranja)) +
  labs(x = "log(PIB per cápita)",
       y = "Esperanza de vida (años)",
       color = NULL) +
  theme(legend.position = "bottom")
```


Relación aproximadamente lineal **en logs**:
justifica la transformación del Paso 3. En HTML,
el tooltip identifica cada país.



Paso 5 · Gráfico 4: los dos grupos a contrastar

```
ggplot(datos,
       aes(x = lifeExp,
           fill = grupo_pib)) +
  geom_density(alpha = .55,
              color = NA) +
  scale_fill_manual(
    values = c(celeste, naranja)) +
  labs(x = "Esperanza de vida (años)",
       y = "Densidad", fill = NULL) +
  theme(legend.position = "top")
```

Separación clara entre grupos, con solapamiento parcial: exactamente lo que la prueba t del Paso 9 va a cuantificar.



Paso 6 · Detección de outliers

```
Q1 <- quantile(datos$gdpPercap, .25)
Q3 <- quantile(datos$gdpPercap, .75)
lim <- Q3 + 1.5 * IQR(datos$gdpPercap)
datos %>% filter(gdpPercap > lim) %>%
  select(country, gdpPercap) %>%
  arrange(desc(gdpPercap)) %>%
  mutate(gdpPercap = round(gdpPercap))
```

A tibble: 4 x 2

	country	gdpPercap
	<fct>	<dbl>
1	Norway	49357
2	Kuwait	47307
3	Singapore	47143
4	United States	42952



Protocolo de la Sesión 1: verificar, documentar, analizar con y sin, y preferir medidas robustas. Nunca eliminar en silencio.


Decisión documentada

- 1 Los 4 valores son **reales**, no errores.
- 2 Se **conservan**: eliminar países sesgaría el análisis.
- 3 El corte por **mediana** del Paso 3 ya es robusto a ellos.
- 4 En lifeExp la regla IQR no marca ningún outlier.

Paso 7 · Normalidad I: el QQ-plot

```
ggplot(datos,
  aes(sample = lifeExp)) +
  stat_qq(color = celeste,
    size = 2, alpha = .7) +
  stat_qq_line(color = rojo,
    linewidth = 1) +
  labs(
    x = "Cuantiles teóricos N(0,1)",
    y = "Cuantiles muestrales")
```

La cola izquierda se despega de la recta: el sesgo negativo visto en el histograma, ahora contra la referencia normal.



Paso 7 · Normalidad II: prueba de Shapiro-Wilk

```
sw <- shapiro.test(datos$lifeExp)
round(c(W = unname(sw$statistic), p = sw$p.value), 4)
```

W	p
0.8947	0.0000

```
datos %>% group_by(grupo_pib) %>%
  summarise(p_shapiro = shapiro.test(lifeExp)$p.value)
```

```
# A tibble: 2 x 2
  grupo_pib p_shapiro
  <chr>      <dbl>
1 PIB alto  3.08e-10
2 PIB bajo  5.25e- 3
```

- Se **rechaza** la normalidad global y en ambos grupos ($p < 0.01$).
- Pero la prueba t infiere sobre **medias**: con $n = 71$ por grupo, el TLC (Sesión 3) garantiza normalidad aproximada de $\bar{X}$.
- Conclusión metodológica: reportar el diagnóstico y seguir con t de Welch.

Paso 8 · Intervalo de confianza para la media

```
ic <- t.test(datos$lifeExp, conf.level = 0.95)
round(c(media = unname(ic$estimate),
      li = ic$conf.int[1], ls = ic$conf.int[2]), 2)
```

```
media    li    ls
67.01 65.00 69.01
```


```
n <- nrow(datos)
ee <- sd(datos$lifeExp) / sqrt(n)
round(mean(datos$lifeExp) + qt(c(.025, .975), n - 1) * ee, 2)
```

```
[1] 65.00 69.01
```

`t.test()` automatiza la fórmula $\bar{x} \pm t_{0.975, n-1} \cdot s / \sqrt{n}$ de la Sesión 4: ambas rutas dan **[65.0; 69.0]**. El procedimiento captura a μ en el 95 % de las muestras posibles.

Paso 8 · IC por continente: el gráfico de reporte

```
ic_g <- datos %>%  
  group_by(continent) %>%  
  summarise(  
    m = mean(lifeExp),  
    ee = sd(lifeExp) / sqrt(n()),  
    tq = qt(.975, n() - 1))  
ggplot(ic_g,  
  aes(x = m,  
      y = reorder(continent, m))) +  
  geom_pointrange(  
    aes(xmin = m - tq * ee,  
        xmax = m + tq * ee),  
    color = azul, linewidth = .9) +  
  labs(x = "Media e IC 95% (años)",  
       y = NULL)
```



El IC de Oceanía es engañosamente angosto: con $n = 2$ el error estándar casi no tiene información. El n manda.

Paso 9 · Prueba t de una muestra: ¿se alcanzó la meta?

```
t1 <- t.test(datos$lifeExp, mu = 70)
t1
```

One Sample t-test

```
data:  datos$lifeExp
t = -2.9537, df = 141, p-value = 0.00368
alternative hypothesis: true mean is not equal to 70
95 percent confidence interval:
 65.00450 69.01034
sample estimates:
mean of x
 67.00742
```

Con $t = -2.95$ y $p = 0.004 < \alpha$, se **rechaza** H_0 : la media mundial 2007 (67.0 años) quedó significativamente **por debajo** de la meta de 70. El IC [65.0; 69.0] no contiene 70 — misma conclusión por dos vías.

Paso 9 · Prueba t de dos muestras: la brecha de ingreso

```
datos %>% group_by(grupo_pib) %>%  
  summarise(n = n(), media = round(mean(lifeExp), 1),  
            de = round(sd(lifeExp), 1))
```

A tibble: 2 x 4

	grupo_pib	n	media	de
	<chr>	<int>	<dbl>	<dbl>
1	PIB alto	71	75.3	6.6
2	PIB bajo	71	58.7	10.4

```
t2 <- t.test(lifeExp ~ grupo_pib, data = datos)  
round(c(dif = -diff(unname(t2$estimate)), li = t2$conf.int[1],  
        ls = t2$conf.int[2], t = unname(t2$statistic)), 2)
```

dif	li	ls	t
16.66	13.75	19.56	11.35

Los países de PIB alto viven **16.7 años más** (IC 95 %: [13.7; 19.6]; $p = 1.2e-20 < 0.001$). `t.test()` usa **Welch** por defecto: no exige varianzas iguales (DE 6.6 vs 10.4).

Paso 10 · Tamaño del efecto: ¿la diferencia importa?

```
g <- datos %>% group_by(grupo_pib) %>%  
  summarise(n = n(), m = mean(lifeExp), s = sd(lifeExp))  
sp <- sqrt(((g$n[1] - 1) * g$s[1]^2 + (g$n[2] - 1) * g$s[2]^2) /  
  (sum(g$n) - 2))  
d <- (g$m[1] - g$m[2]) / sp  
round(c(dif_medias = g$m[1] - g$m[2], sd_conjunta = sp, cohen_d = d), 2)
```

dif_medias	sd_conjunta	cohen_d
16.66	8.74	1.90

$ d $ de referencia	Magnitud (Cohen)	Lectura
0.2	Pequeño	Detectable solo con muestras grandes
0.5	Mediano	Visible al inspeccionar los datos
0.8	Grande	Diferencia evidente entre grupos
1.90 (este caso)	Muy grande	Brecha de primer orden para política

Con n grande, casi todo es “significativo”: el **d** dice si además es **relevante**.

Paso 11 · La tabla final de resultados

```
tibble(
  Resultado = c("Media mundial 2007",
                "Prueba t vs meta de 70 años",
                "Brecha PIB alto - PIB bajo",
                "Tamaño del efecto"),
  Valor = c(
    sprintf("%.1f años [%.1f;%.1f]", ic$estimate,
            ic$conf.int[1], ic$conf.int[2]),
    sprintf("t = %.2f; p = %.3f", t1$statistic, t1$p.value),
    sprintf("%.1f años [%.1f;%.1f]; p < 0.001",
            -diff(unname(t2$estimate)),
            t2$conf.int[1], t2$conf.int[2]),
    sprintf("d = %.2f (muy grande)", d))) %>% kable()
```

Resultado	Valor
Media mundial 2007	67.0 años [65.0; 69.0]
Prueba t vs meta de 70 años	t = -2.95; p = 0.004
Brecha PIB alto - PIB bajo	16.7 años [13.7; 19.6]; p < 0.001
Tamaño del efecto	d = 1.90 (muy grande)

Estimación, IC y p-valor por pregunta: el mínimo exigible de un informe técnico.

i **Párrafo de resultados (ejemplo redactado):** “En 2007 la esperanza de vida promedio mundial fue de 67.0 años (IC 95 %: 65.0–69.0), significativamente por debajo de la meta de 70 años ($p = 0.004$). Los países del grupo de PIB alto vivieron en promedio 16.7 años más que los del grupo de PIB bajo (IC 95 %: 13.7–19.6; $p < 0.001$), una brecha de magnitud muy grande ($d = 1.90$). Estos resultados describen una asociación: no permiten afirmar que aumentar el PIB **cause** mayor longevidad.”

Anatomía del párrafo — cada frase aporta un elemento:

- **Estimación puntual** con su unidad (67.0 años; 16.7 años)
- **Incertidumbre:** IC 95 % siempre junto a la estimación
- **Decisión:** p-valor contra el α declarado en el Paso 1
- **Magnitud:** tamaño del efecto, no solo significancia
- **Alcance:** asociación $\neq$ causalidad (curso de econometría)

Paso 13 · Checklist de reproducibilidad

Antes de entregar el informe

- 1 Un script único que corre de arriba abajo sin errores
- 2 `set.seed()` antes de cualquier simulación o muestreo
- 3 Datos crudos intactos; toda limpieza queda en código
- 4 Decisiones documentadas (outliers, cortes, transformaciones)
- 5 Versiones registradas: R, paquetes (`sessionInfo()`)
- 6 Texto, código y resultados en un solo documento Quarto

```
set.seed(2026)  
R.version.string
```

```
[1] "R version 4.5.2 (2025-10-31)"
```

Por qué importa en políticas públicas

- Las decisiones basadas en evidencia deben ser **auditable**s
- Otro analista debe llegar al **mismo número** con los mismos datos
- Los errores se detectan releendo **código**, no recuerdos

Síntesis: qué integró cada paso

El flujo en una mirada

- 1 Pregunta e hipótesis **antes** de los datos (S4)
- 2 Inspección, tipos de variables y calidad (S1)
- 3 Transformación log y grupos por mediana (S1)
- 4 Descriptivos y 4 gráficos exploratorios (S1)
- 5 Outliers documentados, no eliminados (S1)
- 6 Normalidad: QQ-plot + Shapiro; TLC al rescate (S2–S3)
- 7 IC, pruebas t, tamaño del efecto (S4)
- 8 Tabla final, párrafo de política, reproducibilidad

Funciones R de esta sesión

```
glimpse() filter() mutate() count()  
group_by() summarise() quantile()  
shapiro.test() qt() t.test() kable()  
sprintf() stat_qq() geom_pointrange()  
ggplotly()
```

Próxima etapa: curso de econometría —
regresión lineal, del “¿difieren?” al “¿cuánto y
bajo qué condiciones?”.

Ejercicio para practicar (30 min)

Replique el flujo completo con `gapminder` filtrado al año **1987**:

- 1 Formule una pregunta de política y sus dos hipótesis ($\alpha = 0.05$) antes de tocar los datos.
- 2 Cree `grupo_pib` por mediana de ese año y construya la tabla de descriptivos por grupo.
- 3 Genere histograma, boxplot por continente y QQ-plot. ¿Cambia el diagnóstico de normalidad?
- 4 Pruebe $H_0 : \mu = 65$ para la media mundial de 1987 y contraste los dos grupos de PIB con Welch.
- 5 Calcule d de Cohen, arme la tabla final y redacte el párrafo de resultados estilo informe.

i Referencias: Wickham & Grolemund, *R for Data Science* (caps. 7 y 27) · Illowsky & Dean, *Introductory Statistics* (caps. 8–10) · Cohen (1988), *Statistical Power Analysis* · Documentación de `gapminder` y `plotly`.