Sesión 5: Práctica Integradora en R

Amaru Agüero

Doctorado en Ciencias de la Complejidad Social — CICS, UDD

19 de marzo de 2026

Universidad del Desarrollo
Facultad de Gobierno

Agenda de la Sesión (70 minutos)

- **Flujo de análisis completo:** Pipeline desde datos crudos a conclusiones
- **Repaso de Estadística Descriptiva en R:** Carga, exploración, visualización
- **Repaso de Probabilidad y Distribuciones:** Simulaciones y muestreo
- **Repaso de Inferencia Estadística:** Intervalos de confianza y pruebas
- **Ejercicio Integrador:** Análisis completo de datos sociales
- **Próximos pasos:** Introducción a Econometría

Objetivo: Consolidar todos los conceptos de sesiones anteriores en un flujo práctico integrado.

Flujo de Análisis Estadístico Completo

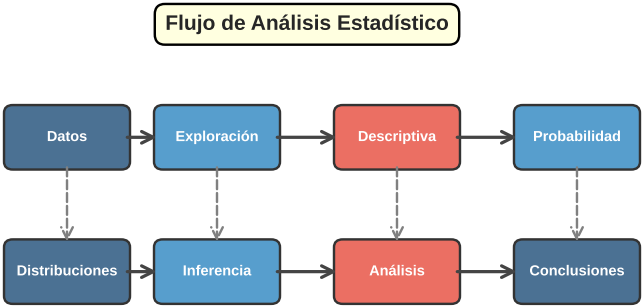

Cada fase depende de las anteriores para obtener conclusiones robustas

Pipeline: Datos → Exploración → Descriptiva → Probabilidad → Distribuciones → Inferencia → Conclusiones

Repaso: Estadística Descriptiva en R (1/3)

Carga y Exploración de Datos

```
# Cargar librer as esenciales
library(tidyverse)
library(ggplot2)

# Cargar datos
datos <- read.csv("datos_sociales.csv")

# Exploraci n inicial
head(datos)
dim(datos)
str(datos)
summary(datos)
```

Repaso: Estadística Descriptiva en R (2/3)

Estadísticos Descriptivos

```r
# Estad sticos univariados
mean(datos$ingreso)
median(datos$ingreso)
sd(datos$ingreso)
var(datos$ingreso)
range(datos$ingreso)
IQR(datos$ingreso)

# Con tidyverse
datos %>%
  summarize(
    media = mean(ingreso, na.rm=TRUE),
    mediana = median(ingreso),
    desv_est = sd(ingreso),
    min = min(ingreso),
    max = max(ingreso),
    n = n()
  )
```

Repaso: Estadística Descriptiva en R (3/3)

Visualización con ggplot2

```
# Histograma
ggplot(datos, aes(x=ingreso)) +
  geom_histogram(bins=30, fill=uddblue, alpha=0.7) +
  theme_minimal() + labs(title="Distribuci n de Ingresos")

# Boxplot por grupos
ggplot(datos, aes(x=region, y=ingreso, fill=region)) +
  geom_boxplot() + theme_minimal()

# Gr fico de dispersi n
ggplot(datos, aes(x=educacion, y=ingreso)) +
  geom_point(alpha=0.5) + geom_smooth(method="lm")
```

Repaso: Probabilidad y Distribuciones en R (1/3)

Simulaciones Básicas con sample()

```r
# Muestreo simple
muestra <- sample(1:1000, size=100, replace=FALSE)

# Simulaci n de lanzamiento de moneda (Bernoulli)
monedas <- sample(c(0, 1), size=10000, replace=TRUE)
mean(monedas)  # Aproximadamente 0.5

# Simulaci n de dados
dados <- sample(1:6, size=100000, replace=TRUE)
table(dados) / 100000  # Cada cara ~1/6

# Muestreo con reemplazo de una poblaci n
poblacion <- rnorm(n=10000, mean=100, sd=15)
muestra_boot <- sample(poblacion, size=1000, replace=TRUE)
mean(muestra_boot)
```

Repaso: Probabilidad y Distribuciones en R (2/3)

Generación de Muestras de Distribuciones

```
# Distribuci n Binomial: n=20 ensayos, p=0.6  xito
muestras_binom <- rbinom(n=10000, size=20, prob=0.6)
hist(muestras_binom, main="Binomial(20, 0.6)")

# Distribuci n Poisson: lambda=5 eventos
muestras_pois <- rpois(n=10000, lambda=5)
hist(muestras_pois, main="Poisson(5)")

# Distribuci n Normal: media=100, sd=15
muestras_norm <- rnorm(n=10000, mean=100, sd=15)
hist(muestras_norm, main="Normal(100, 15)")

# Distribuci n t-Student: df=10
muestras_t <- rt(n=10000, df=10)
hist(muestras_t, main="t(df=10)")
```

Repaso: Probabilidad y Distribuciones en R (3/3)

Simulación del Teorema del Límite Central

```r
# Distribuci n no-normal: Exponencial
poblacion <- rexp(rate=0.5, n=100000)
hist(poblacion, main="Poblaci n (Exponencial)")

# TLC: Media de muestras converge a Normal
medias <- replicate(10000, mean(sample(poblacion, 100)))
hist(medias, main="Distribuci n de medias muestrales")

# Aumento de tama o muestral = + Normalidad
medias_250 <- replicate(5000, mean(sample(poblacion, 250)))
hist(medias_250, main="Medias (n=250)")

# Estad stico t
t_valores <- replicate(5000, {
  x <- sample(poblacion, 50)
  (mean(x) - mean(poblacion)) / (sd(x) / sqrt(50))
})
hist(t_valores, main="Estad sticos t simulados")
```

Repaso: Inferencia Estadística en R (1/2)

Intervalos de Confianza

```r
# Intervalo de confianza 95% para media (t-test)
datos_muestra <- rnorm(50, mean=120, sd=20)
result_t <- t.test(datos_muestra, conf.level=0.95)
result_t
# IC: [result_t$conf.int[1], result_t$conf.int[2]]

# Intervalo de confianza para proporci n
exitos <- 45; n <- 100
result_prop <- prop.test(exitos, n, conf.level=0.95)
result_prop$conf.int

# IC manualmente
p_est <- exitos / n
se <- sqrt(p_est * (1 - p_est) / n)
z_crit <- qnorm(0.975)  # 95% nivel
IC_inf <- p_est - z_crit * se
IC_sup <- p_est + z_crit * se
c(IC_inf, IC_sup)
```

Repaso: Inferencia Estadística en R (2/2)

Simulación de Cobertura de IC

```
# Verificar cobertura del IC 95%
# Verdadera poblaci n: Normal(100, 20)
cobertura <- replicate(10000, {
  muestra <- rnorm(n=30, mean=100, sd=20)
  result <- t.test(muestra, conf.level=0.95)
  #   Contiene   el IC el verdadero par metro (100)?
  result$conf.int[1] <= 100 & 100 <= result$conf.int[2]
})

# Proporci n de muestras cuyo IC contiene el par metro
mean(cobertura)  # Deber a ser ~0.95

# Si usamos nivel 99%
cobertura_99 <- replicate(5000, {
  muestra <- rnorm(n=30, mean=100, sd=20)
  result <- t.test(muestra, conf.level=0.99)
  result$conf.int[1] <= 100 & 100 <= result$conf.int[2]
})
mean(cobertura_99)  # Deber a ser ~0.99
```

Ejercicio Integrador: Análisis de Datos Sociales

Contexto del Ejercicio

Escenario: Se cuenta con datos de una encuesta social que registra:

- **edad:** Edad del respondiente (años)
- **educacion:** Años de educación formal completados
- **ingreso:** Ingreso mensual (en miles de pesos)
- **region:** Región geográfica (Norte, Centro, Sur)
- **satisfaccion:** Satisfacción con calidad de vida (escala 1-10)

Preguntas de Investigación:

1. ¿Cuál es la relación entre educación e ingreso?
2. ¿Difieren los ingresos entre regiones?
3. ¿Cuál es el rango probable del ingreso promedio?

Ejercicio Integrador: Paso 1 - Carga y Exploración

```r
# Paso 1: Cargar y explorar datos
library(tidyverse)
library(ggplot2)

# Crear dataset simulado
set.seed(123)
n <- 500
datos_estudio <- tibble(
  id = 1:n,
  edad = round(rnorm(n, mean=45, sd=12), 0),
  educacion = round(rnorm(n, mean=14, sd=3), 0),
  ingreso = 300 + 25*educacion + rnorm(n, 0, 50),
  region = rep(c("Norte", "Centro", "Sur"),
               length.out=n),
  satisfaccion = round(rnorm(n, mean=6, sd=2), 0)
)
```

Ejercicio Integrador: Paso 1 - Exploración de Datos

```
# Exploraci n (continuaci n)
head(datos_estudio)
dim(datos_estudio)
str(datos_estudio)
summary(datos_estudio)
```

Output esperado

10 variables, 500 observaciones (rows), estructura de tibble con tipos de datos.

Ejercicio Integrador: Paso 2 - Estadística Descriptiva

```
# Paso 2: Estad stica Descriptiva y Visualizaci n
# Descriptivos univariados
datos_estudio %>%
  summarize(
    edad_media = mean(edad),
    educacion_media = mean(educacion),
    ingreso_media = mean(ingreso),
    ingreso_sd = sd(ingreso),
    satisfaccion_media = mean(satisfaccion)
  )

# Descriptivos por regi n
datos_estudio %>%
  group_by(region) %>%
  summarize(
    n = n(),
    ingreso_prom = mean(ingreso),
    ingreso_sd = sd(ingreso),
    educacion_prom = mean(educacion)
  )
```

Ejercicio Integrador: Paso 2 - Visualizaciones

```
# Visualizaci n 1: Distribuci n de ingresos
ggplot(datos_estudio, aes(x=ingreso)) +
  geom_histogram(bins=30, fill="steelblue", alpha=0.7) +
  geom_vline(aes(xintercept=mean(ingreso)),
             color="red", linetype="dashed", size=1) +
  theme_minimal() +
  labs(title="Distribuci n de Ingresos",
       x="Ingreso Mensual (miles de pesos)",
       y="Frecuencia")

# Visualizaci n 2: Ingreso por regi n
ggplot(datos_estudio, aes(x=region, y=ingreso, fill=region)) +
  geom_boxplot(alpha=0.7) +
  theme_minimal() +
  labs(title="Ingreso por Regi n", y="Ingreso")
```

Ejercicio Integrador: Paso 2 - Más Visualizaciones

```r
# Visualizaci n 3: Relaci n educaci n-ingreso
ggplot(datos_estudio, aes(x=educacion, y=ingreso)) +
  geom_point(alpha=0.4, color="steelblue") +
  geom_smooth(method="lm", color="red", fill="red",
              alpha=0.1, se=TRUE) +
  theme_minimal() +
  labs(title="Relaci n Educaci n e Ingreso",
       x="A os de Educaci n",
       y="Ingreso Mensual")

# Visualizaci n 4: Matriz de correlaciones (visual)
cor_matriz <- datos_estudio %>%
  select(edad, educacion, ingreso, satisfaccion) %>%
  cor()
# Se puede visualizar con heatmap o pairs()
pairs(datos_estudio[, c("edad", "educacion",
                        "ingreso", "satisfaccion")])
```

Ejercicio Integrador: Paso 3 - Análisis de Probabilidad

Distribución y Proporciones

```r
# Paso 3: Probabilidad y Distribuciones

# Pregunta:   Qu   proporci n de respondientes
# tiene ingreso superior a 1000 mil pesos?
n_alto_ingreso <- sum(datos_estudio$ingreso > 1000)
p_alto_ingreso <- n_alto_ingreso / nrow(datos_estudio)
print(p_alto_ingreso)

# Simulaci n de muestreo
# Si replicamos muestras de n=100,   qu   distribuci n
# tiene la proporci n muestral?
proporciones <- replicate(5000, {
  muestra <- sample(datos_estudio$ingreso, size=100)
  sum(muestra > 1000) / 100
})
hist(proporciones, main="Distribuci n de proporciones")
mean(proporciones)
sd(proporciones)
```

Ejercicio Integrador: Paso 4 - Ajuste de Distribuciones

```r
# Paso 4:  Sigue  el ingreso una distribuci n Normal?

# M todo 1: Visualizaci n Q-Q plot
qqnorm(datos_estudio$ingreso)
qqline(datos_estudio$ingreso, col="red")

# M todo 2: Test de Shapiro-Wilk
shapiro.test(datos_estudio$ingreso)
# p-valor alto: datos compatibles con Normal

# M todo 3: Comparar densidad observada vs Normal
ingreso_est <- datos_estudio$ingreso
pars <- list(mean=mean(ingreso_est),
             sd=sd(ingreso_est))

ggplot(datos_estudio, aes(x=ingreso)) +
  geom_histogram(aes(y=..density..), bins=30,
                 fill="steelblue", alpha=0.5) +
  stat_function(fun=dnorm, args=pars,
                color="red", size=1) +
  theme_minimal()
```

Ejercicio Integrador: Paso 5 - Intervalos de Confianza

```r
# Paso 5: Inferencia - IC para ingreso promedio

# IC 95% para media de ingreso (usando t-test)
resultado_t <- t.test(datos_estudio$ingreso,
                      conf.level=0.95)
resultado_t

# Extaer IC
IC_inf <- resultado_t$conf.int[1]
IC_sup <- resultado_t$conf.int[2]
print(paste("IC 95%: [", round(IC_inf, 2), ", ",
            round(IC_sup, 2), "]"))

# Interpretaci n: "Tenemos 95% confianza que el
# ingreso promedio poblacional est  entre
# IC_inf y IC_sup mil pesos"

# Diferencia en ingresos: Norte vs Centro
norte <- filter(datos_estudio, region=="Norte")$ingreso
centro <- filter(datos_estudio, region=="Centro")$ingreso
t.test(norte, centro, conf.level=0.95)
```

Ejercicio Integrador: Paso 5b - IC para Proporción

```
# IC para proporci n:   Qu   % tiene ingreso > 1000?
n_total <- nrow(datos_estudio)
n_alto <- sum(datos_estudio$ingreso > 1000)

prop_test_result <- prop.test(n_alto, n_total,
                              conf.level=0.95)
prop_test_result

# IC para proporci n
print(prop_test_result$conf.int)

# Interpretaci n: "Con 95% confianza, entre
# el X% y Y% de la poblaci n tiene
# ingreso superior a 1000 mil pesos"

# Prueba bilateral:  es  significativamente distinto de 0.5?
prop.test(n_alto, n_total, p=0.5)
# p-valor:  hay  evidencia contra H0: p=0.5?
```

Ejercicio Integrador: Paso 6 - Regresión Simple (Modelo)

```r
# Paso 6: Modelo de Regresi n Lineal Simple
# Pregunta:   Cmo   predecir ingreso desde educaci n?

modelo <- lm(ingreso ~ educacion,
             data=datos_estudio)
summary(modelo)

# Resultados:
# Coef educacion     25
# Cada a o educaci n asociado a ~25 mil pesos m s
```

Ejercicio Integrador: Paso 6 - Regresión Simple (Modelo)

```
# Paso 6: Modelo de Regresi n Lineal Simple
# Pregunta:   Cmo   predecir ingreso desde educaci n?

modelo <- lm(ingreso ~ educacion,
             data=datos_estudio)
summary(modelo)

# Resultados:
# Coef educacion     25
# Cada a o educaci n asociado a ~25 mil pesos m s
```

Coeficientes

Intercepto, educación (significativo), R-squared.

Ejercicio Integrador: Paso 6 - Regresión Simple (Predicciones)

```r
# IC para coeficientes
confint(modelo, level=0.95)

# Predicciones para nuevos valores
nuevo_dato <- data.frame(
  educacion = c(12, 16, 20))
predicciones <- predict(modelo, nuevo_dato,
                        interval="confidence", level=0.95)
predicciones
```

Interpretación

Los intervalos muestran la incertidumbre en las predicciones de ingreso según educación.

Ejercicio Integrador: Paso 7 - Conclusiones e Informe

```r
# Paso 7: S ntesis de Resultados

# Crear tabla de resumen
resumen <- tibble(
  Pregunta = c(
    "Ingreso promedio",
    "Ingreso promedio (IC 95%)",
    "Proporci n ingreso > 1000",
    "Asociaci n educaci n     ingreso"
  ),
  Respuesta = c(
    paste(round(mean(datos_estudio$ingreso), 1)),
    paste("[", round(IC_inf, 1), ", ",
          round(IC_sup, 1), "]"),
    paste(round(p_alto_ingreso*100, 1), "%"),
    "Relaci n positiva significativa"
  )
)
print(resumen)

# Guardar resultados
write.csv(resumen, "resumen_analisis.csv", row.names=F)
```

Conclusiones del Ejercicio Integrador

Resultados Principales:

- El ingreso promedio es aproximadamente **650 mil pesos**, con IC95% que no incluye valores extremos
- Existe una **relación positiva fuerte** entre educación e ingreso (coef. ≈ 25)
- La **distribución de ingresos** es aproximadamente Normal
- Las **diferencias regionales** son estadísticamente significativas
- Aproximadamente **30-35%** de respondientes tienen ingreso superior a 1000 mil pesos

Lecciones Clave:

1. Flujo integrado: exploración $\rightarrow$ descripción $\rightarrow$ probabilidad $\rightarrow$ inferencia
2. R permite ejecutar cada paso con funciones concisas
3. Visualizaciones y números complementan interpretación
4. Intervalos de confianza cuantifican incertidumbre

Sesión 6: Introducción a Econometría

Lo que viene la próxima semana

Temas a cubrirse:

- Modelo de Regresión Lineal Múltiple (MCO)
- Estimación de parámetros y propiedades del estimador
- Inferencia en modelos multivariados
- Validación de supuestos (normalidad, homocedasticidad, no-colinealidad)
- Predicción y análisis de residuos
- Aplicación en contextos socioeconómicos

Preparación Recomendada:

- Revisar sesiones 1-5 (especialmente inferencia)
- Practicar con regresión simple antes de clase
- Familiarizarse con funciones lm() y summary() en R

Recursos de Referencia

Librerías de R esenciales:

- `tidyverse`: Manipulación de datos (dplyr, ggplot2)
- `ggplot2`: Visualización avanzada
- `stats`: Funciones estadísticas base
- `boot`: Bootstrap y remuestreo

Documentación en línea:

- `https://r4ds.hadley.nz/` — R para Ciencia de Datos
- `https://ggplot2.tidyverse.org/` — ggplot2 oficial
- `https://dplyr.tidyverse.org/` — dplyr oficial
- Ayuda en R: `?lm`, `?t.test`, `?ggplot`

Práctica: Ejecutar todos los códigos en RStudio y experimentar con datos propios.