Sesión 1: Fundamentos y Estadística Descriptiva

Amaru Agüero

Doctorado en Ciencias de la Complejidad Social — CICS, UDD

18 de marzo de 2026

Universidad del Desarrollo
Facultad de Gobierno

Agenda de la Sesión

- **Tipos de datos y escalas de medición**

Duración: 70 minutos

Agenda de la Sesión

- **Tipos de datos y escalas de medición**
  - Variables cualitativas y cuantitativas

Duración: 70 minutos

Agenda de la Sesión

- **Tipos de datos y escalas de medición**
  - Variables cualitativas y cuantitativas
  - Escalas: nominal, ordinal, intervalo, razón

Duración: 70 minutos

Agenda de la Sesión

- **Tipos de datos y escalas de medición**
  - Variables cualitativas y cuantitativas
  - Escalas: nominal, ordinal, intervalo, razón
- **Medidas de tendencia central**

Duración: 70 minutos

Agenda de la Sesión

- **Tipos de datos y escalas de medición**
  - Variables cualitativas y cuantitativas
  - Escalas: nominal, ordinal, intervalo, razón
- **Medidas de tendencia central**
  - Media, mediana, moda

Duración: 70 minutos

Agenda de la Sesión

- **Tipos de datos y escalas de medición**
  - Variables cualitativas y cuantitativas
  - Escalas: nominal, ordinal, intervalo, razón
- **Medidas de tendencia central**
  - Media, mediana, moda
  - Interpretación y sensibilidad a outliers

Duración: 70 minutos

Agenda de la Sesión

- **Tipos de datos y escalas de medición**
  - Variables cualitativas y cuantitativas
  - Escalas: nominal, ordinal, intervalo, razón
- **Medidas de tendencia central**
  - Media, mediana, moda
  - Interpretación y sensibilidad a outliers
- **Medidas de dispersión**

Duración: 70 minutos

Agenda de la Sesión

- **Tipos de datos y escalas de medición**
  - Variables cualitativas y cuantitativas
  - Escalas: nominal, ordinal, intervalo, razón
- **Medidas de tendencia central**
  - Media, mediana, moda
  - Interpretación y sensibilidad a outliers
- **Medidas de dispersión**
  - Varianza y desviación estándar

Duración: 70 minutos

Agenda de la Sesión

- **Tipos de datos y escalas de medición**
  - Variables cualitativas y cuantitativas
  - Escalas: nominal, ordinal, intervalo, razón
- **Medidas de tendencia central**
  - Media, mediana, moda
  - Interpretación y sensibilidad a outliers
- **Medidas de dispersión**
  - Varianza y desviación estándar
  - Rango intercuartílico y coeficiente de variación

Duración: 70 minutos

Agenda de la Sesión

- **Tipos de datos y escalas de medición**
  - Variables cualitativas y cuantitativas
  - Escalas: nominal, ordinal, intervalo, razón
- **Medidas de tendencia central**
  - Media, mediana, moda
  - Interpretación y sensibilidad a outliers
- **Medidas de dispersión**
  - Varianza y desviación estándar
  - Rango intercuartílico y coeficiente de variación
- **Visualización con ggplot2**

Duración: 70 minutos

Agenda de la Sesión

- **Tipos de datos y escalas de medición**
  - Variables cualitativas y cuantitativas
  - Escalas: nominal, ordinal, intervalo, razón
- **Medidas de tendencia central**
  - Media, mediana, moda
  - Interpretación y sensibilidad a outliers
- **Medidas de dispersión**
  - Varianza y desviación estándar
  - Rango intercuartílico y coeficiente de variación
- **Visualización con ggplot2**
  - Histogramas, boxplots, scatter plots

Duración: 70 minutos

Agenda de la Sesión

- **Tipos de datos y escalas de medición**
  - Variables cualitativas y cuantitativas
  - Escalas: nominal, ordinal, intervalo, razón
- **Medidas de tendencia central**
  - Media, mediana, moda
  - Interpretación y sensibilidad a outliers
- **Medidas de dispersión**
  - Varianza y desviación estándar
  - Rango intercuartílico y coeficiente de variación
- **Visualización con ggplot2**
  - Histogramas, boxplots, scatter plots
- **Ejercicio práctico**

Duración: 70 minutos

¿Por qué Estadística Descriptiva?

Objetivo fundamental

La estadística descriptiva nos permite:

- Resumir información compleja
- Identificar patrones en datos
- Comunicar hallazgos con claridad
- Preparar datos para análisis inferencial

En ciencias sociales

Estudiar características de poblaciones:

- Ingresos, educación, empleo
- Opiniones y comportamientos
- Indicadores de bienestar
- Dinámicas de redes sociales

¿Por qué Estadística Descriptiva?

Objetivo fundamental

La estadística descriptiva nos permite:

- Resumir información compleja
- Identificar patrones en datos
- Comunicar hallazgos con claridad
- Preparar datos para análisis inferencial

En ciencias sociales

Estudiar características de poblaciones:

- Ingresos, educación, empleo
- Opiniones y comportamientos
- Indicadores de bienestar
- Dinámicas de redes sociales

"Antes de inferir, primero entender."

Tipos de Datos y Escalas de Medición

Clasificación fundamental

Datos Cualitativos (Categóricos)

- **Nominal**: sin orden
  - Género, región, partido político
- **Ordinal**: con orden
  - Nivel educativo, satisfacción (1-5)

Datos Cuantitativos (Numéricos)

- **Discreta**: conteos
  - Número de hijos, delitos por comuna
- **Continua**: mediciones
  - Ingreso, altura, temperatura

Tipos de Datos y Escalas de Medición

Clasificación fundamental

Datos Cualitativos (Categóricos)

- **Nominal**: sin orden
  - Género, región, partido político
- **Ordinal**: con orden
  - Nivel educativo, satisfacción (1-5)

Datos Cuantitativos (Numéricos)

- **Discreta**: conteos
  - Número de hijos, delitos por comuna
- **Continua**: mediciones
  - Ingreso, altura, temperatura

Importancia

El tipo de dato determina las técnicas estadísticas apropiadas y la interpretación de resultados.

Tipos de Variables: Visualización

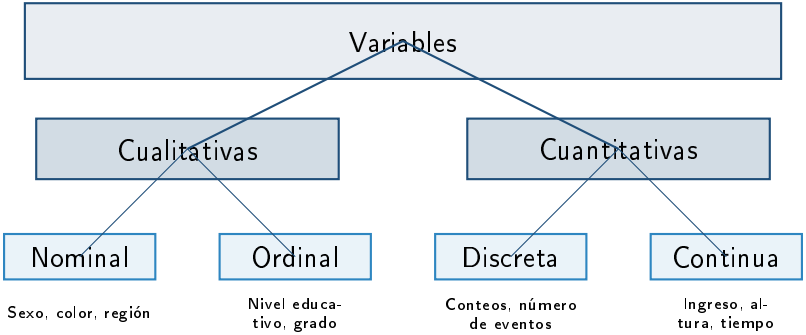

Nota: Si disponible, ver figura 'tipos$_v$ariables.pdf'eneldirectoriodefiguras

Ejemplos en Investigación Social

Encuesta de bienestar

- Nominal: estado laboral
- Ordinal: satisfacción
- Discreta: años educación
- Continua: ingreso

Ejemplos en Investigación Social

Encuesta de bienestar

- Nominal: estado laboral
- Ordinal: satisfacción
- Discreta: años educación
- Continua: ingreso

Red social y polarización

- Nominal: ideología
- Ordinal: escala ideológica
- Discreta: conexiones
- Continua: índice polarización

Ejemplos en Investigación Social

Encuesta de bienestar

- Nominal: estado laboral
- Ordinal: satisfacción
- Discreta: años educación
- Continua: ingreso

Red social y polarización

- Nominal: ideología
- Ordinal: escala ideológica
- Discreta: conexiones
- Continua: índice polarización

Mediana (ordinal) vs. media (continua)

Medidas de Tendencia Central: Conceptos

¿Qué son?

Estadísticos que representan el "centro" o "valor típico" de un conjunto de datos.

Medidas de Tendencia Central: Conceptos

¿Qué son?

Estadísticos que representan el "centro" o "valor típico" de un conjunto de datos.

Media ($\bar{x}$)

Promedio aritmético

$$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$$

Mediana

Valor central cuando datos están ordenados

- n impar: valor central
- n par: promedio dos valores centrales

Moda

Valor más frecuente

- Puede no existir
- Puede haber múltiples

Propiedades y Comparación

Propiedad	**Media**	**Mediana**	**Moda**
Nivel de medición mínimo	Cuantitativo	Ordinal	Cualquier nivel
Utiliza todos los datos	Sí	No	No
Sensible a outliers	Muy	Poco	No
Única en un dataset	Siempre	Casi siempre	No necesariamente
Fácil de calcular	Sí	Sí	Sí

Propiedades y Comparación

Propiedad	Media	Mediana	Moda
Nivel de medición mínimo	Cuantitativo	Ordinal	Cualquier nivel
Utiliza todos los datos	Sí	No	No
Sensible a outliers	Muy	Poco	No
Única en un dataset	Siempre	Casi siempre	No necesariamente
Fácil de calcular	Sí	Sí	Sí

Recomendaciones de uso

- **Media**: datos simétricos, distribuidos normalmente
- **Mediana**: datos sesgados, presencia de outliers (ej: ingresos)
- **Moda**: datos categóricos, interés en categoría más frecuente

Sensibilidad a Outliers: Ejemplo Numérico

Dataset de ingresos (UF)

Sin outliers: 2.0, 2.2, 2.5, 2.8, 3.1, 3.3, 3.5

- Media: 2.77 UF | Mediana: 2.8 UF

Sensibilidad a Outliers: Ejemplo Numérico

Dataset de ingresos (UF)

Sin outliers: 2.0, 2.2, 2.5, 2.8, 3.1, 3.3, 3.5

- Media: 2.77 UF | Mediana: 2.8 UF

Con outlier: 2.0, 2.2, 2.5, 2.8, 3.1, 3.3, 3.5, 500.0

- Media: 64.85 UF ← cambia drásticamente
- Mediana: 2.95 UF ← sigue siendo representativa

Sensibilidad a Outliers: Ejemplo Numérico

Dataset de ingresos (UF)

Sin outliers: 2.0, 2.2, 2.5, 2.8, 3.1, 3.3, 3.5

- Media: 2.77 UF | Mediana: 2.8 UF

Con outlier: 2.0, 2.2, 2.5, 2.8, 3.1, 3.3, 3.5, 500.0

- Media: 64.85 UF ← cambia drásticamente
- Mediana: 2.95 UF ← sigue siendo representativa

Conclusión para ciencias sociales

Con datos sesgados (ingresos, riqueza), **mediana** > media

Medidas de Dispersión

¿Por qué las necesitamos?

Dos datasets pueden tener la misma media pero dispersiones muy distintas:

- **Grupo A**: 2.5, 2.5, 2.5, 2.5, 2.5 $\Rightarrow$ Media = 2.5, Desv = 0
- **Grupo B**: 1.0, 2.0, 2.5, 3.0, 4.0 $\Rightarrow$ Media = 2.5, Desv = 1.12

Las medidas de dispersión cuantifican esta variabilidad.

Medidas de Dispersión

¿Por qué las necesitamos?

Dos datasets pueden tener la misma media pero dispersiones muy distintas:

- **Grupo A**: 2.5, 2.5, 2.5, 2.5, 2.5 $\Rightarrow$ Media = 2.5, Desv = 0
- **Grupo B**: 1.0, 2.0, 2.5, 3.0, 4.0 $\Rightarrow$ Media = 2.5, Desv = 1.12

Las medidas de dispersión cuantifican esta variabilidad.

Medidas principales

- Rango (máximo - mínimo)
- Varianza y Desviación Estándar
- Rango Intercuartílico (IQR)
- Coeficiente de Variación

Varianza y Desviación Estándar

Varianza

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Unidades al cuadrado; difícil de interpretar

Varianza y Desviación Estándar

Varianza

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Unidades al cuadrado; difícil de interpretar

Desviación Estándar

$$s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Mismas unidades; desviación promedio desde media

Varianza y Desviación Estándar

Varianza

$$s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2$$

Unidades al cuadrado; difícil de interpretar

Desviación Estándar

$$s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

Mismas unidades; desviación promedio desde media

Regla empírica

68% dentro $[\bar{x} \pm s]$; 95% dentro $[\bar{x} \pm 2s]$

Cuartiles y Rango Intercuartílico

Cuartiles

- Q_1: percentil 25
- Q_2: percentil 50 (mediana)
- Q_3: percentil 75

Rango Intercuartílico (IQR)

$$\text{IQR} = Q_3 - Q_1$$

50% central; robusto a outliers

Cuartiles y Rango Intercuartílico

Cuartiles

- Q_1: percentil 25
- Q_2: percentil 50 (mediana)
- Q_3: percentil 75

Rango Intercuartílico (IQR)

$$\text{IQR} = Q_3 - Q_1$$

50% central; robusto a outliers

Outliers (método IQR)

Fuera $[Q_1 - 1.5 \times \text{IQR}, Q_3 + 1.5 \times \text{IQR}]$

Coeficiente de Variación (CV)

Coeficiente de Variación (CV)

$$CV = \frac{s}{\bar{x}} \times 100\%$$

- Dispersión **relativa** (no absoluta)
- Permite comparar variabilidad entre variables con distintas escalas
- Ejemplo: comparar dispersión de ingresos vs. educación
- CV alto: datos muy dispersos respecto a la media
- Permite comparación entre variables

Coeficiente de Variación (CV)

Coeficiente de Variación (CV)

$$CV = \frac{s}{\bar{x}} \times 100\%$$

- Dispersión **relativa** (no absoluta)
- Permite comparar variabilidad entre variables con distintas escalas
- Ejemplo: comparar dispersión de ingresos vs. educación
- CV alto: datos muy dispersos respecto a la media
- Permite comparación entre variables

Interpretación

Si $CV_{\text{ingresos}} = 45\%$ y $CV_{\text{educación}} = 30\%$, los ingresos tienen mayor variabilidad relativa.

Z-Scores (Estandarización)

Z-Scores

$$z_i = \frac{x_i - \bar{x}}{s}$$

- Transforma datos a media 0, desv. est. 1
- Interpretación: "cuántas desviaciones estándar del promedio"
- Permite comparación entre variables con escalas distintas
- Identificar valores inusuales: $|z| > 3$ es potencial outlier

Z-Scores (Estandarización)

Z-Scores

$$z_i = \frac{x_i - \bar{x}}{s}$$

- Transforma datos a media 0, desv. est. 1
- Interpretación: "cuántas desviaciones estándar del promedio"
- Permite comparación entre variables con escalas distintas
- Identificar valores inusuales: $|z| > 3$ es potencial outlier

Ejemplo

Si ingreso medio es 3 UF con s = 0.5, una persona con 4.5 UF tiene:

$$z = \frac{4.5 - 3}{0.5} = 3 \text{ (3 desviaciones estándar arriba de la media)}$$

Implementación en R: Cargar y Resumir Datos

```r
library(tidyverse)
library(ggplot2)
datos <- read.csv("datos_encuesta.csv")
str(datos)
head(datos)
datos %>% summarise(
  media = mean(ingreso, na.rm = TRUE),
  mediana = median(ingreso, na.rm = TRUE),
  desv_est = sd(ingreso, na.rm = TRUE),
  q1 = quantile(ingreso, 0.25),
  q3 = quantile(ingreso, 0.75)
)
```

Visualización: Histogramas de Ingresos

```
ggplot(datos, aes(x = ingreso)) +
  geom_histogram(binwidth = 0.5,
    fill = "#2E86C1", color = "white") +
  labs(title = "Income Distribution",
       x = "Income (UF)", y = "Frequency") +
  theme_minimal()
ggplot(datos, aes(x = ingreso)) +
  geom_histogram(aes(y = after_stat(density)),
    binwidth = 0.5, fill = "#2E86C1") +
  geom_density(color = "#1F4E79") +
  theme_minimal()
```

Nota: Ver figura 'histograma¡ngresos.pdf'

Visualización: Boxplots Comparativos

```
ggplot(datos, aes(x = sector, y = ingreso,
                  fill = sector)) +
  geom_boxplot(alpha = 0.7) +
  geom_jitter(width = 0.2, alpha = 0.3) +
  labs(title = "Income by Sector",
       x = "Sector", y = "Income (UF)",
       fill = "Sector") +
  theme_minimal()
ggplot(datos, aes(x = sector, y = ingreso)) +
  geom_boxplot(fill = "#2E86C1") +
  coord_flip() + theme_minimal()
```

Nota: Ver figura 'boxplot$_c$omparativo.pdf' paraejemploreal

Visualización: Relación entre Variables

```
ggplot(datos, aes(x = education_years,
  y = income, color = gender)) +
  geom_point(size = 2.5, alpha = 0.6) +
  geom_smooth(method = "lm", se = TRUE) +
  labs(title = "Education vs Income",
       x = "Years", y = "Income (UF)",
       color = "Gender") +
  theme_minimal()
```

Nota: Ver figura 'scatter$_e$ducacion¡ngreso.pdf' paraejemploreal

Tabla Resumida de Estadísticos por Grupo

```
resumen <- datos %>%
  group_by(sector) %>%
  summarise(
    n = n(),
    media = mean(ingreso),
    mediana = median(ingreso),
    sd = sd(ingreso),
    cv = (sd / media) * 100,
    min = min(ingreso),
    max = max(ingreso)
  )
print(resumen)
```

Identificación y Manejo de Outliers

```
datos <- datos %>%
  mutate(z_ingreso = scale(ingreso)[,1],
         es_outlier = abs(z_ingreso) > 3)
ggplot(datos, aes(x = "Ingreso", y = ingreso)) +
  geom_boxplot(fill = "#2E86C1", alpha = 0.5) +
  geom_point(aes(color = es_outlier),
    size = 3, alpha = 0.7) +
  theme_minimal()
tabla_outliers <- datos %>%
  summarise(
    total = n(),
    outliers = sum(es_outlier),
    pct = (sum(es_outlier) / n()) * 100)
```

Transformaciones: Normalizando Datos Sesgados

Problema

Ingresos y riqueza: distribuciones fuertemente sesgadas

```
datos <- datos %>%
  mutate(log_income = log(income),
         sqrt_income = sqrt(income))
p1 <- ggplot(datos, aes(x = income)) +
  geom_histogram(fill = "#2E86C1") +
  ggtitle("Original")
p2 <- ggplot(datos, aes(x = log_income)) +
  geom_histogram(fill = "#2E86C1") +
  ggtitle("Log Transformed")
grid.arrange(p1, p2, ncol = 2)
```

Correlación entre Variables

Pearson: $r = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{(n-1)s_x s_y}$

Rango $[-1, +1]$; mide relación lineal

```
corr <- cor(datos$education, datos$income)
corr_mat <- cor(datos[c("age", "education",
                        "income")])
library(corrplot)
corrplot(corr_mat, method = "circle")
```

Análisis Estratificado por Subgrupos

Pregunta

¿Cómo varían ingresos por género, región y sector?

```
datos %>%
  group_by(gender, region, sector) %>%
  summarise(n = n(),
    mean_income = mean(income),
    med_income = median(income),
    sd_income = sd(income))
ggplot(datos, aes(x = gender, y = income,
                  fill = region)) +
  geom_boxplot(alpha = 0.7) +
  facet_wrap(~ sector)
```

Caso Práctico: Análisis de Brecha de Género (Cálculo)

Calculate wage gap

```
datos %>%
  group_by(gender) %>%
  summarise(mean_income = mean(income),
    median_income = median(income))
gap <- datos %>%
  group_by(gender) %>%
  summarise(mean = mean(income)) %>%
  pivot_wider(names_from = gender,
              values_from = mean) %>%
  mutate(gap_pct = ((Female -
    Male) / Male) * 100)
```

Caso Práctico: Análisis de Brecha de Género (Visualización)

Visualizar

```
ggplot(datos, aes(x = gender, y = income,
                  fill = gender)) +
  geom_violin(alpha = 0.6) +
  geom_boxplot(width = 0.1, fill = "white") +
  labs(title = "Income Distribution by Gender",
       x = "Gender", y = "Income (UF)") +
  theme_minimal()
```

Caso Práctico: Análisis de Brecha de Género (Visualización)

Visualizar

```
ggplot(datos, aes(x = gender, y = income,
                  fill = gender)) +
  geom_violin(alpha = 0.6) +
  geom_boxplot(width = 0.1, fill = "white") +
  labs(title = "Income Distribution by Gender",
       x = "Gender", y = "Income (UF)") +
  theme_minimal()
```

Interpretación

La mediana y cuartiles muestran si la brecha es real más allá de valores extremos.

Simetría y Sesgo

Sesgo

$= 0$: simétrica
> 0: derecha
< 0: izquierda

Ejemplos

Ingresos > 0
Jubilación < 0

Simetría y Sesgo

Sesgo

$= 0$: simétrica
> 0: derecha
< 0: izquierda

Ejemplos

Ingresos > 0
Jubilación < 0

```
library(moments)
sesgo <- skewness(datos$ingreso)
ggplot(datos, aes(x = ingreso)) +
  geom_histogram(aes(y = after_stat(density)),
    fill = "#2E86C1") +
  geom_density(color = "#1F4E79")
```

Checklist: Análisis Descriptivo Completo

Antes de cualquier análisis inferencial, verificar:

- ✓ **Estructura del dataset**: dimensiones, tipos de datos, valores faltantes
- ✓ **Tendencia central**: media, mediana, moda (¿cuál es representativa?)
- ✓ **Dispersión**: desv. estándar, IQR, rango (¿cuán concentrados están datos?)
- ✓ **Forma**: simetría, sesgo, curtosis (¿es aproximadamente normal?)
- ✓ **Outliers**: detectar y evaluar si son reales o errores
- ✓ **Distribuciones por grupo**: ¿hay patrones por subgrupos?
- ✓ **Relaciones bivariadas**: correlaciones entre pares de variables
- ✓ **Valores faltantes**: ¿cuántos?, ¿patrón?, ¿imputar o eliminar?

Checklist: Análisis Descriptivo Completo

Antes de cualquier análisis inferencial, verificar:

- ✓ **Estructura del dataset**: dimensiones, tipos de datos, valores faltantes
- ✓ **Tendencia central**: media, mediana, moda (¿cuál es representativa?)
- ✓ **Dispersión**: desv. estándar, IQR, rango (¿cuán concentrados están datos?)
- ✓ **Forma**: simetría, sesgo, curtosis (¿es aproximadamente normal?)
- ✓ **Outliers**: detectar y evaluar si son reales o errores
- ✓ **Distribuciones por grupo**: ¿hay patrones por subgrupos?
- ✓ **Relaciones bivariadas**: correlaciones entre pares de variables
- ✓ **Valores faltantes**: ¿cuántos?, ¿patrón?, ¿imputar o eliminar?

Salida de una buena estadística descriptiva

Una tabla o gráfico que comunique hallazgos clave de forma clara y honesta.

Exercise: 30 min

Instructions