

Sesión 1 · Fundamentos de Probabilidad

Fundamentos de Probabilidad y Estadística — Doctorados en Ciencias de la Complejidad Social y en Políticas Públicas · UDD

Amaru Agüero Jiménez (a.agueroj@udd.cl)

marzo de 2026

Panorama de la sesión

Bloque	Concepto formal	Ejemplo aplicado
Espacio muestral y eventos Axiomas de Kolmogorov	$\Omega, A \subseteq \Omega$, álgebra de conjuntos $P(\Omega) = 1$, aditividad numerable	Hogar consigue empleo o no Propiedades demostradas paso a paso
Condicional, total y Bayes	$P(A B) = P(A \cap B)/P(B)$	Programa de empleo, focalización
Independencia	$P(A \cap B) = P(A)P(B)$	¿El programa “no informa” sobre el empleo?
Variable aleatoria PMF, CDF y densidad	$X : \Omega \rightarrow \mathbb{R}$ $p(x), F(x), f(x)$	Postulaciones aceptadas Tiempos de espera en oficinas públicas

i Metodología de todo el curso: cada concepto abre con su definición formal, sigue con la intuición y cierra con un ejemplo de políticas públicas resuelto **paso a paso**, verificado en R.

Experimento aleatorio y espacio muestral

Definiciones. Un **experimento aleatorio** es un procedimiento cuyo resultado no puede predecirse con certeza, pero cuyo conjunto de resultados posibles se conoce de antemano; ese conjunto es el **espacio muestral** Ω . Un **evento** $A \subseteq \Omega$ **ocurre** si el resultado observado cumple $\omega \in A$.

$$\Omega = \{\omega : \omega \text{ es un resultado posible del experimento}\}$$


Experimento	Ω	Un evento A
Encuestar un hogar: ¿consiguió empleo?	$\{S, N\}$	$\{S\}$
Lanzar una moneda dos veces	$\{CC, CS, SC, SS\}$	“al menos una cara” $= \{CC, CS, SC\}$
Postular a 3 fondos concursables	$\{0, 1, 2, 3\}$	“acepta más de una” $= \{2, 3\}$
Medir el ingreso mensual de un hogar	$[0, \infty)$	“bajo la línea de pobreza” $= [0, L)$

Interpretación frecuentista: la probabilidad como límite

Si repetimos el experimento n veces en condiciones idénticas y n_A es el número de veces que ocurre A :

$$P(A) = \lim_{n \rightarrow \infty} \frac{n_A}{n}$$

Proporción acumulada de hogares con empleo (simulación)



Con pocos hogares la frecuencia oscila fuerte; con muchos se estabiliza — la lógica detrás del **tamaño muestral** de las encuestas.

Laboratorio: frecuencia relativa y probabilidad

Mueva los controles y observe cómo la frecuencia relativa acumulada se estabiliza en torno a la probabilidad verdadera (ley de los grandes números).

Versión interactiva (solo HTML): dos deslizadores controlan el número de lanzamientos n y la probabilidad verdadera p ; el gráfico redibuja en vivo la frecuencia relativa acumulada de n ensayos Bernoulli(p) junto a la línea horizontal en p .


Conclusión: es la misma lógica de la simulación Monte Carlo de la lámina anterior — al crecer n , la frecuencia relativa n_A/n converge a $P(A)$.



Intuición

Cada observación nueva pesa cada vez menos en el promedio: por eso la curva se aquieta y termina pegada a la probabilidad verdadera cuando el número de lanzamientos crece.

Eventos como conjuntos: las cuatro operaciones




Operaciones sobre eventos $A, B \subseteq \Omega$:

- **Unión** $A \cup B = \{\omega : \omega \in A \text{ o } \omega \in B\}$ — ocurre *al menos uno*.
- **Intersección** $A \cap B = \{\omega : \omega \in A \text{ y } \omega \in B\}$ — ocurren *ambos*.
- **Complemento** $A^c = \Omega \setminus A$ — *no* ocurre A .
- **Diferencia** $A \setminus B = A \cap B^c$ — ocurre A *pero no* B .

La fórmula del recuadro en la figura,
 $P(A \cup B) = P(A) + P(B) - P(A \cap B)$, la
demostraremos en unos minutos a partir de los axiomas.

Las cuatro operaciones, vistas como áreas



Intuición

Unión es “o”, intersección es “y”, complemento es “no”: operar con eventos es aplicar los conectores lógicos del lenguaje a zonas del diagrama.

Diccionario: lenguaje natural y notación de conjuntos

Frase en lenguaje natural	Notación
“ocurre A o B (o ambos)”	$A \cup B$
“ocurren A y B a la vez”	$A \cap B$
“no ocurre A ”	A^c
“ocurre A pero no B ”	$A \setminus B = A \cap B^c$
“no ocurre ninguno de los dos”	$(A \cup B)^c = A^c \cap B^c$
“no ocurren ambos a la vez”	$(A \cap B)^c = A^c \cup B^c$
“ A y B son incompatibles”	$A \cap B = \emptyset$



Las filas 5 y 6 son las **leyes de De Morgan**: el complemento intercambia uniones con intersecciones. Traducir bien el enunciado verbal a conjuntos es el paso donde más errores se cometen en los ejercicios.

Axiomas de Kolmogorov (1933)

Una **medida de probabilidad** es una función P que asigna a cada evento $A \subseteq \Omega$ un número $P(A)$, y que satisface exactamente tres axiomas:

A1 (No negatividad): $P(A) \geq 0$ para todo evento A

A2 (Normalización): $P(\Omega) = 1$

A3 (Aditividad numerable): $A_1, A_2, \dots$ disjuntos dos a dos $\Rightarrow P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$

Qué significa esto: toda la teoría de probabilidad —Bayes, la ley de los grandes números, la inferencia que verán en Métodos Cuantitativos— se deduce de estas tres reglas.

Caso equiprobable: si Ω es finito y todos los resultados pesan igual, $P(A) = \frac{|A|}{|\Omega|}$ (casos favorables sobre casos posibles).

Propiedades derivadas (1/2): vacío y complemento

Propiedad 1: $P(\emptyset) = 0$. Como Ω y $\emptyset$ son disjuntos y $\Omega \cup \emptyset = \Omega$:

$$\begin{aligned} 1 &= P(\Omega) = P(\Omega \cup \emptyset) && \text{(A2 y unión con el vacío)} \\ &= P(\Omega) + P(\emptyset) = 1 + P(\emptyset) && \text{(A3, eventos disjuntos)} \\ \Rightarrow P(\emptyset) &= 0 && \blacksquare \end{aligned}$$

Propiedad 2: $P(A^c) = 1 - P(A)$. Como $A \cup A^c = \Omega$ con $A \cap A^c = \emptyset$:

$$\begin{aligned} 1 &= P(\Omega) = P(A \cup A^c) && \text{(A2)} \\ &= P(A) + P(A^c) && \text{(A3, disjuntos)} \\ \Rightarrow P(A^c) &= 1 - P(A) && \blacksquare \end{aligned}$$

Qué significa esto: si la probabilidad de que un hogar consiga empleo es 0.42, la de que **no** lo consiga es $1 - 0.42 = 0.58$ — no hace falta contarlos de nuevo.

Propiedades derivadas (2/2): monotonía y regla de adición

Propiedad 3 (Monotonía): $A \subseteq B \Rightarrow P(A) \leq P(B)$. Descomponemos B en partes disjuntas:

$$\begin{aligned} B &= A \cup (B \setminus A), \quad A \cap (B \setminus A) = \emptyset \\ P(B) &= P(A) + P(B \setminus A) \geq P(A) \quad (\text{A3 y luego A1}) \quad \blacksquare \end{aligned}$$

Propiedad 4 (Regla de adición). Descomponemos $A \cup B$ y B en eventos disjuntos:

$$\begin{aligned} A \cup B &= A \cup (B \setminus A) \Rightarrow P(A \cup B) = P(A) + P(B \setminus A) \\ B &= (A \cap B) \cup (B \setminus A) \Rightarrow P(B \setminus A) = P(B) - P(A \cap B) \\ \Rightarrow P(A \cup B) &= P(A) + P(B) - P(A \cap B) \quad \blacksquare \end{aligned}$$

Qué significa esto: al sumar $P(A) + P(B)$, los resultados de $A \cap B$ se cuentan dos veces; la fórmula descuenta ese doble conteo exactamente una vez.

El ejemplo maestro: programa de capacitación y empleo

Una municipalidad siguió a **500 hogares**. Definimos el experimento “elegir un hogar al azar” (Ω = los 500 hogares, equiprobables) y los eventos:

- T = “el hogar participó en el programa de capacitación laboral”
- E = “el hogar consiguió empleo formal dentro del año”

	Consiguió empleo (E)	No consiguió (E^c)	Total
Participó (T)	120	80	200
No participó (T^c)	90	210	300
Total	210	290	500

Pregunta empírica: ¿los participantes consiguen empleo con mayor probabilidad que los no participantes? Esta tabla alimentará *todas* las definiciones que siguen.

Paso a paso: probabilidades conjuntas y marginales

Paso 1 — Conjuntas (celda sobre total, modelo equiprobable $P(A) = |A|/|\Omega|$):

$$P(T \cap E) = \frac{120}{500} = 0.24 \quad P(T \cap E^c) = \frac{80}{500} = 0.16$$

$$P(T^c \cap E) = \frac{90}{500} = 0.18 \quad P(T^c \cap E^c) = \frac{210}{500} = 0.42$$

Paso 2 — Marginales (sumar las conjuntas de cada fila o columna, que son disjuntas):

$$P(T) = 0.24 + 0.16 = 0.40 \text{ y } P(E) = 0.24 + 0.18 = 0.42.$$

Paso 3 — Verificación con la regla de adición: $P(T \cup E) = 0.40 + 0.42 - 0.24 = \boxed{0.58}$.

	E	E^c	Marginal
T	0.24	0.16	0.40
T^c	0.18	0.42	0.60
Marginal	0.42	0.58	1.00

Probabilidad condicional: la definición central del curso


$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \quad \text{definida solo si } P(B) > 0$$

Intuición: saber que ocurrió B *reduce* el espacio muestral de Ω a B ; el cociente re-escala las probabilidades para que el nuevo total sea 1.

Resultado formal: para B fijo, la función $A \mapsto P(A \mid B)$ es en sí misma una medida de probabilidad — cumple A1, A2 y A3. Por eso todo lo demostrado hoy vale también “condicional en B ”.

! $P(A \mid B)$ y $P(B \mid A)$ son objetos **distintos** con denominadores distintos. Confundirlos es la *falacia del fiscal*: la probabilidad de la evidencia dado inocente no es la probabilidad de inocente dado la evidencia. Lo veremos en números con el Teorema de Bayes.

Condicionar es restringir el espacio muestral



Al saber que ocurrió B , los resultados fuera de B dejan de ser posibles: $P(A | B)$ compara el área de $A \cap B$ con el área total de B , no con la de Ω .



Intuición

El diagrama muestra el zoom: al condicionar en B , el rectángulo completo deja de importar y el círculo B pasa a ser el nuevo universo de referencia.

Paso a paso: condicionales en la tabla de empleo

Paso 1 — condicional entre participantes:

$$P(E | T) = \frac{P(E \cap T)}{P(T)} = \frac{0.24}{0.40} = 0.60$$

Paso 2 — entre no participantes:


$$P(E | T^c) = \frac{P(E \cap T^c)}{P(T^c)} = \frac{0.18}{0.60} = 0.30$$

Paso 3 — la condicional “invertida”:

$$P(T | E) = \frac{0.24}{0.42} \approx 0.571 \neq P(E | T)$$

Interpretación de política: la probabilidad de empleo se duplica entre participantes (0.60 vs 0.30). Es una **asociación**, no todavía un efecto causal: puede haber autoselección.

Probabilidad de empleo según participación



Regla del producto y regla de la cadena

Despejando $P(A \cap B)$ de la definición de condicional (regla del **producto**):

$$P(A \cap B) = P(B) P(A \mid B) = P(A) P(B \mid A)$$

Iterando, se obtiene la regla de la **cadena** para n eventos:

$$P(A_1 \cap A_2 \cap A_3) = P(A_1) P(A_2 \mid A_1) P(A_3 \mid A_1 \cap A_2)$$

Ejemplo paso a paso — beca en tres etapas. Con $P(A_1) = 0.60$ (requisitos), $P(A_2 \mid A_1) = 0.50$ (adjudicación) y $P(A_3 \mid A_1 \cap A_2) = 0.40$ (completar el programa):

$$\begin{aligned} P(A_1 \cap A_2 \cap A_3) &= P(A_1) P(A_2 \mid A_1) P(A_3 \mid A_1 \cap A_2) \\ &= 0.60 \times 0.50 \times 0.40 = \boxed{0.12} \end{aligned}$$

Qué significa esto: solo el 12% de la cohorte llega al final; cada etapa se condiciona en las anteriores.

Ley de probabilidad total

Definición (partición). Los eventos $A_1, \dots, A_k$ forman una **partición** de Ω si son disjuntos dos a dos ($A_i \cap A_j = \emptyset$ para $i \neq j$), cubren todo ($\bigcup_{i=1}^k A_i = \Omega$) y $P(A_i) > 0$.

Teorema. Para cualquier evento B :


$$P(B) = \sum_{i=1}^k P(B \mid A_i) P(A_i)$$

Demostración (3 líneas).

$$\begin{aligned} B &= B \cap \Omega = B \cap \left(\bigcup_i A_i \right) = \bigcup_i (B \cap A_i) && \text{(distributividad)} \\ P(B) &= \sum_i P(B \cap A_i) && \text{(A3: los } B \cap A_i \text{ son disjuntos)} \\ &= \sum_i P(B \mid A_i) P(A_i) && \text{(regla del producto) } \blacksquare \end{aligned}$$

Qué significa esto: $P(B)$ es un **promedio ponderado** de las condicionales, con pesos dados por el tamaño de cada pedazo de la partición.

La ley de probabilidad total en un diagrama



Las franjas A_1, A_2, A_3 parten Ω ; el evento B (elipse) queda cortado en pedazos disjuntos y $P(B) = \sum_i P(B \cap A_i) = \sum_i P(B \mid A_i) P(A_i)$.



Intuición

Para medir el evento completo, recórralo pedazo a pedazo: cada franja aporta lo suyo y ninguna parte se cuenta dos veces — un promedio ponderado de las franjas.

Paso a paso: deserción de un programa nacional


Enunciado. Un programa opera en tres macrozonas. La distribución de beneficiarios es Norte 25 %, Centro 45 %, Sur 30 %; las tasas de deserción (D) por zona son 0.08, 0.12 y 0.20.

Paso 1 — identificar la partición: $\{N, C, S\}$.

Paso 2 — aplicar la ley de probabilidad total:

$$\begin{aligned}P(D) &= P(D | N)P(N) + P(D | C)P(C) \\&\quad + P(D | S)P(S) \\&= 0.08(0.25) + 0.12(0.45) + 0.20(0.30) \\&= 0.020 + 0.054 + 0.060 = \boxed{0.134}\end{aligned}$$

Qué significa esto: la tasa nacional (13.4 %) no es el promedio simple de las tasas zonales (13.3 % sería con pesos iguales); pondera por dónde están los beneficiarios.



Teorema de Bayes: derivación formal en 3 pasos

Sea $\{A_1, \dots, A_k\}$ una partición de Ω y B un evento con $P(B) > 0$.

Paso 1 (definición): $P(A_j | B) = \frac{P(A_j \cap B)}{P(B)}$

Paso 2 (producto): $P(A_j \cap B) = P(B | A_j) P(A_j)$

Paso 3 (prob. total): $P(A_j | B) = \frac{P(B | A_j) P(A_j)}{\sum_{i=1}^k P(B | A_i) P(A_i)}$ ■

Terminología: $P(A_j)$ es la *prior*, $P(B | A_j)$ la *verosimilitud* y $P(A_j | B)$ la *posterior*. Bayes “invierte” la condicional: pasa de $P(\text{dato} | \text{estado})$ a $P(\text{estado} | \text{dato})$.

Aplicación inmediata (deserción): ¿de qué zona proviene un desertor típico?

$$P(S | D) = \frac{P(D | S)P(S)}{P(D)} = \frac{0.060}{0.134} \approx \boxed{0.448}$$

El Sur aporta el 30 % de los beneficiarios pero casi el 45 % de los desertores.

Bayes paso a paso: focalización de un subsidio (1/2)

Enunciado. Un instrumento de focalización clasifica hogares como vulnerables (+) o no (−). Se sabe que:

- **Prevalencia:** $P(V) = 0.10$ — el 10 % de los hogares es efectivamente vulnerable.
- **Sensibilidad:** $P(+ | V) = 0.90$ — detecta al 90 % de los vulnerables.
- **Especificidad:** $P(- | V^c) = 0.85$, de modo que $P(+ | V^c) = 1 - 0.85 = 0.15$.

Pregunta: si el instrumento clasifica a un hogar como vulnerable, ¿cuál es la probabilidad de que lo sea de verdad, $P(V | +)$?

Paso 1 — Numerador (regla del producto):

$$P(+ \cap V) = P(+ | V) P(V) = 0.90 \times 0.10 = 0.090$$

Paso 2 — Denominador (ley de probabilidad total con la partición $\{V, V^c\}$):

$$P(+) = P(+ | V)P(V) + P(+ | V^c)P(V^c) = 0.90(0.10) + 0.15(0.90) = 0.090 + 0.135 = 0.225$$

Bayes paso a paso: focalización de un subsidio (2/2)

Paso 3 — Posterior (Teorema de Bayes):

$$P(V \mid +) = \frac{P(+ \mid V) P(V)}{P(+)} = \frac{0.090}{0.225} = \boxed{0.40}$$

El mismo cálculo en frecuencias naturales (1.000 hogares):

	Clasificado +	Clasificado −	Total
Vulnerable (V)	90	10	100
No vulnerable (V^c)	135	765	900
Total	225	775	1.000


De los 225 clasificados +, solo 90 son vulnerables: $90/225 = 0.40$; el otro 60 % es **error de inclusión**.
Verificación en R:

```
round(0.90 * 0.10 / (0.90 * 0.10 + 0.15 * 0.90), 3)
```


[1] 0.4

Prior vs posterior: la evidencia actualiza, no reemplaza

Focalización: prior vs posterior




Teorema de Bayes: Test Médico



Lectura de la figura derecha (test médico): con prevalencia 1 %, sensibilidad 99 % y especificidad 95 %, $P(\text{enfermo} \mid +) = \frac{0.0099}{0.0594} \approx 0.167$. Un test “casi perfecto” acierta solo 1 de cada 6 positivos cuando la condición es rara.

El posterior depende de la prevalencia

Mismo instrumento (sens 0.90, espec 0.85), distinta poblacion



Implicancia de diseño: el mismo instrumento aplicado a una población de baja prevalencia (barrido universal) genera muchos más errores de inclusión que aplicado a una población pre-filtrada. La curva punteada es la referencia "posterior = prior".

Mueva los controles del instrumento de focalización y observe cómo cambian el prior y los dos posteriores.

Versión interactiva (solo HTML): tres deslizadores (prevalencia, sensibilidad, especificidad) recalculan en vivo las barras de $P(V)$, $P(V \mid +)$ y $P(V \mid -)$.

Los valores iniciales reproducen el ejemplo de focalización ya resuelto: con $P(V) = 0.10$, sensibilidad 0.90 y especificidad 0.85 se obtiene $P(V \mid +) = 0.40$ y $P(V \mid -) \approx 0.013$. Al subir la prevalencia, el mismo instrumento comete muchos menos errores de inclusión.



Intuición

El posterior mezcla lo que ya se sabía (la prior) con lo que el dato aporta: si la condición es rara, hasta un instrumento muy bueno se equivoca seguido al dar positivo.

Independencia: definición y equivalencia

Definición. Los eventos A y B son **independientes** (notación $A \perp B$) si

$$P(A \cap B) = P(A) P(B)$$

Equivalencia con la condicional (si $P(B) > 0$):

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)} = \frac{P(A) P(B)}{P(B)} = P(A)$$

y simétricamente $P(B \mid A) = P(B)$ si $P(A) > 0$.

Qué significa esto: saber que ocurrió B **no cambia** la probabilidad de A — la información sobre B es inútil para predecir A . Es el supuesto detrás del *muestreo aleatorio* (“las respuestas de dos hogares sorteados no se informan mutuamente”) y de la *asignación aleatoria* en experimentos.

Propiedad útil: si $A \perp B$, también $A \perp B^c$, $A^c \perp B$ y $A^c \perp B^c$.

Error común: independencia no es exclusión mutua


Propiedad	Independientes	Mutuamente excluyentes
Definición	$P(A \cap B) = P(A)P(B)$	$A \cap B = \emptyset$
$P(A \cap B)$	$P(A)P(B) > 0$ si ambas > 0	0 siempre
$P(A B)$	$= P(A)$: saber B no informa	$= 0$: saber B descarta A
¿Pueden ocurrir juntos?	Sí	Nunca
Ejemplo	Empleo de dos hogares sorteados	“Quintil I” y “Quintil V” del mismo hogar

Demostración del contraste. Si $A \cap B = \emptyset$ con $P(A) > 0$ y $P(B) > 0$:

$$P(A \cap B) = 0 \neq P(A)P(B) > 0$$

Eventos excluyentes con probabilidad positiva son **máximamente dependientes**: observar uno elimina al otro. Solo pueden ser ambas cosas si $P(A) = 0$ o $P(B) = 0$.

En el diagrama: exclusión mutua vs independencia



La exclusión mutua sí se dibuja: círculos sin traslape. **La independencia no se dibuja:** no es una propiedad de la forma o posición de los conjuntos, sino de los **productos de probabilidades** — exige $P(A \cap B) = P(A)P(B)$, algo que ningún diagrama de áreas puede mostrar por sí solo.



Intuición

Excluyentes: no caben juntos — ver uno descarta al otro. Independientes: se ignoran — ver uno no dice nada del otro. Son ideas casi opuestas, no sinónimos.

Paso a paso: ¿son independientes T y E en la tabla?

Paso 1 — probabilidad conjunta observada: $P(T \cap E) = \frac{120}{500} = 0.24$

Paso 2 — producto de marginales (lo que valdría bajo independencia):
 $P(T) P(E) = 0.40 \times 0.42 = 0.168$

Paso 3 — comparar:

$$P(T \cap E) = 0.24 \neq 0.168 = P(T) P(E) \Rightarrow T \text{ y } E \text{ son dependientes}$$

Equivalentemente, $P(E | T) = 0.60 \neq 0.42 = P(E)$: participar “informa” sobre el empleo.

```
round(c(P_TyE = 120/500, P_T_x_P_E = (200/500) * (210/500),  
      P_E_dado_T = 120/200, P_E = 210/500), 3)
```

P_TyE	P_T_x_P_E	P_E_dado_T	P_E
0.240	0.168	0.600	0.420

Ojo: dependencia estadística $\neq$ causalidad: la brecha 0.60 vs 0.30 puede reflejar autoselección; separarlas es el objetivo de los diseños causales de Métodos Cuantitativos.

Variable aleatoria: una función, no un número

Definición. Una **variable aleatoria** es una función que asigna un número real a cada resultado del experimento:

$$X : \Omega \rightarrow \mathbb{R}, \quad \omega \mapsto X(\omega)$$

Los eventos sobre X son **preimágenes**: $\{X = x\} = \{\omega \in \Omega : X(\omega) = x\}$, y su probabilidad es la del conjunto de resultados que se mapean a x .


Ejemplo explícito de mapeo. Encuestamos 2 hogares; cada uno recibe (S) o no recibe (N) el subsidio. Sea X = “número de hogares que reciben”:

$\omega \in \Omega$	SS	SN	NS	NN
$X(\omega)$	2	1	1	0

Así, $\{X = 1\} = \{SN, NS\}$ y por lo tanto $P(X = 1) = P(\{SN\}) + P(\{NS\})$.

Qué significa esto: X traduce resultados a números para hacer aritmética; la aleatoriedad vive en ω , la función X es fija.

Variables discretas y continuas



Discreta: su **soporte** (valores con probabilidad positiva) es finito o numerable.

- N° de postulaciones aceptadas: $\{0, 1, 2, 3\}$
- N° de delitos por comuna al mes: $\{0, 1, 2, \dots\}$
- Se describe con la **PMF** $p(x)$.

Continua: toma valores en intervalos de $\mathbb{R}$ (soporte no numerable) y $P(X = x) = 0$ para todo x .

- Ingreso del hogar, tiempo de espera, tasa de pobreza comunal.
- Se describe con la **densidad** $f(x)$.

La **CDF** $F(x)$ existe y caracteriza la distribución en **ambos** casos.

Función de masa de probabilidad (PMF)

Definición. Para X discreta con soporte $\mathcal{S} = \{x_1, x_2, \dots\}$, la PMF es $p(x) = P(X = x)$, y debe cumplir **dos condiciones**:

$$(i) \ p(x) \geq 0 \quad \forall x \qquad (ii) \ \sum_{x \in \mathcal{S}} p(x) = 1$$

Ejemplo. X = número de postulaciones aceptadas entre 3 fondos concursables:

x	0	1	2	3
$p(x)$	0.35	0.30	0.20	0.15

Verificación de validez:

$$(i) \text{ todos } \geq 0 \quad \checkmark \qquad (ii) \ 0.35 + 0.30 + 0.20 + 0.15 = 1.00 \quad \checkmark$$

Qué significa esto: la PMF reparte exactamente 1; toda probabilidad se obtiene **sumando** masas.

Paso a paso: probabilidades desde la PMF


Pregunta 1: $P(X \leq 2)$

$$\begin{aligned}P(X \leq 2) &= p(0) + p(1) + p(2) \\&= 0.35 + 0.30 + 0.20 \\&= \boxed{0.85}\end{aligned}$$

Pregunta 2: $P(X > 1)$, por dos vías:

$$\begin{aligned}P(X > 1) &= p(2) + p(3) = 0.35 \\P(X > 1) &= 1 - P(X \leq 1) \\&= 1 - 0.65 = \boxed{0.35}\end{aligned}$$

PMF: $P(X \leq 2)$ = suma de barras azules



```
p <- c(0.35, 0.30, 0.20, 0.15)
c(suma = sum(p), P_le_2 = sum(p[1:3]), P_gt_1 = sum(p[3:4]))
```

suma	P_le_2	P_gt_1
1.00	0.85	0.35

Función de distribución acumulada (CDF)

Definición. Para cualquier variable aleatoria X (discreta o continua):

$$F(x) = P(X \leq x), \quad x \in \mathbb{R}$$

Propiedades que toda CDF cumple:

- ❶ **Monótona no decreciente:** $x_1 < x_2 \Rightarrow F(x_1) \leq F(x_2)$ (monotonía de P).
- ❷ **Límites:** $\lim_{x \rightarrow -\infty} F(x) = 0$ y $\lim_{x \rightarrow +\infty} F(x) = 1$.
- ❸ **Continua por la derecha:** $\lim_{h \downarrow 0} F(x+h) = F(x)$.
- ❹ **Regla de intervalos:** $P(a < X \leq b) = F(b) - F(a)$.

Para nuestra PMF (postulaciones aceptadas), acumulando $p(x)$:

Intervalo	$x < 0$	$0 \leq x < 1$	$1 \leq x < 2$	$2 \leq x < 3$	$x \geq 3$
$F(x)$	0	0.35	0.65	0.85	1


En discretas, F es una **escalera**: salta $p(x)$ en cada punto del soporte y es plana entre ellos.

La CDF escalera en R con geom_step

```
esc <- tibble(  
  x = c(-1, 0, 1, 2, 3, 4),  
  Fx = c(0, .35, .65, .85, 1, 1))  
  
ggplot(esc, aes(x, Fx)) +  
  geom_step(direction = "hv",  
            color = azul,  
            linewidth = 1) +  
  geom_point(  
    data = filter(esc, x %in% 0:3),  
    color = rojo, size = 2.5) +  
  labs(x = "x", y = "F(x)")
```

`direction = "hv"`: horizontal y luego vertical
— la forma correcta de la escalera. Los puntos
rojos marcan el valor de F en el salto
(continuidad por la derecha).

CDF de las postulaciones aceptadas



Lectura directa: $F(2) = 0.85$ reproduce el $P(X \leq 2)$ que calculamos sumando la PMF.

Variables continuas: la función de densidad

Definición. X es (absolutamente) continua si existe $f(x) \geq 0$ tal que

$$F(x) = \int_{-\infty}^x f(t) dt \quad \Longleftrightarrow \quad f(x) = F'(x) \quad \text{donde } F \text{ es derivable}$$

con $\int_{-\infty}^{\infty} f(x) dx = 1$. Las probabilidades son **áreas**: $P(a \leq X \leq b) = \int_a^b f(x) dx$.

¿Por qué $P(X = x) = 0$? Para todo $\varepsilon > 0$, por monotonía:

$$\begin{aligned} 0 \leq P(X = x) &\leq P(x - \varepsilon < X \leq x) = F(x) - F(x - \varepsilon) \\ &\rightarrow 0 \quad \text{cuando } \varepsilon \rightarrow 0 \quad (\text{porque } F \text{ es continua}) \quad \blacksquare \end{aligned}$$

Consecuencias importantes:

- En continuas, $P(a \leq X \leq b) = P(a < X < b)$: los bordes no aportan probabilidad.
- $f(x)$ **no** es una probabilidad (puede superar 1); solo sus **integrales** lo son.

Paso a paso: la distribución Uniforme(0, 10)

Enunciado. El tiempo de espera X (minutos) en una oficina de atención es Uniforme en $[0, 10]$:

$$f(x) = \frac{1}{10}, \quad 0 \leq x \leq 10 \quad (\text{y } 0 \text{ fuera})$$

Paso 1 — validez: $\int_0^{10} \frac{1}{10} dx = \frac{10}{10} = 1 \checkmark$


Paso 2 — $P(2 \leq X \leq 5)$ como integral:

$$\begin{aligned} P(2 \leq X \leq 5) &= \int_2^5 \frac{1}{10} dx = \left[\frac{x}{10} \right]_2^5 \\ &= \frac{5}{10} - \frac{2}{10} = \boxed{0.30} \end{aligned}$$

Paso 3 — $P(X = 4) = \int_4^4 \frac{1}{10} dx = 0.$

```
round(punif(5, 0, 10) - punif(2, 0, 10), 2)
```

```
[1] 0.3
```



Mapa del curso: dónde se usa lo de hoy

Sesión	Tema	Usa de esta sesión
Hoy, bloque 2	Distribuciones, $\mathbb{E}(X)$ y $\text{Var}(X)$	PMF, densidad, CDF
Día 2, bloque 1	Muestreo, ley de grandes números, TCL	Independencia, frecuencia relativa
Día 2, bloque 2	Intervalos de confianza y pruebas de hipótesis	CDF, complemento, condicional
Métodos Cuantitativos	Regresión: $\mathbb{E}(Y X)$, inferencia causal	Condicional, independencia, Bayes

Las tres ideas que deben quedar hoy:

- 1 La probabilidad es una **medida sobre conjuntos**: tres axiomas bastan y el resto se demuestra.
- 2 **Condicionar es re-normalizar**; Bayes invierte condicionales con producto y probabilidad total.
- 3 Una variable aleatoria es una **función** $X : \Omega \rightarrow \mathbb{R}$; PMF, CDF y densidad la describen.

Ejercicios propuestos (para el descanso)

- 1 Con $P(A) = 0.55$, $P(B) = 0.35$ y $P(A \cap B) = 0.20$: calcule $P(A \cup B)$ y $P(A | B)$, y determine si A y B son independientes.
- 2 Un test de elegibilidad tiene prevalencia $P(C) = 0.05$, sensibilidad 0.85 y especificidad 0.90. Calcule $P(C | +)$ con los tres pasos de Bayes.
- 3 Sea $p(x) = 0.40, 0.30, 0.20, 0.10$ para $x = 0, 1, 2, 3$. Verifique que es una PMF válida y calcule $F(1)$ y $P(X \geq 2)$.
- 4 $X \sim \text{Uniforme}(0, 20)$: escriba $f(x)$ y calcule $P(5 \leq X \leq 12)$ y $P(X = 8)$.

Respuestas:

- 1 $P(A \cup B) = 0.55 + 0.35 - 0.20 = 0.70$; $P(A | B) = 0.20/0.35 \approx 0.571$; no independientes: $P(A)P(B) = 0.1925 \neq 0.20$.
- 2 $P(C | +) = \frac{0.85 \times 0.05}{0.85(0.05) + 0.10(0.95)} = 0.0425/0.1375 \approx 0.309$.
- 3 Suma = 1.00 ✓; $F(1) = 0.70$; $P(X \geq 2) = 0.30$.
- 4 $f(x) = 1/20$ en $[0, 20]$; $P(5 \leq X \leq 12) = 7/20 = 0.35$; $P(X = 8) = 0$.

Referencias: Casella & Berger, *Statistical Inference* (cap. 1) · Wasserman, *All of Statistics* (caps. 1–2)
· Illowsky & Dean, *Introductory Statistics* (caps. 3–5).