

Sesión 3 · Muestreo e Inferencia Estadística

Fundamentos de Probabilidad y Estadística — Doctorados en Ciencias de la Complejidad Social y en Políticas Públicas · UDD

Amaru Agüero Jiménez (a.agueroj@udd.cl)

marzo de 2026

Panorama de la sesión

Bloque	Concepto clave	Herramienta en R
Muestreo	Población, muestra i.i.d., θ vs $\hat{\theta}$	<code>sample()</code>
Distribución muestral	$\mathbb{E}[\bar{X}] = \mu$, $\text{Var}(\bar{X}) = \sigma^2/n$	<code>replicate()</code>
LGN y TCL	$\bar{X}_n \xrightarrow{p} \mu$ · fluctuaciones $\rightarrow N(0, 1)$	<code>cummean()</code> , simulación
Propiedades	Insensatez, eficiencia, consistencia	<code>var()</code> , simulación
Intervalos	IC 95 % con z y con t	<code>t.test()</code> , <code>qt()</code>
Contraste de hipótesis	6 pasos, valor-p, errores I y II	<code>t.test()</code>
Potencia	$1 - \beta$ y diseño muestral	<code>power.t.test()</code>

i La pregunta de la sesión: observamos una muestra de n unidades, pero la política pública se decide sobre la **población completa**. ¿Cómo saltamos de una a otra cuantificando la incertidumbre del salto?

De la población a la muestra: notación formal

Población: modelamos la variable de interés como $X \sim F$, con parámetro desconocido $\theta \in \Theta \subseteq \mathbb{R}^k$ (fijo, no aleatorio).

Muestra aleatoria simple: $X_1, X_2, \dots, X_n$ son **i.i.d.** (independientes e idénticamente distribuidas):

$$X_1, \dots, X_n \stackrel{\text{iid}}{\sim} F \iff P(X_1 \leq x_1, \dots, X_n \leq x_n) = \prod_{i=1}^n F(x_i)$$

- **Independientes:** conocer una observación no informa sobre las demás.
- **Idénticamente distribuidas:** todas provienen de la misma F , con $\mathbb{E}[X_i] = \mu$ y $\text{Var}(X_i) = \sigma^2$ para todo i .



Ejemplo: la encuesta CASEN selecciona hogares con probabilidades conocidas para que los ingresos muestrales se comporten (aproximadamente) como extracciones i.i.d. de la distribución de ingresos de Chile. Un muestreo por conveniencia rompe el supuesto y toda la teoría que sigue.

Parámetro, estadístico y estimador

θ = parámetro (poblacional, fijo, desconocido) $\hat{\theta}_n = g(X_1, \dots, X_n)$ = estimador

Un **estadístico** es cualquier función de la muestra que **no depende de parámetros desconocidos**. Un **estimador** es el estadístico que usamos para aproximar θ ; su valor realizado $\hat{\theta}(x_1, \dots, x_n)$ es la **estimación**.

Parámetro poblacional	Estimador muestral	En R
Media $\mu = \mathbb{E}[X]$	$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$	<code>mean(x)</code>
Varianza $\sigma^2 = \text{Var}(X)$	$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$	<code>var(x)</code>
Proporción p	$\hat{p} = \frac{1}{n} \sum_{i=1}^n \mathbb{1}(X_i = 1)$	<code>mean(x == 1)</code>
Correlación ρ	r de Pearson	<code>cor(x, y)</code>

Que significa esto: la tasa de pobreza *verdadera* de una región es θ ; la tasa calculada con la CASEN es $\hat{\theta}_n$. Nunca son idénticas — la inferencia mide cuánto pueden diferir.


La distribución muestral: el estimador ES una variable aleatoria

Como $\hat{\theta}_n$ es función de variables aleatorias, **es una variable aleatoria**: cambia de muestra en muestra.

$$F_{\hat{\theta}_n}(t) = P(\hat{\theta}_n \leq t)$$

es su **distribución muestral**: la distribución de los valores de $\hat{\theta}_n$ bajo muestreo repetido de tamaño n .

- Cada encuesta distinta entrega una media distinta.
- La distribución muestral describe ese abanico de resultados posibles.
- Toda la inferencia (IC, tests) se construye sobre ella.



Demostración: $\mathbb{E}[\bar{X}_n] = \mu$

Sean $X_1, \dots, X_n$ i.i.d. con $\mathbb{E}[X_i] = \mu$. Entonces:

$$\begin{aligned}\mathbb{E}[\bar{X}_n] &= \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n X_i\right] \\&= \frac{1}{n} \mathbb{E}\left[\sum_{i=1}^n X_i\right] \quad (\text{la constante } 1/n \text{ sale de } \mathbb{E}) \\&= \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X_i] \quad (\text{linealidad de la esperanza}) \\&= \frac{1}{n} \cdot n\mu = \mu \quad (\text{idéntica distribución}) \blacksquare\end{aligned}$$

Que significa esto: el promedio muestral no apunta sistemáticamente ni por arriba ni por abajo de μ . Si repitiéramos la encuesta miles de veces, el promedio de los promedios coincidiría con el parámetro. Nótese que solo usamos linealidad: **no** se necesita independencia ni normalidad.

Demostración: $\text{Var}(\bar{X}_n) = \sigma^2/n$



Ahora sí usamos la **independencia** (las covarianzas cruzadas se anulan):

$$\begin{aligned}\text{Var}(\bar{X}_n) &= \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}\left(\sum_{i=1}^n X_i\right) \quad (\text{Var}(cY) = c^2 \text{Var}(Y)) \\ &= \frac{1}{n^2} \left[\sum_{i=1}^n \text{Var}(X_i) + \sum_{i \neq j} \text{Cov}(X_i, X_j) \right] \quad (\text{varianza de una suma}) \\ &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n} \quad (\text{indep.} \Rightarrow \text{Cov} = 0) \blacksquare\end{aligned}$$

Error estándar: $\text{SE}(\bar{X}_n) = \sigma/\sqrt{n}$, la desviación estándar de la distribución muestral de $\bar{X}_n$.

Que significa esto: la precisión mejora con $\sqrt{n}$, no con n : para **duplicar** la precisión hay que **cuadruplicar** la muestra.

Simulación: la distribución muestral en acción



Población **exponencial** (media $\mu = 5$, DE $\sigma = 5$, muy sesgada). Las medias de muestras con $n = 30$ se concentran alrededor de 5 con DE empírica ≈ 0.90 , casi idéntica al valor teórico $\sigma/\sqrt{n} = 5/\sqrt{30} \approx 0.91$ — y su forma ya es simétrica.

Ley de los Grandes Números: enunciado formal


Teorema (ley débil de los grandes números). Sean $X_1, X_2, \dots$ i.i.d. con $\mathbb{E}[X_i] = \mu$ y $\text{Var}(X_i) = \sigma^2 < \infty$. Entonces la media muestral **converge en probabilidad** al parámetro:

$$\bar{X}_n \xrightarrow{p} \mu \iff \lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| > \varepsilon) = 0 \quad \text{para todo } \varepsilon > 0$$

Demostración (vía la desigualdad de Chebyshev), paso a paso:

$$\begin{aligned} P(|\bar{X}_n - \mu| > \varepsilon) &\leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} \quad (\text{Chebyshev sobre } \bar{X}_n) \\ &= \frac{\sigma^2}{n \varepsilon^2} \quad (\text{ya demostramos } \text{Var}(\bar{X}_n) = \sigma^2/n) \\ &\xrightarrow{n \rightarrow \infty} 0 \quad \blacksquare \end{aligned}$$

LGN en acción: trayectorias de la media muestral



Cada trayectoria es una encuesta que crece: con n pequeño las cinco difieren mucho; hacia $n = 1000$ **todas** están pegadas a $p = 0.60$. Eso — y solo eso — es lo que garantiza la LGN.

Teorema Central del Límite: enunciado formal

Teorema (Lindeberg–Lévy). Sean $X_1, X_2, \dots$ i.i.d. con $\mathbb{E}[X_i] = \mu$ y $\text{Var}(X_i) = \sigma^2 \in (0, \infty)$. Entonces

$$Z_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} \mathcal{N}(0, 1) \quad (n \rightarrow \infty)$$


donde $\xrightarrow{d}$ denota **convergencia en distribución**: $\lim_{n \rightarrow \infty} P(Z_n \leq z) = \Phi(z)$ para todo $z \in \mathbb{R}$.

Hipótesis (todas necesarias): (i) observaciones i.i.d.; (ii) media finita; (iii) **varianza finita**. No se exige normalidad ni simetría de F .

Lectura en palabras: cualquiera sea la forma de la población — ingresos sesgados, conteos, dicotómicas — la media muestral estandarizada se comporta como una normal estándar cuando n es grande. En la práctica: $\bar{X}_n \overset{\text{aprox}}{\sim} \mathcal{N}(\mu, \sigma^2/n)$.

Que significa esto: el TCL es la licencia matemática para usar la campana de Gauss en encuestas de ingreso, pobreza o victimización, aunque ninguna de esas variables sea normal.

TCL en acción: de una exponencial a la normal



Con $n = 2$ la distribución de $\bar{X}_n$ hereda el sesgo exponencial; con $n = 30$ la curva normal (roja, con media 5 y DE $5/\sqrt{n}$) ya calza; con $n = 100$ el ajuste es casi perfecto. La regla práctica $n \geq 30$ nace de aquí — con poblaciones muy sesgadas conviene más.

Mueva los controles y observe cómo el histograma de medias de una población exponencial (media 5, DE 5) se acerca a la campana normal, y cómo el SE empírico calza con el teórico.

Experimento (disponible en la versión HTML): se extraen m muestras de tamaño n de una población $\text{Exp}(1/5)$ y se grafica el histograma de sus medias junto a la normal teórica $\mathcal{N}(5, 25/n)$, con n y m controlados por deslizadores.

- Con n pequeño el histograma hereda el sesgo exponencial; desde $n \approx 30$ la campana ya calza.
- El SE empírico (DE de las m medias) reproduce el teórico $\sigma/\sqrt{n} = 5/\sqrt{n}$.
- Aumentar m no angosta el histograma (eso solo lo hace n): únicamente lo dibuja con más nitidez.

LGN vs TCL: qué dice cada teorema

	Ley de los Grandes Números	Teorema Central del Límite
Pregunta que responde	¿ A dónde va $\bar{X}_n$?	¿ Cómo fluctúa $\bar{X}_n$ alrededor de μ ?
Enunciado	$\bar{X}_n \xrightarrow{p} \mu$	$\sqrt{n}(\bar{X}_n - \mu)/\sigma \xrightarrow{d} N(0, 1)$
Garantiza	El destino: la media llega al parámetro	La forma: fluctuaciones normales a escala $\sigma/\sqrt{n}$
NO dice	Ni la velocidad ni la forma de las fluctuaciones	Que los datos X_i sean normales (no lo necesita)
En una encuesta	Con n grande, $\hat{p} \approx p$	Habilita el margen de error $\pm 1.96 \cdot SE$




Intuición

La LGN dice que el viaje **llega a destino**; el TCL describe **los tropiezos alrededor del destino**. Sin LGN no sabríamos que estimamos lo correcto; sin TCL no podríamos cuantificar la incertidumbre de la estimación.

Por qué el TCL habilita toda la inferencia

Teorema del Límite Central (Distribución Original: Uniforme)



El TCL convierte un problema imposible en uno resuelto:

- **Sin TCL:** necesitaríamos conocer la distribución exacta de $\bar{X}_n$ para cada población posible.
- **Con TCL:** basta μ , σ y n ; la forma límite es siempre la misma normal.
- Los **intervalos de confianza** y los **contrastes de hipótesis** de esta sesión descansan en esta aproximación.
- Cuando falla (colas muy pesadas con varianza infinita, dependencia fuerte, n pequeño), la inferencia estándar puede ser engañosa.

¿Qué hace bueno a un estimador? Tres propiedades

Propiedad	Definición formal	Pregunta que responde
Insesgadez	$\mathbb{E}[\hat{\theta}_n] = \theta$ para todo θ	¿Apunta al blanco en promedio?
Eficiencia	$\text{Var}(\hat{\theta}_n) \leq \text{Var}(\tilde{\theta}_n)$ entre insesgados	¿Es el de menor dispersión?
Consistencia	$\hat{\theta}_n \xrightarrow{p} \theta$ cuando $n \rightarrow \infty$	¿Acierta con datos infinitos?

El **sesgo** se define como $\text{Sesgo}(\hat{\theta}_n) = \mathbb{E}[\hat{\theta}_n] - \theta$, y el criterio que integra sesgo y varianza es el **error cuadrático medio**:

$$\text{ECM}(\hat{\theta}_n) = \mathbb{E}[(\hat{\theta}_n - \theta)^2] = \text{Var}(\hat{\theta}_n) + [\text{Sesgo}(\hat{\theta}_n)]^2$$


Que significa esto: un indicador oficial (tasa de pobreza, desempleo) construido con un estimador sesgado distorsiona sistemáticamente la política, aunque la muestra sea enorme.

Insesgadez: $\mathbb{E}[\hat{\theta}_n] = \theta$

Definición. $\hat{\theta}_n$ es **insesgado** para θ si

$$\mathbb{E}[\hat{\theta}_n] = \theta \quad \forall \theta \in \Theta$$

- Ya demostramos que $\mathbb{E}[\bar{X}_n] = \mu$: la media muestral **es insesgada** para μ .
- La insesgadez es sobre el **promedio de muestras repetidas**: una realización particular casi nunca coincide con θ .
- Un estimador sesgado se equivoca *en la misma dirección* una y otra vez.



¿Por qué s^2 divide entre $n - 1$?

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 \quad \text{porque} \quad \mathbb{E} \left[\sum_{i=1}^n (X_i - \bar{X})^2 \right] = (n-1) \sigma^2$$

El grado de libertad perdido: las desviaciones satisfacen la restricción lineal $\sum_{i=1}^n (X_i - \bar{X}) = 0$, de modo que solo $n - 1$ de ellas son libres. Además, $\bar{X}$ está *más cerca* de los datos que μ (minimiza $\sum (X_i - c)^2$), así que $\sum (X_i - \bar{X})^2 \leq \sum (X_i - \mu)^2$: dividir por n **subestima** σ^2 con $\mathbb{E}[\hat{\sigma}_n^2] = \frac{n-1}{n} \sigma^2$.

```
set.seed(2026)
sims <- replicate(20000, {
  x <- rnorm(5, mean = 50, sd = 10)          # sigma^2 = 100, n = 5
  c(divide_n = sum((x - mean(x))^2) / 5, divide_n1 = var(x))
})
round(rowMeans(sims), 1)
```

divide_n	divide_n1
80.2	100.2

Con $\sigma^2 = 100$ y $n = 5$: dividir por n promedia ≈ 80.2 (el valor teórico $\frac{4}{5} \times 100 = 80$, un sesgo del 20 %); dividir por $n - 1$ promedia ≈ 100.2 . La corrección funciona.

Eficiencia: menor varianza entre insesgados


Definición. Entre dos estimadores **insesgados** $\hat{\theta}_n$ y $\tilde{\theta}_n$, $\hat{\theta}_n$ es más **eficiente** si

$$\text{Var}(\hat{\theta}_n) \leq \text{Var}(\tilde{\theta}_n)$$

Ejemplo clásico: bajo normalidad, media y mediana muestral son ambas insesgadas para μ , pero

$$\frac{\text{Var}(\text{mediana})}{\text{Var}(\bar{X}_n)} \xrightarrow{n \rightarrow \infty} \frac{\pi}{2} \approx 1.57$$

Usar la mediana equivale a **desechar un tercio de la muestra**. (Con colas pesadas la comparación puede invertirse.)



Consistencia: $\text{plim } \hat{\theta}_n = \theta$


Definición. $\hat{\theta}_n$ es **consistente** si converge en probabilidad a θ :

$$\lim_{n \rightarrow \infty} P(|\hat{\theta}_n - \theta| > \varepsilon) = 0 \quad \forall \varepsilon > 0$$

Para $\bar{X}_n$ es la **Ley de los Grandes Números**; basta notar que


$$\text{ECM}(\bar{X}_n) = \frac{\sigma^2}{n} \rightarrow 0$$

Que significa esto: con más datos, la probabilidad de equivocarse por más de cualquier margen ε se hace despreciable. Un estimador inconsistente no se salva ni con un censo.




Sesgo y varianza: las cuatro dianas


Insesgado y preciso




Insesgado, impreciso



Sesgado, preciso



Sesgado e impreciso



El centro de la diana es θ ; cada punto, una estimación con una muestra distinta. **Sesgo** = el centro de la nube no coincide con θ ; **varianza** = dispersión de la nube. El ECM penaliza ambos:
$$\text{ECM} = \text{Var} + \text{Sesgo}^2.$$

Intervalo de confianza: derivación (1/2)

Punto de partida. Por el TCL (o exactamente, si $X_i \sim \mathcal{N}$), con σ conocida:

$$Z = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \sim \mathcal{N}(0, 1)$$

Z es una cantidad **pivotal**: contiene a μ , pero su distribución no depende de ningún parámetro desconocido. De la normal estándar sabemos que $z_{0.975} = 1.96$, luego:

$$P(-1.96 \leq Z \leq 1.96) = \Phi(1.96) - \Phi(-1.96) = 0.975 - 0.025 = 0.95$$

Que significa esto: antes de observar los datos, hay un 95 % de probabilidad de que la media muestral caiga a menos de 1.96 errores estándar de μ . La derivación siguiente solo *despeja* μ de esa desigualdad.



Intuición

La estaca (el parámetro) está fija; el aro (el intervalo) cambia con cada muestra: confianza 95 % significa que 95 de cada 100 aros la capturan.

Intervalo de confianza: derivación (2/2)

Partimos de la probabilidad anterior y despejamos μ paso a paso:

$$\begin{aligned} 0.95 &= P\left(-1.96 \leq \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \leq 1.96\right) \\ &= P\left(-1.96 \frac{\sigma}{\sqrt{n}} \leq \bar{X}_n - \mu \leq 1.96 \frac{\sigma}{\sqrt{n}}\right) && \text{(multiplicar por } \sigma/\sqrt{n} > 0) \\ &= P\left(-\bar{X}_n - 1.96 \frac{\sigma}{\sqrt{n}} \leq -\mu \leq -\bar{X}_n + 1.96 \frac{\sigma}{\sqrt{n}}\right) && \text{(restar } \bar{X}_n) \\ &= P\left(\bar{X}_n - 1.96 \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}_n + 1.96 \frac{\sigma}{\sqrt{n}}\right) && \text{(multiplicar por } -1 \text{ invierte)} \end{aligned}$$

$$IC_{95\%}(\mu) = \left[\bar{X}_n - 1.96 \frac{\sigma}{\sqrt{n}}, \bar{X}_n + 1.96 \frac{\sigma}{\sqrt{n}} \right]$$

Lo aleatorio son los **extremos**, no μ : bajo muestreo repetido, el 95 % de estos intervalos contiene a μ .

σ desconocida: la t de Student


En la práctica σ se estima con s , y ese reemplazo agrega incertidumbre. Si $X_i \sim \mathcal{N}(\mu, \sigma^2)$:

$$T = \frac{\bar{X}_n - \mu}{s/\sqrt{n}} \sim t_{n-1}$$

con $n - 1$ **grados de libertad**. La t tiene colas más pesadas que la normal y converge a ella cuando $n \rightarrow \infty$.

$$IC_{95\%}(\mu) = \bar{X}_n \pm t_{n-1, 0.975} \frac{s}{\sqrt{n}}$$

Con $n = 25$: $t_{24, 0.975} = 2.064 > 1.96$ — intervalos más anchos, el precio honesto de no conocer σ .



Ejemplo IC paso a paso: ingreso de hogares beneficiarios

Pregunta: una muestra i.i.d. de $n = 36$ hogares beneficiarios de una transferencia reporta ingreso mensual con $\bar{x} = 520$ y $s = 90$ (miles de CLP). Construya el IC del 95 % para el ingreso medio poblacional μ .

Paso 1 — Error estándar:

$$\widehat{SE} = \frac{s}{\sqrt{n}} = \frac{90}{\sqrt{36}} = \frac{90}{6} = 15$$

Paso 2 — Valor crítico ($gl = n - 1 = 35$): $t_{35, 0.975} = 2.0301$ (en R: `qt(0.975, 35)`).

Paso 3 — Margen de error:

$$ME = t_{35, 0.975} \times \widehat{SE} = 2.0301 \times 15 = 30.45$$

Paso 4 — Límites:

$$IC_{95\%} = [520 - 30.45, 520 + 30.45] \Rightarrow \boxed{[489.55, 550.45]}$$

Verificación con `t.test()` en R

```
set.seed(123)
ingresos <- as.numeric(scale(rnorm(36))) * 90 + 520 # muestra con xbar = 520, s = 90 exactos
c(media = mean(ingresos), de = sd(ingresos), se = sd(ingresos) / sqrt(36))
```

media	de	se
520	90	15

```
tidy(t.test(ingresos)) %>%
  select(estimate, conf.low, conf.high) %>% kable(digits = 2)
```

estimate	conf.low	conf.high
520	489.55	550.45

Los límites de `t.test()` — [489.55, 550.45] — coinciden exactamente con el cálculo manual. Con 95 % de confianza, el ingreso medio de la población beneficiaria está entre **489.6 y 550.4 mil CLP**: si la línea de elegibilidad del programa fuera 560, este dato descartaría (al 95 %) que el hogar promedio la supere.

Interpretación del IC: una correcta, muchas incorrectas

Afirmación sobre $IC_{95\%} = [489.55, 550.45]$

¿Válida?

El procedimiento que generó este intervalo captura a μ el 95 % de las veces bajo muestreo repetido
Hay 95 % de probabilidad de que μ esté entre 489.55 y 550.45

Sí

No: μ es fijo; el intervalo ya lo contiene o no

El 95 % de los hogares tiene ingreso en ese rango
El 95 % de las medias muestrales futuras caerá en ese rango

No: el IC es para la **media**, no para individuos

No: confunde IC con distribución de $\bar{X}$

Con otra muestra obtendríamos el mismo intervalo

No: los extremos son aleatorios




La confianza es una propiedad del **procedimiento**, no de un intervalo particular. La frase operativa honesta: “con 95 % de confianza, μ está entre 489.6 y 550.4”.

Simulación de cobertura: 100 intervalos, $\mu = 50$

```
set.seed(1)
ics <- map_dfr(1:100, function(i) {
  x <- rnorm(30, mean = 50, sd = 10)
  ci <- t.test(x)$conf.int
  tibble(id = i, li = ci[1],
         ls = ci[2])
})
ics <- ics %>%
  mutate(cubre = li <= 50 & ls >= 50)
sum(ics$cubre) # 95 de 100
```

Cada segmento es el IC de una muestra distinta de la **misma** población. En esta corrida, **95 de 100** contienen a $\mu = 50$ — la tasa nominal en acción.




El ancho del intervalo: qué lo gobierna

$$\text{ancho} = 2 t_{n-1, 1-\alpha/2} \frac{s}{\sqrt{n}}$$

Con los datos del ejemplo ($s = 90$):

- $n = 36$, 95 %: ancho = $2(2.030)(15) = 60.9$
- $n = 36$, **99 %**: ancho = $2(2.724)(15) = 81.7$ — más confianza, menos precisión
- $n = 144$, 95 %: ancho = $2(1.977)(7.5) = 29.7$ — cuadruplicar n **divide el ancho por 2**

Que significa esto: precisión y confianza se compran con tamaño muestral, y el precio crece cuadráticamente.



Laboratorio: ancho del intervalo de confianza

Mueva los controles y observe cómo n , σ y el nivel de confianza gobiernan el ancho del intervalo alrededor de una media fija $\bar{x} = 50$.

Experimento (disponible en la versión HTML): deslizadores para n , σ y el nivel de confianza redibujan el intervalo $\bar{x} \pm z_{1-\alpha/2} \sigma / \sqrt{n}$ como segmento centrado en $\bar{x} = 50$, con lectura en vivo del margen de error.

- Cuadruplicar n divide el ancho por 2 (la raíz cuadrada cobra su precio).
- Subir la confianza de 95 % a 99 % agranda z de 1.96 a 2.576: más seguridad, menos precisión.
- σ entra de forma lineal: poblaciones más heterogéneas exigen muestras mayores.

Contraste de hipótesis: procedimiento formal en 6 pasos

- 1 **Hipótesis:** $H_0 : \theta = \theta_0$ (statu quo) vs $H_1 : \theta \neq \theta_0$ (bilateral) o $>, <$ (unilateral). Se plantean **antes** de mirar los datos.
- 2 **Estadístico de contraste:** una función de la muestra con distribución conocida bajo H_0 ; para la media con σ desconocida, $T = \frac{\bar{X}_n - \theta_0}{s/\sqrt{n}}$.
- 3 **Distribución nula:** $T \sim t_{n-1}$ si H_0 es cierta (exacta bajo normalidad, aproximada por TCL).
- 4 **Regla de decisión:** fijar α (típicamente 0.05) y rechazar H_0 si $|t| > t_{n-1, 1-\alpha/2}$, o equivalentemente si valor-p $< \alpha$.
- 5 **Cálculo:** evaluar t con los datos y obtener el valor-p.
- 6 **Conclusión en contexto:** traducir “rechazo / no rechazo” a la pregunta de política, con magnitud y dirección.



El contraste es una **prueba por contradicción probabilística**: suponemos H_0 cierta y medimos cuán inverosímil resulta lo observado bajo ese supuesto.

Ejemplo completo (1/2): ¿difiere el puntaje de la meta nacional?

Pregunta empírica: la meta nacional de una prueba estandarizada es 256 puntos. En una muestra i.i.d. de $n = 25$ escuelas de un municipio, $\bar{x} = 268$ y $s = 24$. Con $\alpha = 0.05$, ¿el puntaje medio municipal difiere de la meta?

Paso 1 — Hipótesis:

$$H_0 : \mu = 256 \quad \text{vs} \quad H_1 : \mu \neq 256$$

Paso 2 — Estadístico de contraste:

$$T = \frac{\bar{X}_n - 256}{s/\sqrt{n}}$$

Paso 3 — Distribución nula: bajo H_0 , $T \sim t_{24}$.

Paso 4 — Regla de decisión: con $\alpha = 0.05$ bilateral, rechazar H_0 si $|t| > t_{24, 0.975} = 2.064$.

Ejemplo completo (2/2): cálculo, decisión y verificación

Paso 5 — Cálculo explícito:

$$\widehat{SE} = \frac{24}{\sqrt{25}} = \frac{24}{5} = 4.8 \quad t = \frac{268 - 256}{4.8} = \frac{12}{4.8} = 2.50$$
$$\text{valor-p} = 2 P(T_{24} \geq 2.50) = 0.0197$$

Paso 6 — Conclusión: como $|2.50| > 2.064$ (y $0.0197 < 0.05$), se rechaza H_0 al 5 %: el puntaje medio municipal difiere de la meta — está **12 puntos por encima** ($IC_{95\%} = [258.1, 277.9]$, que excluye 256).

```
set.seed(42)
puntajes <- as.numeric(scale(rnorm(25))) * 24 + 268 # xbar = 268, s = 24 exactos
tidy(t.test(puntajes, mu = 256)) %>%
  select(estimate, statistic, p.value, conf.low, conf.high) %>% kable(digits = 4)
```

estimate	statistic	p.value	conf.low	conf.high
268	2.5	0.0197	258.0933	277.9067

`t.test()` reproduce el cálculo manual: $t = 2.5$, $\text{valor-p} = 0.0197$.

Errores tipo I y tipo II: definiciones formales

$$\alpha = P(\text{rechazar } H_0 \mid H_0 \text{ cierta})$$

$$\beta = P(\text{no rechazar } H_0 \mid H_1 \text{ cierta})$$


- **Tipo I (falso positivo):** declarar que el programa tiene efecto cuando no lo tiene — se gasta en escalar una política inútil.
- **Tipo II (falso negativo):** no detectar un efecto real — se cancela una política que funcionaba.
- α lo fija el investigador **antes** del análisis; β depende de n , del tamaño del efecto y de σ .
- Con n fijo, bajar α **sube** β : no hay almuerzo gratis.

Matriz de Decision en Pruebas de Hipotesis

	H0 es Verdadera	H0 es Falsa
Rechazar H0	ERROR TIPO I (Falso Positivo) Prob = α	CORRECTO (Potencia) Prob = $1 - \beta$
No rechazar H0	CORRECTO (Verdadero Negativo) Prob = $1 - \alpha$	ERROR TIPO II (Falso Negativo) Prob = β

α = nivel de significancia (típicamente 0.05) | β = probabilidad de Error Tipo II

α , β y potencia en un solo gráfico



Con el efecto verdadero a 2.5 errores estándar y regla bilateral con corte en 1.96:
 $\beta = P(-1.96 \leq Z_{H_1} \leq 1.96) = 0.295$ y potencia $1 - \beta = 0.705$. Mover el corte a la derecha (bajar α) agranda el área naranja: menos falsos positivos, más falsos negativos.

Contraste unilateral derecho de $H_0 : \mu = 0$ vs $H_1 : \mu = \delta$, con $SE = 1/\sqrt{n}$. Mueva los controles y observe cómo se reparten α , β y la potencia.

Experimento (disponible en la versión HTML): deslizadores para δ , n y α redibujan las dos campanas (H_0 centrada en 0 y H_1 en δ , ambas con $SE = 1/\sqrt{n}$) con las áreas α , β y potencia sombreadas y su lectura numérica en vivo.

- Aumentar n angosta ambas campanas: se separan y la potencia sube sin tocar α .
- Aumentar δ aleja H_1 del corte: efectos grandes son fáciles de detectar.
- Bajar α mueve el corte a la derecha: menos falsos positivos, pero β crece.

Valor-p: definición formal


$$\text{valor-p} = P(|T| \geq |t_{obs}| \mid H_0 \text{ cierta})$$

La probabilidad — **calculada suponiendo H_0 cierta** — de observar un estadístico tan o más extremo que el obtenido.

En el ejemplo: $t_{obs} = 2.50$ con $T \sim t_{24}$,

$$\text{valor-p} = 2 P(T_{24} \geq 2.50) = 0.0197$$

Es una medida de **incompatibilidad entre los datos y H_0** : mientras más pequeño, más raro sería lo observado si H_0 fuera cierta.



Intuición

El valor-p es un medidor de sorpresa: qué tan raro sería observar algo así de extremo si H_0 fuera cierta. Mucha sorpresa (p pequeño) invita a abandonar el supuesto.

Valor-p: lo que NO significa

Malinterpretación frecuente

“p es la probabilidad de que H_0 sea cierta”

“ $p < 0.05$ prueba que el efecto existe”

“ $p > 0.05$ demuestra que no hay efecto”

“p mide el tamaño del efecto”

“p es la probabilidad de equivocarse al rechazar”

Por qué es falsa

El valor-p se calcula **asumiendo** H_0 cierta; no es $P(H_0 \mid \text{datos})$

Solo indica incompatibilidad con H_0 ; puede ser un error tipo I

Ausencia de evidencia no es evidencia de ausencia (quizás faltó potencia)

Con n enorme, efectos triviales dan p minúsculos; reporte el IC

Esa tasa es α , fijada de antemano, no el p observado



Buenas prácticas (ASA, 2016): reportar siempre la **estimación puntual con su IC**, el valor-p exacto (no solo “ $p < 0.05$ ”) y el tamaño muestral. La significancia estadística no es significancia práctica ni relevancia de política.

Potencia estadística: $1 - \beta$


$$1 - \beta = P(\text{rechazar } H_0 \mid H_1 \text{ cierta})$$

La probabilidad de **detectar un efecto que sí existe**.
Convención de diseño: potencia ≥ 0.80 .

Cuatro palancas la determinan:

- $n \uparrow \Rightarrow$ potencia $\uparrow$ (SE cae con $\sqrt{n}$)
- Tamaño del efecto $|\mu_1 - \mu_0| \uparrow \Rightarrow$ potencia $\uparrow$
- $\alpha \uparrow \Rightarrow$ potencia $\uparrow$ (a costa de más falsos positivos)
- $\sigma \downarrow \Rightarrow$ potencia $\uparrow$ (medir mejor, poblaciones homogéneas)

Que significa esto: una evaluación con potencia 0.36 tiene un 64 % de probabilidad de “no encontrar” un efecto real — el estudio nace condenado.




Curva de potencia con power.t.test()

```
d <- seq(2, 20, by = 0.5)
pot <- map_dbl(d, function(delta)
  power.t.test(n = 25, delta = delta,
    sd = 24, sig.level = 0.05,
    type = "one.sample")$power)
```

Con los datos del ejemplo ($s = 24$):

- Detectar $\delta = 8$ puntos con $n = 25$: potencia = 0.36 — insuficiente.
- Para potencia 0.80 con $\delta = 8$ se requiere $n = 73$.
- Con $n = 25$ solo efectos $\delta \geq 12$ superan potencia 0.67.



El flujo inferencial completo

Paso	Pregunta	Herramienta formal	En R
1. Estimar	¿Cuál es el valor de θ ?	$\bar{X}_n, s^2, \hat{p}$	<code>mean()</code> , <code>var()</code>
2. Precisión	¿Cuánto varía el estimador?	$SE = s/\sqrt{n}$	<code>sd(x)/sqrt(n)</code>
3. Rango plausible	¿Dónde está μ ?	$\bar{X}_n \pm t_{n-1} SE$	<code>t.test(x)</code>
4. Decisión	¿Es compatible con θ_0 ?	6 pasos, t , valor-p	<code>t.test(x, mu =)</code>
5. Riesgos	¿Qué errores puedo cometer?	α, β , matriz de decisión	fijar α ex ante
6. Diseño	¿Qué n necesito?	potencia $1 - \beta \geq 0.80$	<code>power.t.test()</code>

i Hilo conductor: todo descansa en la distribución muestral ($\mathbb{E}[\bar{X}] = \mu$, $\text{Var}(\bar{X}) = \sigma^2/n$) y en el TCL, que garantiza la forma normal aproximada. **Próximo bloque:** correlación y regresión lineal simple — la inferencia aplicada a la relación entre dos variables.

Ejercicios propuestos (con respuestas)

Una encuesta de satisfacción con un servicio público entrevista a $n = 49$ usuarios: $\bar{x} = 72$ y $s = 14$ (escala 0–100).

- 1 Calcule el error estándar y el IC del 95 % para la satisfacción media μ .
- 2 La meta institucional es $\mu_0 = 75$. Contraste $H_0 : \mu = 75$ vs $H_1 : \mu \neq 75$ con $\alpha = 0.05$ siguiendo los 6 pasos.
- 3 ¿Qué potencia tiene este diseño para detectar una desviación real de 3 puntos? ¿Qué n exigiría potencia 0.90? Use `power.t.test(delta = 3, sd = 14, type = "one.sample")`.
- 4 Explique por qué “no rechazar H_0 ” en (2) no demuestra que la meta se cumple.

i Respuestas: (1) $SE = 14/7 = 2$; $t_{48,0.975} = 2.011$; $IC_{95\%} = [67.98, 76.02]$. (2) $t = (72 - 75)/2 = -1.5$; valor- $p = 0.140 > 0.05$: no se rechaza H_0 — los datos son compatibles con la meta. (3) Potencia = 0.31; para 0.90 se requiere $n = 231$. (4) Con potencia 0.31, la probabilidad de no detectar una desviación real de 3 puntos es 69 %: el resultado es no concluyente, no una confirmación. **Referencias:** Wasserman, *All of Statistics* (caps. 6–10) · Illowsky & Dean, *Introductory Statistics* (caps. 7–9) · Wasserstein & Lazar (2016), *The ASA Statement on p-Values*.