

Sesión 4 · Regresión Lineal y Lectura de Resultados

Fundamentos de Probabilidad y Estadística — Doctorados en Ciencias de la Complejidad Social y en Políticas Públicas · UDD

Amaru Agüero Jiménez (a.agueroj@udd.cl)

marzo de 2026


Panorama de la sesión

Bloque	Concepto clave	Herramienta en R
Modelo poblacional	$y = \beta_0 + \beta_1 x + u$ y el supuesto $\mathbb{E}[u x] = 0$	—
Estimación MCO	Derivación completa + ejemplo a mano	<code>lm()</code> , <code>coef()</code>
Bondad de ajuste	$SST = SSE + SSR$, R^2	<code>summary()</code> \$r.squared
Inferencia	SE , estadístico t , valor- p , IC 95 %	<code>broom::tidy()</code> , <code>confint()</code>
Lectura de tablas	Anatomía de una tabla de resultados	<code>modelsummary()</code>
Regresión múltiple	<i>Ceteris paribus</i> , dummies, logaritmos	<code>lm(y ~ x1 + x2)</code>

i Datos de trabajo: `wooldridge::wage1` — 526 trabajadores (EE.UU., 1976): salario por hora (USD), educación, experiencia y antigüedad. **Pregunta empírica ancla:** ¿cuál es el retorno salarial de un año adicional de educación?

La pregunta ancla: ¿cuánto rinde un año más de educación?

526 trabajadores: la recta MCO resume la nube con pendiente 0.54




Para diseñar subsidios a la educación superior o evaluar la gratuidad, necesitamos **cuantificar** esta asociación: la regresión lineal convierte la nube de puntos en **un número interpretable** (la pendiente) con su margen de error.

El modelo poblacional de regresión lineal simple

$$y = \beta_0 + \beta_1 x + u$$

- y : variable **dependiente** (salario por hora)
- x : variable **explicativa** (años de educación)
- β_0 : **intercepto** poblacional — nivel de y cuando $x = 0$
- β_1 : **pendiente** poblacional — el parámetro de interés
- u : **término de error** — *todo lo demás* que afecta a y : habilidad, redes, origen familiar, suerte

Los parámetros (β_0, β_1) son fijos y **desconocidos**; con la muestra los *estimamos*.



MCO elige la recta que minimiza las **distancias verticales** (segmentos verdes) al cuadrado.

El supuesto clave: $\mathbb{E}[u \mid x] = 0$


Definición (media condicional cero). Para todo valor de x :

$$\mathbb{E}[u \mid x] = 0$$

Entonces la recta poblacional **es** la media condicional:

$$\begin{aligned}\mathbb{E}[y \mid x] &= \mathbb{E}[\beta_0 + \beta_1 x + u \mid x] \\ &= \beta_0 + \beta_1 x + \mathbb{E}[u \mid x] \\ &= \beta_0 + \beta_1 x\end{aligned}$$

Lectura: a cada nivel de educación, los factores no observados (habilidad, redes) promedian cero — no están sistemáticamente asociados a x . Implica $\text{Cov}(x, u) = 0$.



Qué significa: la recta no es un dibujo — es la **esperanza condicional** de y dado x .

β_1 es una derivada: el efecto marginal

Definición. Bajo $\mathbb{E}[u \mid x] = 0$, la pendiente es la derivada de la media condicional:

$$\beta_1 = \frac{d \mathbb{E}[y \mid x]}{dx} \quad \Rightarrow \quad \Delta \mathbb{E}[y \mid x] = \beta_1 \Delta x \quad (\text{manteniendo } u \text{ fijo})$$

- Si $\Delta x = 1$: y cambia **en promedio** β_1 unidades *de* y . Las unidades importan: con salario en USD/hora y educación en años, β_1 se lee en **USD/hora por año**.
- **Linealidad:** el modelo impone que el efecto marginal es el **mismo** en todos los niveles de x (pasar de 8 a 9 años “vale” lo mismo que de 15 a 16).

💡 **Políticas públicas:** si $\beta_1 = 0.54$, un programa que agrega un año de escolaridad se asocia con +0.54 USD/hora. Que esa asociación sea un **efecto causal** exige tomarse en serio $\mathbb{E}[u \mid x] = 0$ (última parte de la sesión).

Derivación de MCO (1/3): el problema de minimización

Definición (estimador MCO). Dada la muestra $\{(x_i, y_i)\}_{i=1}^n$, el estimador de mínimos cuadrados ordinarios resuelve:

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{b_0, b_1} Q(b_0, b_1), \quad Q(b_0, b_1) = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2$$

¿Por qué **cuadrados** y no otra cosa?

- 1 Evitan que errores positivos y negativos se **cancelen** (a diferencia de sumar errores a secas).
- 2 Penalizan más los errores **grandes** que los pequeños.
- 3 Q es **diferenciable y convexa** en (b_0, b_1) : el mínimo se obtiene con cálculo y tiene **solución cerrada**.

Qué significa: buscamos la recta que deja los datos “lo menos mal explicados posible”, midiendo el desajuste con la suma de errores al cuadrado.

Derivación de MCO (2/3): condiciones de primer orden

Paso 1. Derivamos Q respecto de cada argumento e igualamos a cero:

$$\frac{\partial Q}{\partial b_0} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) = 0$$

$$\frac{\partial Q}{\partial b_1} = -2 \sum_{i=1}^n x_i (y_i - b_0 - b_1 x_i) = 0$$

Paso 2. Dividiendo por -2 y reordenando obtenemos las **ecuaciones normales**:

$$\begin{aligned} \sum_{i=1}^n y_i &= n b_0 + b_1 \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i y_i &= b_0 \sum_{i=1}^n x_i + b_1 \sum_{i=1}^n x_i^2 \end{aligned}$$

Qué significa: en el óptimo, los residuos suman cero y no covarían con x — dos propiedades que MCO impone *por construcción*.

Derivación de MCO (3/3): resolución del sistema

Paso 3. De la primera ecuación normal, dividiendo por n : $\bar{y} = b_0 + b_1\bar{x} \Rightarrow b_0 = \bar{y} - b_1\bar{x}$.

Paso 4. Sustituimos b_0 en la segunda condición y despejamos b_1 :

$$\sum_{i=1}^n x_i (y_i - \bar{y} + b_1\bar{x} - b_1x_i) = 0$$

$$\sum_{i=1}^n x_i (y_i - \bar{y}) = b_1 \sum_{i=1}^n x_i (x_i - \bar{x})$$

$$b_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

(la última línea usa $\sum x_i(y_i - \bar{y}) = \sum (x_i - \bar{x})(y_i - \bar{y})$, pues $\sum \bar{x}(y_i - \bar{y}) = 0$; ídem en el denominador).

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\widehat{\text{Cov}}(x, y)}{\widehat{\text{Var}}(x)}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$$

Qué significa: la pendiente es la covarianza reescalada por la varianza de x ; exige que x **varíe**.

Ejemplo a mano (1/3): seis trabajadores

Enunciado. Microdatos de $n = 6$ trabajadores: x_i = educación (años), y_i = salario por hora (USD).

Paso 1: medias $\bar{x} = 72/6 = 12$, $\bar{y} = 39/6 = 6.5$.

i	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	8	4	-4	-2.5	10	16
2	10	5	-2	-1.5	3	4
3	12	6	0	-0.5	0	0
4	12	7	0	0.5	0	0
5	14	8	2	1.5	3	4
6	16	9	4	2.5	10	16
Σ	72	39	0	0	26	40

Las columnas de desvíos suman cero **siempre** (propiedad de la media) — un chequeo aritmético gratis.

Ejemplo a mano (2/3): cálculo de los estimadores

Paso 2. Pendiente — cociente de las dos sumas de la tabla:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{26}{40} = 0.65$$

Paso 3. Intercepto — evaluando en las medias:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 6.5 - 0.65 \times 12 = 6.5 - 7.8 = -1.3$$

Resultado:

$$\widehat{\text{salario}} = -1.3 + 0.65 \times \text{educ}$$

- **Pendiente:** cada año adicional de educación se asocia con +0.65 USD/hora de salario, en promedio.
- **Intercepto:** el valor predicho con $\text{educ} = 0$ es -1.3 (¡negativo!). No se interpreta: es una **extrapolación** fuera del soporte de los datos (nadie en la muestra tiene 0 años de educación).

Ejemplo a mano (3/3): verificación con `lm()` y residuos

```
d6 <- tibble(  
  educ = c(8, 10, 12, 12, 14, 16),  
  salario = c(4, 5, 6, 7, 8, 9))  
coef(lm(salario ~ educ, data = d6))
```

(Intercept)	educ
-1.30	0.65


Coincide **exactamente** con el cálculo manual:

$$\hat{\beta}_0 = -1.3, \hat{\beta}_1 = 0.65.$$


Residuos $\hat{u}_i = y_i - \hat{y}_i$:

0.1, -0.2, -0.5, 0.5, 0.2, -0.1

$$\sum_{i=1}^6 \hat{u}_i = 0$$



La geometría de MCO: distancias verticales al cuadrado



MCO minimiza las distancias **verticales** (errores al predecir y), no las perpendiculares a la recta. Cualquier otra recta —aquí una con pendiente 0.40— produce una suma de cuadrados **mayor**: $6.04 > 0.60$.

Propiedades algebraicas de la recta MCO

Tres propiedades que valen **siempre** (con intercepto en el modelo), sea cual sea la muestra:

P1. $\sum_{i=1}^n \hat{u}_i = 0$ — los residuos suman cero. **P2.** $\sum_{i=1}^n x_i \hat{u}_i = 0$ — los residuos no están correlacionados con x . **P3.** La recta pasa por el punto de medias: $\hat{\beta}_0 + \hat{\beta}_1 \bar{x} = \bar{y}$.

Demostración de P1 (directa desde la primera CPO evaluada en el óptimo):

$$\left. \frac{\partial Q}{\partial b_0} \right|_{(\hat{\beta}_0, \hat{\beta}_1)} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$
$$\implies \sum_{i=1}^n \hat{u}_i = 0 \quad \blacksquare$$

P2 es la segunda CPO; P3 es la definición de $\hat{\beta}_0$ reordenada. En el ejemplo a mano:
 $0.1 - 0.2 - 0.5 + 0.5 + 0.2 - 0.1 = 0$.

Qué significa: el residuo promedio nulo es **construcción algebraica**, no evidencia de que el modelo sea bueno.

Valores ajustados y residuos: notación formal

Definiciones. Para cada observación i :


$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad (\text{valor ajustado})$$

$$\hat{u}_i = y_i - \hat{y}_i \quad (\text{residuo})$$

Toda observación se descompone en parte explicada y no explicada:

$$y_i = \hat{y}_i + \hat{u}_i$$

! No confundir: u_i es el **error poblacional** (no observable); $\hat{u}_i$ es el **residuo muestral** (calculable). $\hat{u}_i$ estima a u_i , no son lo mismo.



El gráfico residuos vs ajustados: media cero en toda la banda y **sin patrón** — así se ve un ajuste lineal razonable.

Bondad de ajuste (1): la descomposición de la varianza

Definiciones. Tres sumas de cuadrados:

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2, \quad SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2, \quad SSR = \sum_{i=1}^n \hat{u}_i^2$$

Teorema (descomposición). Con intercepto en el modelo:

$$SST = SSE + SSR$$


La clave de la prueba es que el término cruzado $\sum (\hat{y}_i - \bar{y})\hat{u}_i$ se anula por **P1 y P2** ($\sum \hat{u}_i = \sum x_i \hat{u}_i = 0$).

Definición (R^2). La fracción de la variación muestral de y explicada linealmente por x :

$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}, \quad 0 \leq R^2 \leq 1$$

Qué significa: la variación total de y se reparte —sin traslape— entre lo que la recta captura y lo que queda en los residuos. Cuidado con la notación: en Wooldridge SSE es la *explicada* y SSR la *residual*; otros textos invierten los nombres.

Bondad de ajuste (2): qué mide y qué NO mide R^2



R^2 **mide**: qué proporción de la varianza de y captura la recta; qué tan cerca de ella caen los puntos.

R^2 **NO mide**:

- **Causalidad**: un R^2 alto no valida $\mathbb{E}[u | x] = 0$.
- **Magnitud** del efecto: $\hat{\beta}_1$ puede ser grande y preciso con R^2 bajo.
- **Corrección** del modelo: puede faltar una curva, un control, etc.

💡 Con microdatos de personas, R^2 de 0.1 a 0.3 es lo **normal** (en wage1: 0.165). El salario depende de mucho más que la educación — eso no invalida el retorno estimado.

Bondad de ajuste (3): R^2 del ejemplo a mano, paso a paso

Paso 1. $SST = \sum (y_i - \bar{y})^2$:

$$6.25 + 2.25 + 0.25 + 0.25 + 2.25 + 6.25 = 17.5$$

Paso 2. $SSR = \sum \hat{u}_i^2$:

$$0.01 + 0.04 + 0.25 + 0.25 + 0.04 + 0.01 = 0.60$$


Paso 3. $SSE = SST - SSR = 17.5 - 0.60 = 16.9$

Paso 4.

$$R^2 = \frac{16.9}{17.5} = 0.966$$

```
round(summary(lm(salario ~ educ, d6))$r.squared, 4)
```

```
[1] 0.9657
```



La educación “explica” el 96.6 % de la varianza salarial **en estos 6 casos artificiales** — en datos reales la cifra cae drásticamente.

Inferencia (1): error estándar y estadístico t

Bajo homocedasticidad ($\text{Var}(u | x) = \sigma^2$), el error estándar de la pendiente es:


$$\text{SE}(\hat{\beta}_1) = \sqrt{\frac{\hat{\sigma}^2}{\sum (x_i - \bar{x})^2}}, \quad \hat{\sigma}^2 = \frac{SSR}{n-2}$$

Para contrastar $H_0: \beta_1 = 0$ (la educación no se asocia al salario):

$$t = \frac{\hat{\beta}_1 - 0}{\text{SE}(\hat{\beta}_1)} \sim t_{n-2} \text{ bajo } H_0$$

Rechazamos al 5 % si $|t| > t^* \approx 1.96$ (con n grande). El SE cae con: más observaciones, más varianza de x , menos ruido σ^2 .

t con 524 g.l.: rechazo si $|t| > 1.96$



Qué significa: el valor- p es la probabilidad de un t tan extremo como el observado si β_1 fuera 0.

Inferencia (2): IC 95 % del retorno a la educación, paso a paso

Modelo $wage = \beta_0 + \beta_1 educ + u$ con `wage1` ($n = 526$). Todo con la salida de `lm()`:

Paso 1 (SE) : $\hat{\sigma}^2 = \frac{SSR}{n-2} = \frac{5980.7}{524} = 11.41$; $SE(\hat{\beta}_1) = \sqrt{\frac{11.41}{4025.4}} = 0.0532$

Paso 2 (t) : $t = \frac{0.5414}{0.0532} = 10.17 \gg 1.96 \Rightarrow$ se rechaza $H_0: \beta_1 = 0$, $p < 0.001$

Paso 3 (t^*) : $t^* = t_{0.975, 524} = 1.9645$

Paso 4 (IC) : $0.5414 \pm 1.9645 \times 0.0532 \Rightarrow IC_{95\%} = [0.437, 0.646]$

```
tidy(m1, conf.int = TRUE) %>% filter(term == "educ") %>%  
  select(term, estimate, std.error, statistic, conf.low, conf.high) %>% kable(digits = 4)
```

term	estimate	std.error	statistic	conf.low	conf.high
educ	0.5414	0.0532	10.1667	0.4368	0.646

Lectura: con 95 % de confianza, el retorno está entre 0.44 y 0.65 USD/hora por año — excluye el cero con holgura.

La tabla de resultados: el formato estándar

	① Salario	② Salario
Constante	-0.905 (0.685)	-2.873*** (0.729)
Educación (años)	0.541*** (0.053)	0.599*** (0.051)
Experiencia (años)		0.022+ (0.012)
Antigüedad (años)		0.169*** (0.022)
Num.Obs.	526	526
R ²	0.165	0.306

Cada celda: **coeficiente** arriba y (**error estándar**) debajo; las estrellas codifican el valor- p : + $p < 0.1$, * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$. El modelo (2) agrega experiencia y antigüedad como controles.

Anatomía de la tabla: qué es cada número — modelo (1)

Número	Qué es	Cómo se lee
0.541	Coeficiente $\hat{\beta}_{educ}$	+0.54 USD/hora por año adicional, en promedio
(0.053)	Error estándar	Precisión: DE de $\hat{\beta}$ entre muestras
$0.541/0.053 = 10.17$ $p < 0.001$, ***	Estadístico t (implícito) Valor- p y estrellas	A cuántos SE está $\hat{\beta}$ de cero Prob. de un t tan extremo si $\beta_{educ} = 0$
526	n (Num.Obs.)	Tamaño muestral que sostiene la inferencia
0.165	R^2	16.5 % de la varianza salarial explicada

! Estrellas: + $p < 0.1$, * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$. La constante (-0.905 , $t = -1.32$) no es significativa ni interpretable aquí.

Lectura guiada: cinco preguntas a toda tabla

#	Pregunta	Dónde mirar	Respuesta: educación, modelo (2)
1	¿ Cuánto ?	Coeficiente	+0.599 USD/hora por año, <i>ceteris paribus</i>
2	¿Es preciso ?	SE e IC 95 %	$SE = 0.051 \Rightarrow IC \approx [0.498, 0.700]$
3	¿Es significativo ?	t , valor- p , estrellas	$t = 0.599/0.051 = 11.7$; ***: $p < 0.001$
4	¿ Cuánto explica ?	R^2	0.306: un 30.6 % de la varianza
5	¿Con qué datos ?	Num.Obs., muestra	$n = 526$, corte transversal 1976

El orden importa: primero magnitud y unidades (1), después precisión (2) y solo entonces significancia (3). Leer las estrellas antes que las unidades es el error más común en informes de política.

Regresión múltiple: formulación y *ceteris paribus*

Definición (modelo lineal múltiple). Con k regresores:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u, \quad \mathbb{E}[u \mid x_1, \dots, x_k] = 0$$

Interpretación formal (derivada parcial). Cada coeficiente es un efecto *ceteris paribus*:

$$\beta_j = \frac{\partial \mathbb{E}[y \mid x_1, \dots, x_k]}{\partial x_j} \quad \text{— manteniendo fijos los demás } x_\ell, \ell \neq j$$

En nuestro ejemplo: $wage = \beta_0 + \beta_1 educ + \beta_2 exper + \beta_3 tenure + u$. Ahora β_1 compara personas con **la misma** experiencia y antigüedad que difieren en un año de educación.

Qué significa: agregar controles cambia la pregunta — de “¿ganan más los más educados?” (comparación bruta) a “¿gana más el más educado **entre personas comparables** en lo observable?”.

Corto vs largo: qué cambia al agregar controles


Paso 1. Modelo corto: $\hat{\beta}_{educ} = 0.541$ — compara personas cualesquiera.

Paso 2. Modelo largo: $\hat{\beta}_{educ} = 0.599$ — compara a igual experiencia y antigüedad.

Paso 3. ¿Por qué **sube**? En estos datos educación y experiencia se correlacionan *negativamente* (quien estudió más lleva menos años trabajando). El modelo corto mezclaba el retorno a la educación con la “penalización” por menor experiencia.

Paso 4. R^2 : $0.165 \rightarrow 0.306$; el SE de educación casi no cambia ($0.053 \rightarrow 0.051$).

El retorno estimado sube de 0.54 a 0.60



Qué significa: los coeficientes **cambian de definición** al cambiar el conjunto de controles; por eso toda tabla sería muestra varias columnas.

Hacia Métodos Cuantitativos: la notación matricial

Apilando las n observaciones, el modelo múltiple se escribe en forma compacta:

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{u}, \quad \mathbf{y} \in \mathbb{R}^n, \quad \mathbf{X} \in \mathbb{R}^{n \times (k+1)}, \quad \beta \in \mathbb{R}^{k+1}$$

y el estimador MCO tiene la misma lógica que hoy — ecuaciones normales $\mathbf{X}'(\mathbf{y} - \mathbf{X}\hat{\beta}) = \mathbf{0}$ — resueltas en bloque:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

- Es la **generalización exacta** de lo que derivamos: con $k = 1$, esa fórmula reproduce $\hat{\beta}_1 = \widehat{\text{Cov}}/\widehat{\text{Var}}$ y $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$. Las condiciones $\sum \hat{u}_i = 0$ y $\sum x_{ij}\hat{u}_i = 0$ son las filas de $\mathbf{X}'\hat{\mathbf{u}} = \mathbf{0}$.
- `lm()` resuelve exactamente este sistema (con descomposición QR, no invirtiendo la matriz).

i En **Métodos Cuantitativos** verán su derivación formal, el teorema de Gauss-Markov (cuándo MCO es el mejor estimador lineal insesgado) y qué pasa cuando los supuestos fallan. Hoy basta con reconocer la fórmula.

Leer una dummy: la brecha salarial de género

Con $female \in \{0, 1\}$, el modelo $wage = \delta_0 + \delta_1 female + u$ compara **medias de grupo**:

$$\mathbb{E}[wage \mid female = 0] = \delta_0$$

$$\mathbb{E}[wage \mid female = 1] = \delta_0 + \delta_1$$

$$\Rightarrow \delta_1 = \text{diferencia de medias}$$


```
round(coef(lm(wage ~ female, wage1)), 2)
```

(Intercept)	female
7.10	-2.51

Paso 1: $\hat{\delta}_0 = 7.10$ = salario medio de los hombres.

Paso 2: $\hat{\delta}_1 = -2.51$ ($SE = 0.30$, $t = -8.28$): las mujeres ganan en promedio 2.51 USD/hora **menos**; media mujeres = $7.10 - 2.51 = 4.59$. **Paso 3:** con controles (educ, exper, tenure) la brecha *no explicada* es -1.81 ($SE = 0.26$).

La dummy estima la brecha de medias: -2.51



Qué significa: el coeficiente de una dummy siempre se lee **respecto de la categoría de referencia** (aquí, hombres).

Semi-elasticidad: leer $\log(y)$ en porcentaje

Modelo log-nivel: $\log(wage) = \beta_0 + \beta_1 educ + u$.

Como $\Delta \log(w) \approx \Delta w/w$, para $\Delta educ = 1$:

$$\Delta \log(wage) = \beta_1$$


$$\% \Delta wage \approx 100 \cdot \beta_1$$

```
tidy(lm(log(wage) ~ educ, wage1)) %>%  
  select(term, estimate, std.error) %>%  
  kable(digits = 4)
```

term	estimate	std.error
(Intercept)	0.5838	0.0973
educ	0.0827	0.0076

Lectura: $\hat{\beta}_1 = 0.0827$ — un año más de educación se asocia con $\approx 8.3\%$ más de salario (efecto exacto: $100(e^{0.0827} - 1) = 8.6\%$). Esta es la forma **estándar** de reportar retornos.

En logs, la pendiente es un cambio porcentual




Qué significa: en logs el efecto es **proporcional**, no en USD fijos: 8.3 % de un salario alto son más dólares que 8.3 % de uno bajo — a menudo más realista.

Advertencia final: asociación no es causalidad

MCO siempre entrega **la mejor recta descriptiva**. Que $\hat{\beta}_1$ estime un *efecto causal* depende de $\mathbb{E}[u \mid x] = 0$ **en serio**. Si un factor omitido (habilidad) se correlaciona con la educación:

$$\text{plim } \hat{\beta}_1 = \beta_1 + \frac{\text{Cov}(x, u)}{\text{Var}(x)} \neq \beta_1$$

- **Sesgo de habilidad:** personas más hábiles estudian más y ganan más $\Rightarrow \text{Cov}(\text{educ}, u) > 0$ y el retorno estimado **sobreestima** el causal.
- La regresión de hoy responde: “¿cuánto más ganan, *en promedio*, los más educados?” — una pregunta **descriptiva condicional**, valiosa pero distinta de “¿cuánto ganaría esta persona si estudiara un año más?”.
- **Métodos Cuantitativos** aborda el salto causal: experimentos, variables instrumentales, panel, diseños cuasi-experimentales.



Además, la **inferencia** (los *SE*, *t* e IC de hoy) descansa en supuestos sobre u que se examinan con diagnósticos como estos — también materia de la asignatura.

Errores comunes al leer una tabla de regresión

Error	Consecuencia	Corrección
Leer $\hat{\beta}$ como efecto causal sin discutir el diseño	Recomendaciones de política infundadas	Preguntar cómo se justifica $\mathbb{E}[u \mid x] = 0$
Confundir significancia con importancia (“*** = relevante”)	Efectos minúsculos vendidos como hallazgos	Leer magnitud en unidades y el IC
Ignorar el SE y reportar solo el punto	Falsa sensación de precisión	Reportar siempre $\hat{\beta} \pm 1.96 SE$
Descartar un modelo por R^2 bajo	Se pierden estimados precisos y útiles	R^2 no mide la validez de $\hat{\beta}$
Interpretar un coeficiente en $\log(y)$ en unidades de y	Error de dos órdenes de magnitud	$100 \cdot \hat{\beta}$ es un cambio en %
Comparar coeficientes entre modelos con distinta muestra	Diferencias espurias	Misma muestra y especificación comparable

Síntesis: checklist para leer cualquier tabla

Antes de opinar sobre una regresión:

- 1 Identificar y , los x , la **muestra** y el n .
- 2 Revisar **unidades** de cada variable (¿hay logs? ¿dummies?).
- 3 Coeficiente: **signo y magnitud** en sus unidades.
- 4 Precisión: IC 95 % mental con $\hat{\beta} \pm 2 SE$.
- 5 Significancia (t , valor- p) — sin confundirla con importancia.
- 6 R^2 como **contexto**, nunca como veredicto.
- 7 Preguntar qué se controla y qué **no** (¿asociación o causalidad?).

Funciones R de esta sesión

`lm()` `coef()` `resid()` `fitted()`
`broom::tidy()` `confint()`
`summary()``$r.squared` `modelsummary()`

Qué sigue: en *Métodos Cuantitativos* — Gauss-Markov, forma matricial $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$, heterocedasticidad e identificación causal. Esta sesión es su punto de partida.

Ejercicios propuestos (con respuestas)

Use la tabla de resultados de la sesión (modelos (1) y (2) con wage1, $n = 526$, $t^* = 1.96$):

- ❶ **Leer la tabla:** en el modelo (2), interprete el coeficiente de antigüedad (0.169, $SE = 0.022$) en una frase completa, con unidades y cláusula *ceteris paribus*.
- ❷ **Calcular un IC:** construya el IC 95 % para ese coeficiente y concluya sobre $H_0: \beta_{tenure} = 0$.
- ❸ **Interpretar una dummy:** en $\widehat{wage} = 7.10 - 2.51 \text{ female}$, ¿qué es 7.10? ¿Qué es -2.51 ? ¿Cuál es el salario medio de las mujeres?

i Respuestas. (1) Un año adicional en el mismo empleador se asocia con +0.17 USD/hora, manteniendo educación y experiencia constantes; significativo al 0.1 %. (2) $0.169 \pm 1.9645 \times 0.022 \Rightarrow [0.127, 0.212]$; excluye el 0 $\Rightarrow$ se rechaza H_0 . (3) 7.10 = salario medio de los hombres (categoría de referencia); -2.51 = brecha de medias; media de mujeres = $7.10 - 2.51 = 4.59$ USD/hora.

Referencias: Wooldridge, *Introductory Econometrics* (caps. 2–4) · Stock & Watson, *Introduction to Econometrics* (caps. 4–6) · Angrist & Pischke, *Mastering 'Metrics* (cap. 2).