

Sesión 4 · Regresión Lineal y Lectura de Resultados

Fundamentos de Probabilidad y Estadística — Doctorados en Ciencias de la Complejidad Social y en Políticas Públicas · UDD

Amaru Agüero Jiménez (a.agueroj@udd.cl)


marzo de 2026

Panorama de la sesión

Bloque	Concepto clave	Herramienta en R
Modelo poblacional	$y = \beta_0 + \beta_1 x + u$ y el supuesto $\mathbb{E}[u x] = 0$	—
Estimación MCO	Derivación completa + ejemplo a mano	<code>lm()</code> , <code>coef()</code>
Bondad de ajuste	$SST = SSE + SSR$, R^2	<code>summary()</code> \$r.squared
Inferencia	SE , estadístico t , valor- p , IC 95 %	<code>broom::tidy()</code> , <code>confint()</code>
Lectura de tablas	Anatomía de una tabla de resultados	<code>modelsummary()</code>
Regresión múltiple	<i>Ceteris paribus</i> , dummies, logaritmos	<code>lm(y ~ x1 + x2)</code>

i Datos de trabajo: `wooldridge::wage1` — 526 trabajadores (EE.UU., 1976): salario por hora (USD), educación, experiencia y antigüedad. **Pregunta empírica ancla:** ¿cuál es el retorno salarial de un año adicional de educación?

La pregunta ancla: ¿cuánto rinde un año más de educación?



Para diseñar subsidios a la educación superior o evaluar la gratuidad, necesitamos **cuantificar** esta asociación: la regresión lineal convierte la nube de puntos en **un número interpretable** (la pendiente) con su margen de error.



Intuición


La regresión es una máquina de resumir: convierte 526 puntos en una sola frase — “cada año extra de educación viaja con medio dólar más por hora”.

El modelo poblacional de regresión lineal simple

$$y = \beta_0 + \beta_1 x + u$$

- y : variable **dependiente** (salario por hora)
- x : variable **explicativa** (años de educación)
- β_0 : **intercepto** poblacional — nivel de y cuando $x = 0$
- β_1 : **pendiente** poblacional — el parámetro de interés
- u : **término de error** — *todo lo demás* que afecta a y : habilidad, redes, origen familiar, suerte

Los parámetros (β_0, β_1) son fijos y **desconocidos**; con la muestra los *estimamos*.



MCO elige la recta que minimiza las **distancias verticales** (segmentos verdes) al cuadrado.

El supuesto clave: $\mathbb{E}[u \mid x] = 0$


Definición (media condicional cero). Para todo valor de x :

$$\mathbb{E}[u \mid x] = 0$$

Entonces la recta poblacional **es** la media condicional:

$$\begin{aligned}\mathbb{E}[y \mid x] &= \mathbb{E}[\beta_0 + \beta_1 x + u \mid x] \\ &= \beta_0 + \beta_1 x + \mathbb{E}[u \mid x] \\ &= \beta_0 + \beta_1 x\end{aligned}$$

Lectura: a cada nivel de educación, los factores no observados (habilidad, redes) promedian cero — no están sistemáticamente asociados a x . Implica $\text{Cov}(x, u) = 0$.



Qué significa: la recta no es un dibujo — es la **esperanza condicional** de y dado x .

β_1 es una derivada: el efecto marginal

Definición. Bajo $\mathbb{E}[u \mid x] = 0$, la pendiente es la derivada de la media condicional:

$$\beta_1 = \frac{d \mathbb{E}[y \mid x]}{dx} \quad \Rightarrow \quad \Delta \mathbb{E}[y \mid x] = \beta_1 \Delta x \quad (\text{manteniendo } u \text{ fijo})$$

- Si $\Delta x = 1$: y cambia **en promedio** β_1 unidades *de* y . Las unidades importan: con salario en USD/hora y educación en años, β_1 se lee en **USD/hora por año**.
- **Linealidad:** el modelo impone que el efecto marginal es el **mismo** en todos los niveles de x (pasar de 8 a 9 años “vale” lo mismo que de 15 a 16).

💡 **Políticas públicas:** si $\beta_1 = 0.54$, un programa que agrega un año de escolaridad se asocia con +0.54 USD/hora. Que esa asociación sea un **efecto causal** exige tomarse en serio $\mathbb{E}[u \mid x] = 0$ (última parte de la sesión).

Derivación de MCO (1/3): el problema de minimización

Definición (estimador MCO). Dada la muestra $\{(x_i, y_i)\}_{i=1}^n$, el estimador de mínimos cuadrados ordinarios resuelve:

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{b_0, b_1} Q(b_0, b_1), \quad Q(b_0, b_1) = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2$$

¿Por qué **cuadrados** y no otra cosa?

- 1 Evitan que errores positivos y negativos se **cancelen** (a diferencia de sumar errores a secas).
- 2 Penalizan más los errores **grandes** que los pequeños.
- 3 Q es **diferenciable y convexa** en (b_0, b_1) : el mínimo se obtiene con cálculo y tiene **solución cerrada**.

Qué significa: buscamos la recta que deja los datos “lo menos mal explicados posible”, midiendo el desajuste con la suma de errores al cuadrado.



Intuición

La recta MCO es el equilibrio de una varilla apoyada sobre la nube: cada punto tira de ella, y los lejanos tiran mucho más fuerte.

Derivación de MCO (2/3): condiciones de primer orden

Paso 1. Derivamos Q respecto de cada argumento e igualamos a cero:

$$\frac{\partial Q}{\partial b_0} = -2 \sum_{i=1}^n (y_i - b_0 - b_1 x_i) = 0$$

$$\frac{\partial Q}{\partial b_1} = -2 \sum_{i=1}^n x_i (y_i - b_0 - b_1 x_i) = 0$$

Paso 2. Dividiendo por -2 y reordenando obtenemos las **ecuaciones normales**:

$$\begin{aligned} \sum_{i=1}^n y_i &= n b_0 + b_1 \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i y_i &= b_0 \sum_{i=1}^n x_i + b_1 \sum_{i=1}^n x_i^2 \end{aligned}$$

Qué significa: en el óptimo, los residuos suman cero y no covarían con x — dos propiedades que MCO impone *por construcción*.

Derivación de MCO (3/3): resolución del sistema

Paso 3. De la primera ecuación normal, dividiendo por n : $\bar{y} = b_0 + b_1\bar{x} \Rightarrow b_0 = \bar{y} - b_1\bar{x}$.

Paso 4. Sustituimos b_0 en la segunda condición y despejamos b_1 :

$$\sum_{i=1}^n x_i (y_i - \bar{y} + b_1\bar{x} - b_1x_i) = 0$$

$$\sum_{i=1}^n x_i (y_i - \bar{y}) = b_1 \sum_{i=1}^n x_i (x_i - \bar{x})$$

$$b_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

(la última línea usa $\sum x_i(y_i - \bar{y}) = \sum (x_i - \bar{x})(y_i - \bar{y})$, pues $\sum \bar{x}(y_i - \bar{y}) = 0$; ídem en el denominador).

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{\widehat{\text{Cov}}(x, y)}{\widehat{\text{Var}}(x)}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$$

Qué significa: la pendiente es la covarianza reescalada por la varianza de x ; exige que x **varíe**.

Ejemplo a mano (1/3): seis trabajadores

Enunciado. Microdatos de $n = 6$ trabajadores: x_i = educación (años), y_i = salario por hora (USD).

Paso 1: medias $\bar{x} = 72/6 = 12$, $\bar{y} = 39/6 = 6.5$.

i	x_i	y_i	$x_i - \bar{x}$	$y_i - \bar{y}$	$(x_i - \bar{x})(y_i - \bar{y})$	$(x_i - \bar{x})^2$
1	8	4	-4	-2.5	10	16
2	10	5	-2	-1.5	3	4
3	12	6	0	-0.5	0	0
4	12	7	0	0.5	0	0
5	14	8	2	1.5	3	4
6	16	9	4	2.5	10	16
Σ	72	39	0	0	26	40

Las columnas de desvíos suman cero **siempre** (propiedad de la media) — un chequeo aritmético gratis.

Ejemplo a mano (2/3): cálculo de los estimadores

Paso 2. Pendiente — cociente de las dos sumas de la tabla:

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{26}{40} = 0.65$$

Paso 3. Intercepto — evaluando en las medias:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x} = 6.5 - 0.65 \times 12 = 6.5 - 7.8 = -1.3$$

Resultado:

$$\widehat{\text{salario}} = -1.3 + 0.65 \times \text{educ}$$

- **Pendiente:** cada año adicional de educación se asocia con +0.65 USD/hora de salario, en promedio.
- **Intercepto:** el valor predicho con $\text{educ} = 0$ es -1.3 (¡negativo!). No se interpreta: es una **extrapolación** fuera del soporte de los datos (nadie en la muestra tiene 0 años de educación).

Ejemplo a mano (3/3): verificación con `lm()` y residuos

```
d6 <- tibble(  
  educ = c(8, 10, 12, 12, 14, 16),  
  salario = c(4, 5, 6, 7, 8, 9))  
coef(lm(salario ~ educ, data = d6))
```

(Intercept)	educ
-1.30	0.65


Coincide **exactamente** con el cálculo manual:

$$\hat{\beta}_0 = -1.3, \hat{\beta}_1 = 0.65.$$


Residuos $\hat{u}_i = y_i - \hat{y}_i$:

0.1, -0.2, -0.5, 0.5, 0.2, -0.1

$$\sum_{i=1}^6 \hat{u}_i = 0$$



La geometría de MCO: distancias verticales al cuadrado




MCO minimiza las distancias **verticales** (errores al predecir y), no las perpendiculares a la recta. Cualquier otra recta —aquí una con pendiente 0.40— produce una suma de cuadrados **mayor**: $6.04 > 0.60$.

Laboratorio: mínimos cuadrados a mano

Objetivo: encontrar a mano la recta que minimiza la suma de cuadrados de los residuos $SSR(b_0, b_1)$ para 8 trabajadores.

La recta ganadora: $-0.46 + 0.57x$, con $SSR = 2.49$



En la versión HTML se mueven b_0 y b_1 con deslizadores: cualquier otra recta deja un SSR mayor que 2.49, el mínimo que MCO alcanza de una sola vez con las fórmulas.

Propiedades algebraicas de la recta MCO

Tres propiedades que valen **siempre** (con intercepto en el modelo), sea cual sea la muestra:

P1. $\sum_{i=1}^n \hat{u}_i = 0$ — los residuos suman cero. **P2.** $\sum_{i=1}^n x_i \hat{u}_i = 0$ — los residuos no están correlacionados con x . **P3.** La recta pasa por el punto de medias: $\hat{\beta}_0 + \hat{\beta}_1 \bar{x} = \bar{y}$.

Demostración de P1 (directa desde la primera CPO evaluada en el óptimo):

$$\left. \frac{\partial Q}{\partial b_0} \right|_{(\hat{\beta}_0, \hat{\beta}_1)} = -2 \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0$$
$$\implies \sum_{i=1}^n \hat{u}_i = 0 \quad \blacksquare$$

P2 es la segunda CPO; P3 es la definición de $\hat{\beta}_0$ reordenada. En el ejemplo a mano:
 $0.1 - 0.2 - 0.5 + 0.5 + 0.2 - 0.1 = 0$.

Qué significa: el residuo promedio nulo es **construcción algebraica**, no evidencia de que el modelo sea bueno.

Valores ajustados y residuos: notación formal

Definiciones. Para cada observación i :


$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i \quad (\text{valor ajustado})$$

$$\hat{u}_i = y_i - \hat{y}_i \quad (\text{residuo})$$

Toda observación se descompone en parte explicada y no explicada:

$$y_i = \hat{y}_i + \hat{u}_i$$

! No confundir: u_i es el **error poblacional** (no observable); $\hat{u}_i$ es el **residuo muestral** (calculable). $\hat{u}_i$ estima a u_i , no son lo mismo.



El gráfico residuos vs ajustados: media cero en toda la banda y **sin patrón** — así se ve un ajuste lineal razonable.

Bondad de ajuste (1): la descomposición de la varianza

Definiciones. Tres sumas de cuadrados:

$$SST = \sum_{i=1}^n (y_i - \bar{y})^2, \quad SSE = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2, \quad SSR = \sum_{i=1}^n \hat{u}_i^2$$

Teorema (descomposición). Con intercepto en el modelo:

$$SST = SSE + SSR$$


La clave de la prueba es que el término cruzado $\sum (\hat{y}_i - \bar{y})\hat{u}_i$ se anula por **P1 y P2** ($\sum \hat{u}_i = \sum x_i \hat{u}_i = 0$).

Definición (R^2). La fracción de la variación muestral de y explicada linealmente por x :

$$R^2 = \frac{SSE}{SST} = 1 - \frac{SSR}{SST}, \quad 0 \leq R^2 \leq 1$$

Qué significa: la variación total de y se reparte —sin traslape— entre lo que la recta captura y lo que queda en los residuos. Cuidado con la notación: en Wooldridge SSE es la *explicada* y SSR la *residual*; otros textos invierten los nombres.

Bondad de ajuste (2): qué mide y qué NO mide R^2



R^2 **mide**: qué proporción de la varianza de y captura la recta; qué tan cerca de ella caen los puntos.

R^2 **NO mide**:

- **Causalidad**: un R^2 alto no valida $\mathbb{E}[u | x] = 0$.
- **Magnitud** del efecto: $\hat{\beta}_1$ puede ser grande y preciso con R^2 bajo.
- **Corrección** del modelo: puede faltar una curva, un control, etc.

💡 Con microdatos de personas, R^2 de 0.1 a 0.3 es lo **normal** (en wage1: 0.165). El salario depende de mucho más que la educación — eso no invalida el retorno estimado.

Bondad de ajuste (3): R^2 del ejemplo a mano, paso a paso

Paso 1. $SST = \sum (y_i - \bar{y})^2$:

$$6.25 + 2.25 + 0.25 + 0.25 + 2.25 + 6.25 = 17.5$$

Paso 2. $SSR = \sum \hat{u}_i^2$:

$$0.01 + 0.04 + 0.25 + 0.25 + 0.04 + 0.01 = 0.60$$


Paso 3. $SSE = SST - SSR = 17.5 - 0.60 = 16.9$

Paso 4.

$$R^2 = \frac{16.9}{17.5} = 0.966$$

```
round(summary(lm(salario ~ educ, d6))$r.squared, 4)
```


```
[1] 0.9657
```



La educación “explica” el 96.6 % de la varianza salarial **en estos 6 casos artificiales** — en datos reales la cifra cae drásticamente.

Laboratorio: ruido y R^2

Experimento: el modelo verdadero es siempre $y = 2 + 0.5x + u$; solo cambia el ruido σ . ¿Qué le pasa al R^2 ?



Mismo modelo verdadero, distinto ruido: con más varianza del error el R^2 cae de 0.74 a 0.02, aunque la recta MCO (roja) siga pegada a la verdadera (azul). Un R^2 bajo **no** dice que el modelo esté mal.

Inferencia (1): error estándar y estadístico t

Bajo homocedasticidad ($\text{Var}(u | x) = \sigma^2$), el error estándar de la pendiente es:


$$\text{SE}(\hat{\beta}_1) = \sqrt{\frac{\hat{\sigma}^2}{\sum (x_i - \bar{x})^2}}, \quad \hat{\sigma}^2 = \frac{SSR}{n-2}$$

Para contrastar $H_0: \beta_1 = 0$ (la educación no se asocia al salario):

$$t = \frac{\hat{\beta}_1 - 0}{\text{SE}(\hat{\beta}_1)} \sim t_{n-2} \text{ bajo } H_0$$

Rechazamos al 5 % si $|t| > t^* \approx 1.96$ (con n grande). El SE cae con: más observaciones, más varianza de x , menos ruido σ^2 .

t con 524 g.l.: rechazo si $|t| > 1.96$



Qué significa: el valor- p es la probabilidad de un t tan extremo como el observado si β_1 fuera 0.

Inferencia (2): IC 95 % del retorno a la educación, paso a paso

Modelo $wage = \beta_0 + \beta_1 educ + u$ con `wage1` ($n = 526$). Todo con la salida de `lm()`:

Paso 1 (SE) : $\hat{\sigma}^2 = \frac{SSR}{n-2} = \frac{5980.7}{524} = 11.41$; $SE(\hat{\beta}_1) = \sqrt{\frac{11.41}{4025.4}} = 0.0532$

Paso 2 (t) : $t = \frac{0.5414}{0.0532} = 10.17 \gg 1.96 \Rightarrow$ se rechaza $H_0: \beta_1 = 0$, $p < 0.001$

Paso 3 (t^*) : $t^* = t_{0.975, 524} = 1.9645$

Paso 4 (IC) : $0.5414 \pm 1.9645 \times 0.0532 \Rightarrow IC_{95\%} = [0.437, 0.646]$

```
tidy(m1, conf.int = TRUE) %>% filter(term == "educ") %>%  
  select(term, estimate, std.error, statistic, conf.low, conf.high) %>% kable(digits = 4)
```

term	estimate	std.error	statistic	conf.low	conf.high
educ	0.5414	0.0532	10.1667	0.4368	0.646

Lectura: con 95 % de confianza, el retorno está entre 0.44 y 0.65 USD/hora por año — excluye el cero con holgura.

La tabla de resultados: el formato estándar

	① Salario	② Salario
Constante	-0.905 (0.685)	-2.873*** (0.729)
Educación (años)	0.541*** (0.053)	0.599*** (0.051)
Experiencia (años)		0.022+ (0.012)
Antigüedad (años)		0.169*** (0.022)
Num.Obs.	526	526
R ²	0.165	0.306

Cada celda: **coeficiente** arriba y (**error estándar**) debajo; las estrellas codifican el valor- p : + $p < 0.1$, * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$. El modelo (2) agrega experiencia y antigüedad como controles.

Anatomía de la tabla: qué es cada número — modelo (1)

Número	Qué es	Cómo se lee
0.541	Coeficiente $\hat{\beta}_{educ}$	+0.54 USD/hora por año adicional, en promedio
(0.053)	Error estándar	Precisión: DE de $\hat{\beta}$ entre muestras
$0.541/0.053 = 10.17$ $p < 0.001$, ***	Estadístico t (implícito) Valor- p y estrellas	A cuántos SE está $\hat{\beta}$ de cero Prob. de un t tan extremo si $\beta_{educ} = 0$
526	n (Num.Obs.)	Tamaño muestral que sostiene la inferencia
0.165	R^2	16.5 % de la varianza salarial explicada

! Estrellas: + $p < 0.1$, * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$. La constante (-0.905 , $t = -1.32$) no es significativa ni interpretable aquí.

Lectura guiada: cinco preguntas a toda tabla

#	Pregunta	Dónde mirar	Respuesta: educación, modelo (2)
1	¿ Cuánto ?	Coeficiente	+0.599 USD/hora por año, <i>ceteris paribus</i>
2	¿Es preciso ?	SE e IC 95 %	$SE = 0.051 \Rightarrow IC \approx [0.498, 0.700]$
3	¿Es significativo ?	t , valor- p , estrellas	$t = 0.599/0.051 = 11.7$; ***: $p < 0.001$
4	¿ Cuánto explica ?	R^2	0.306: un 30.6 % de la varianza
5	¿Con qué datos ?	Num.Obs., muestra	$n = 526$, corte transversal 1976

El orden importa: primero magnitud y unidades (1), después precisión (2) y solo entonces significancia (3). Leer las estrellas antes que las unidades es el error más común en informes de política.

Regresión múltiple: formulación y *ceteris paribus*

Definición (modelo lineal múltiple). Con k regresores:

$$y = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_k x_k + u, \quad \mathbb{E}[u \mid x_1, \dots, x_k] = 0$$

Interpretación formal (derivada parcial). Cada coeficiente es un efecto *ceteris paribus*:

$$\beta_j = \frac{\partial \mathbb{E}[y \mid x_1, \dots, x_k]}{\partial x_j} \quad \text{— manteniendo fijos los demás } x_\ell, \ell \neq j$$

En nuestro ejemplo: $wage = \beta_0 + \beta_1 educ + \beta_2 exper + \beta_3 tenure + u$. Ahora β_1 compara personas con **la misma** experiencia y antigüedad que difieren en un año de educación.

Qué significa: agregar controles cambia la pregunta — de “¿ganan más los más educados?” (comparación bruta) a “¿gana más el más educado **entre personas comparables** en lo observable?”.



Intuición

Controlar es comparar manzanas con manzanas: la pendiente de educación ya no mezcla novatos con veteranos, sino que compara personas con la misma experiencia y antigüedad.

Corto vs largo: qué cambia al agregar controles


Paso 1. Modelo corto: $\hat{\beta}_{educ} = 0.541$ — compara personas cualesquiera.

Paso 2. Modelo largo: $\hat{\beta}_{educ} = 0.599$ — compara a igual experiencia y antigüedad.

Paso 3. ¿Por qué **sube**? En estos datos educación y experiencia se correlacionan *negativamente* (quien estudió más lleva menos años trabajando). El modelo corto mezclaba el retorno a la educación con la “penalización” por menor experiencia.

Paso 4. R^2 : $0.165 \rightarrow 0.306$; el SE de educación casi no cambia ($0.053 \rightarrow 0.051$).

El retorno estimado sube de 0.54 a 0.60



Qué significa: los coeficientes **cambian de definición** al cambiar el conjunto de controles; por eso toda tabla sería muestra varias columnas.

Hacia Métodos Cuantitativos: la notación matricial

Apilando las n observaciones, el modelo múltiple se escribe en forma compacta:

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{u}, \quad \mathbf{y} \in \mathbb{R}^n, \quad \mathbf{X} \in \mathbb{R}^{n \times (k+1)}, \quad \beta \in \mathbb{R}^{k+1}$$

y el estimador MCO tiene la misma lógica que hoy — ecuaciones normales $\mathbf{X}'(\mathbf{y} - \mathbf{X}\hat{\beta}) = \mathbf{0}$ — resueltas en bloque:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$$

- Es la **generalización exacta** de lo que derivamos: con $k = 1$, esa fórmula reproduce $\hat{\beta}_1 = \widehat{\text{Cov}}/\widehat{\text{Var}}$ y $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1\bar{x}$. Las condiciones $\sum \hat{u}_i = 0$ y $\sum x_{ij}\hat{u}_i = 0$ son las filas de $\mathbf{X}'\hat{\mathbf{u}} = \mathbf{0}$.
- `lm()` resuelve exactamente este sistema (con descomposición QR, no invirtiendo la matriz).

i En **Métodos Cuantitativos** verán su derivación formal, el teorema de Gauss-Markov (cuándo MCO es el mejor estimador lineal insesgado) y qué pasa cuando los supuestos fallan. Hoy basta con reconocer la fórmula.

Leer una dummy: la brecha salarial de género

Con $female \in \{0, 1\}$, el modelo $wage = \delta_0 + \delta_1 female + u$ compara **medias de grupo**:

$$\mathbb{E}[wage \mid female = 0] = \delta_0$$

$$\mathbb{E}[wage \mid female = 1] = \delta_0 + \delta_1$$

$$\Rightarrow \delta_1 = \text{diferencia de medias}$$


```
round(coef(lm(wage ~ female, wage1)), 2)
```

(Intercept)	female
7.10	-2.51

Paso 1: $\hat{\delta}_0 = 7.10$ = salario medio de los hombres.

Paso 2: $\hat{\delta}_1 = -2.51$ ($SE = 0.30$, $t = -8.28$): las mujeres ganan en promedio 2.51 USD/hora **menos**; media mujeres = $7.10 - 2.51 = 4.59$. **Paso 3:** con controles (educ, exper, tenure) la brecha *no explicada* es -1.81 ($SE = 0.26$).

La dummy estima la brecha de medias: -2.51



Qué significa: el coeficiente de una dummy siempre se lee **respecto de la categoría de referencia** (aquí, hombres).

Semi-elasticidad: leer $\log(y)$ en porcentaje

Modelo log-nivel: $\log(wage) = \beta_0 + \beta_1 educ + u$.

Como $\Delta \log(w) \approx \Delta w/w$, para $\Delta educ = 1$:

$$\Delta \log(wage) = \beta_1$$


$$\% \Delta wage \approx 100 \cdot \beta_1$$

```
tidy(lm(log(wage) ~ educ, wage1)) %>%  
  select(term, estimate, std.error) %>%  
  kable(digits = 4)
```

term	estimate	std.error
(Intercept)	0.5838	0.0973
educ	0.0827	0.0076

Lectura: $\hat{\beta}_1 = 0.0827$ — un año más de educación se asocia con $\approx 8.3\%$ más de salario (efecto exacto: $100(e^{0.0827} - 1) = 8.6\%$). Esta es la forma **estándar** de reportar retornos.

En logs, la pendiente es un cambio porcentual




Qué significa: en logs el efecto es **proporcional**, no en USD fijos: 8.3 % de un salario alto son más dólares que 8.3 % de uno bajo — a menudo más realista.

Advertencia final: asociación no es causalidad

MCO siempre entrega **la mejor recta descriptiva**. Que $\hat{\beta}_1$ estime un *efecto causal* depende de $\mathbb{E}[u \mid x] = 0$ **en serio**. Si un factor omitido (habilidad) se correlaciona con la educación:

$$\text{plim } \hat{\beta}_1 = \beta_1 + \frac{\text{Cov}(x, u)}{\text{Var}(x)} \neq \beta_1$$

- **Sesgo de habilidad:** personas más hábiles estudian más y ganan más $\Rightarrow \text{Cov}(\text{educ}, u) > 0$ y el retorno estimado **sobreestima** el causal.
- La regresión de hoy responde: “¿cuánto más ganan, *en promedio*, los más educados?” — una pregunta **descriptiva condicional**, valiosa pero distinta de “¿cuánto ganaría esta persona si estudiara un año más?”.
- **Métodos Cuantitativos** aborda el salto causal: experimentos, variables instrumentales, panel, diseños cuasi-experimentales.



Además, la **inferencia** (los *SE*, *t* e IC de hoy) descansa en supuestos sobre u que se examinan con diagnósticos como estos — también materia de la asignatura.

Errores comunes al leer una tabla de regresión

Error	Consecuencia	Corrección
Leer $\hat{\beta}$ como efecto causal sin discutir el diseño	Recomendaciones de política infundadas	Preguntar cómo se justifica $\mathbb{E}[u \mid x] = 0$
Confundir significancia con importancia (“*** = relevante”)	Efectos minúsculos vendidos como hallazgos	Leer magnitud en unidades y el IC
Ignorar el SE y reportar solo el punto	Falsa sensación de precisión	Reportar siempre $\hat{\beta} \pm 1.96 SE$
Descartar un modelo por R^2 bajo	Se pierden estimados precisos y útiles	R^2 no mide la validez de $\hat{\beta}$
Interpretar un coeficiente en $\log(y)$ en unidades de y	Error de dos órdenes de magnitud	$100 \cdot \hat{\beta}$ es un cambio en %
Comparar coeficientes entre modelos con distinta muestra	Diferencias espurias	Misma muestra y especificación comparable

Síntesis: checklist para leer cualquier tabla

Antes de opinar sobre una regresión:

- 1 Identificar y , los x , la **muestra** y el n .
- 2 Revisar **unidades** de cada variable (¿hay logs? ¿dummies?).
- 3 Coeficiente: **signo y magnitud** en sus unidades.
- 4 Precisión: IC 95 % para $\hat{\beta} \pm 2 SE$.
- 5 Significancia (t , valor- p) — sin confundirla con importancia.
- 6 R^2 como **contexto**, nunca como veredicto.
- 7 Preguntar qué se controla y qué **no** (¿asociación o causalidad?).

Funciones R de esta sesión

`lm()` `coef()` `resid()` `fitted()`
`broom::tidy()` `confint()`
`summary()``$r.squared` `modelsummary()`

Qué sigue: en *Métodos Cuantitativos* — Gauss-Markov, forma matricial $(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$, heterocedasticidad e identificación causal. Esta sesión es su punto de partida.

Ejercicios propuestos (con respuestas)

Use la tabla de resultados de la sesión (modelos (1) y (2) con wage1, $n = 526$, $t^* = 1.96$):

- ❶ **Leer la tabla:** en el modelo (2), interprete el coeficiente de antigüedad (0.169, $SE = 0.022$) en una frase completa, con unidades y cláusula *ceteris paribus*.
- ❷ **Calcular un IC:** construya el IC 95 % para ese coeficiente y concluya sobre $H_0: \beta_{tenure} = 0$.
- ❸ **Interpretar una dummy:** en $\widehat{wage} = 7.10 - 2.51 \text{ female}$, ¿qué es 7.10? ¿Qué es -2.51 ? ¿Cuál es el salario medio de las mujeres?

i Respuestas. (1) Un año adicional en el mismo empleador se asocia con +0.17 USD/hora, manteniendo educación y experiencia constantes; significativo al 0.1 %. (2) $0.169 \pm 1.9645 \times 0.022 \Rightarrow [0.127, 0.212]$; excluye el 0 $\Rightarrow$ se rechaza H_0 . (3) 7.10 = salario medio de los hombres (categoría de referencia); -2.51 = brecha de medias; media de mujeres = $7.10 - 2.51 = 4.59$ USD/hora.

Referencias: Wooldridge, *Introductory Econometrics* (caps. 2–4) · Stock & Watson, *Introduction to Econometrics* (caps. 4–6) · Angrist & Pischke, *Mastering 'Metrics* (cap. 2).